Vorlesung Betriebssysteme

Martin Zeller
Hochschule Ravensburg-Weingarten

Der vorliegende Foliensatz basiert auf Folien
von Frau Prof. Dr. Keller

Ausweich-Termin

???

Ziel der Vorlesung

Grundlegendes Verständnis für die Aufgaben und die Arbeitsweise von Betriebssystemen. Kenntnisse zu Betriebssystem-Schnittstellen.

- Prozesse, Threads
- Interprozesskommunikation, Synchronisation
- Scheduling
- Speicherverwaltung
- Ein- Ausgabe
- Dateisysteme

Inhalt der Vorlesung

- Grundlegende Mechanismen
  - Ressourcen, Prozesse, Threads
  - User-Level, Kernel-Level
  - Systemaufrufe, Interrupts
- Speicherverwaltung
- Synchronisation
- Interprozesskommunikation
- Ein- und Ausgabe
- Dateisysteme

Stapelbetrieb (Batch Systeme)

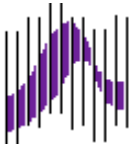

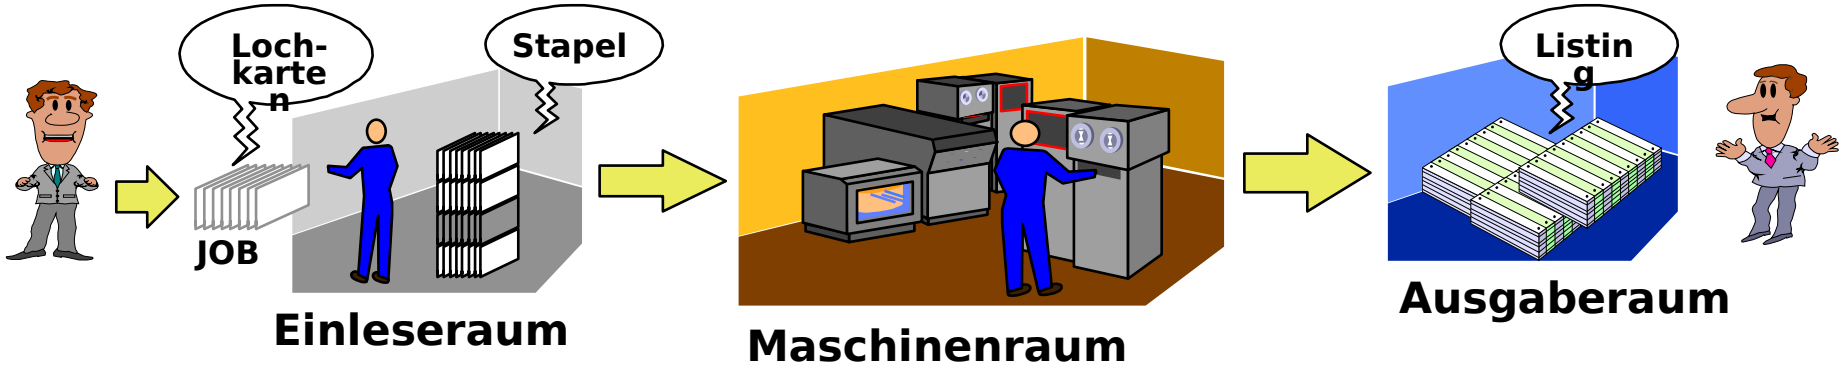

- Erste Programmiersprachen und Betriebssysteme (Monitore)
- Assembler, FORTRAN (Formular Translator)
- FMS (Fortran Monitoring System)

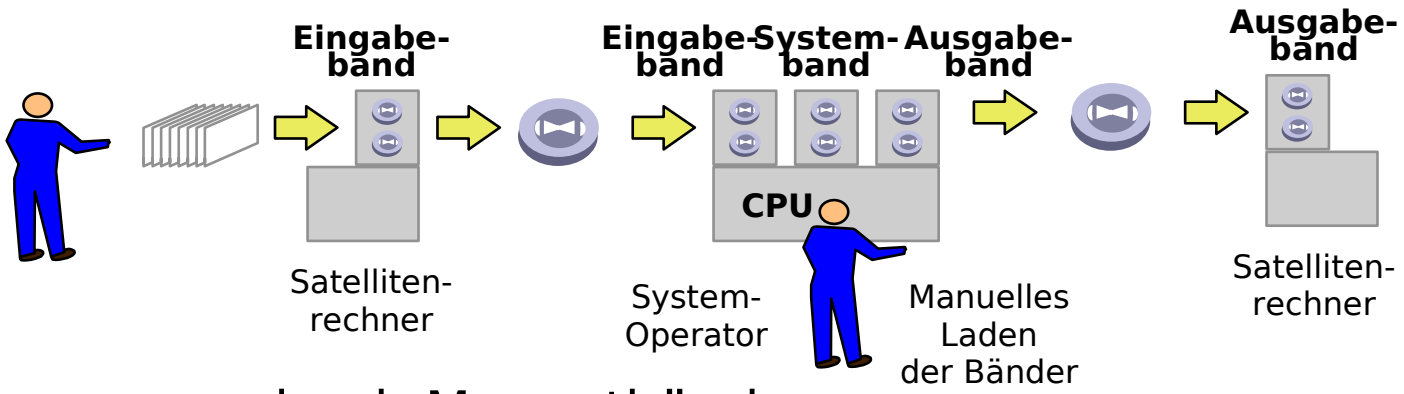

Verbesserung durch Magnetbänder

Systemressourcen

von Neumann Architektur

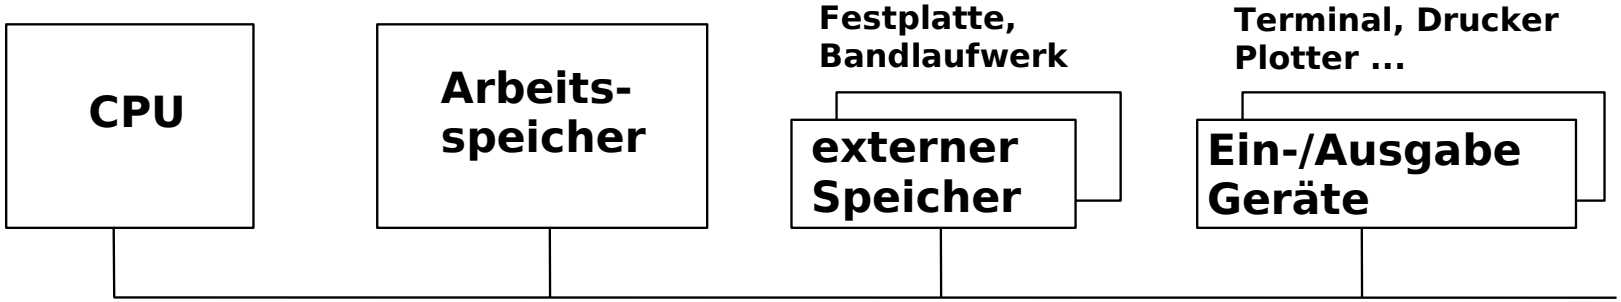

Ausführung mehrerer nebenläufiger Programme (Multiprogramming)

Betriebssystem
Anwendungs-
programm
Daten

Verwaltung von Daten

Zuteilung an Programme

Multi Program Multi User Systeme

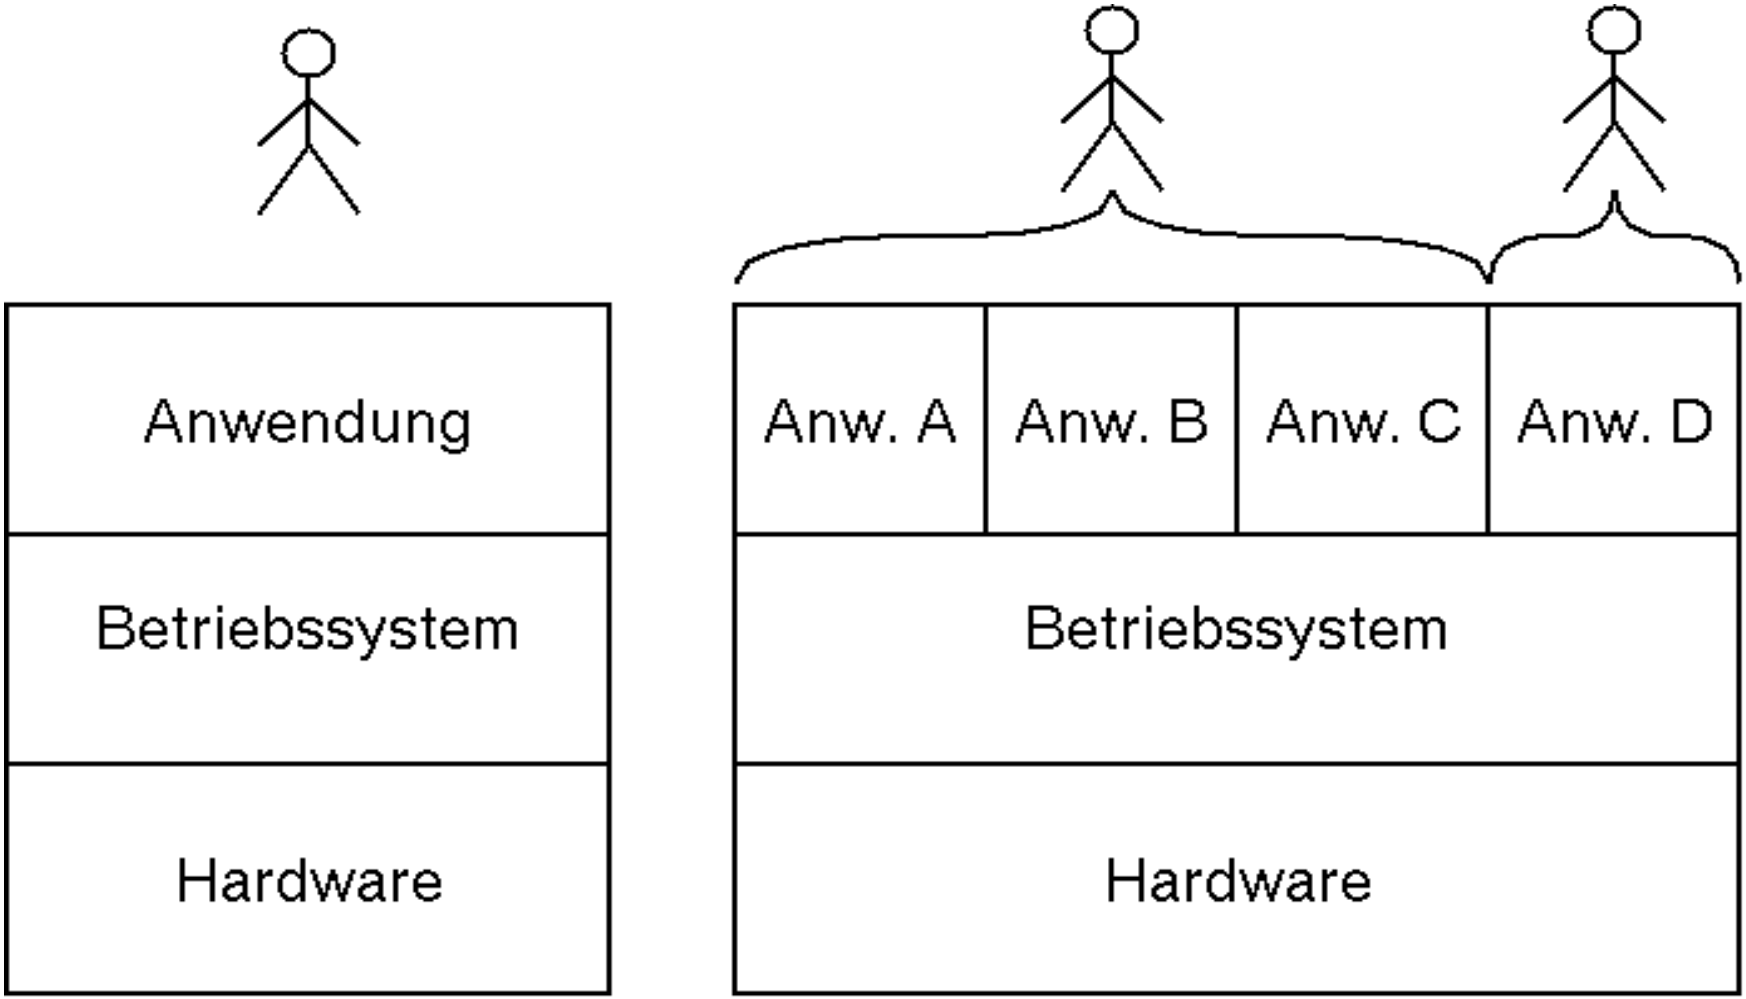

Taxonomie Systemsoftware

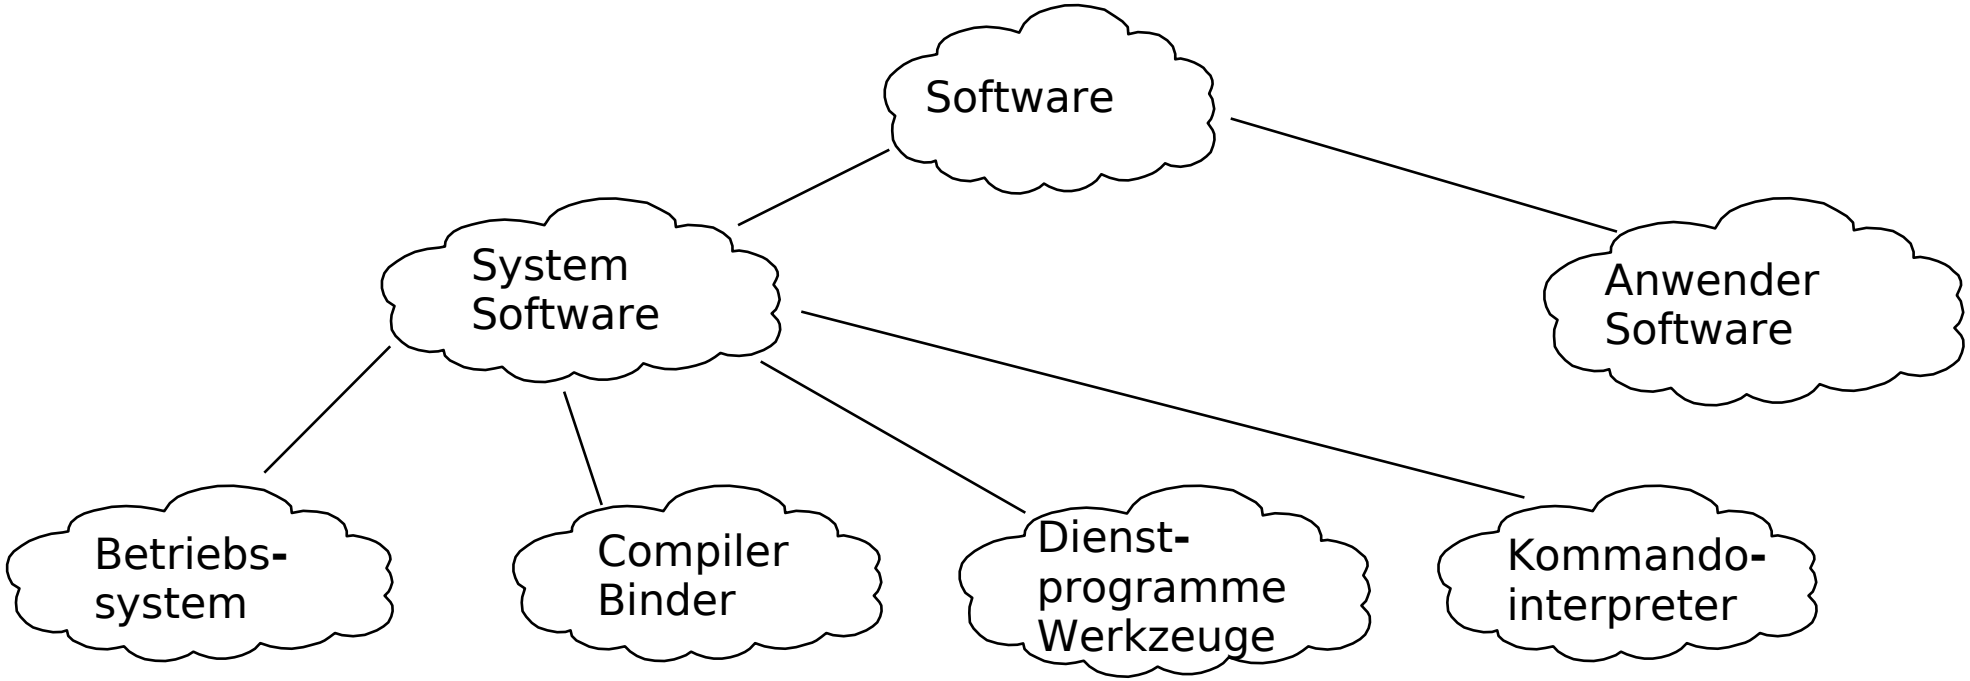

- Hardwareunabhängige Ein-/Ausgabe
- Effiziente Nutzung der Ressourcen
- Laden von Programmen

- Erstellen von Anwender-programmen

- Editoren
- Filter

- Mensch/Maschine Schnittstelle
- Textorientiert z.B. UNIX-Shell
- Grafische Oberfläche z.B. MS-Windows, X-Windows, MacOS

Virtualisierungssysteme

Virtualisierungssysteme realisieren mehrere virtuelle Maschinen auf einem Rechner

- VmWare, KVM, VirtualBox, Xen ...
- Java Virtual Machine (SmallTalk, . . .)
- OS/370, OS/390
- Partitionierende RTOS (LynxOS-178, . . .)
- Solaris (Container)

Virtualisierungssysteme (2)

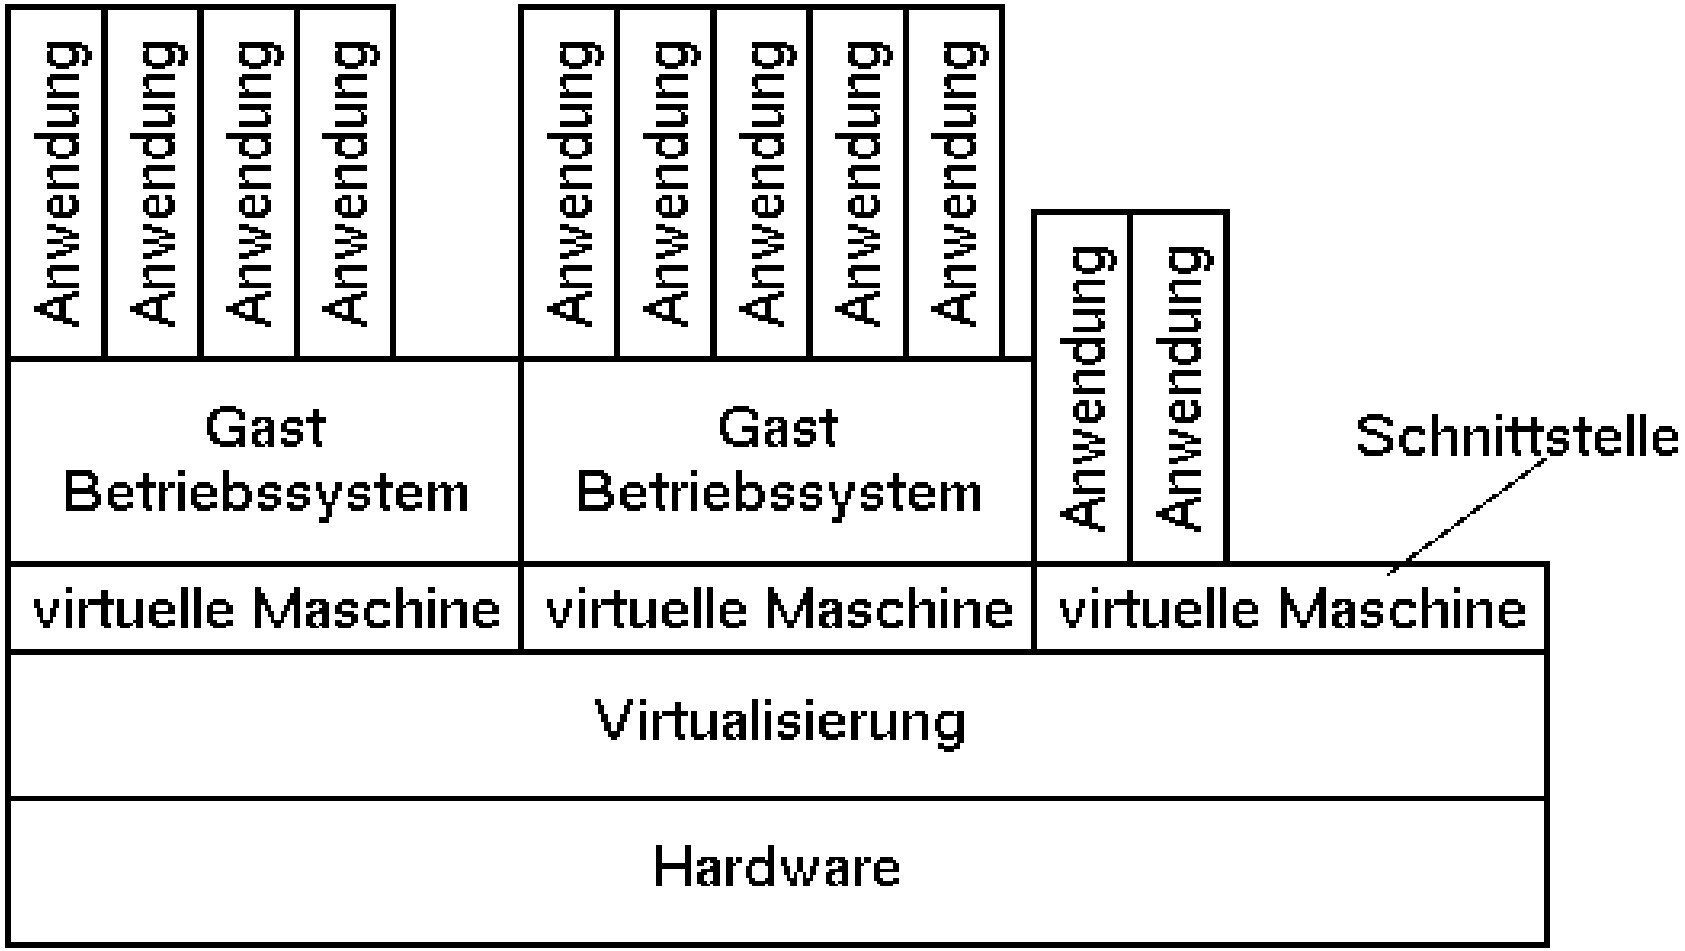

Virtualisierungssysteme (3)

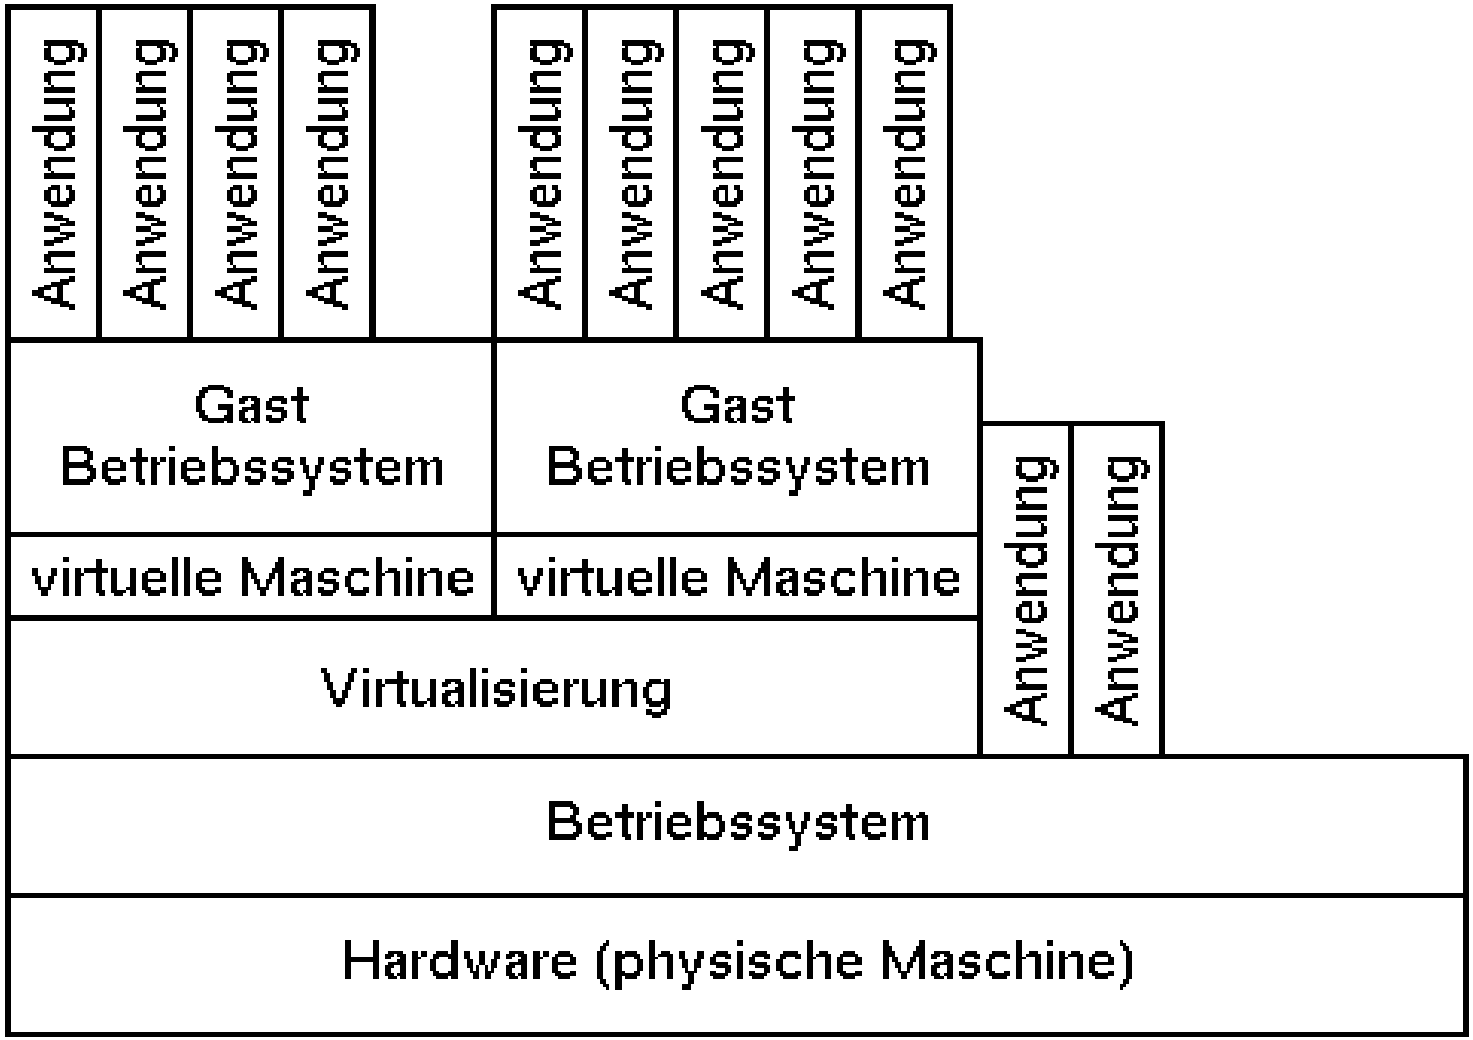

Betriebssystemstrukturen

Struktur aus der Sicht des Systemprogrammierers

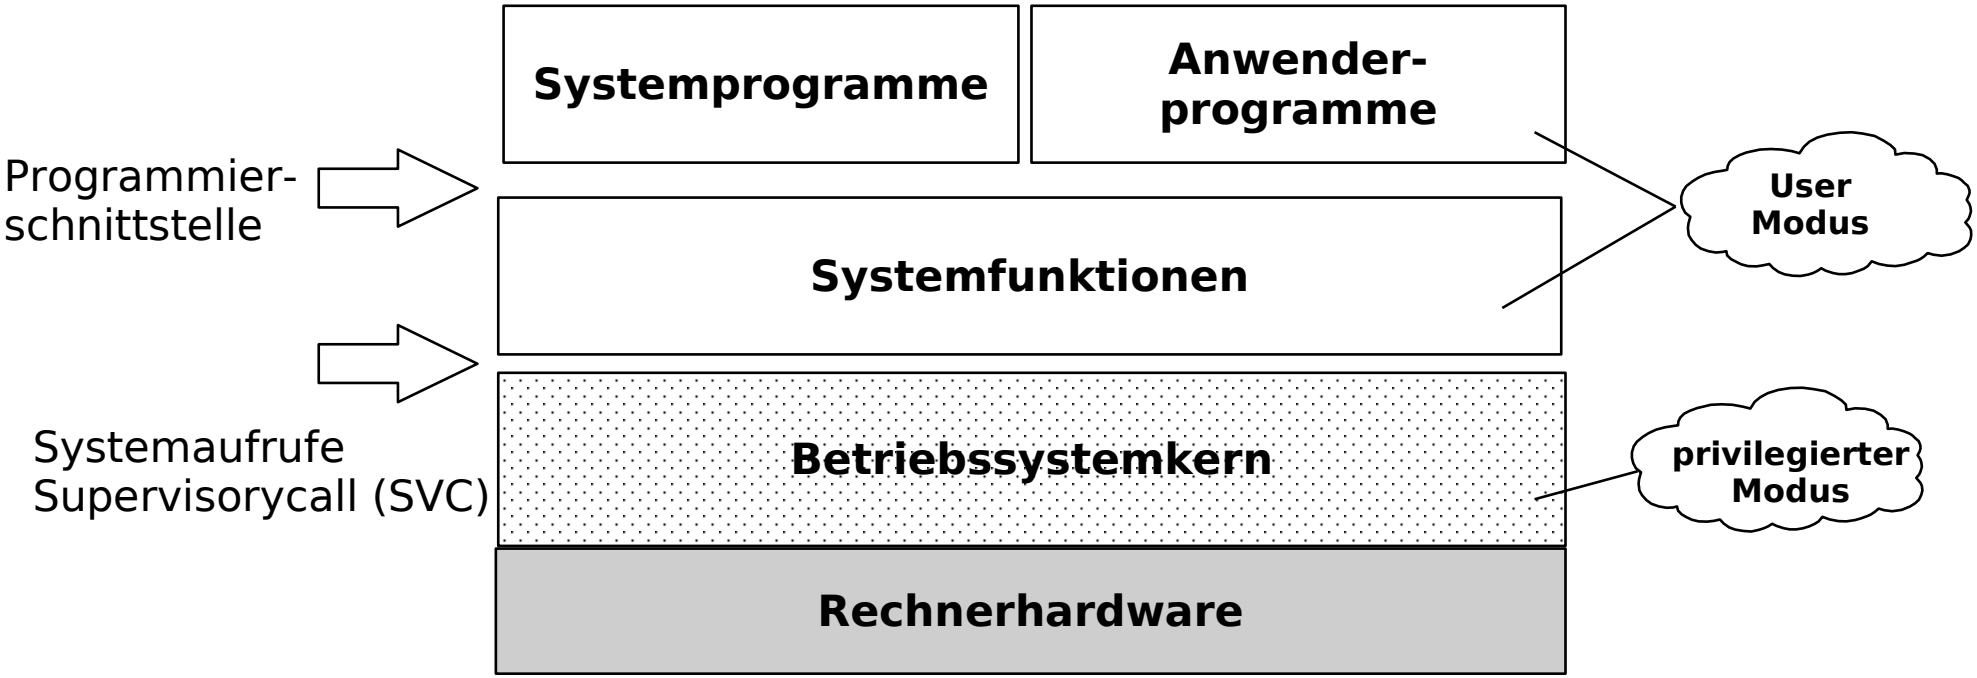

Windows NT Modell

zu jedem Subsystem existiert eine API

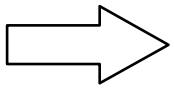

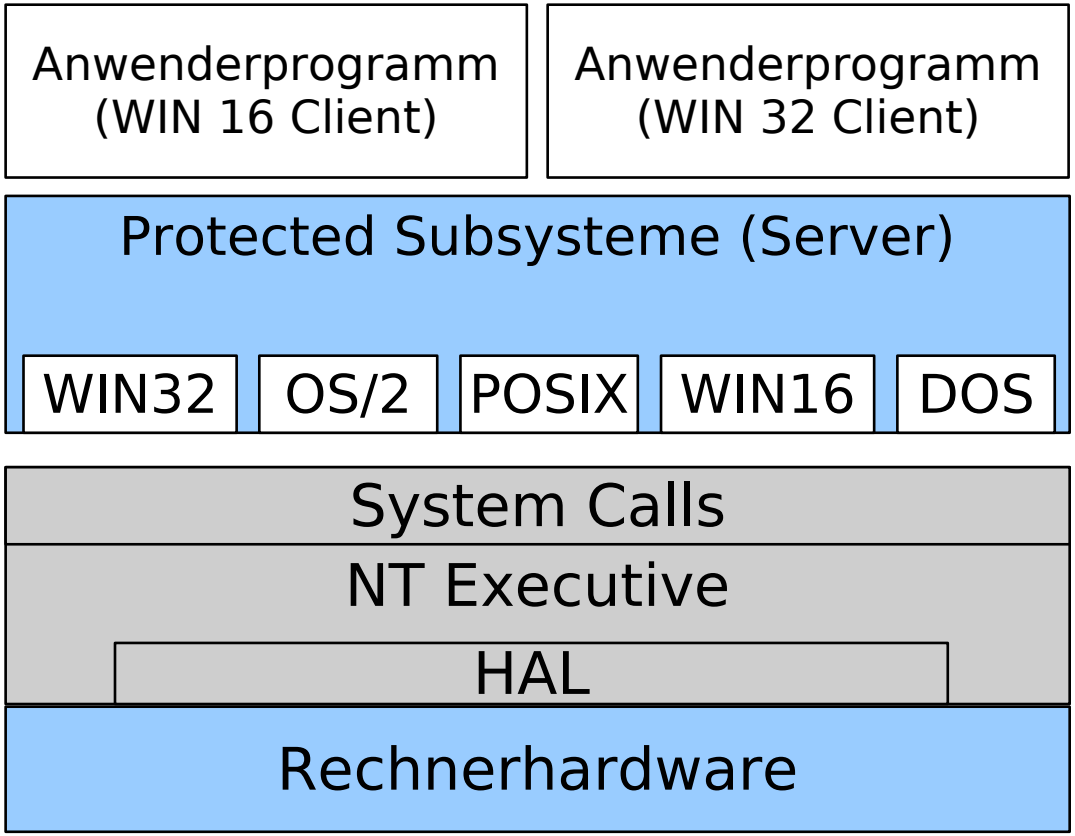

User Modus

privilegierter Modus

Windows NT = Windows New Technologie
HAL = Hardeware Abstraction Layer

Prozess

Aus Sicht des Anwenders:

- laufendes Programm

Aus Sicht des Betriebssystems:

- Programm mit Ausführungszustand
- Einheit der Ressourcen-Vergabe / Verwaltungseinheit
  - Rechenzeit
  - Speicher
  - Zugriff auf I/O-Geräte
- ggf. Einheit der Abrechnung

Prozess-Attribute

Ausführungszustand

- PID (process identification)
- PC (program counter)
- SP (stack pointer)
- PSW (program status word)
  - Kennung User-Level/Kernel-Level
  - Priorität
  - Interrupt-Steuerung
  - Overflow-Anzeige
  - Ergebnis des letzten Vergleichs

Prozess-Attribute

Hauptspeicher-Organisation

- Pointer auf Code-Segment (Text-Segment) Programm, globale und static Variable
- Pointer auf Stack-Segment
- Pointer auf Heap-Segment

Externer Speicher/Geräte

- Wurzel-Verzeichnis
- Arbeits-Verzeichnis
- Datei-Deskriptoren

Benutzer-ID, Gruppen-ID

Speicherbelegung eines Prozess

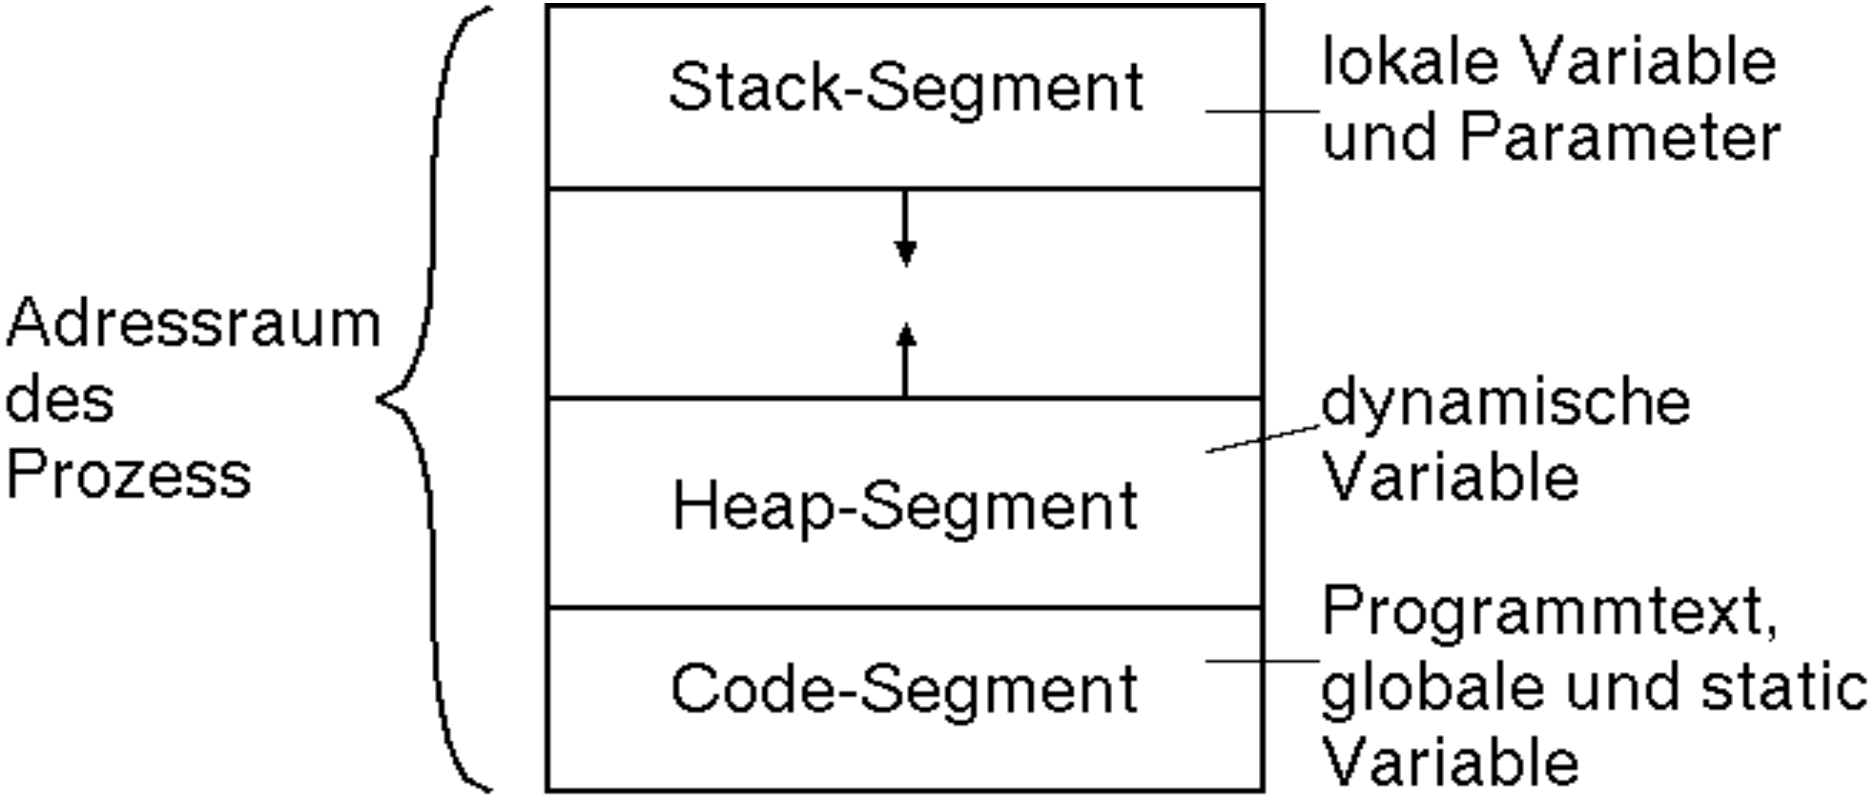

Aufruf einer Funktion im Prozess

Funktion foo() ruft bar() auf

- foo() speichert auf Stack und verschiebt SP
  - Rücksprungadresse
  - Parameterwerte
- foo() verzweigt zu bar() (PC zeigt auf bar())
- bar() legt lokale Variable auf dem Stack an
- bar() führt Anweisungen aus
- bar() speichert Return-Wert an vereinbarter Stelle
- bar() setzt SP zurück auf Frame von foo()
- bar() springt zurück zu foo() (PC zeigt auf foo())

Aufruf einer Funktion im Prozess

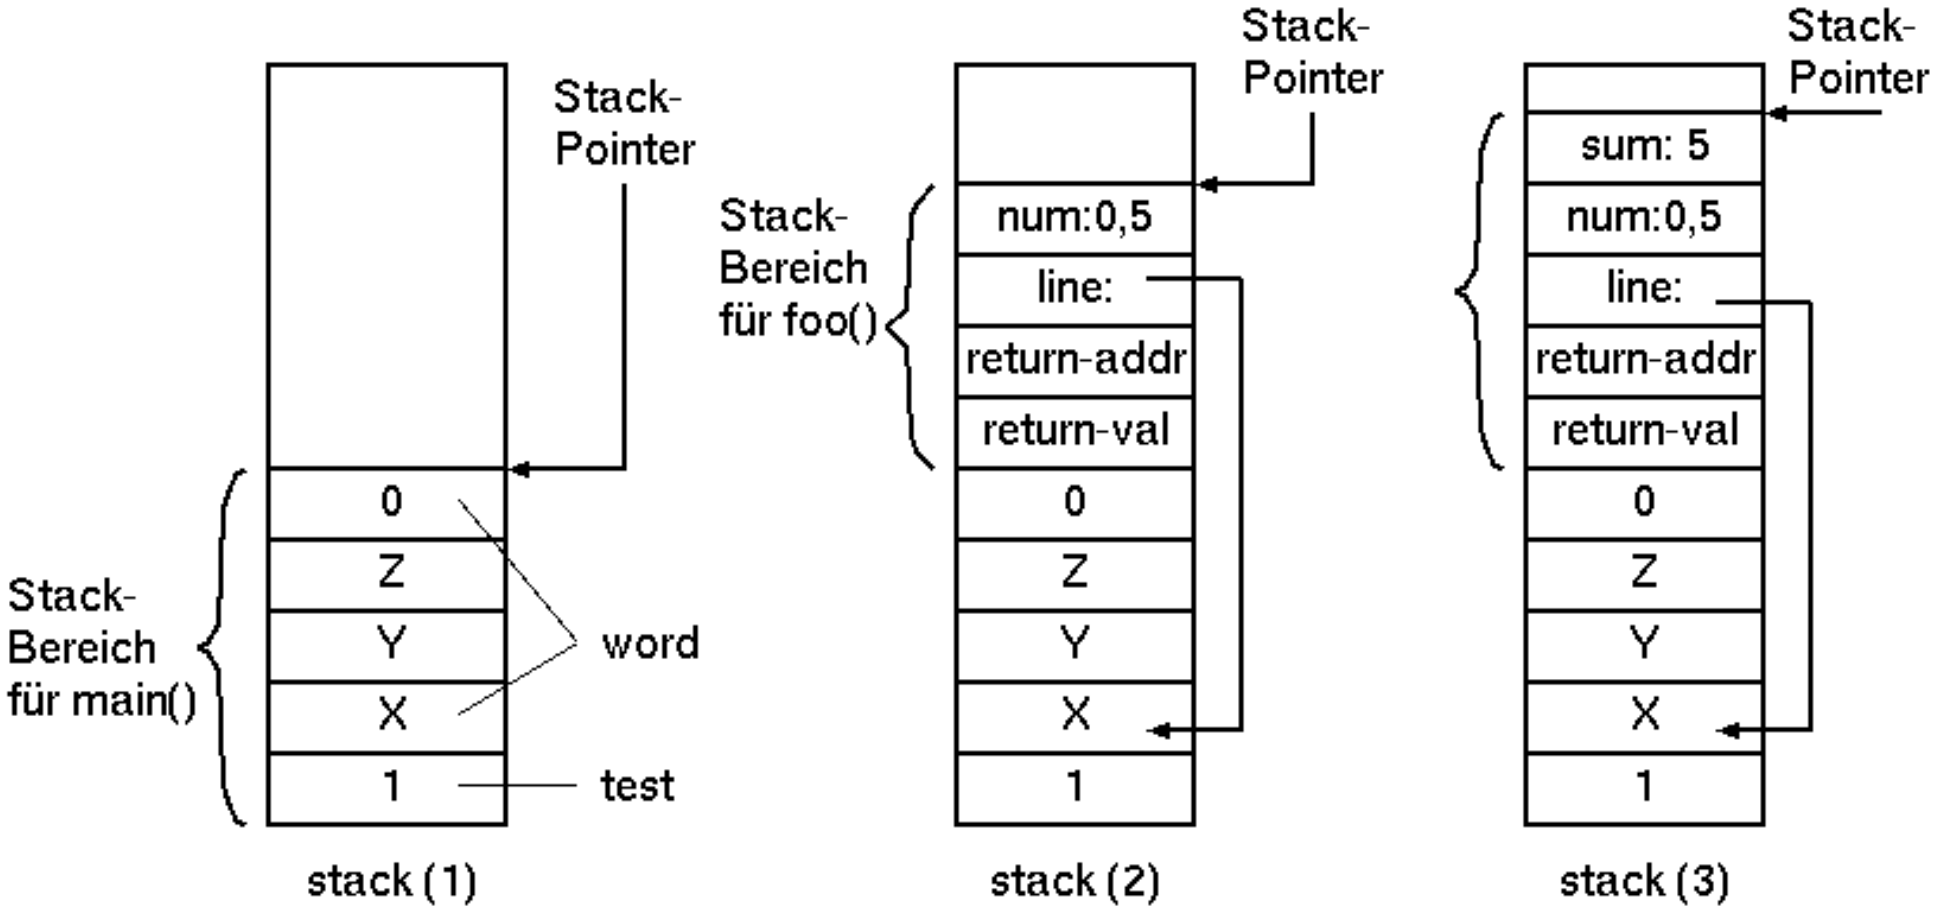

Aufruf einer Betr.Sys-Funktion (1)

Funktion foo() ruft write() auf

- foo() speichert Parameterwerte in Registern
- foo() speichert Index von write() in Register
- foo() führt Anweisung „SVC“ aus (Kernel-Mode)
- SVC holt Funktionszeiger auf write() aus Tabelle
- write() sichert (Rest des) Prozess-Zustands auf System-Stack
- write() führt Anweisungen aus

⋮

Aufruf einer Betr.Sys-Funktion (2)

Funktion foo() ruft write() auf (2)

- write() führt Anweisungen aus
- ggf. startet das BS einen anderen Prozess
- write() speichert Return-Wert an vereinbarter Stelle
- write() stellt den Zustand von foo() wieder her
- write() springt zurück zu foo() (PC zeigt auf foo())

Interrupt einer Funktion

foo() läuft, ein I/O-Gerät erzeugt einen Interrupt

- CPU geht in den Kernel-Mode
- CPU speichert u.a. Befehlszähler von foo()-Prozess
- CPU verzweigt zu Code gemäß Interrupt-Vektor
  z.B. Assembler-Code + BS-Funktion bar()
- bar() sichert (Rest-)Zustand von foo()-Prozess auf Stack
- bar() führt Anweisungen aus
- bar() stellt den Zustand von foo() wieder her
- bar() springt zurück zu foo() (PC zeigt auf foo())

SVC/Trap und Interrupt

Hard- und Soft-Interrupt: Übergang User/Kernel

- Anweisungen svc/trap/int: Software-Interrupt
- Geräte erzeugen Hardware-Interrupt

Ablauf

- CPU sichert einen Teil des Prozess-Zustands auf einem zentralen Stack.
- PC, PSW, SP, Code-/Heap-Pointer . . .
- CPU verzweigt über Tabelle zur Interrupt-Routine
- Anweisung „Return-from-Interrupt“ stellt vorherigen Prozessorzustand wieder her.

Windows NT - Protected Subsysteme

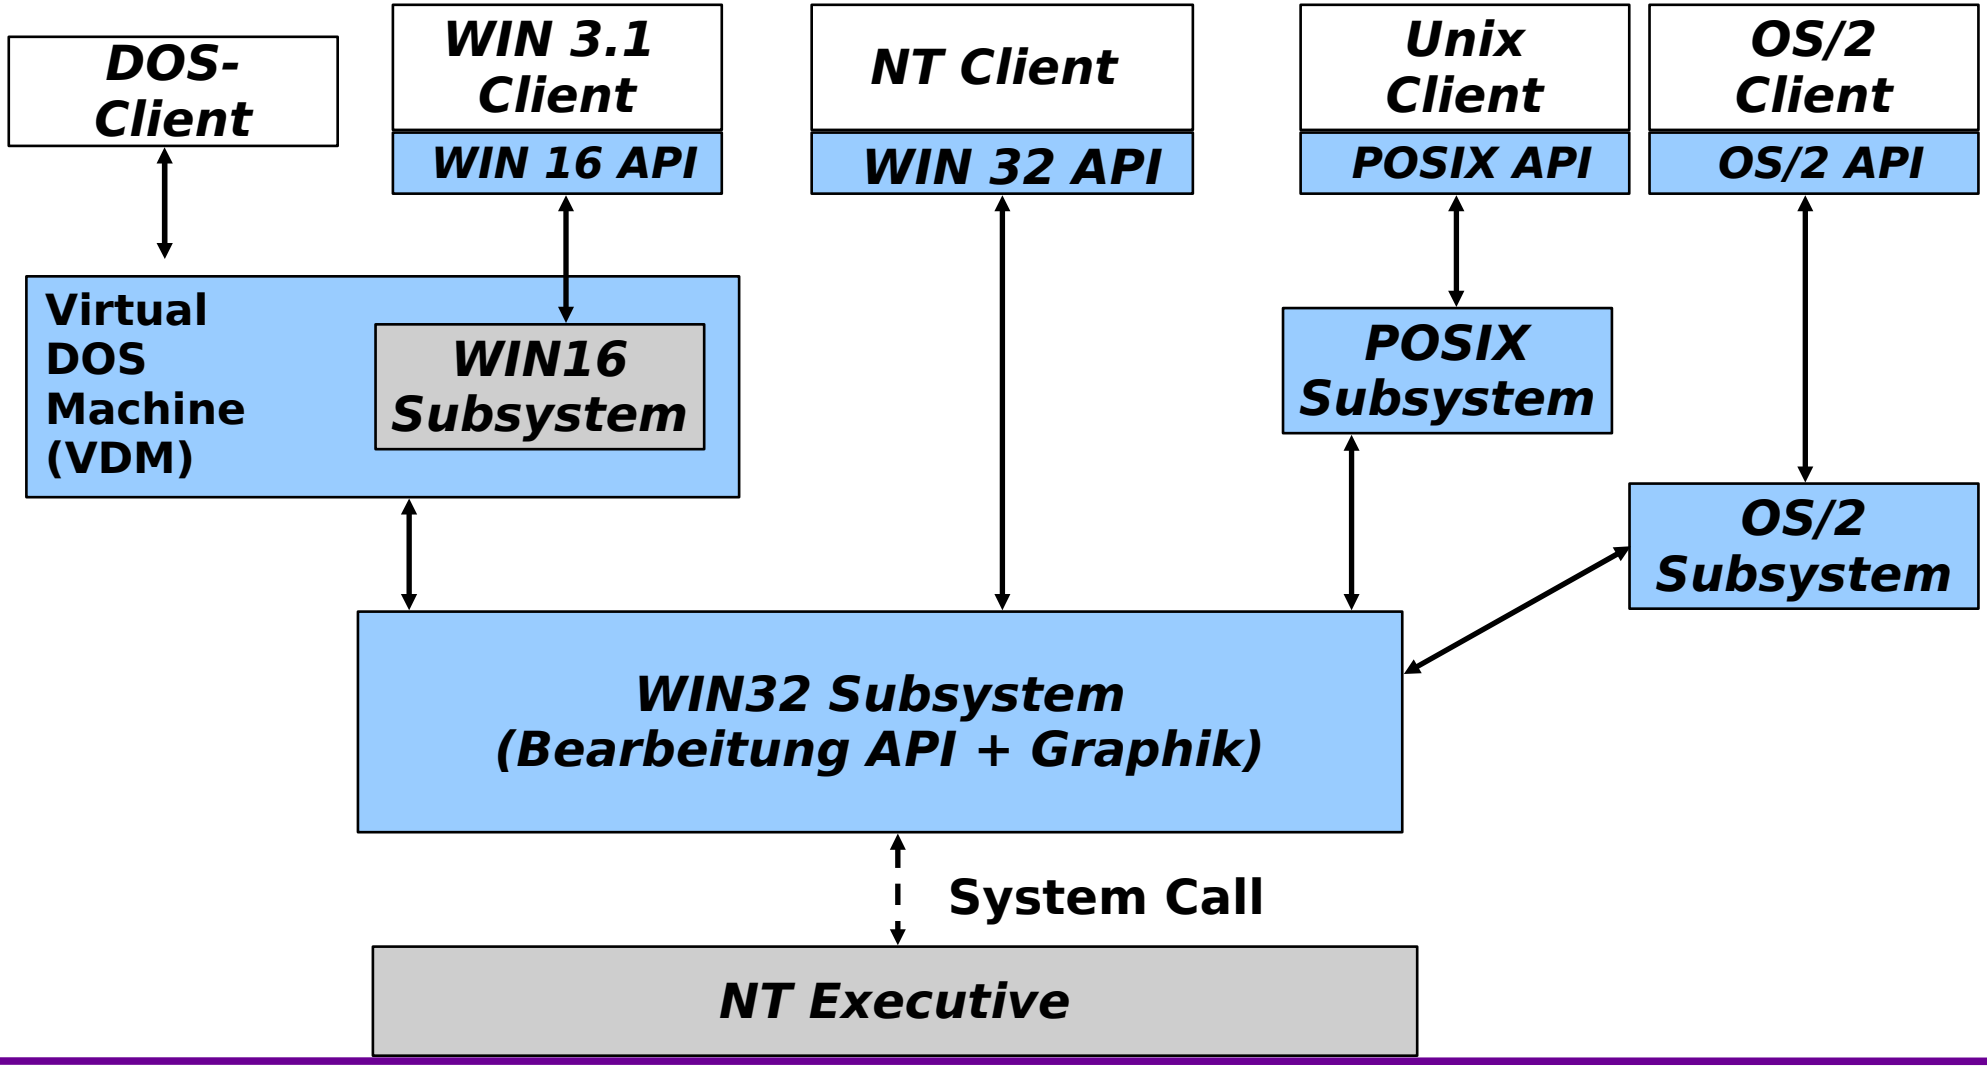

Unterbrechungstechnik

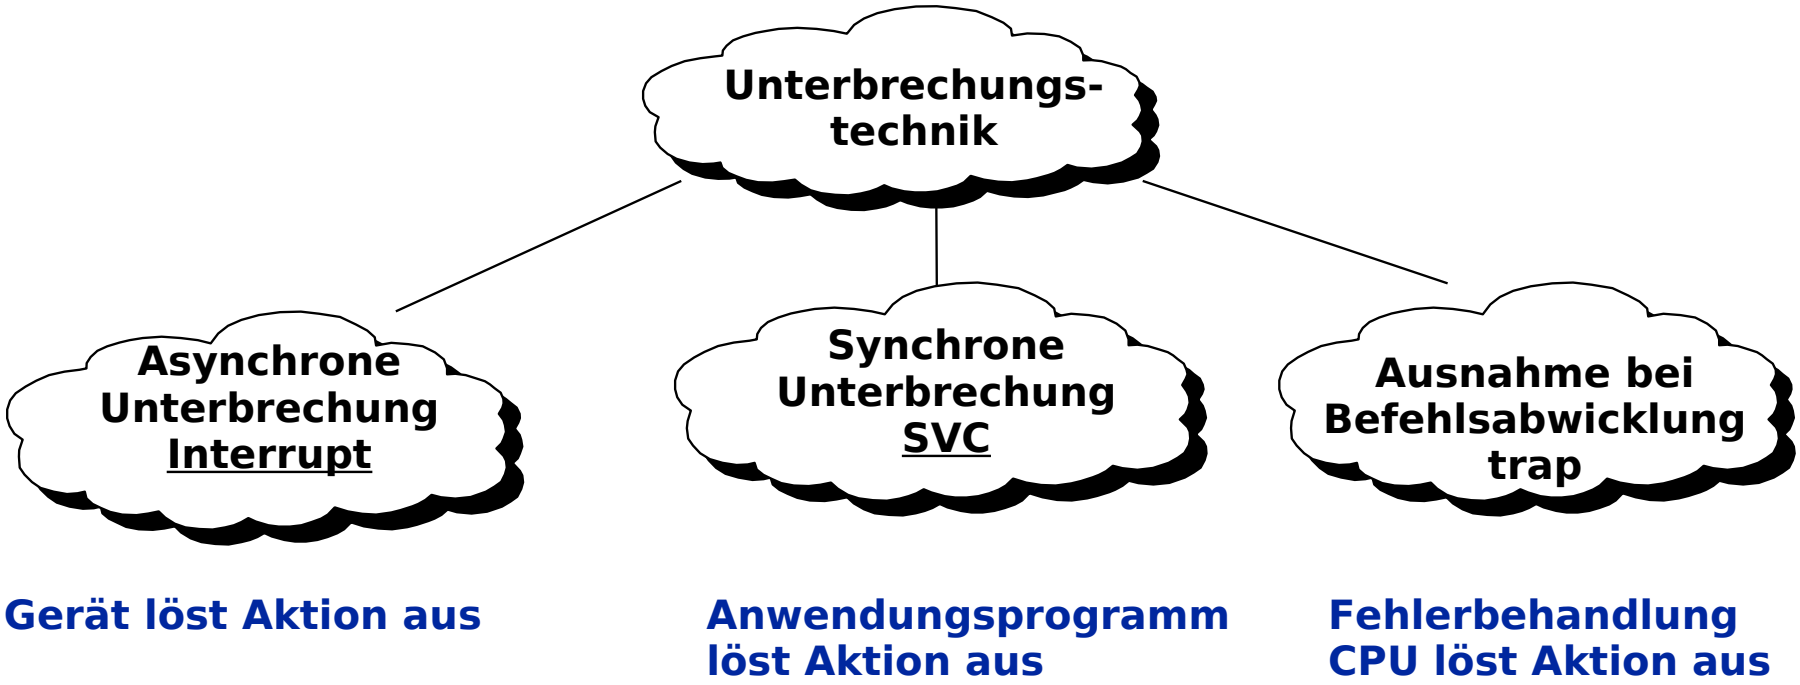

Systemaufrufe (SVC)

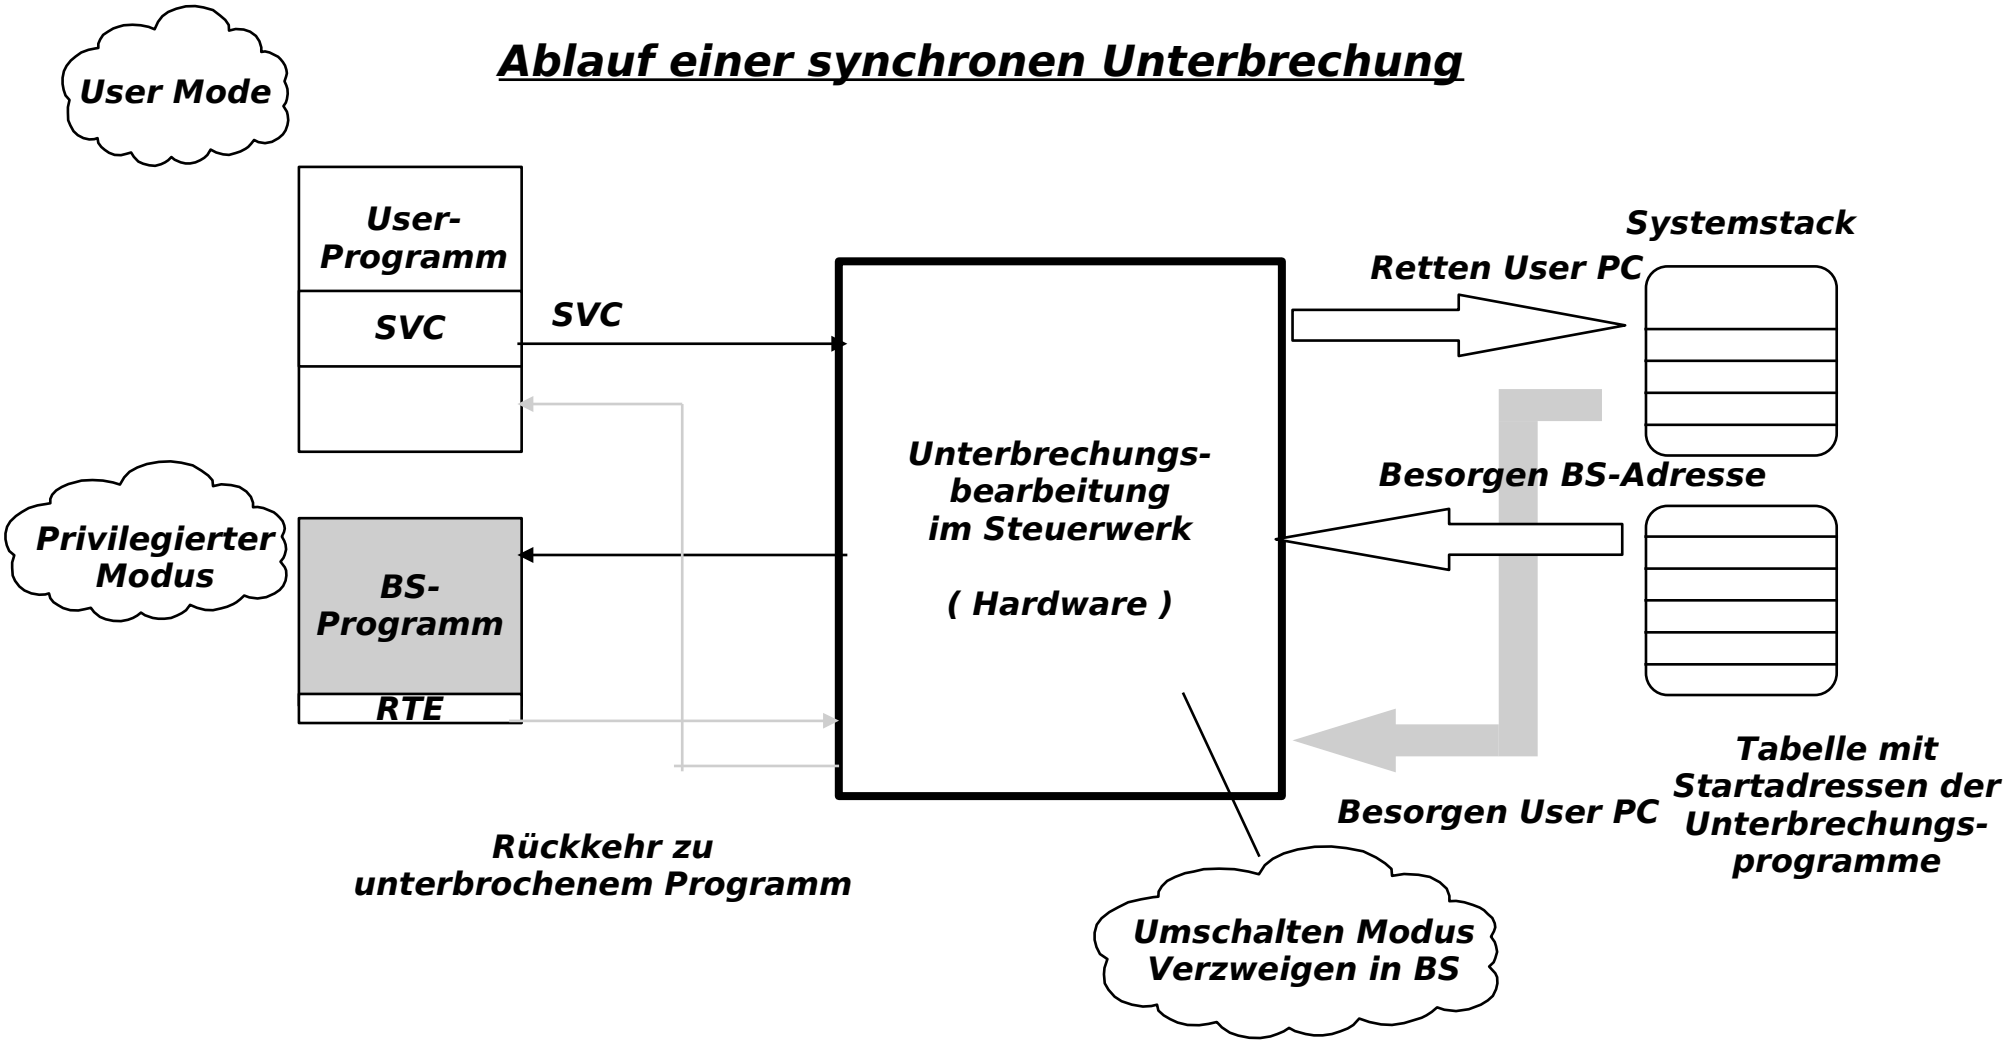

Systemfunktionen als Programmierschnittstelle

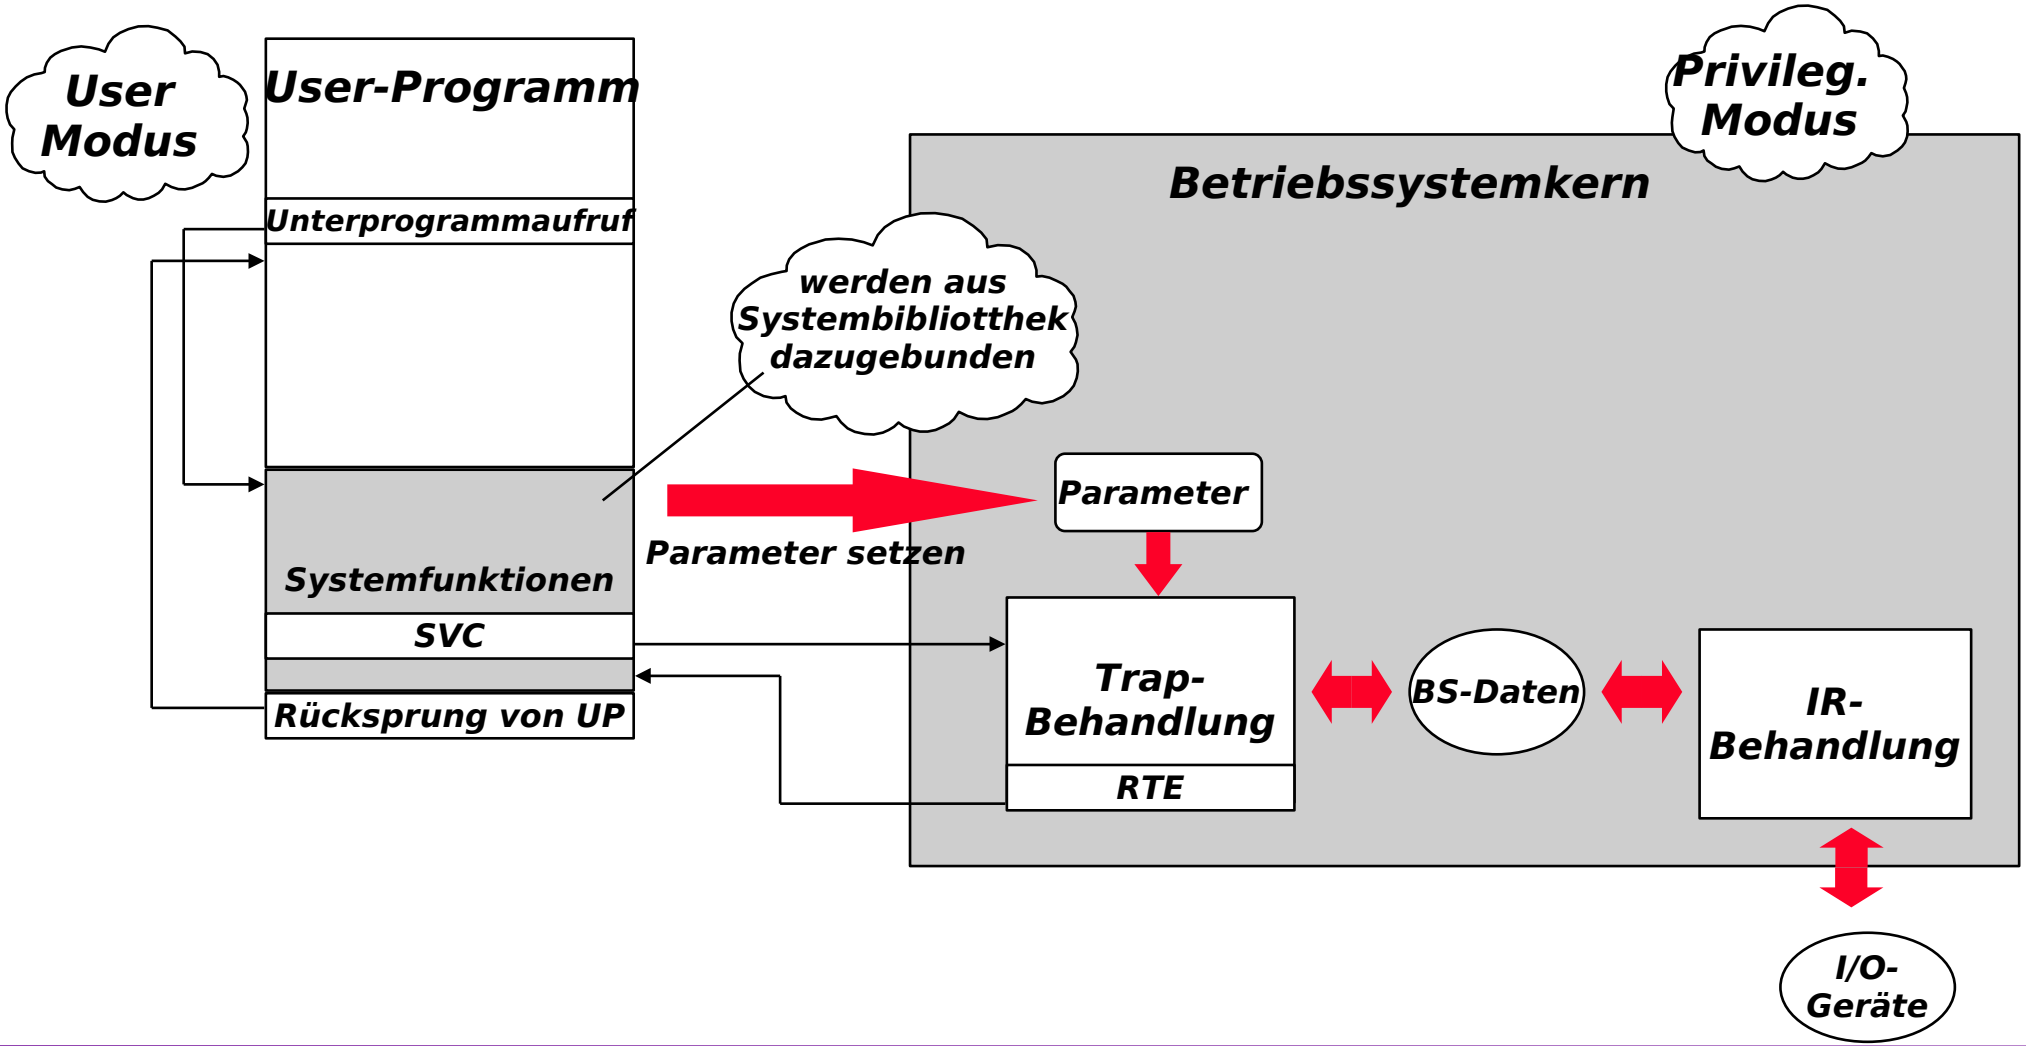

Systemaufrufe

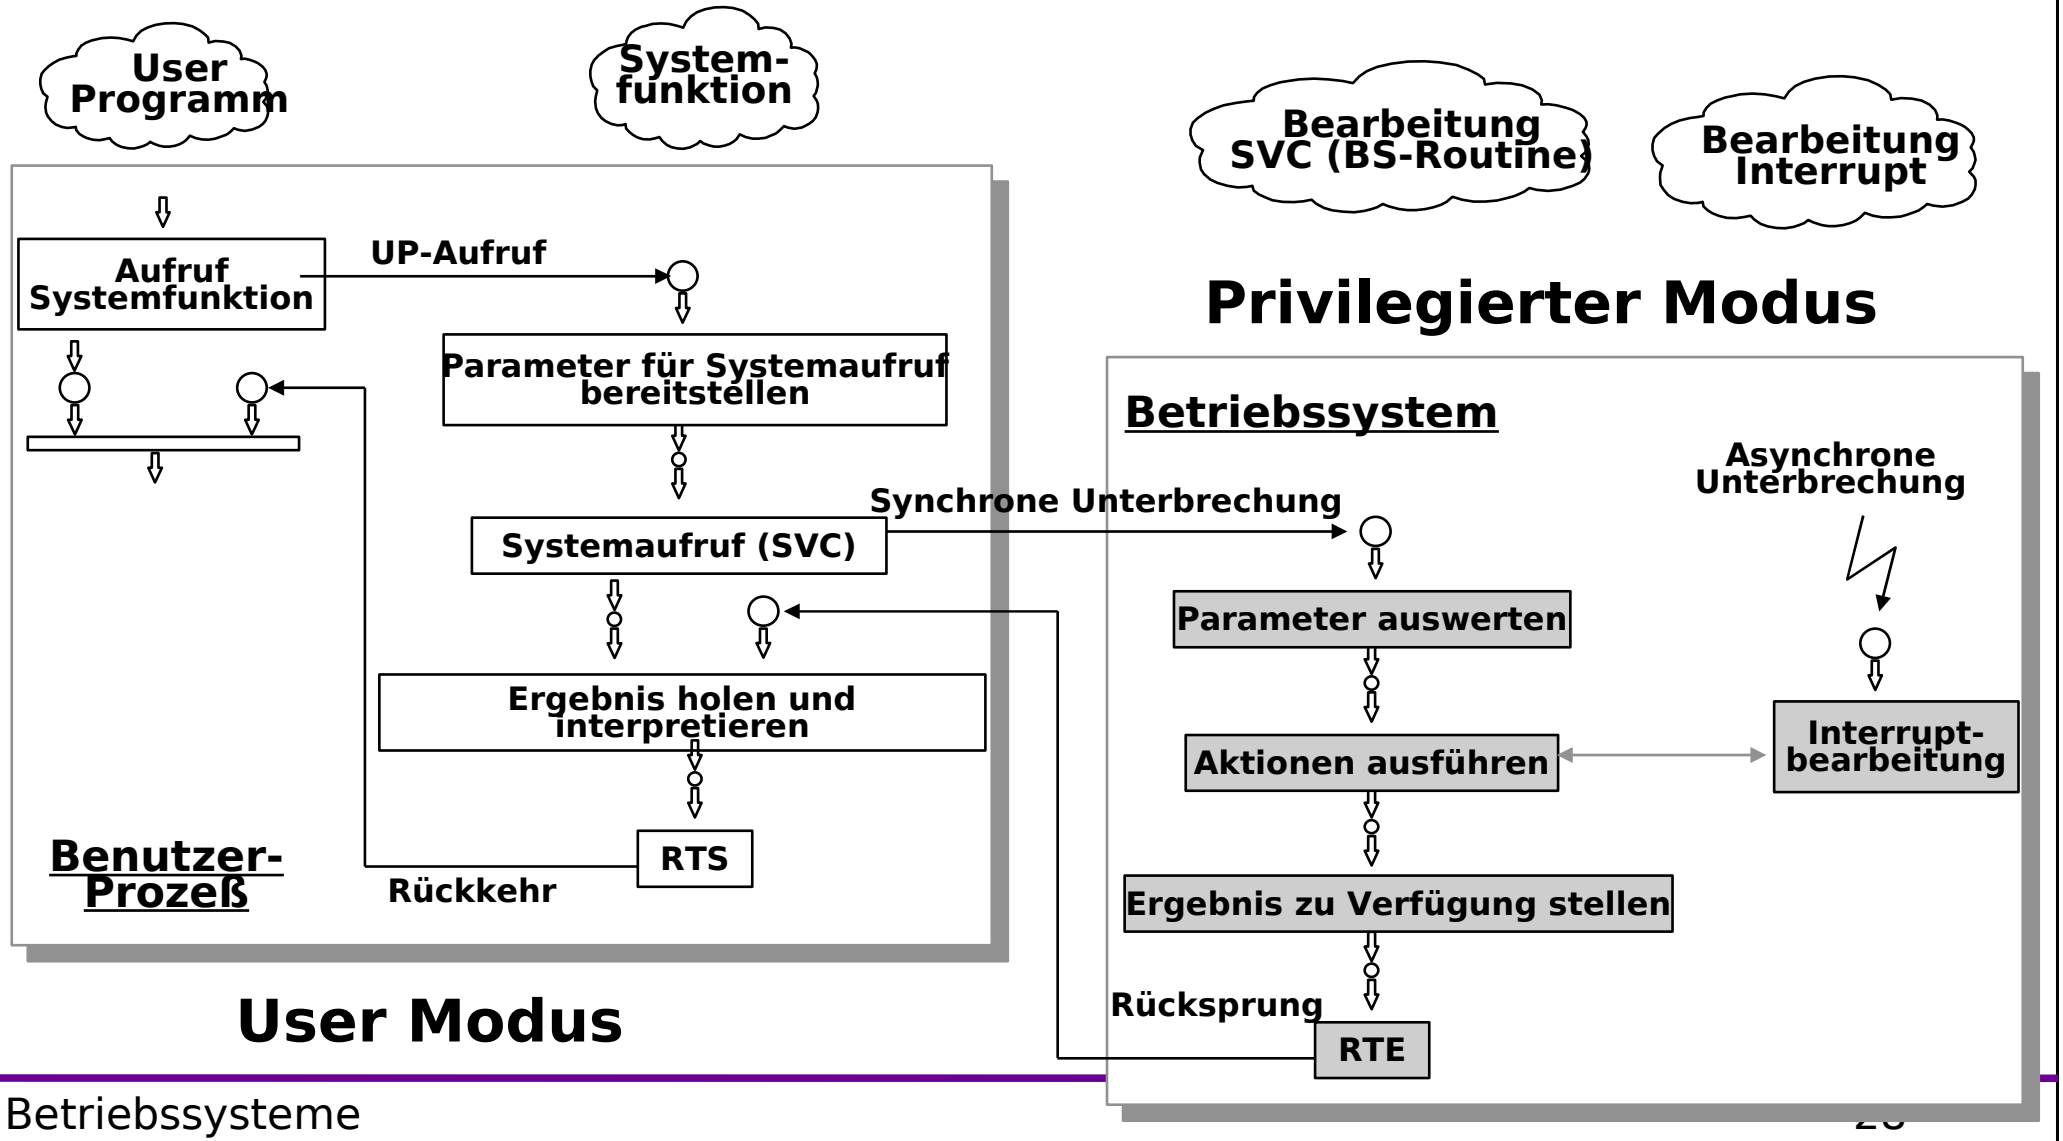

Beispiel : Daten in Datei schreiben

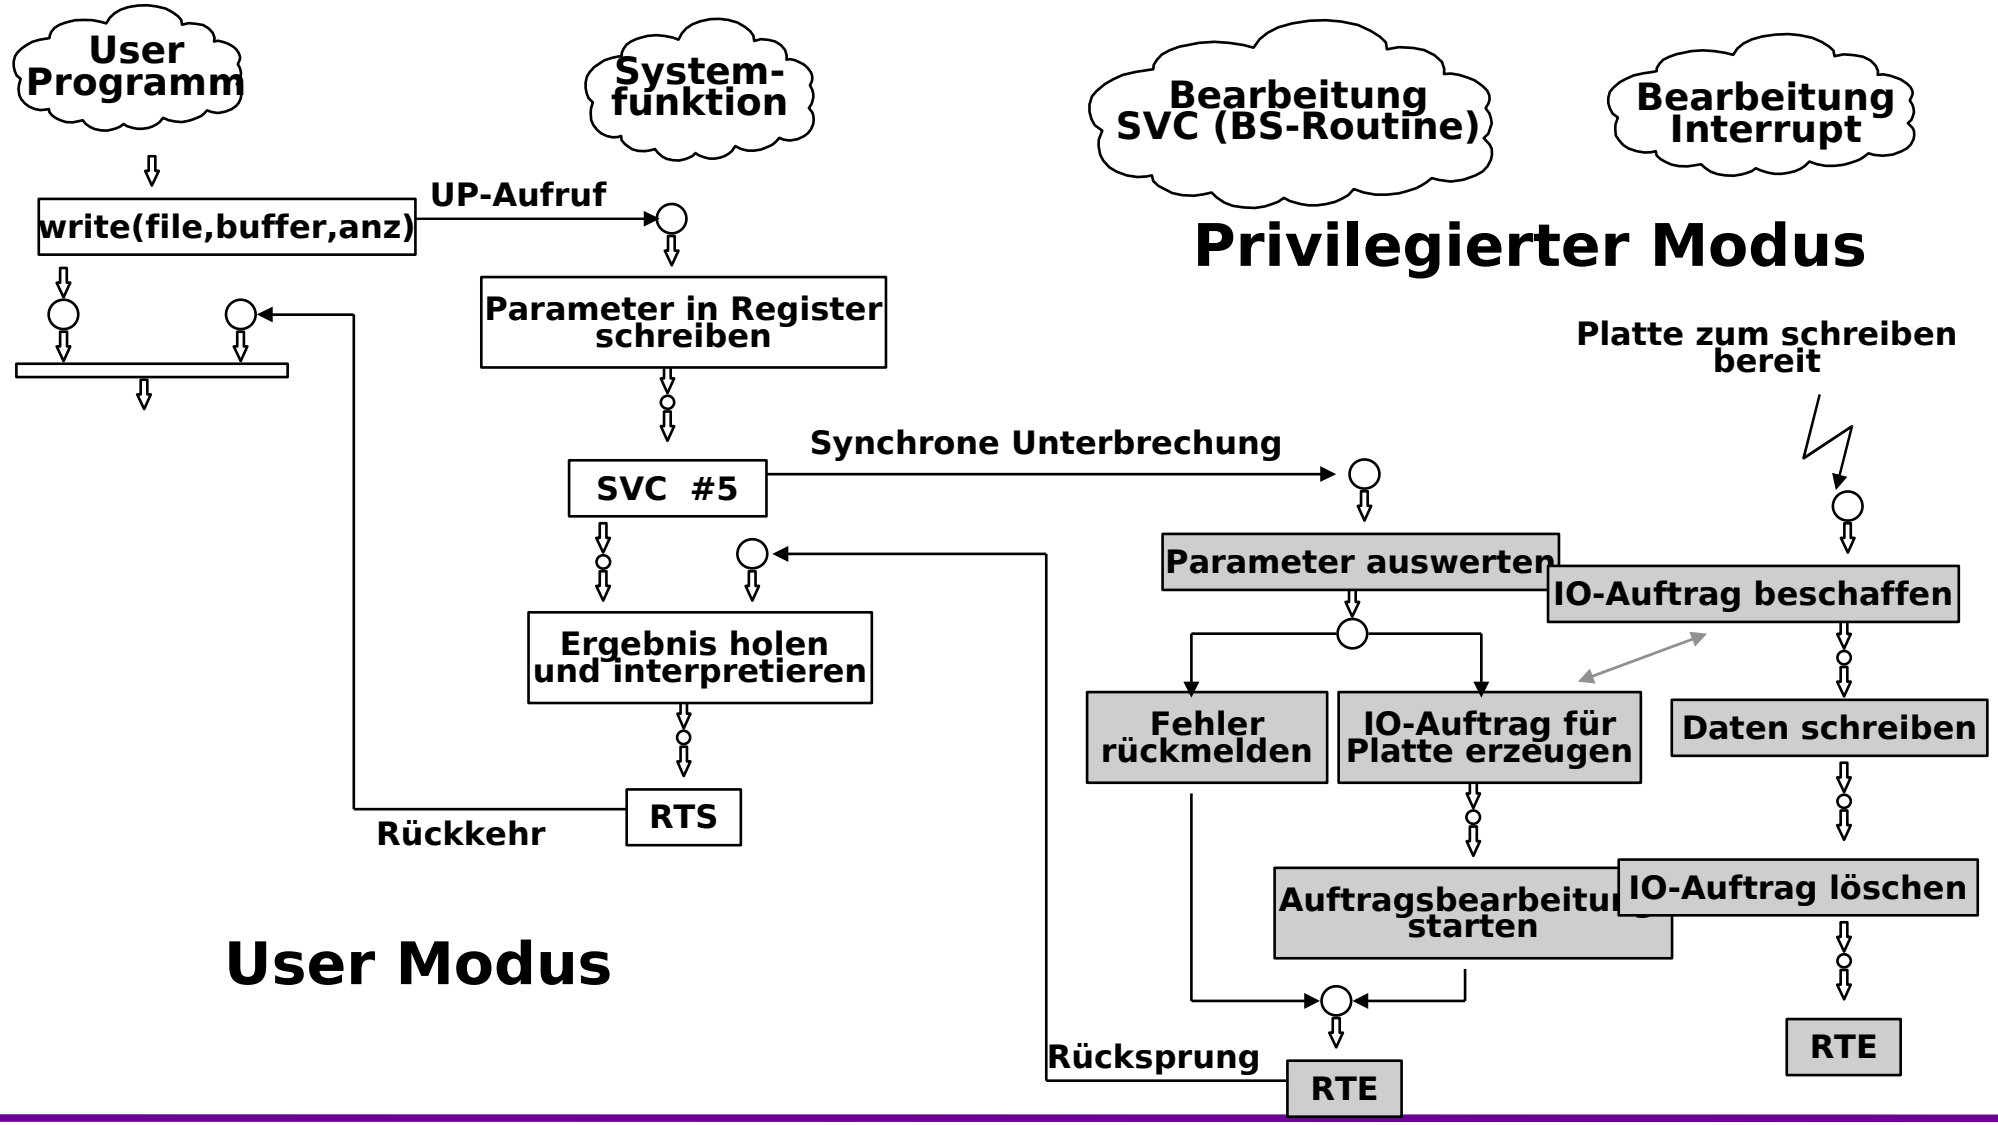

Multitasking - Prozess, Task

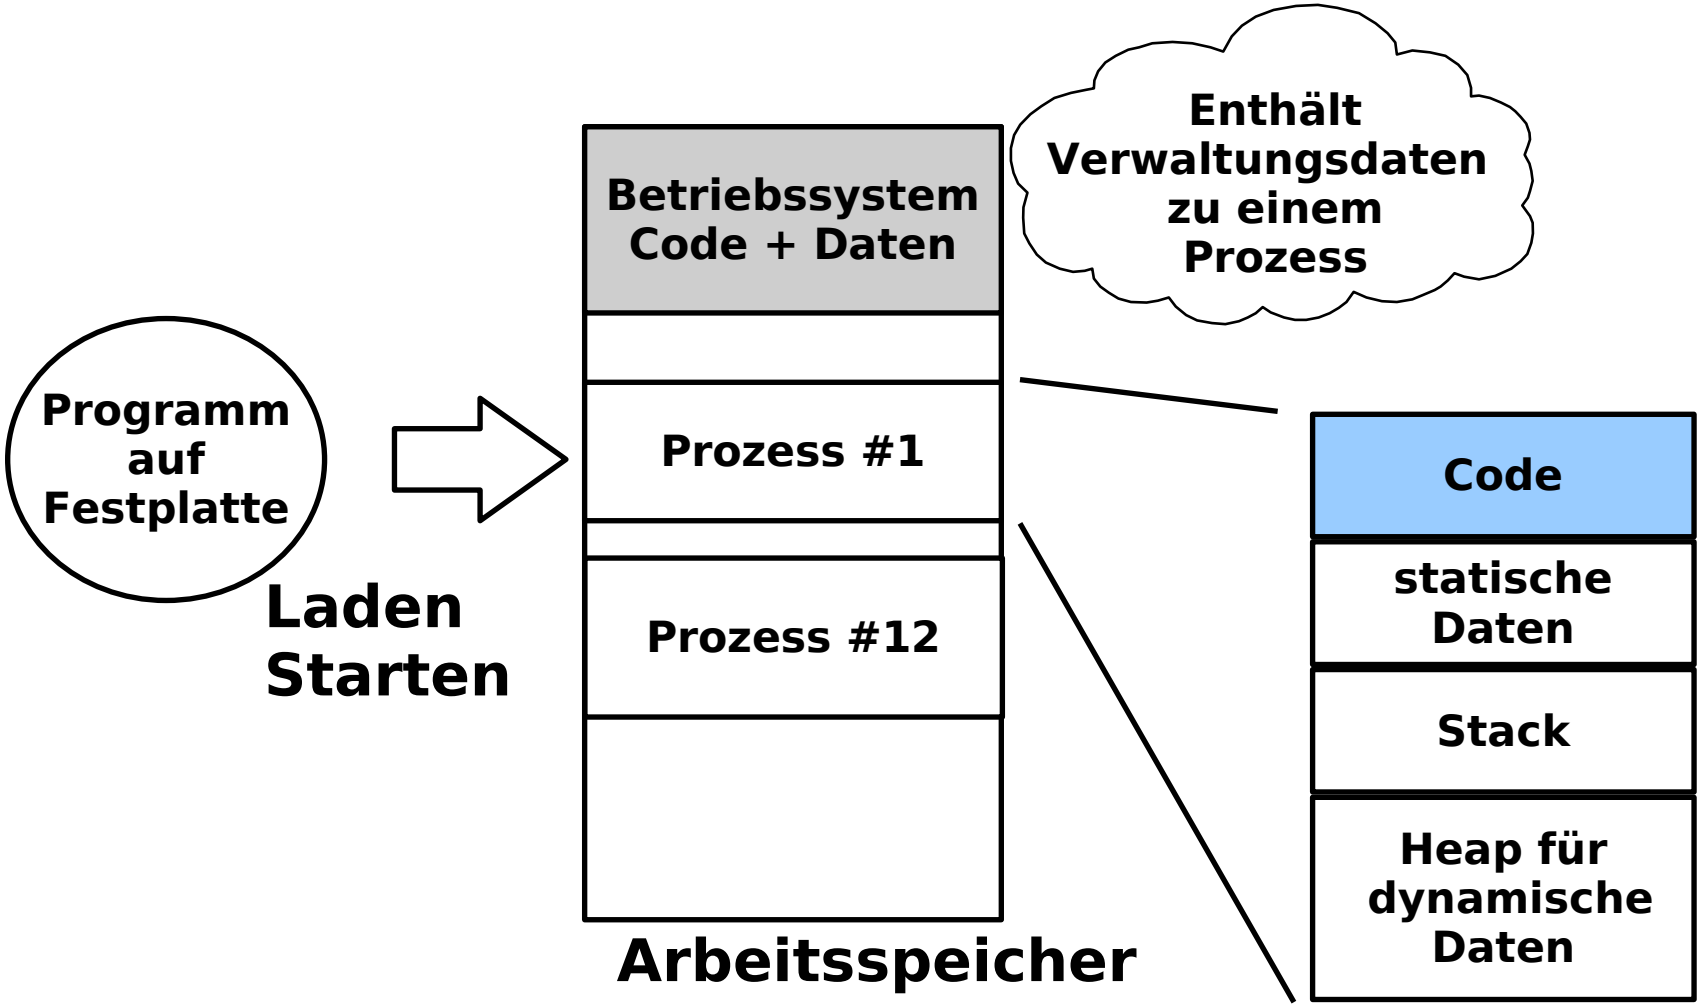

Threads

- Sequentielle Programm- / Funktionsausführung innerhalb eines Prozesses **(thread = Ausführungsfaden)**
  - Ein Thread bearbeitet eine sequentielle Teilaufgabe innerhalb eines Prozesses
  - Mehrere nebenläufige Teilaufgaben können in mehreren Threads innerhalb eines Prozesses abgearbeitet werden (**Multithreading**)
  - Thread verfügt über einen eigenen **Hardwarekontext**
    PC, SP, weitere Prozessorregister (Ausführungszustand)
    und einen eigenen Stack
  - Ein Thread läuft jedoch im Softwarekontext des Prozesses und teilt sich damit den virtuellen Adressraum und alle Ressourcen mit allen anderen Threads des Prozesses

Threads
Nebenläufige Ausführungsfunktionen

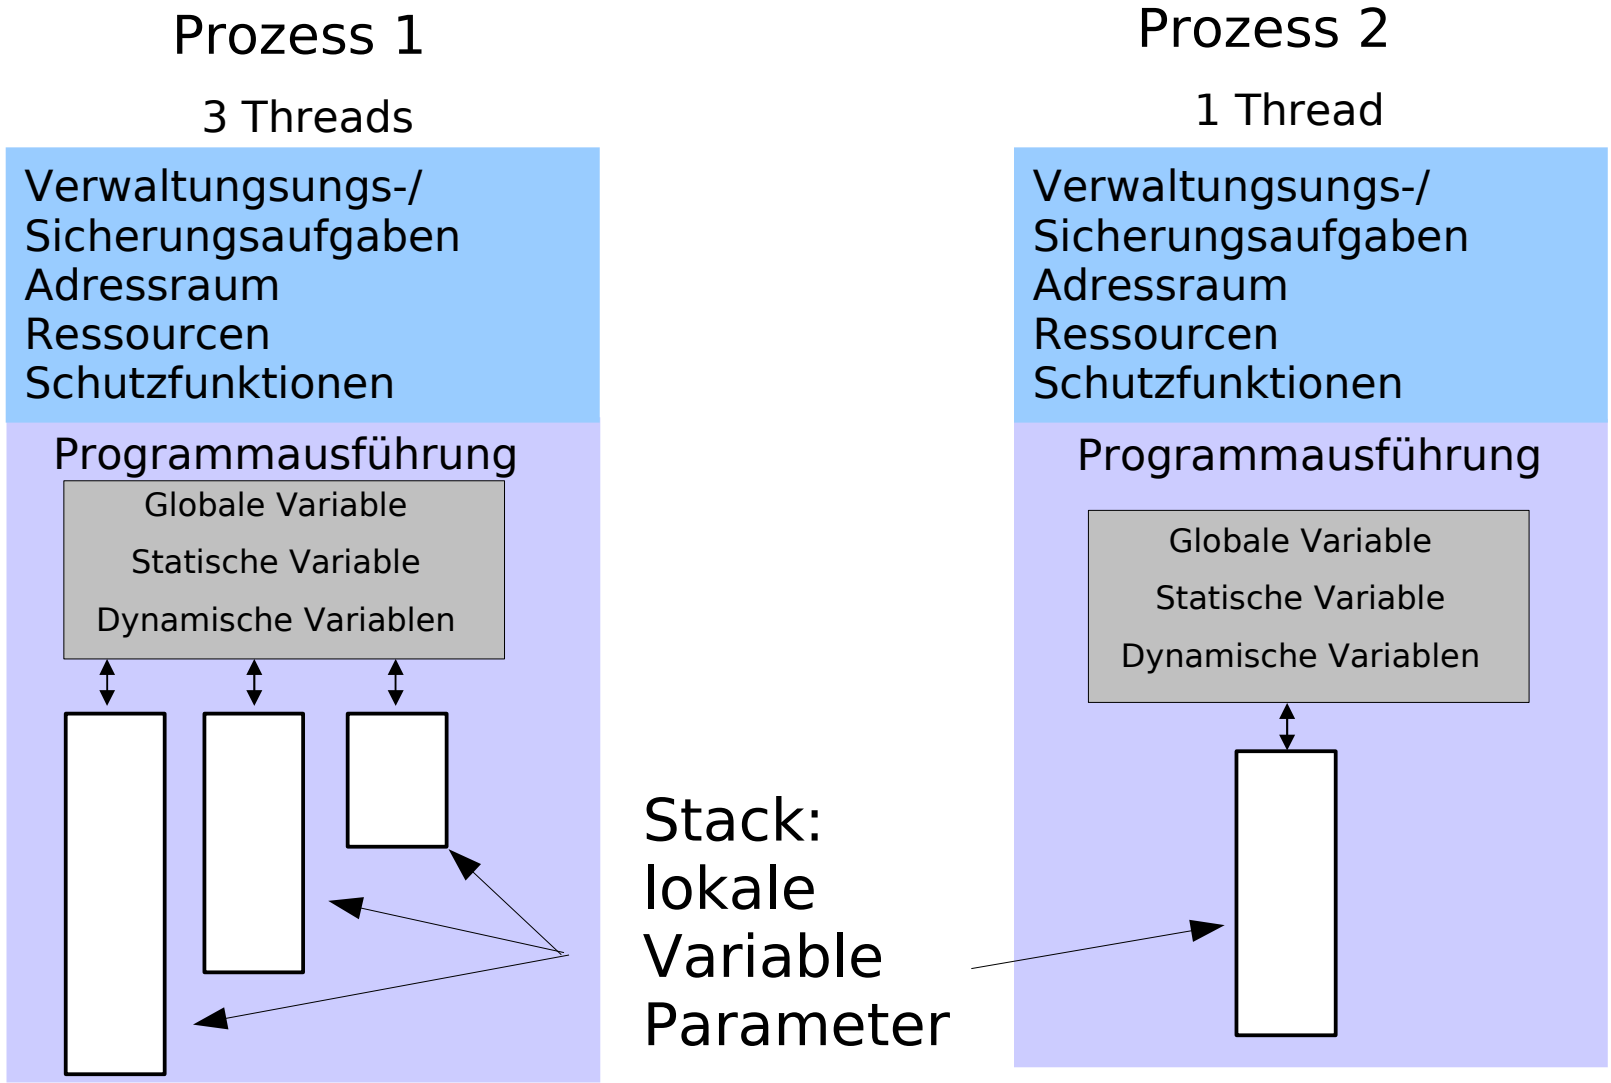

Threads

- Vorteile:
  - Threadwechsel ist schneller als Prozesswechsel, da nur der Hardwarekontext ausgetauscht werden muss
  - einfacher Austausch von Informationen zwischen nebenläufigen Threads durch einen gemeinsamen Adressraum (globale Daten des Prozesses), s.u.
- Nachteile:
  - Durch den gemeinsamen Adressraum ist kein Schutz vor fehlerhaftem Zugriff auf globale Daten möglich
    - Wenn mehrere Threads auf gemeinsame Daten arbeiten, müssen diese Threads synchronisiert werden. Fehlende oder fehlerhafte Synchronisation verursacht Datenverluste oder Dateninkonsistenzen
    - Fehler in der Synchronisation von Threads sind meist schwer zu lokalisieren

Multithreading
Thread-Implementierung

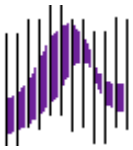

- Benutzer-Threads (ULT = user level thread)
  - unabhängig vom Betriebssystem realisierbar
- Kernel-Threads (KLT = kernel level thread)
  - Windows NT/2000/XP, Linux (ab Kernel 2.6), Mach
- Kombination (Solaris)

User Level Threads

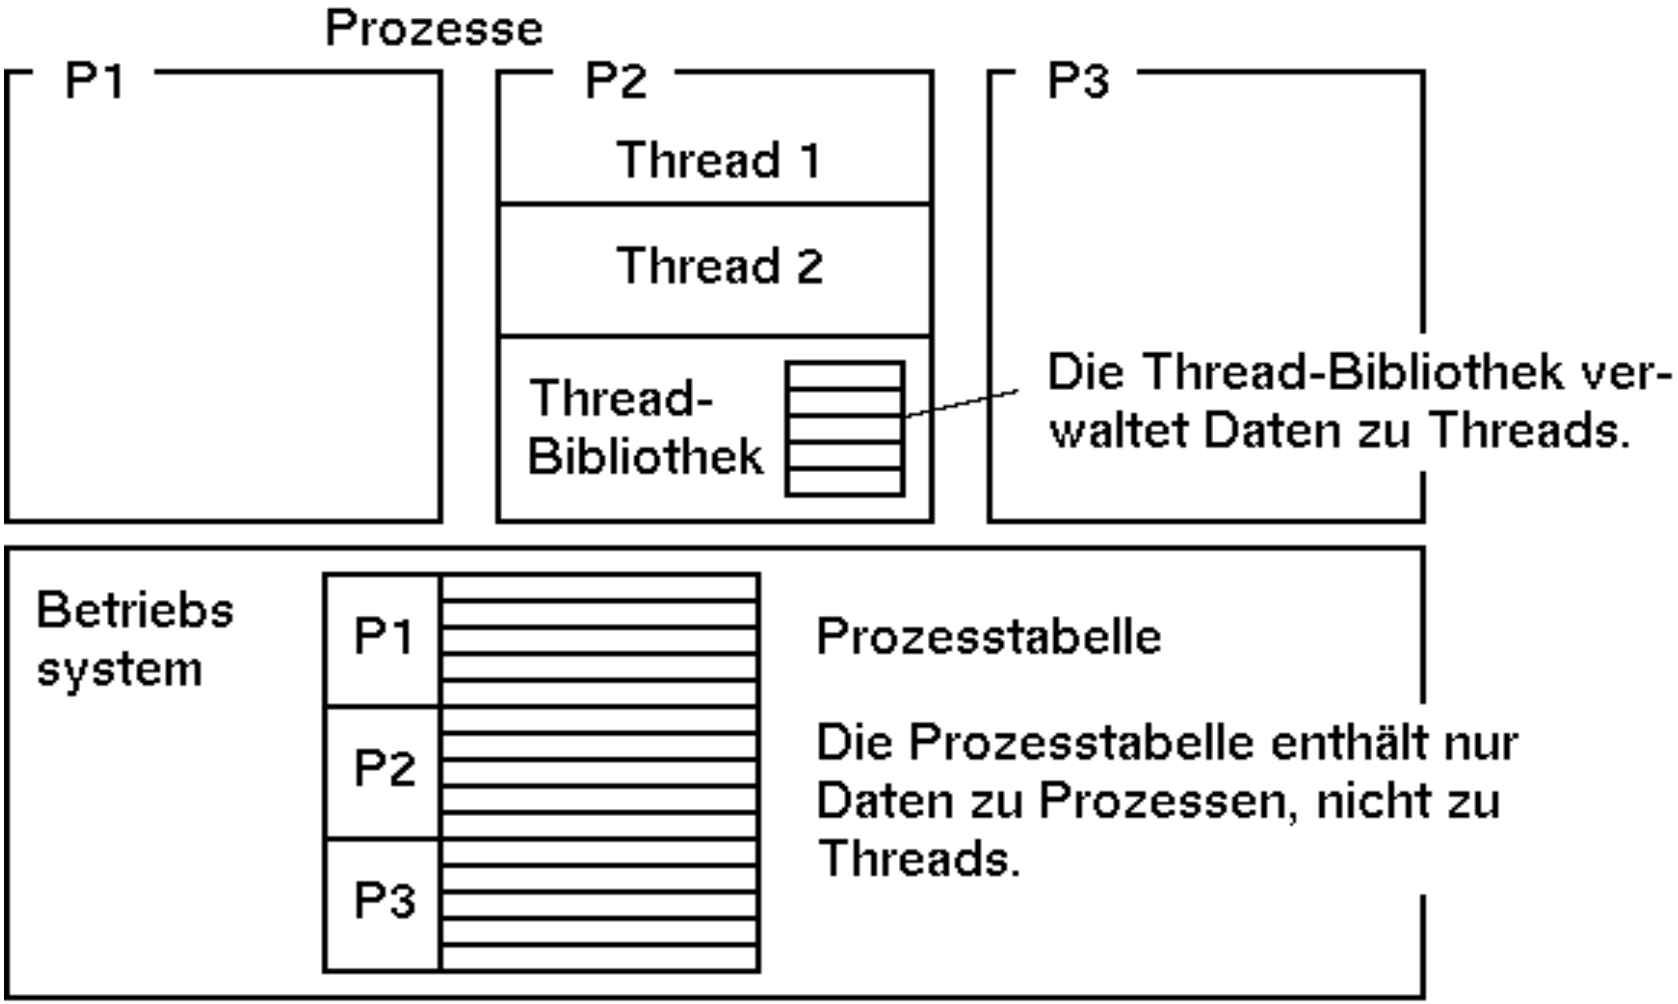

Kernel Level Threads

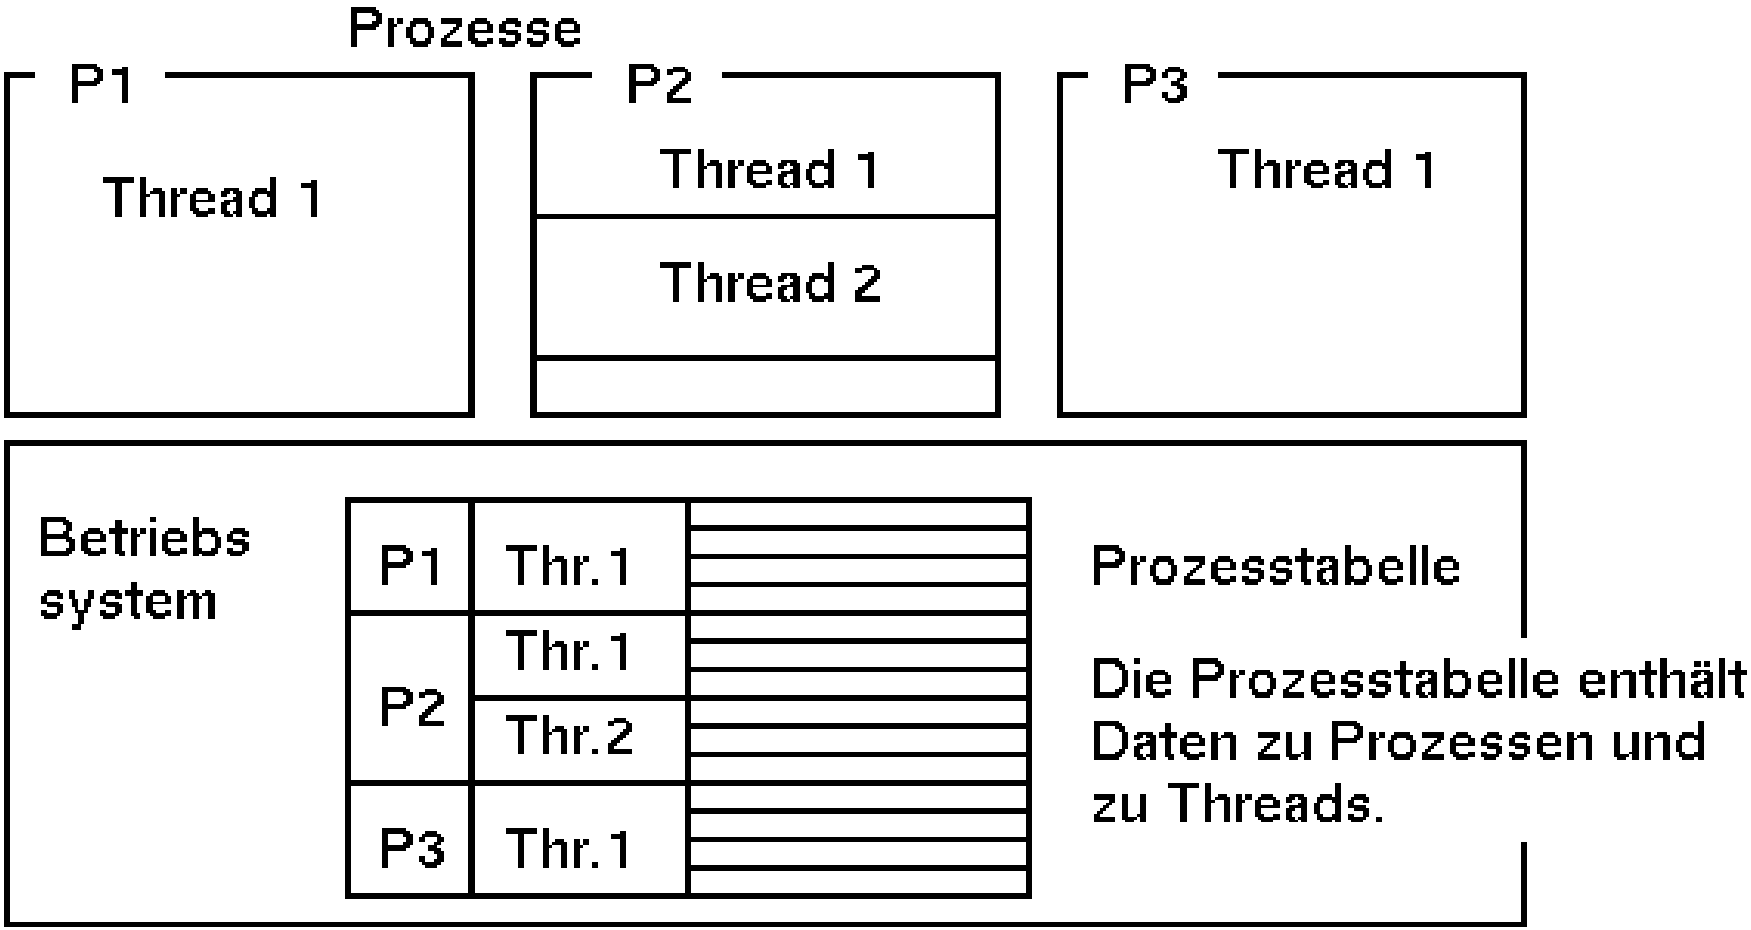

Multithreading Benutzer-Threads

- Laufen im User Modus. Der BS-Kern (Kernel) kennt und verwaltet selbst keine Threads sondern nur Prozesse.
- Der Anwendungsprozess verwaltet seine Threads selbst
- Die Verwaltung erfolgt über eine Thread-Bibliothek, in der alle Funktionen zur Verwaltung, Erzeugung, Terminierung und Synchronisation realisiert werden.
  - In der Bibliothek sind für jeden Thread entsprechende Datenstrukturen implementiert.
  - Weiterhin übernimmt die Bibliothek auch das Umschalten und Scheduling zwischen den Threads innerhalb des Prozesses.
  - Scheduling von Prozessen ist damit unabhängig vom Scheduling der Threads

Multithreading Benutzer-Threads

Beispiel: User-Level-Threads

- BS kennt Prozess A und Prozess B
- Prozess A besitzt Thread A.1 und Thread A.2.
- Prozess B besitzt nur Thread B.1

Fall 1:

Prozess A ist rechnend. Innerhalb A ist Thread A.2 rechnend. Thread A.2 ruft eine blockiernde Systemfunktion z.B. I/O-Wunsch auf.

SVC d.h. Sprung in den Kernel zur Abarbeitung der Systemfunktion.

Prozess A wird blockiert. Prozess B wird rechnend.

Im Prozess A wird Thread A.2 immer noch als rechnend eingestuft.

I/O.Ereignis ist eingetroffen.

Sprung in den Kernel

Prozess A wird vom Kernel wieder deblockiert.

Wenn Prozess A vom Kernel wieder in den Zustand rechnend überführt wird kann Thread A.2 weiter ausgeführt werden.

Multithreading Kernel-Threads

Beispiel Kernel-Level-Threads

- BS kennt Prozess A und Prozess B
- Prozess A besitzt Thread A.1 und Thread A.2.
- Prozess B besitzt nur Thread B.1

Fall 2:

Prozess A ist rechnend. Innerhalb A ist Thread A.2 rechnend. Thread A.2 ruft blockiernde Funktion der Thread-Bibliothek auf z.B. warten auf Ereignis von Thread A.1

- Prozess A bleibt rechnend (falls Zeitscheibe noch nicht abgelaufen ist),
- Thread A.2 wird blockiert und Thread A.1 wird rechnend.

Multithreading Benutzer-Threads

- Vorteile:
  - Threadwechsel wird im User-Modus abgearbeitet. Kein SVC und daher wesentlich schneller.
  - Prozessspezifisches Scheduling der Threads unabhängig vom Scheduling des BS-Kerns.
  - Die Bibliothek kann auf jedes beliebige Betriebssystem aufgebaut werden. Es sind keinerlei Änderungen im Kernel notwendig.

- Nachteile:
  - Blockiert ein Thread durch einen SVC blockiert auch der Prozess und damit auch alle anderen Threads im Prozess.
  - Mehrprozessorbetrieb ist nicht nutzbar. Alle Threads eines Prozesses laufen auf einem Prozessor ab.

Multithreading Kernel-Threads

- Kernel übernimmt die Verwaltung von Threads und Prozessen; insbesondere auch das Scheduling der Threads

- Vorteile:
  - Unterstützt Mehrprozessoren-Architektur
  - Ein blockierter Thread blockiert nicht andere Threads im gleichen Prozess.

- Nachteil:
  - Ein Threadwechsel bedeutet immer auch aufrufen eines SVC und damit Übergang in den privilegierten Modus.

Prozesse unter UNIX - Prozessarten

- Interaktive Prozesse
  - Shell-Prozesse arbeiten mit stdin (Tastatur) und stdout (Bildschirm)
- Daemon-Prozesse
  (daemon = Disc And Execution MONitor)
  - arbeiten im Hintergrund ohne stdin und stdout z.B. Druckspooler, Swapper, Paging Daemon, cron, ... (unter Windows: services)
  - jedem run-level (Systemzustand) sind deamons zugeordnet: /etc/rcX.d/*

Prozesse unter UNIX

- Prozesse werden in einer Prozesstabelle und PCB‘s verwaltet. Ein Prozess wird unter Unix auch als Task bezeichnet.
  - Jeder Eintrag in der Prozesstabelle verweist auf den PCB des Prozesses.
- Jeder Prozess wird durch eine eindeutige PID verwaltet und verfügt über eine Gruppen-ID und Benutzer-ID.
  - Über Gruppe und Benutzer werden Zugriffsrechte auf Ressourcen geregelt.

Prozesse Erzeugen/Beenden (Unix)

- Prozess erzeugen
  - Systemfunktion pid = fork()
    Es wird eine Kopie des aktuellen Prozesses erzeugt.
    Ergebnis der Funktion (gespeichert in pid):
    - < 0 wenn Prozess nicht erzeugt werden konnte
      (z.B. Prozesstabelle ist voll)
    - = 0 im Kind-Prozess
    - >0 im Eltern-Prozess; Variable pid enthält die Prozessidentifikation der erzeugten Kopie d.h. des Kind-Prozesses

- freiwilliges Ende
  - exit (...) (wird vom Prozess selbst aufgerufen)

- Ausführen eines neuen Programms
  - exec(....) (ändert den Prozess selbst)

- warten auf das Ende eines erzeugten Kind-Prozesses
  - wait(....), waitpid() (wird vom Eltern-Prozess aufgerufen)
    waitpid() kann auch nicht-blockierend verwendet werden.

Prozesse unter UNIX

- Jeder Prozess kennt seinen Eltern-Prozess, seine Kinder.
- Terminiert ein Kind-Prozess, so wird er in den Zustand **Zombie** versetzt bis der Eltern-Prozess den Terminierungsstatus vom BS abgeholt hat (Funktion waitpid()).
- Terminiert der Eltern-Prozess, so werden alle existierenden Kind-Prozesse einem neuen Eltern-Prozess zugeordnet.
  - Dies ist immer der Prozess INIT (Pid = 1).
- Möchte der Eltern-Prozess nicht auf das Ende eines Kind-Prozesses warten, sondern ohne zu warten nur den Status abholen, kann er die Systemfunktion waitpid(. . . , . . . , WNOHANG) verwenden.

Prozesse unter UNIX - Erzeugen

Beispiel

```
.
.
.
.

pid = fork();
if ( pid <0 )  printf("Prozeß wurde nicht erzeugt\n");
else
    if ( pid == 0 )
        /* Starten eines neuen Programms im erzeugten Kindprozess */
       execl(......)
     else
         /* Elternprozeß wartet auf Ende des Kindprozesses */
         wait(...)
```

Prozesse unter UNIX erzeugen

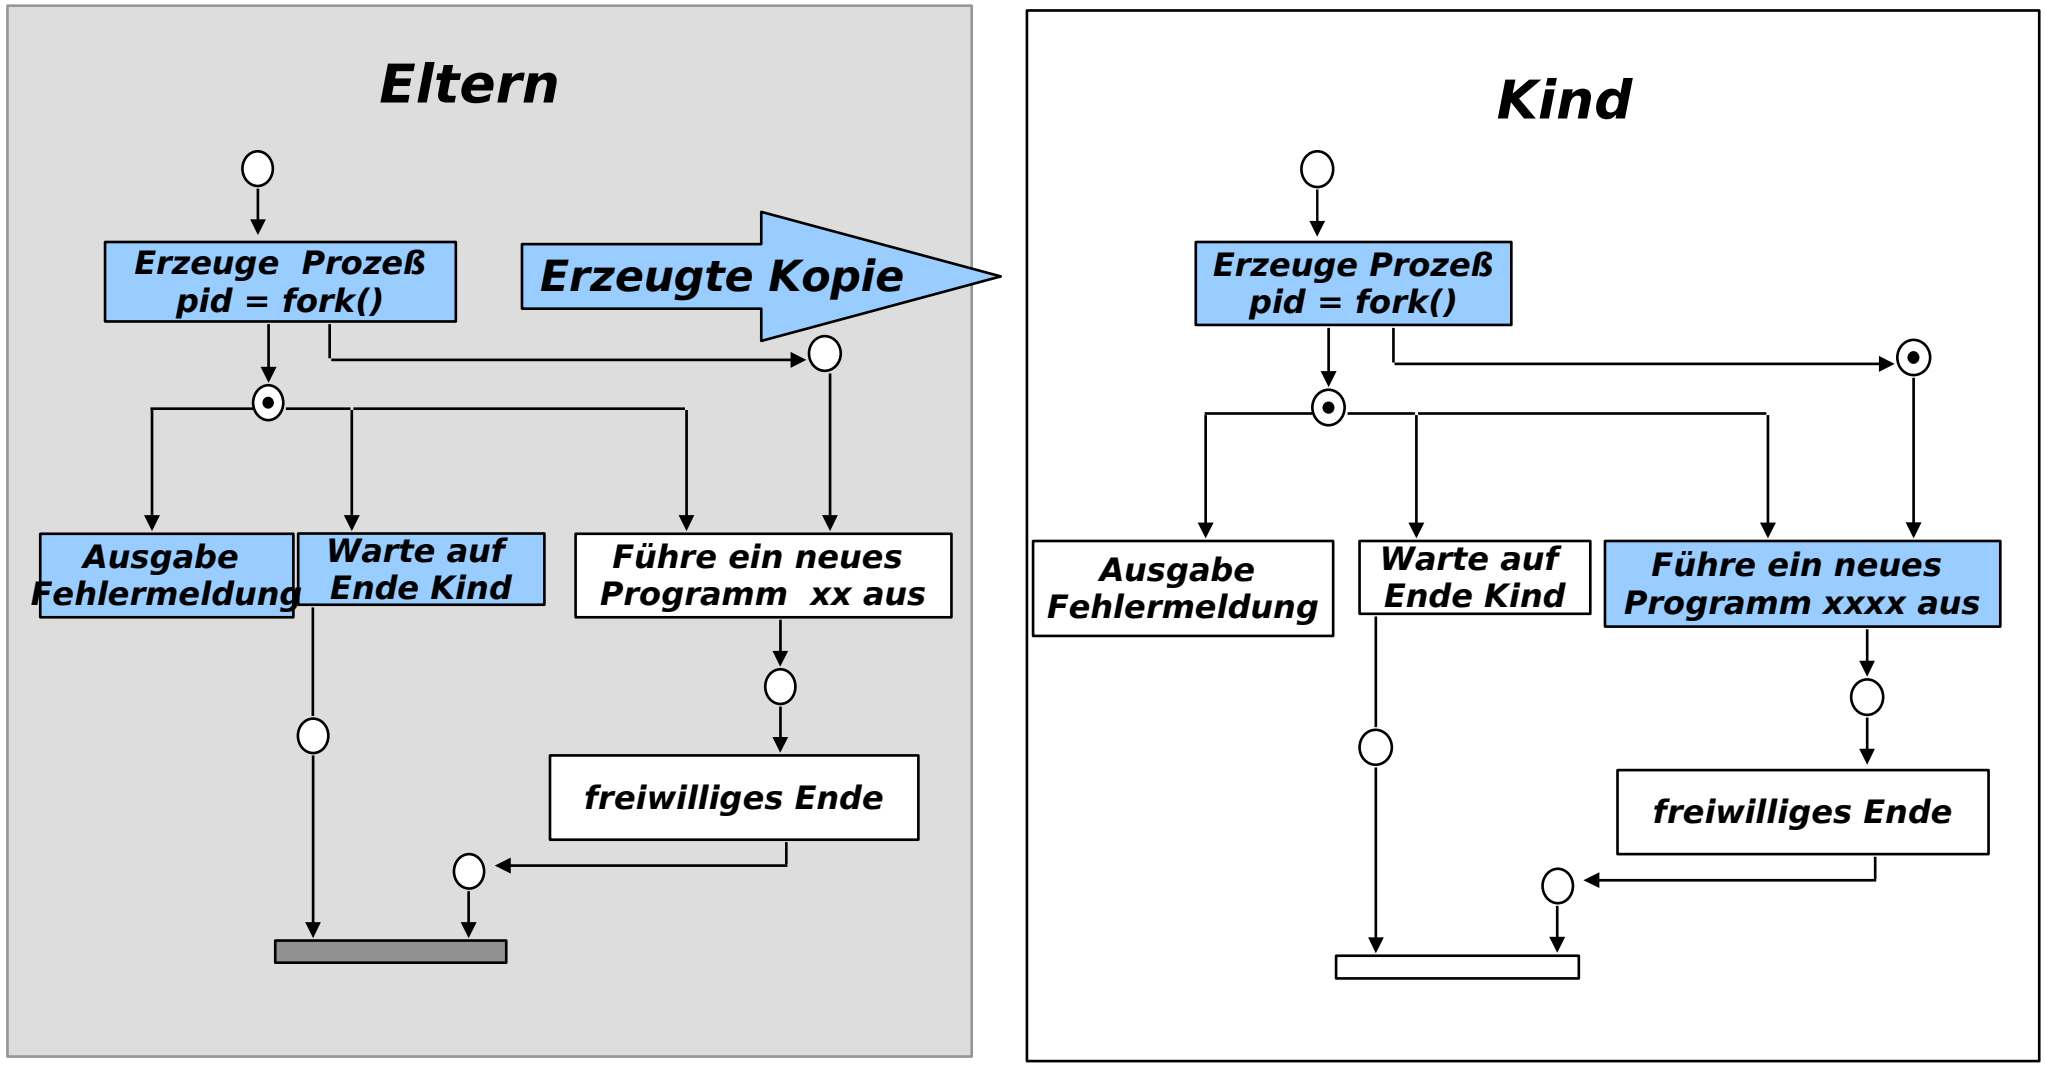

Prozesse unter UNIX – weitere Systemfunktionen

- Eigene PID erfragen pid()
- PID des Elternprozesses erfragen ppid()

Multitasking - Prozesszustände

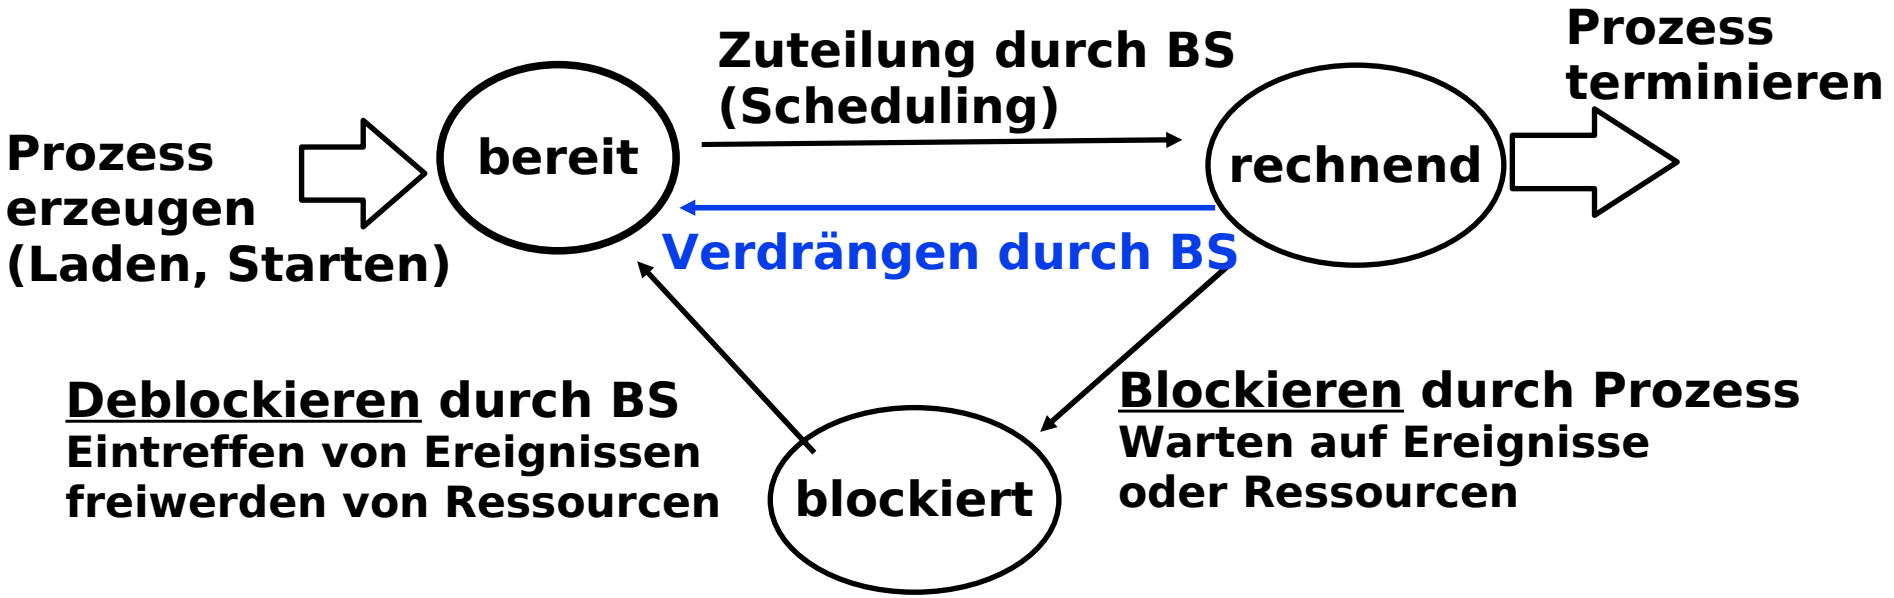

preemptive Scheduling:
Prozesswechsel wird vom Betriebssystem erzwungen (Zeitscheibenverfahren)

non preemptive Scheduling:
Prozesswechsel erfolgt nur durch freiwillige Abgabe der CPU durch einen Prozess (Systemaufrufe im Programm)

Prozess- bzw. Thread-Zustände

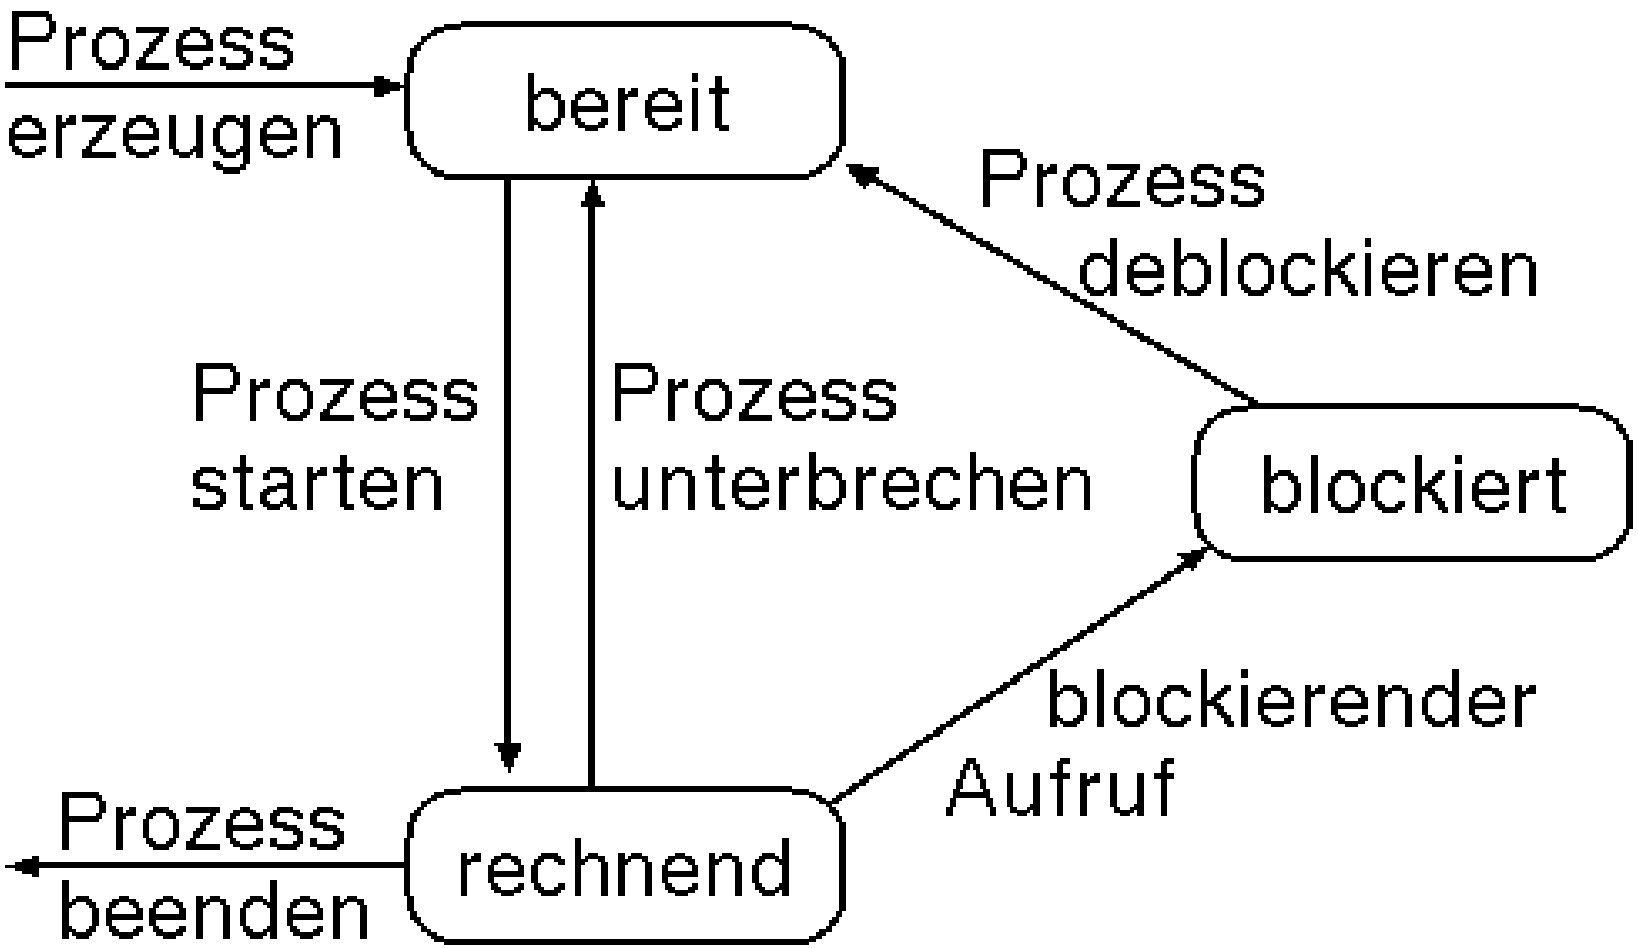

Scheduling/Dispatching

- Scheduling
  - Auswahl des Prozesses, der als nächstes rechnen darf.
  - Der Scheduling-Algorithmus betrachtet nur Prozesse im Zustand „bereit“.
- Dispatching
  - Auslagern des laufenden Prozesses:
    Prozess-Zustand sichern
  - Einlagern des ausgewählten Prozesses:
    Prozess-Zustand rekonstruieren

Multitasking
Prozesswechsel durch Systemaufruf

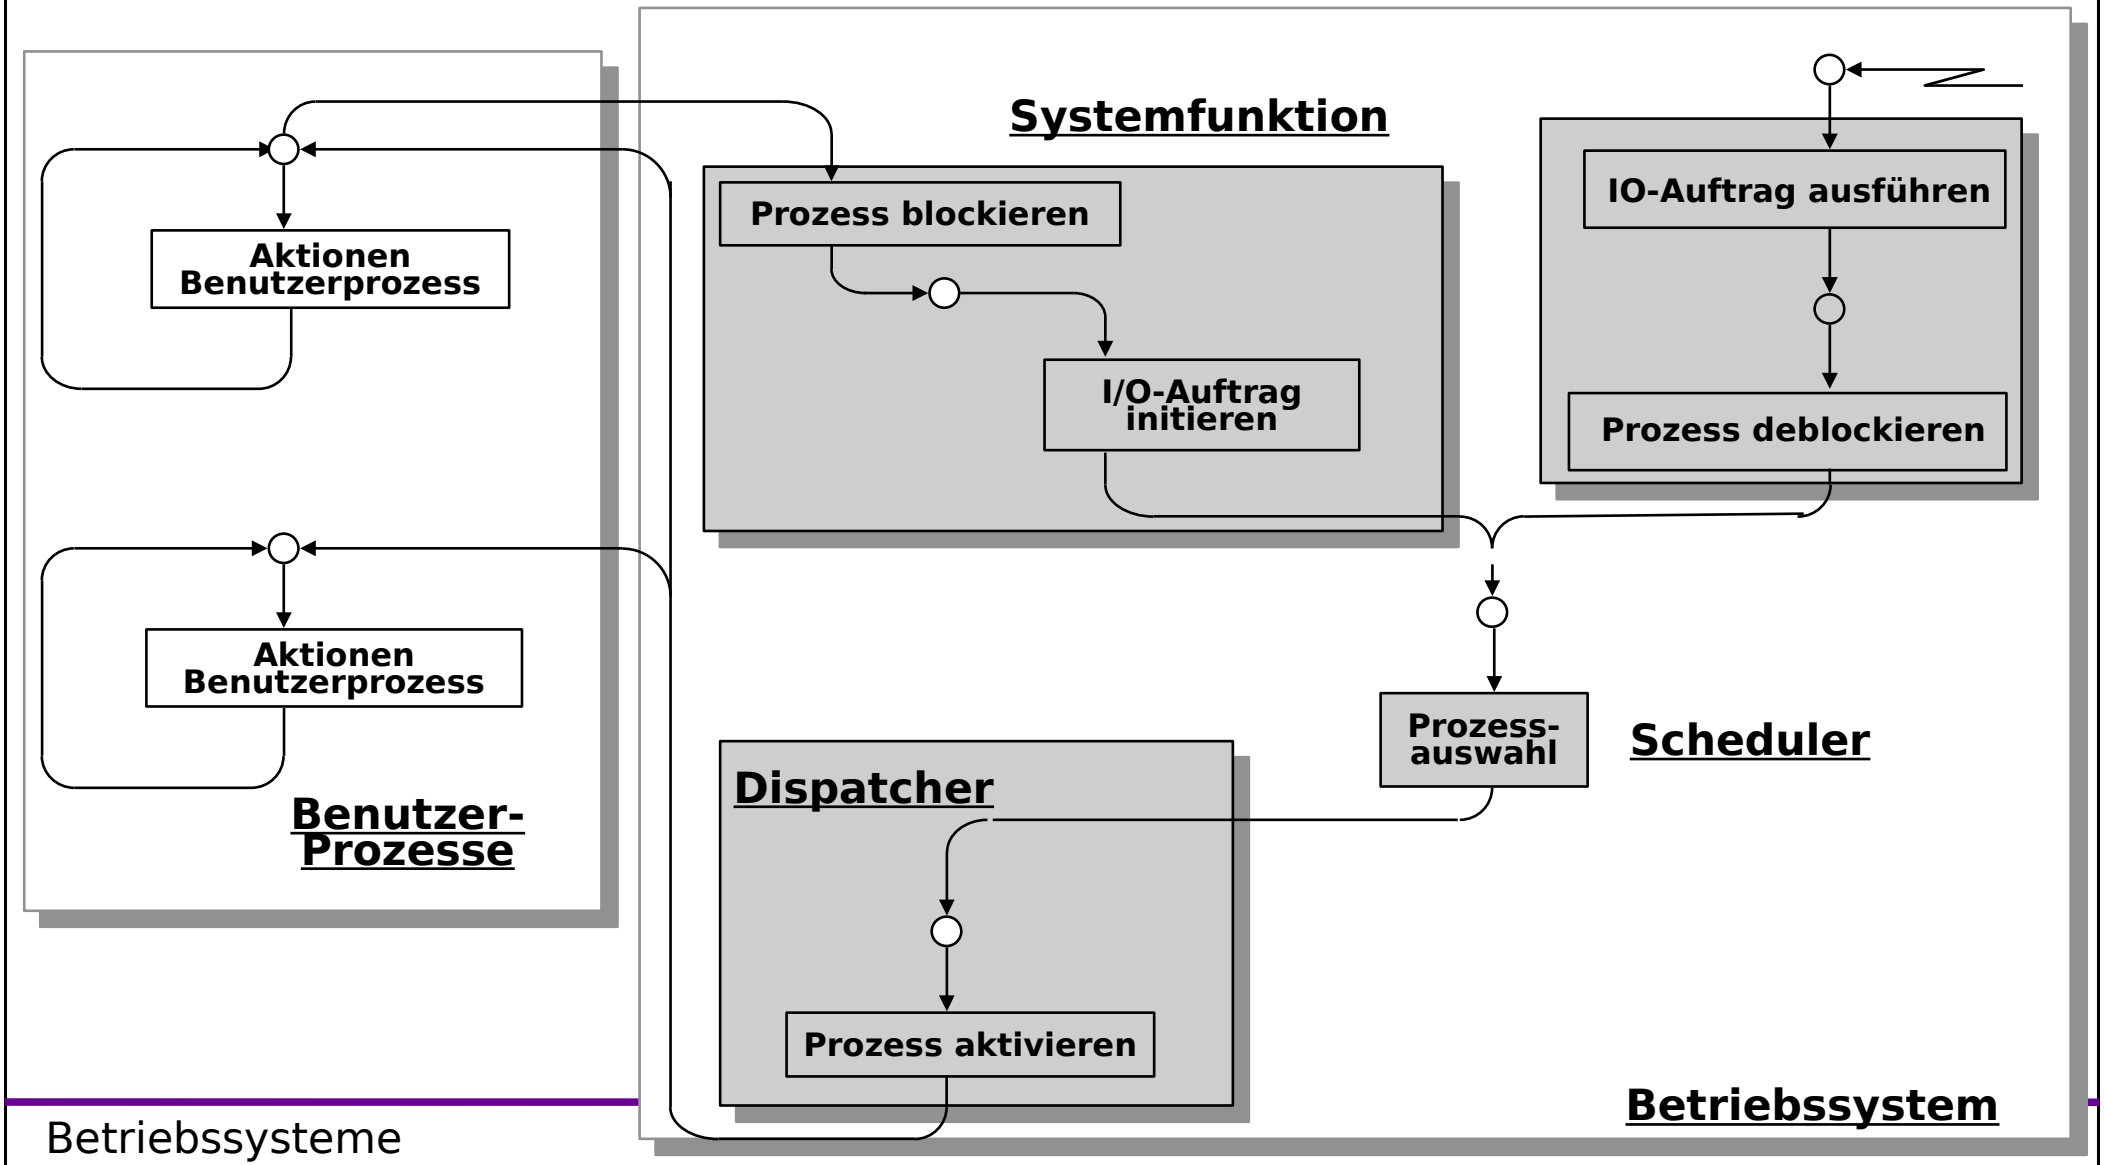

Multitasking
Prozesswechsel durch Zeitscheibe

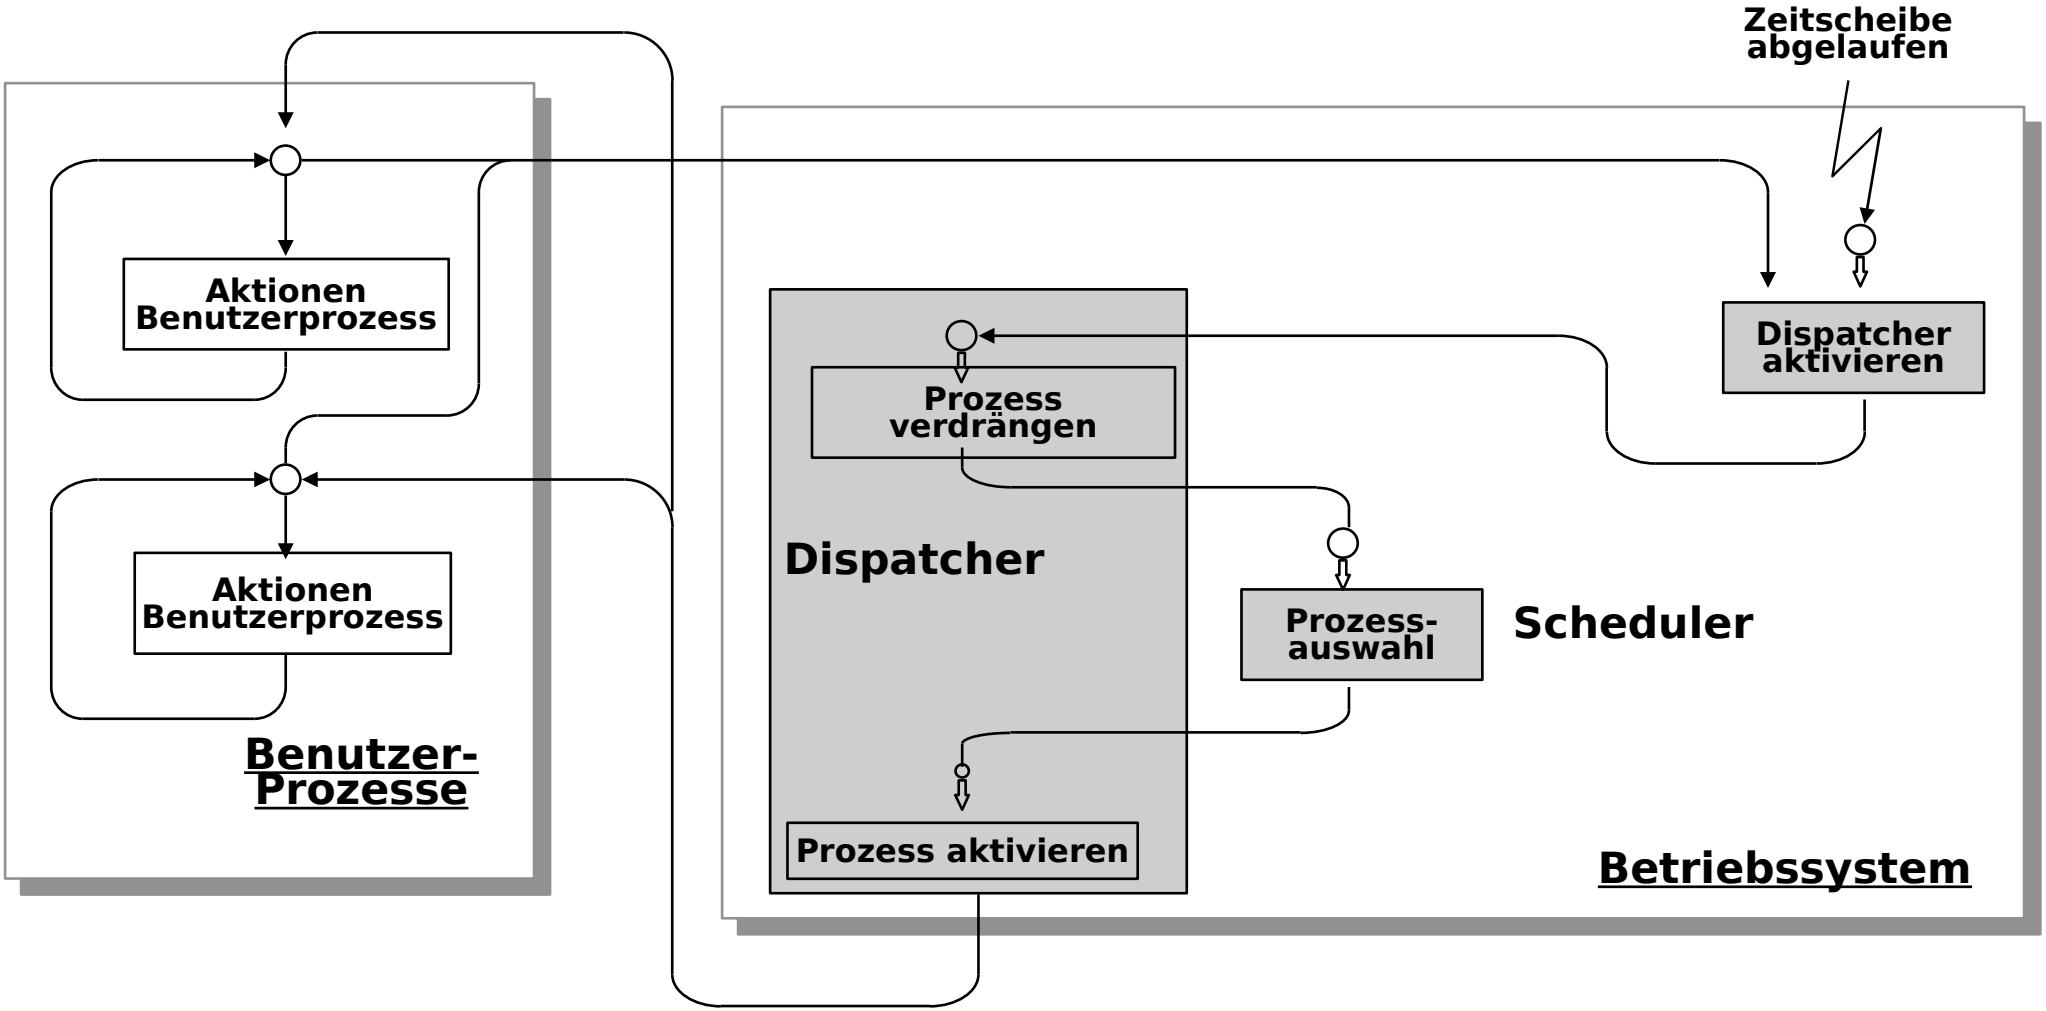

Ziele des Schedulings (Prozesse/Threads)

- Alle Systeme:
  - Fairness (jeder Prozess erhält Rechenzeit)
  - Policy Enforcement (Prioritäten einhalten)
  - Auslastung (alle Komponenten sind ausgelastet)
- Batch-Systeme
  - Durchsatz
  - Bearbeitungszeit/Verweilzeit
- Dialog-Systeme
  - Antwortzeit
- Echtzeitsysteme
  - Fristen einhalten (meeting deadlines)
  - Gleichförmiges, vorhersehbares Verhalten (predictable)

Scheduling für Batch-Systeme

First-Come First-Served (keine Unterbrechung)

- Vorteil:
  - einfach zu implementieren
- Nachteil:
  - evtl. schlechte Auslastung
  - evtl. schlechter Durchsatz

Shortest Job First (keine Unterbrechung)

- Laufzeit muss vorab bekannt sein

Shortest Remainig Time Next

- verbleibende Laufzeit muss bekannt sein

Scheduling für Echtzeitsysteme

- Prioritätsbasiertes Scheduling
- Raten Monotones Scheduling
  - Mehrere periodisch aktive Prozesse, jeder Prozess besitzt eine Intervalllänge.
  - Priorität ist umgekehrt proportional zur Intervalllänge
- Earliest Deadline First
  - Jeder Prozess gibt seine nächste Deadline an
  - Der Scheduler sortiert die Prozesse nach Deadline und führt sie entsprechend aus

Scheduling für Dialog-Systeme

Round-Robin

- Alle Prozesse bekommen der Reihe nach eine Zeitscheibe
- Kritische Größe: Länge der Zeitscheibe z.B. 4 - 100ms

Prioritätsbasiertes Scheduling

- der Prozess mit höchster Priorität läuft
  - evtl. nicht fair
- Laufen verringert Priorität (und oder)
- Warten erhöht Priorität

Scheduling für Dialog-Systeme (2)

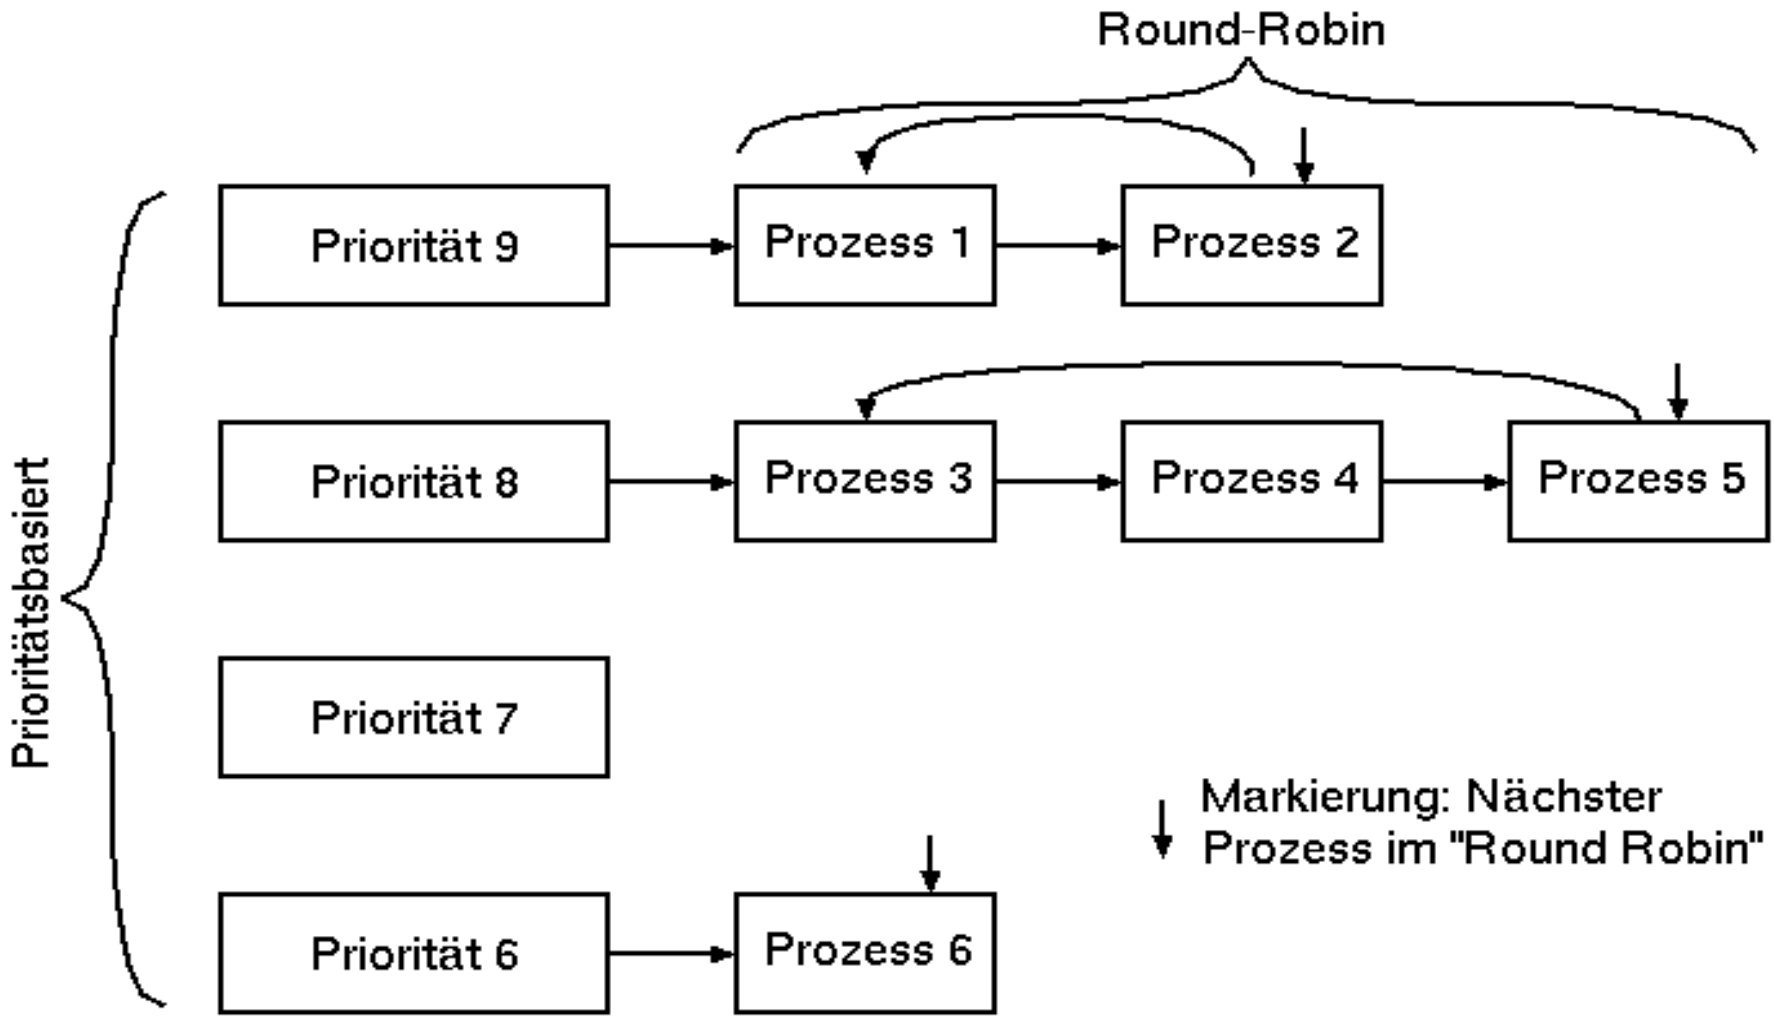

Scheduling für Dialog-Systeme (3)

Lottery-Scheduling

- Jeder Prozess bekommt „Lose“
- Scheduler wählt zufällig eine Losnummer
- Der Gewinner-Prozesse darf laufen

Die CPU-Zeit wird – im Mittel - gemäß der Anzahl der Lose verteilt.

Scheduling für Threads

User Level Threads

- Anwendung / Thread-Blibliothek übernimmt das Scheduling
- Algorithmus kann an die Anwendung angepasst werden

Kernel Threads

- Kernel übernimmt Scheduling
- Threads im bereits laufenden Prozess werden bevorzugt (kein Prozesswechsel)

Multithreading in Linux

- Unter Linux werden Threads durch einen Systemaufruf „clone()“ erzeugt
- User-API: PThread-Bibliothek
- Linux verwaltet Threads in verschiedenen Varianten
- Ein neuer Thread kann diverse Ressourcen des „Eltern-Threads“ verwenden.
  - Verzeichnisse
  - Datei-Deskriptoren
  - Signalhandler
  - PID
- Ein Thread kann auch ein neuer Prozess sein.

Scheduling Algorithmen

- Stapelverarbeitung
  - Minimierung der Prozesswechsel um einzelne Jobs mit schneller Geschwindigkeit abzuarbeiten
  - Maximaler Durchsatz (Jobs pro Zeiteinheit)
  - Non preemtive, preemptive mit langen Zuteilungszeiten
- Interaktion
  - Hinreichend schnelle Antwort auf Interaktionen des Benutzers
  - Fairness – jeder Benutzerprozess bekommt anteilig Rechenzeiten auf der CPU zugeteilt
  - Preemptive Scheduling notwendig – ein Prozess darf die CPU nicht für sich alleine belegen
- Echtzeit
  - Einhaltung von Fristen, ggf. Unterbrechungen für die Reaktion auf Ereignisse notwendig

Scheduling Feedback

- Kriterium zur Auswahl = momentan vergangene Rechenzeit eines Prozesses
- Preemptive: CPU wird dem Prozess nach einer Zeitscheibe durch das BS entzogen
- Jedem Prozess werden Prioritäten dynamisch vergeben. Es gibt n Prioritäten. Beim Start gelangt der Prozess in die Priorität 0. Nach Ablauf einer Zeitscheibe wird er auf die Priorität 1 gesetzt. Nach Ablauf von i Zeiteinheiten wird er auf die Priorität i gesetzt. Für jede Priorität existiert eine Warteschlange die nach dem Prinzip FCFS abgearbeitet wird.
- Die Warteschlange mit höchster Nummer hat die niedrigste Priorität. Diese wird nach dem Verfahren RR abgearbeitet.
- Nachteil: Prozesse mit hoher Rechenzeit können verhungern (starvation)

Scheduling Feedback

Beispiel

- Prozesse:
  A (RZ=20)
  B (RZ=3)
  C (RZ=5)
  D (RZ=10)
- Alle Prozesse starten alle zur gleichen zeit t0.
- ABCDABCDABCDACDACDADADADADADADAAAAAA

Scheduler in UNIX

- **Timesharing nach Round Robin**

  Ziel : **Optimieren der Antwortzeiten von interaktiven Prozessen**
  Zeitscheibe: **ca. 4ms - 100ms**

- **Zuteilung der CPU nach Prioritäten**

Die Priorität eines Prozesses wird dynamisch entsprechend seiner Aktiviäten verändert. Rechneintensive Prozesse werden bestraft. Interaktive Prozesse werden belohnt.

Auslastung der CPU durch den Prozeß: a
Der Wert von a wird mit jedem Zeittakt um 1 erhöht. Nach jeder Sekunde werden die Prioritäten neu berechnet

a:= a/2
Priorität:= Basispriorität +a/Konstante +Nice-Wert

Round Robin innerhalb einer Prioritätenschlange

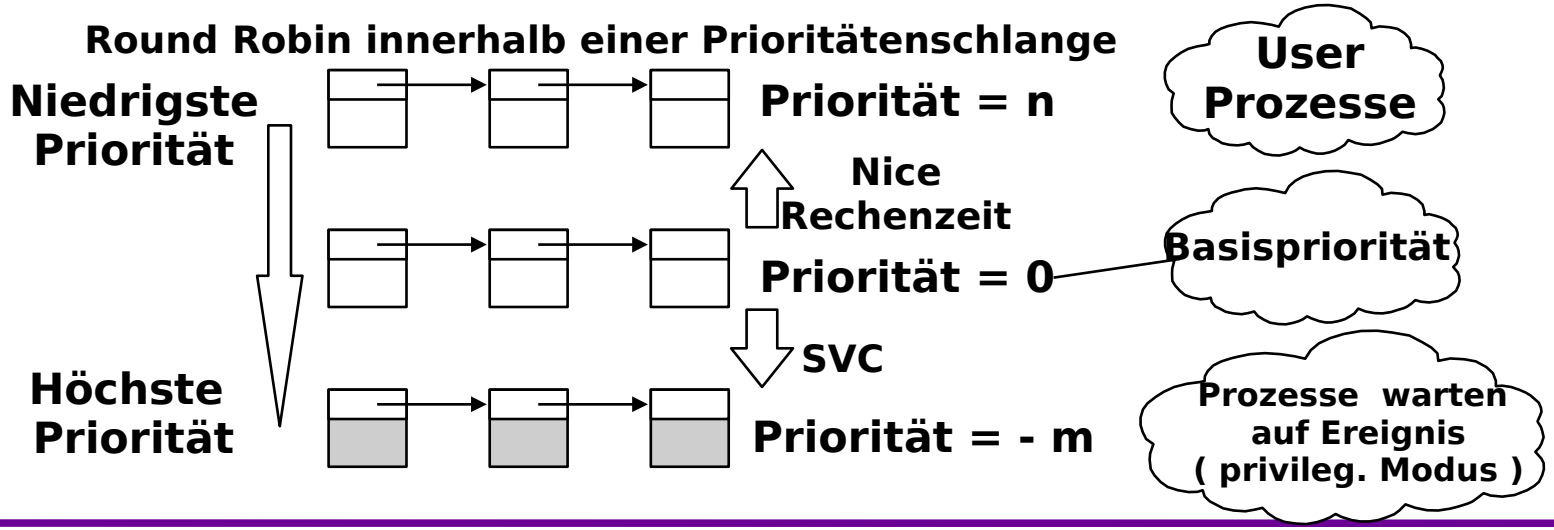

Scheduler in Linux

Die Priorität eines Prozesses wird einmal pro Sekunde neu berechnet.

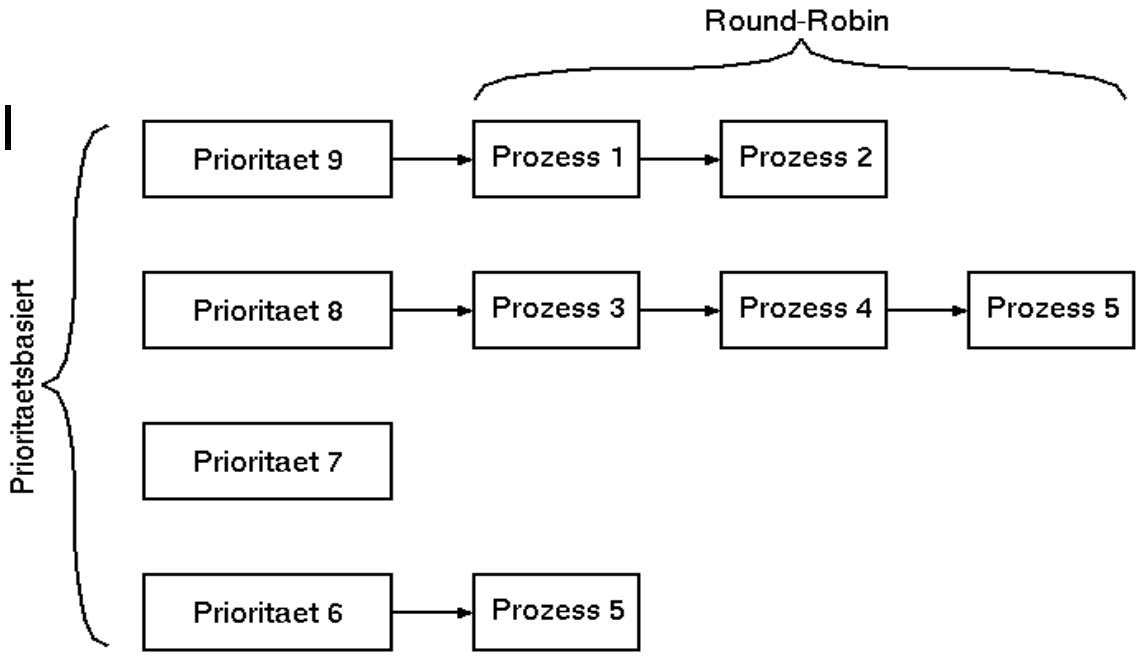

Priorität = f(BasisPriorität, nice-Wert, CPU-Nutzung)

Prozesse, die im Kernel-Mode warten, erhalten eine höhere Priorität. Diese hängt davon ab, auf welches Ereignis sie warten.

Prozesse in Windows NT / 2000

- Zwischen Prozessen besteht keine Eltern-Kind-Beziehung.
- Objektorientierte Implementierung d.h. für jeden Prozess wird ein Systemobjekt angelegt, in dem die Eigenschaften des aktuellen Prozesses gespeichert sind.
- Das Scheduling erfolgt nur über Threads. Damit muß ein Prozess mindestens einen Thread besitzen, damit er lauffähig ist.
- Ein Prozess kann über die Systemfunktion CreateProcess() dynamische zur Laufzeit mehrere Prozesse erzeugen.

Objektklasse Prozess in Windows NT

Objektklasse PROZESS	
Process ID **Access token** **Base priority** **Default processor affinity** **Quota limits** **Execution time** **I/O counters** **VM operation counters** **Execution/debugging ports** **Exit status**	**Objektattribute**
Create process **Open process** **Query process information** **Set process information** **Current process** **Terminate process** **Allocate/free virtual memory** **Read/write virtual memory** **Protect virtual memory** **Lock/unlock virtual memory** **Query virtual memory** **Flush virtual memory**	**Objektmethoden**

Prozesse in Windows NT / 2000

Eigenschaften eines Prozesses

- **Process ID:** Eine eindeutige Nummer, die NT für jeden erzeugten Prozess vergibt, um damit den Prozess eindeutig identifizieren zu können
- **Access token:** Eine Referenz auf ein NT-Objekt, in dem Sicherheits- und Zugriffsinformationen über den eingeloggten Benutzer, zu dem der Prozess gehört, abgelegt sind.
- **Base priority:** Eine Basispriorität für den Prozess. Beim starten des Prozesses wird die Priorität auf diese Basispriorität gesetzt.
- **Default processor affinity:** Eine vorgegebene Menge von Prozessoren, auf denen die Threads eines Prozesses laufen können.
- **Quota limits:** Maximalwerte für die Anzahl von physikalischen Seiten, Größe der Paging-Datei, und Rechenzeit
- **Execution time:** Die aktuell von allen Threads verbrauchte Rechenzeit
- **I/O counters:** Zähler für die Anzahl der I/O Operationen
- **VM operation counters:** Zähler für die ausgeführten Speicheroperationen
- **Exit status:** Ein Wert, der den Grund für ein Prozessende beschreibt.

Prozesse in Windows NT / 2000

- Methoden
  - Prozesserzeugung CreateProcess()
  - Auf das Ende eines Prozesses warten WaitForSingleObject()
  - Abfrage von Prozessinformationen
  - Einstellen von Prozessinformationen
  - Prozessterminierung (freiwillig) ExitProcess()
  - Prozessterminierung (unfreiwillig) TerminateProcess()

Scheduler in Windows NT

- **Variable Prioritäten**
  - Die Prioritäten 1..15 werden zur Laufzeit vom Kernel verändert mit dem Ziel interaktive Prozesse mit hoher Priorität, I/O-intensive Threads mit mittlerer Priorität und rechenintensive Prozesse mit niedriger Priorität zu behandeln.
  - Die Priorität wird erhöht, wenn ein Prozess vom Zustand „wartend“ in den Zustand „bereit“ gelangt
  - Die Priorität wird erniedrigt, wenn ein Thread nach Ablauf einer Zeitscheibe unterbrochen wird.
  - Die Priorität wird minimal zur Basispriorität und maximal auf 15 verändert.
  - Realzeitprioritäten (16 .. 31) werden nicht vom System geändert.
- **Ein Thread erbt die Basispriorität vom Prozess**
  -
  -
  - Ein Thread kann die vererbte Basispriorität um maximal 2 nach oben oder nach unten verändern
  -
  -

- Preemptives Zeit- und Prioritätengesteuertes Scheduling

Multithreading Windows NT/2000

- Threads werden als Kernel-Threads realisiert
- Ein Prozess kann mehrere Threads besitzen
- Scheduling in NT/2000 erfolgt ausschließlich über Threads, d.h. in Prozess besteht aus mindestens einem Thread.
- Ein Thread kann selbst wieder Threads erzeugen.
- Eigenschaften eines Thread sind:
  - eine eindeutige Kennung (Thread-ID)
  - Thread-Kontext (Prozessorregister, PC, Stack, Stackzeiger)
  - Basispriorität und dynamische Priorität
  - Prozessoraffinität (Prozessoren/Kerne auf der dieser Thread ausgeführt werden kann)
  - Ausführungzeit (Rechenzeit)
  - Terminierungsstatus

Threadzustände Windows NT/2000

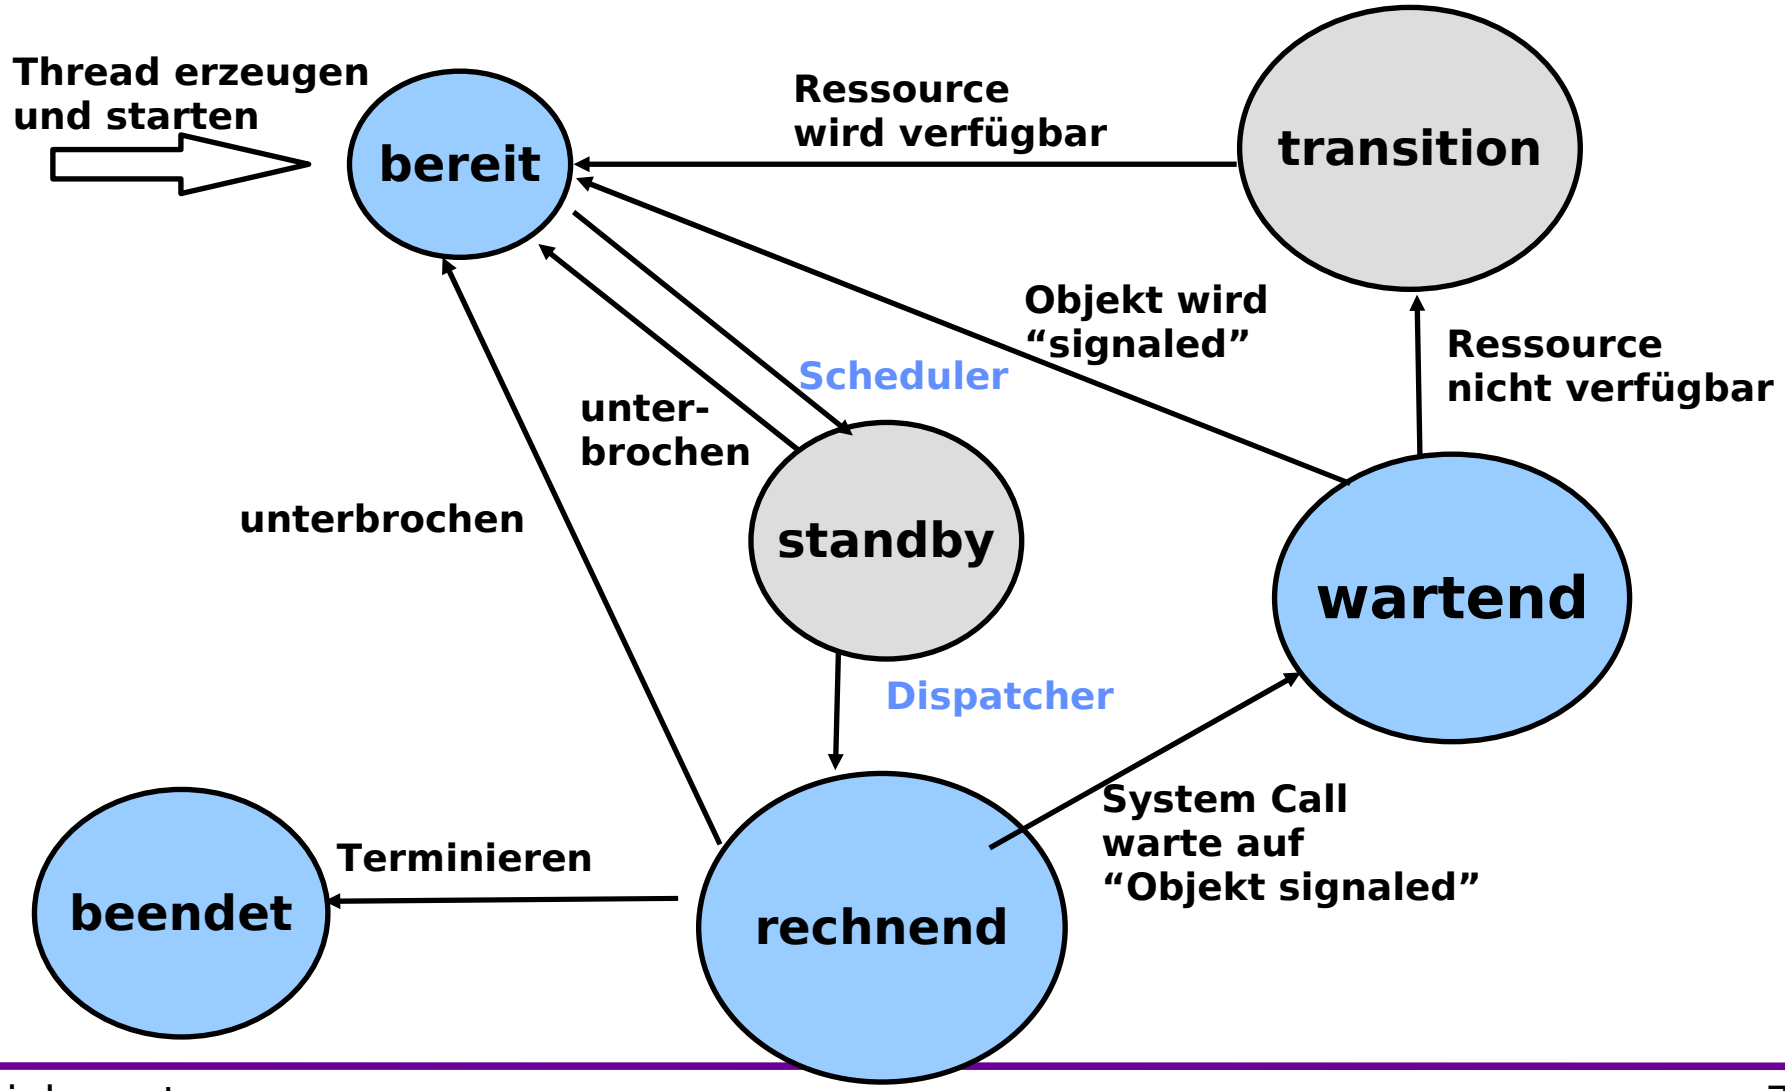

Threadzustände Windows 2000

- Bereit: Kann vom Scheduler eingeplant werden
- Rechnend (aktiv): Ist gerade auf einem Prozessor rechnend
- Standby: Wurde vom Scheduler ausgewählt muss aber noch auf einen bestimmten Prozessor warten. Die Abarbeitung erfolgt sobald der Prozessor frei wird.
- Wartend/blockiert: Wartet auf Ereignis, auf I/O, auf Systemobjekte oder freiwillig ohne Grund
- Transition: Grund der Blockierung ist aufgehoben kann jedoch nicht abgearbeitet werden da noch Ressourcen z.B. Speicher fehlen.
- Beendet (Terminiert): Hat sich selbst beendet oder wurde von einem anderen Thread bzw. Prozess beendet

Dynamische Speicheranforderung

- Prozesse können zur Laufzeit dynamisch Speicherblöcke anfordern bzw. freigeben
  - Beispiel: Aufbau einer verketteten Liste, Bäume, Funktionen : malloc(), free() in C, new in C++, Java
- Realisierung durch Speicherverwaltung

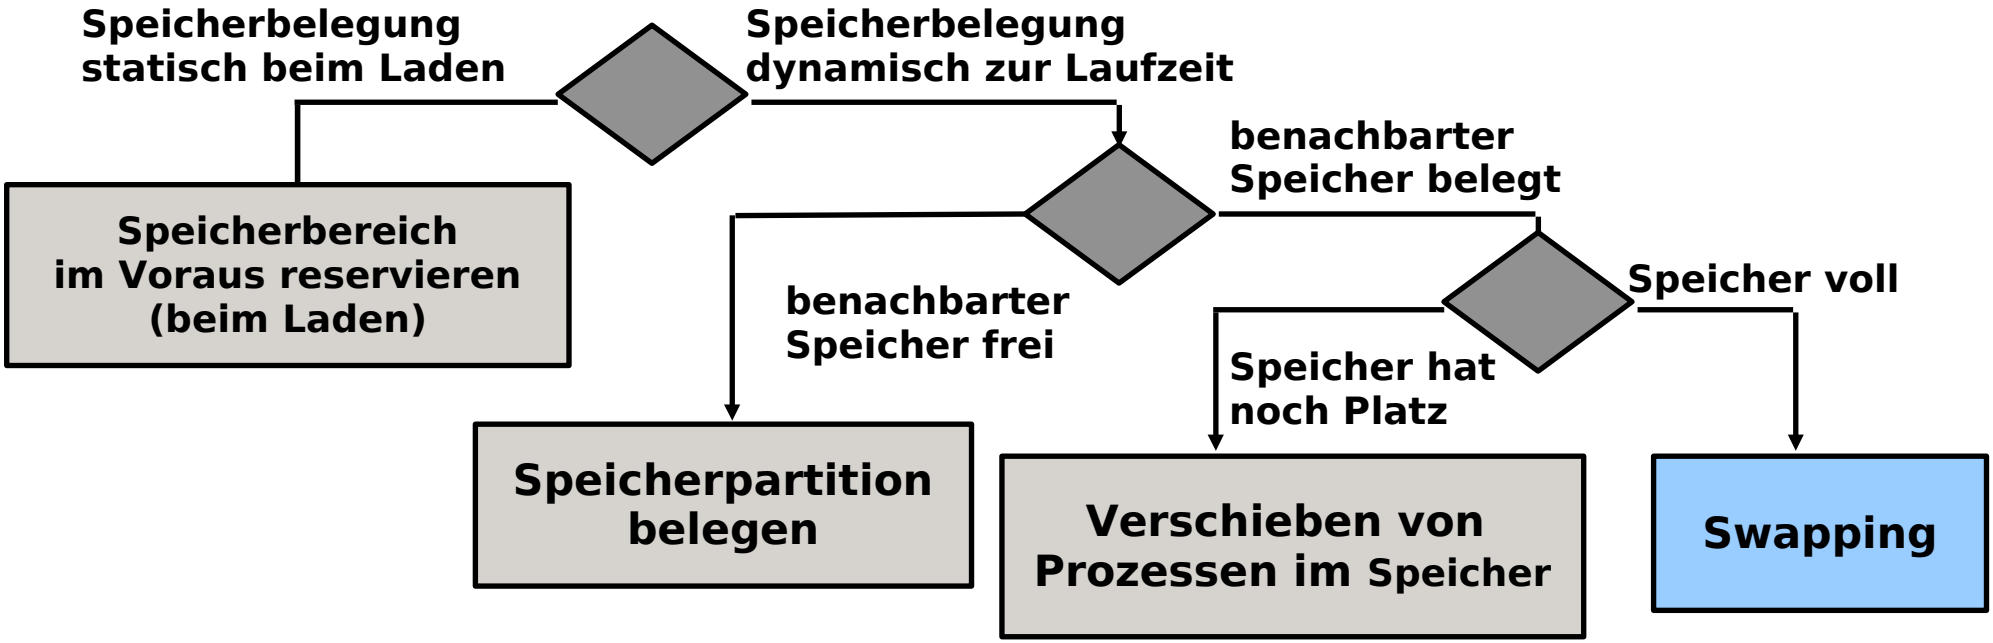

Verwaltung mit Bitliste

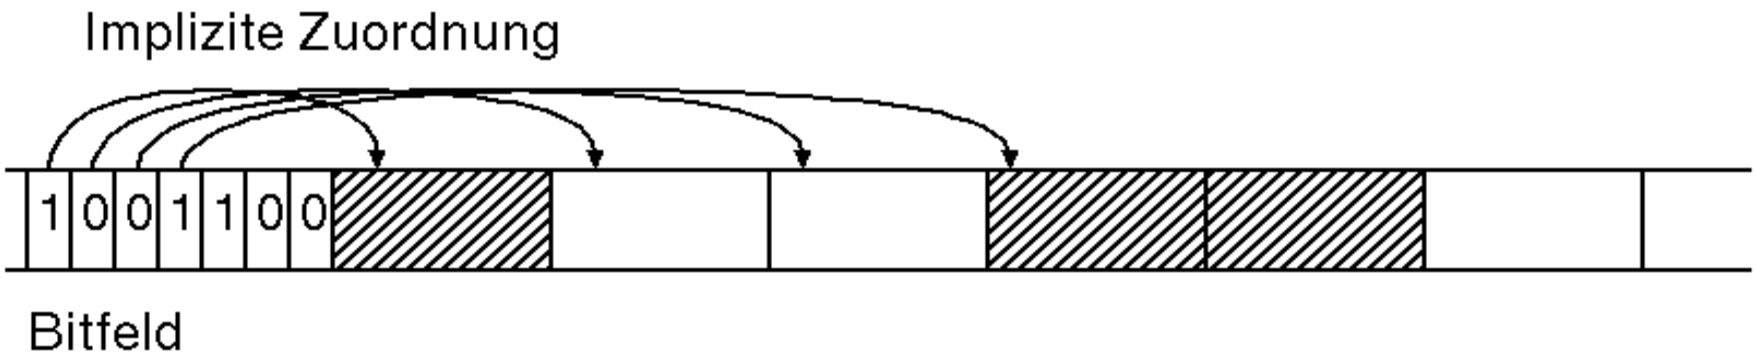

- Der Speicher wird in Blöcke fester Länge eingeteilt
  z.B. 4 Byte, 8 Byte bis wenige KB.
- Jedem Speicherblock ist ein Bit in einer Bitliste zugeordnet.
- Das Bit gibt an, ob der Block gerade frei oder belegt.
- Speicherblöcke können also nur als Ganzes belegt oder freigegeben werden.

Verwaltung mit Listen

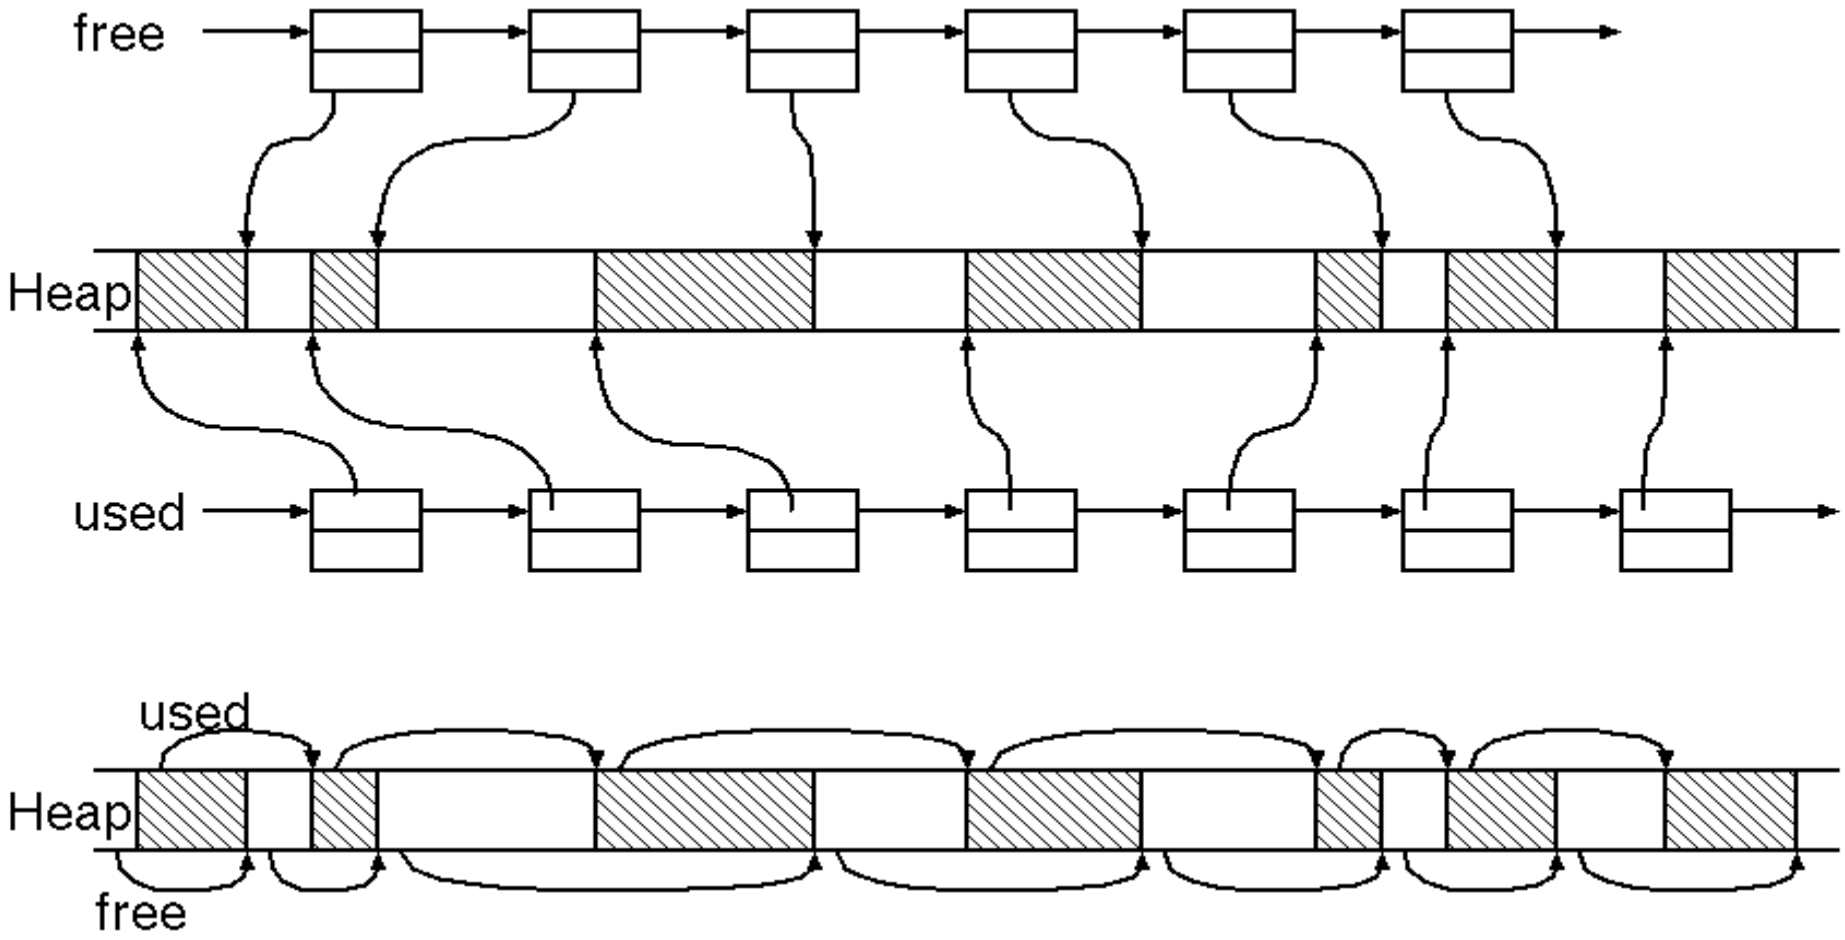

Heap-Speicher Strategien

- First-Fit
  Der Speicher wird in die erste Lücke, die groß genug ist, gelegt.

- Next-Fit
  Der Speicher wird in die nächste Lücke, die groß genug ist, gelegt.

- Best-Fit
  Der Speicher wird in die kleinste Lücke, die die groß genug ist, gelegt.

- Worst-Fit
  Der Speicher wird in die größte Lücke gelegt.

Buddy-Verfahren

- n Listen mit Speicherblöcken gleicher Größe (ggf. Baum mit Listen)
- Liste 0 enthält die größten Speicherstücke
- Jede weitere Liste enthält jeweils halb so große Stücke, wie die vorherige Liste.

Anfrage nach einem Stück Speicher der Größe X

1)Suche in Liste mit passender Größe ggf. fertig.

2)Bei Misserfolg: Suche nach größerem Stück, Stück teilen, Teil 1 allokieren, Teil 2 neu einsortieren

Buddy-Verfahren

Freigabe eines Stücks

- Speicherstück in Freispeicherliste der entsprechenden Größe einordnen
- Wenn ein benachbartes Stück ebenfall frei ist, so werden die beiden Stücke zusammegefasst und in die übergeordnete Liste eingefügt.

Linux zwei Mechanismen:

- Buddy-Verfahren
- Slab-Allocator
  (häufig benutzte Größen werden gecached)

Speicher-Hierarchie

- Cache-Speicher, Größe: n
  - schnell
  - teuer
  - flüchtig
- CMOS RAM Hauptspeicher, Größe: ca. 1000*n
  - mittelschnell
  - mittelteuer
  - flüchtig (noch)
- Festplatten, SSD Größe: ca. 1 000 000*n
  - langsam
  - günstig
  - persistent

Hauptspeicherverwaltung

- Arbeitsspeicher muss auf mehrere Prozesse aufgeteilt werden
  - Dynamisches Einlagern und Auslagern von Prozessen
  - Verschieben von Prozessen zur Laufzeit (**relocation**)
  - Zugriffsschutz

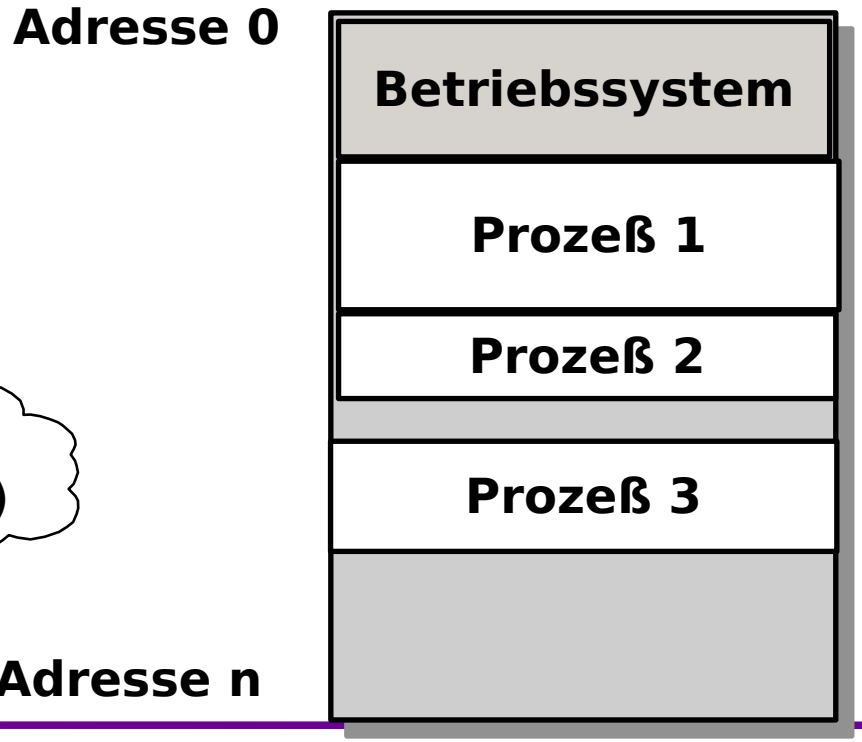

Speicherpartitionierung

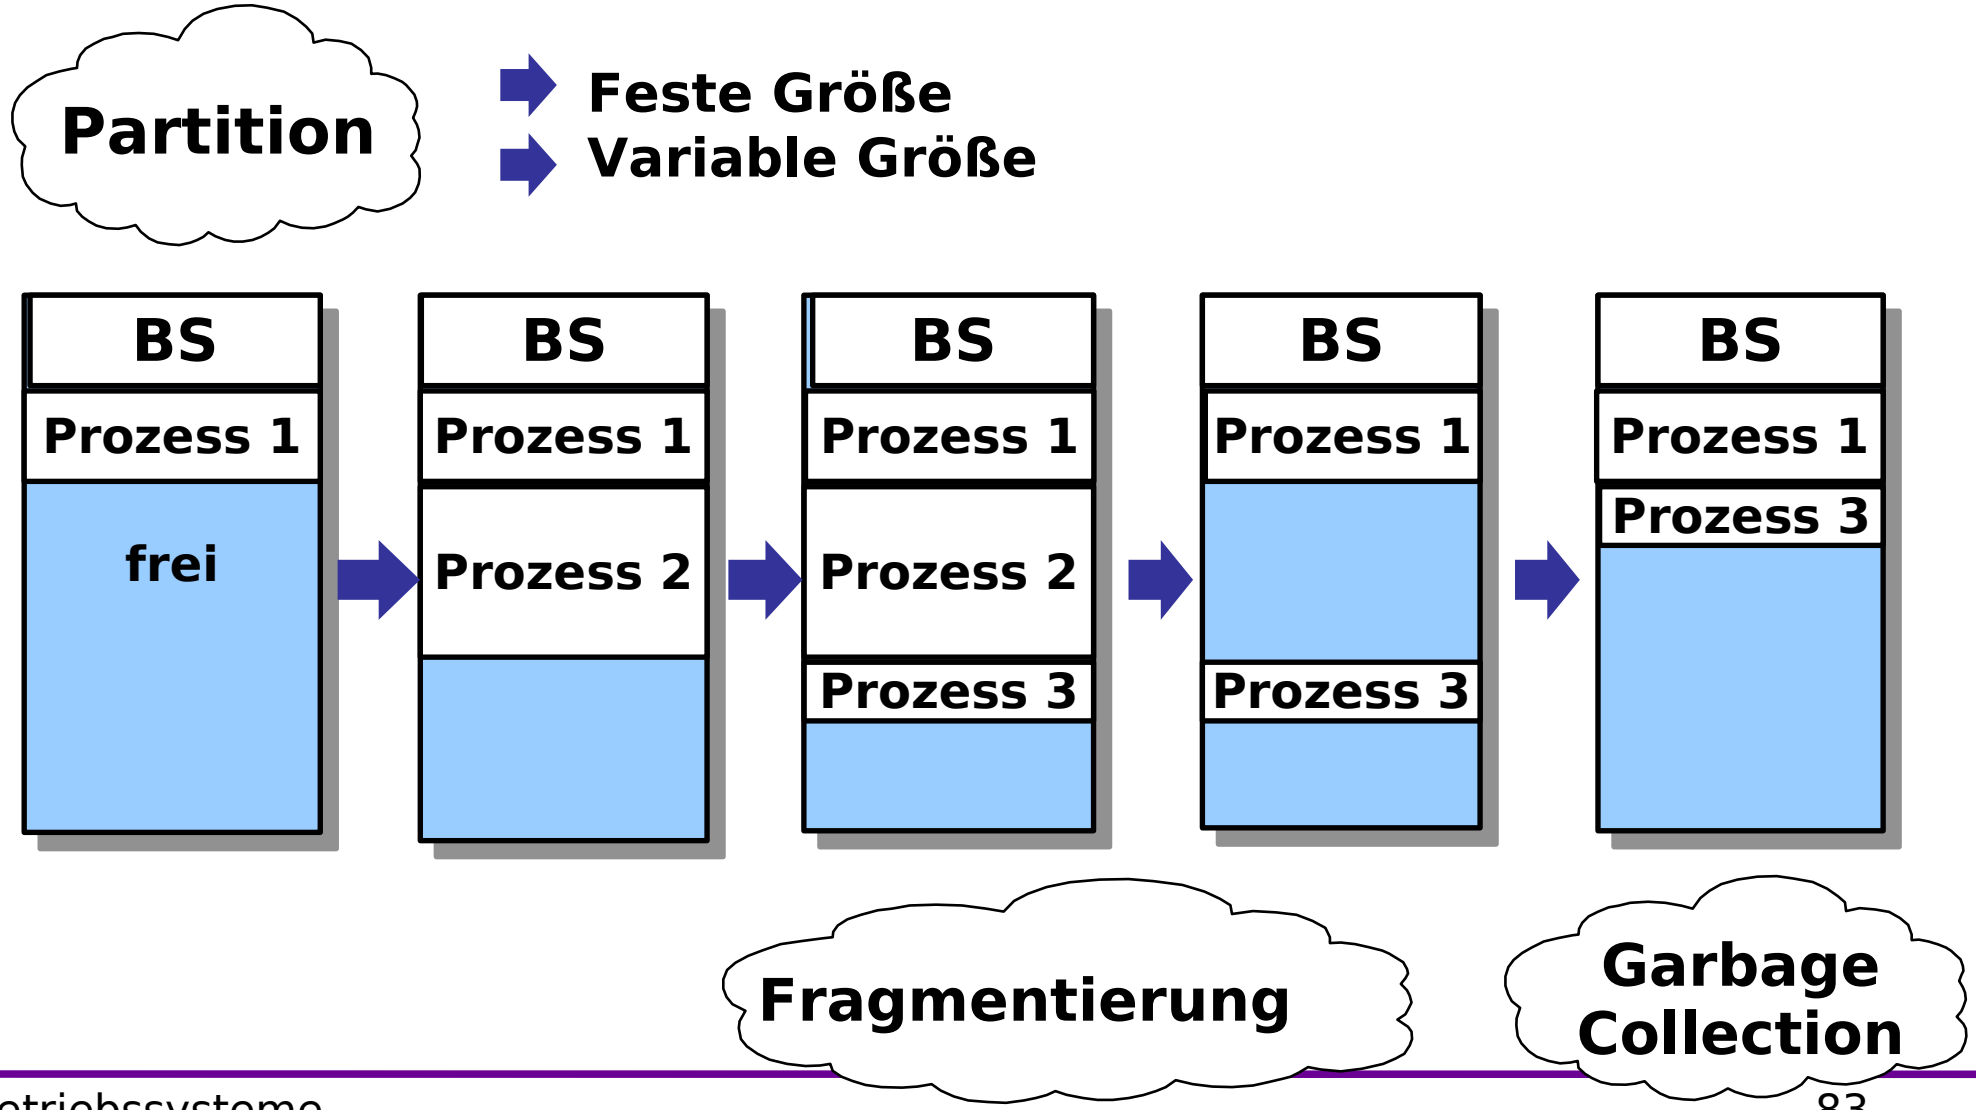

Abbildung von Segmenten

Jeder Prozess erhält ein oder mehrere Segment(e).

Jedes Segment bildet einen Adressraum, beginnend bei der Adresse 0

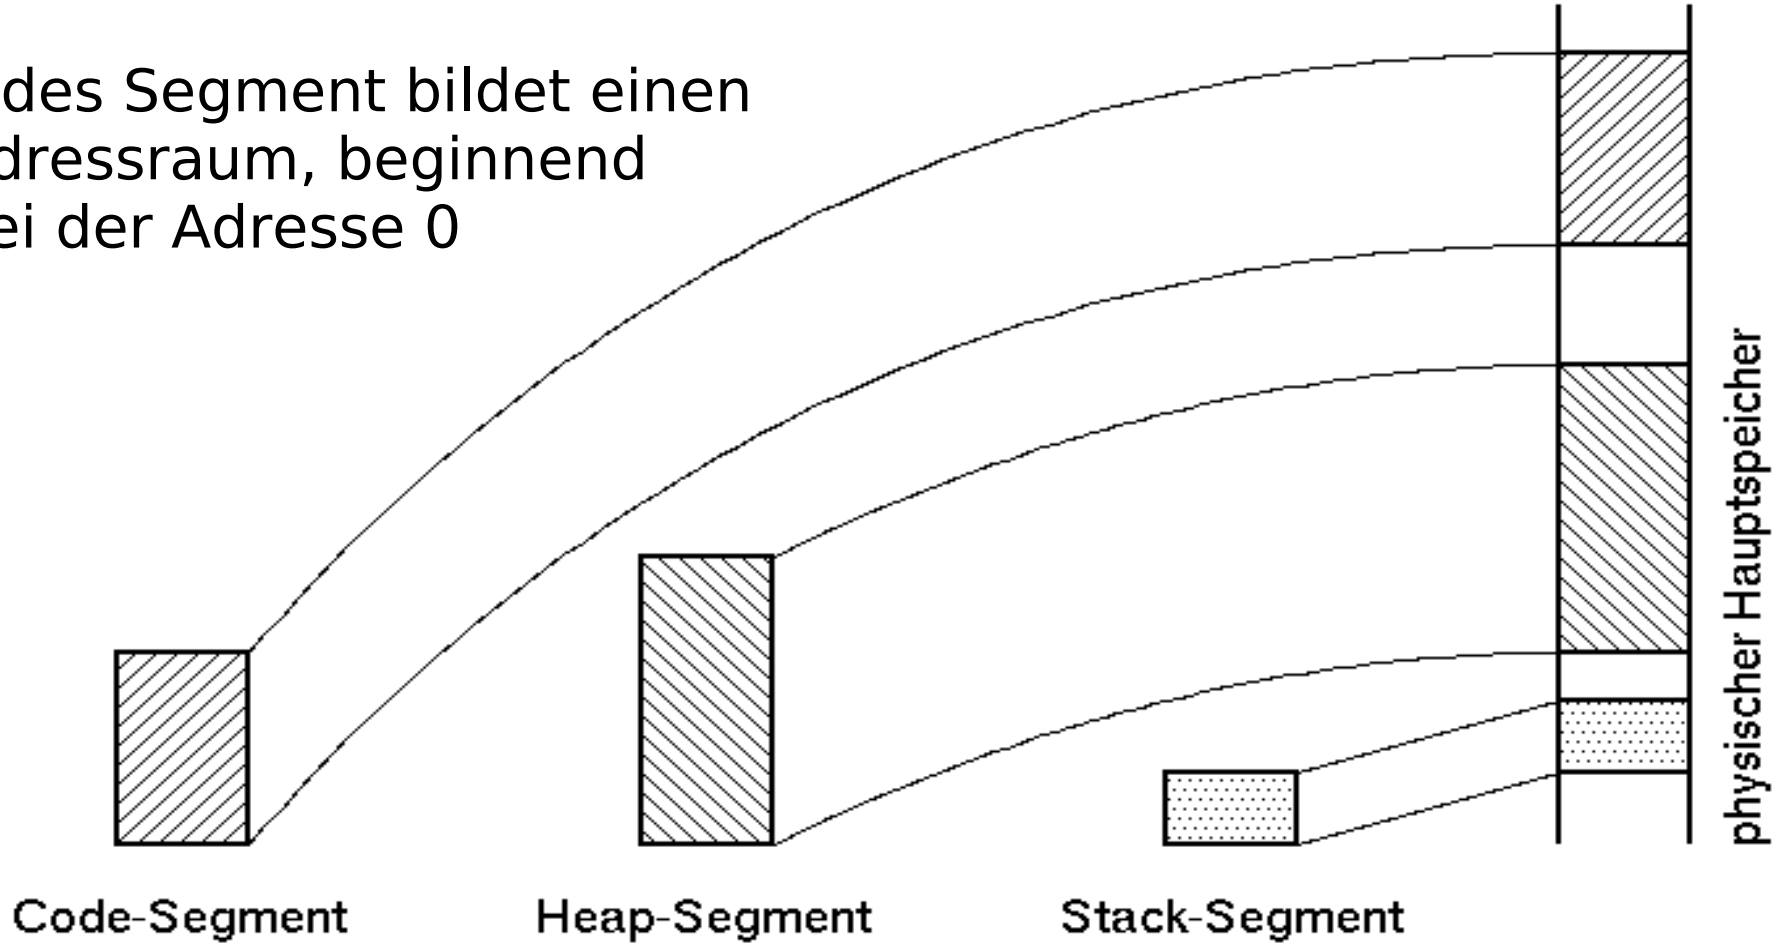

Adressierung bei Segmentierung

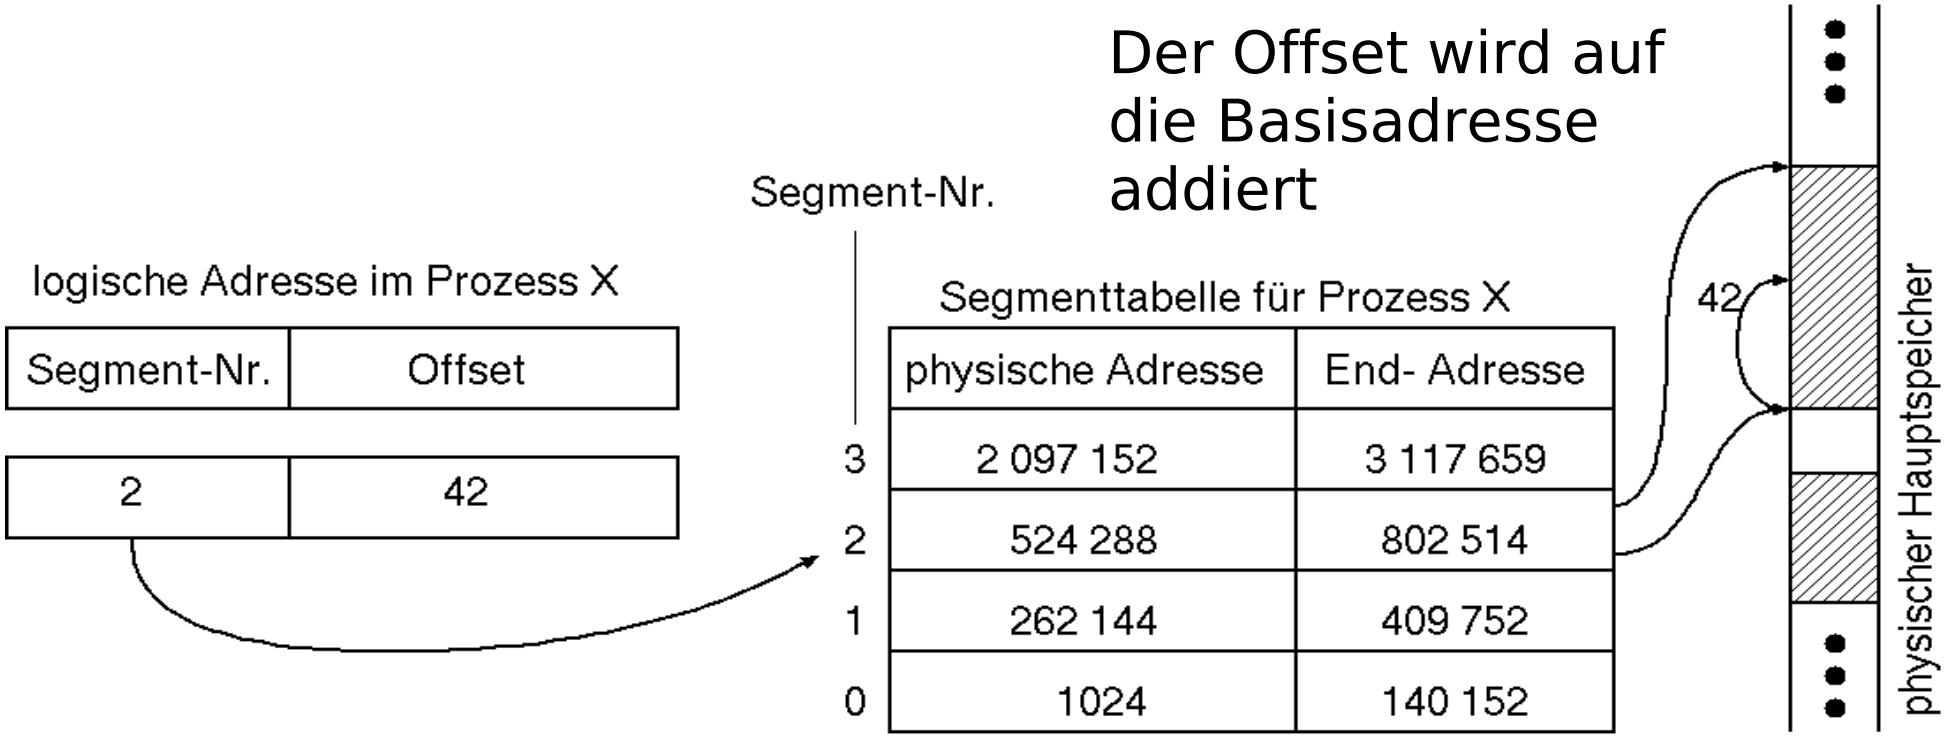

In der Segmenttabelle steht i.A. auch ein Zeiger auf das Ende des Segments. Damit können unzulässige Speicherzugriffe entdeckt und verhindert werden.

Verwaltung der Segmentinformation

- Die Segmentnummer und der der Offset werden vom Compiler festgelegt.
- Die Segment-Basisadresse, und die Segment-Endadresse werden vom Betriebssystem festgelegt. Beide Größen können zur Laufzeit geändert werden.
- Weitere Attribute eines Segments:
  - Zugriffsrechte (lesen, schreiben, ausführen)
  - verschiebbar
  - auslagerbar
  - sharable

Shared Segments

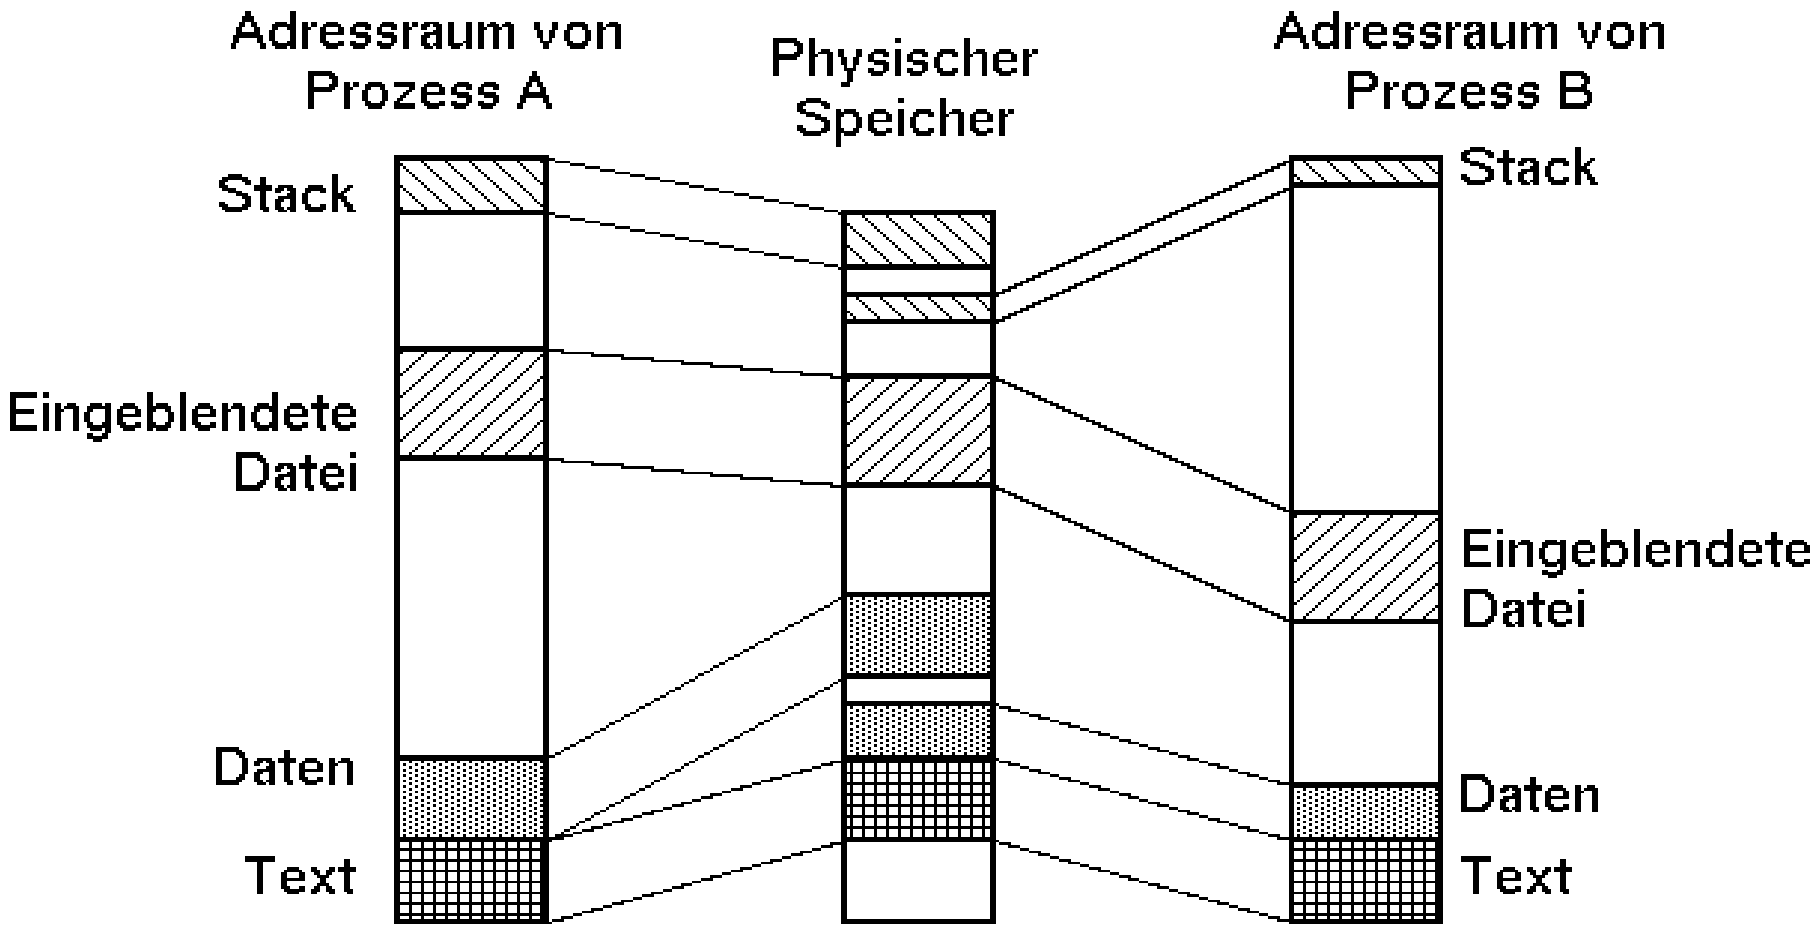

Shared Segments (2)

Gemeinsame Nutzung von Segmenten

- Text:
  Wird ein Programm mehr als einmal gestartet, so genügt ein Text-Segment für alle Prozesse. (Globale und static Variable getrennt halten.)
- Bibliotheken:
  Benutzen verschiedene Programme dieselbe Bibliothek, so kann diese in einem gemeinsamen Segment gehalten werden. (Code muss reentrant sein.)
- Eingeblendete Dateien
- Shared Memory

Segmentierung

- Einteilung nach Eigenschaften:
  - shared/exclusive
  - variable/konstante Größe
  - evtl. Zugriffsrechte, . . .
- Segmentierung schon in der Executable-Datei

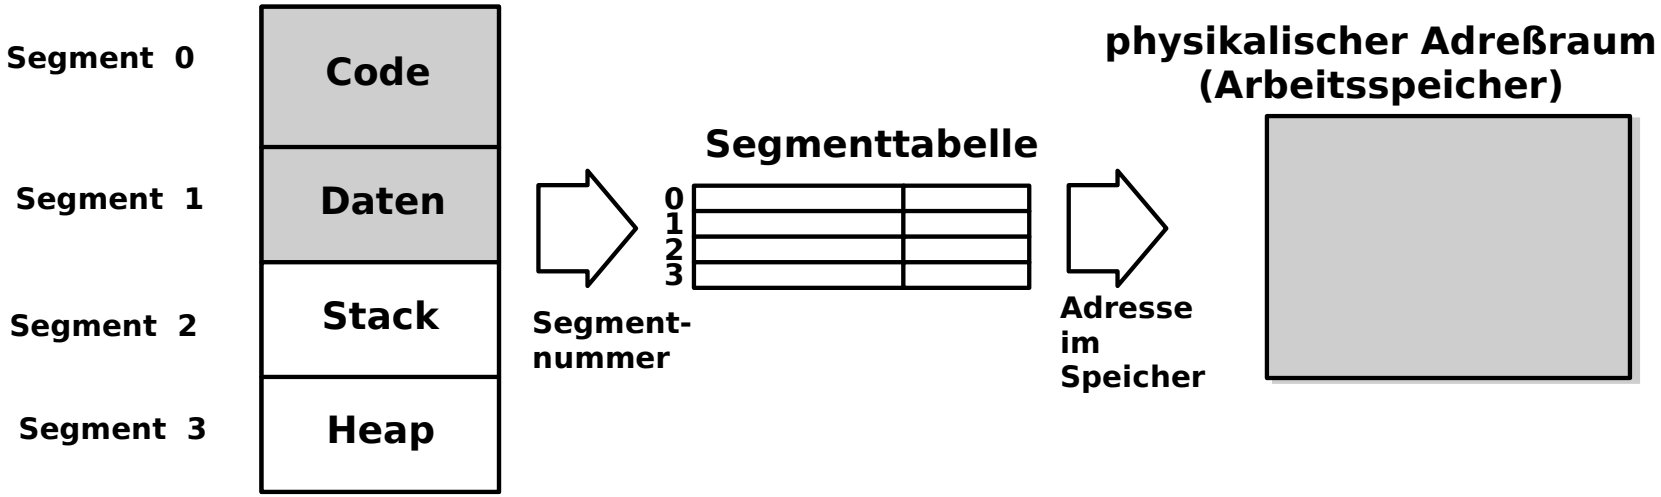

Segmentierung

- **Adressumrechnung**

Logische Adresse

Segmentnummer	Offset

Physikalische Adresse

Basisadresse + Offset

- **Eintrag einer Segmenttabelle**

Anfangsadresse	Größe des Segments	Attribute

- **Attribute eines Segments**
  - **Zugriffsrechte (lesen, schreiben, ausführen)**
  - **verschiebbar**
  - **auslagerbar**
  - **sharable**

- **Compiler und/oder die CPU muss Segmentierung unterstützen**

Paging

- Der physische Hauptspeicher wird in Kacheln/Rahmen gleicher Größe aufgeteilt.
- Der virtuelle Speicher der Prozesse ist in Seiten dieser Größe aufgeteilt.
- Eine virtuelle Adresse besteht aus Seitennummer und Offset.
- Eine virtuelle Seite kann in eine beliebige (freie) Kachel eingelagert werden.
- Bei jedem Speicherzugriff wird die Seitennummer der virtuellen Adresse auf eine Kachelnummer abgebildet.

Paging Größen und Umrechnung

- Eine virtuelle Adresse besteht aus n Bit Seiten-Nr. und k Bit Offset.
- Größe einer Seite und damit Größe einer Kachel: 2^k Speicherworte bzw. Byte.
- Die letzten k Bit der Seiten-Adresse sind immer 0.
- Um auf eine Speicheradresse zuzugreifen, wird die Seitennummer durch die Kachelnummer ersetzt.
- Der Offset wird in die letzten k Bit eingeblendet.
- Seiten können auf die Festplatte ausgelagert werden.

Umrechnung: Seite → Kachel

Die Seitentabelle muss jeder Seitennummer eine Adresse (Kachelnummer) zuordnen

- Eine Tabelle mit 2^n Einträgen
- Ein Baum aus mehreren Tabellen (Digitalbaum)
- Eine kürzere Tabelle, z.B. mit einem Eintrag je Kachel (invertierte Liste)

Zweistufiges Paging

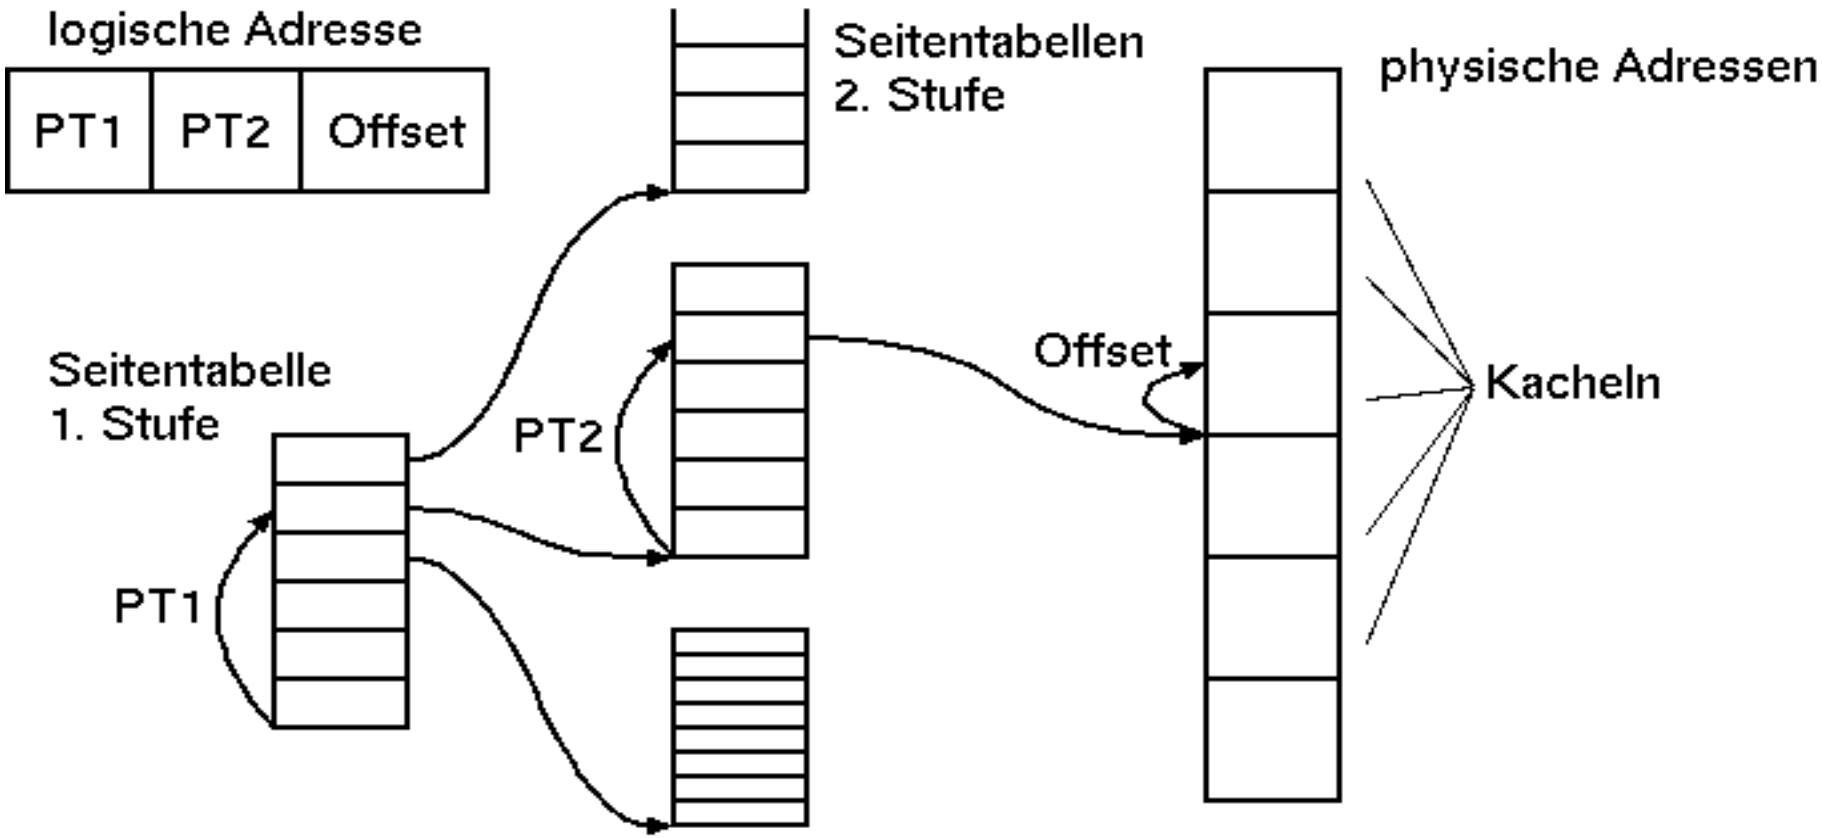

Invertierte Liste

Aus der Seitennummer wird ein Hash-Wert errechnet. Dieser Hash-Wert ist dann der Index in die invertierte Liste.

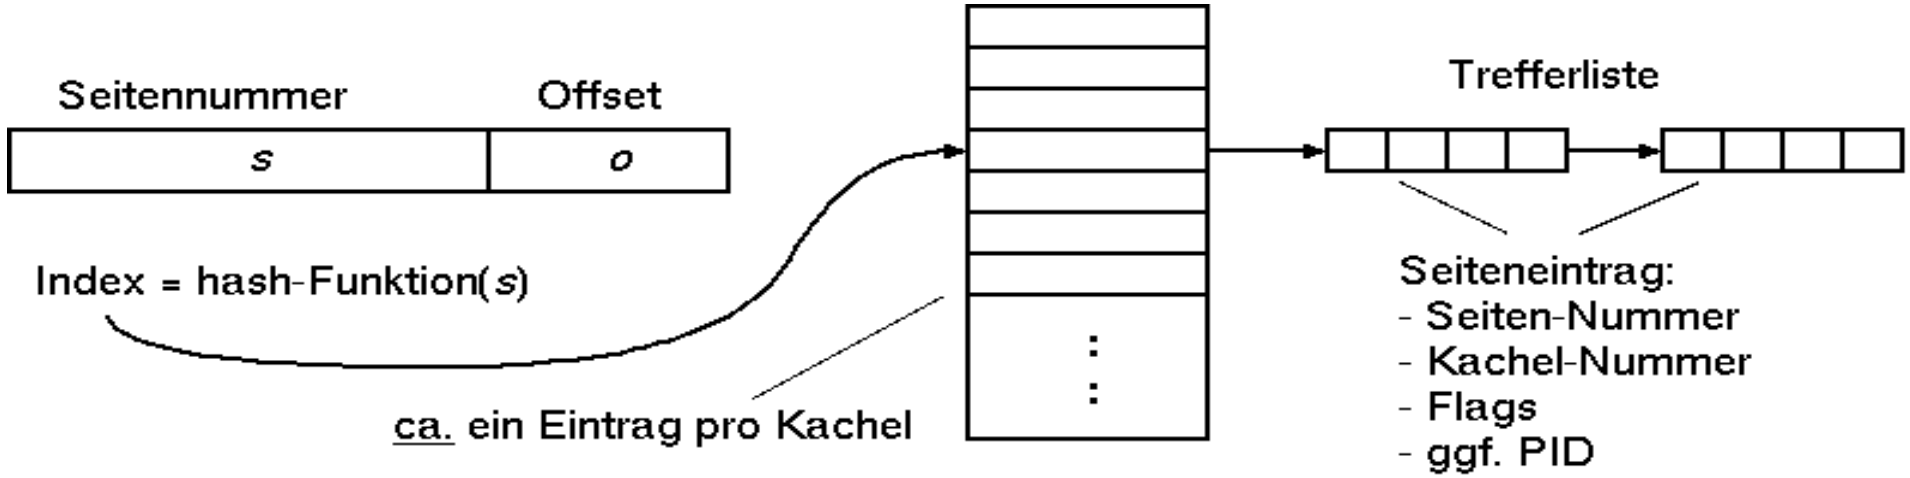

Beispiel für eine Hash-Funktion

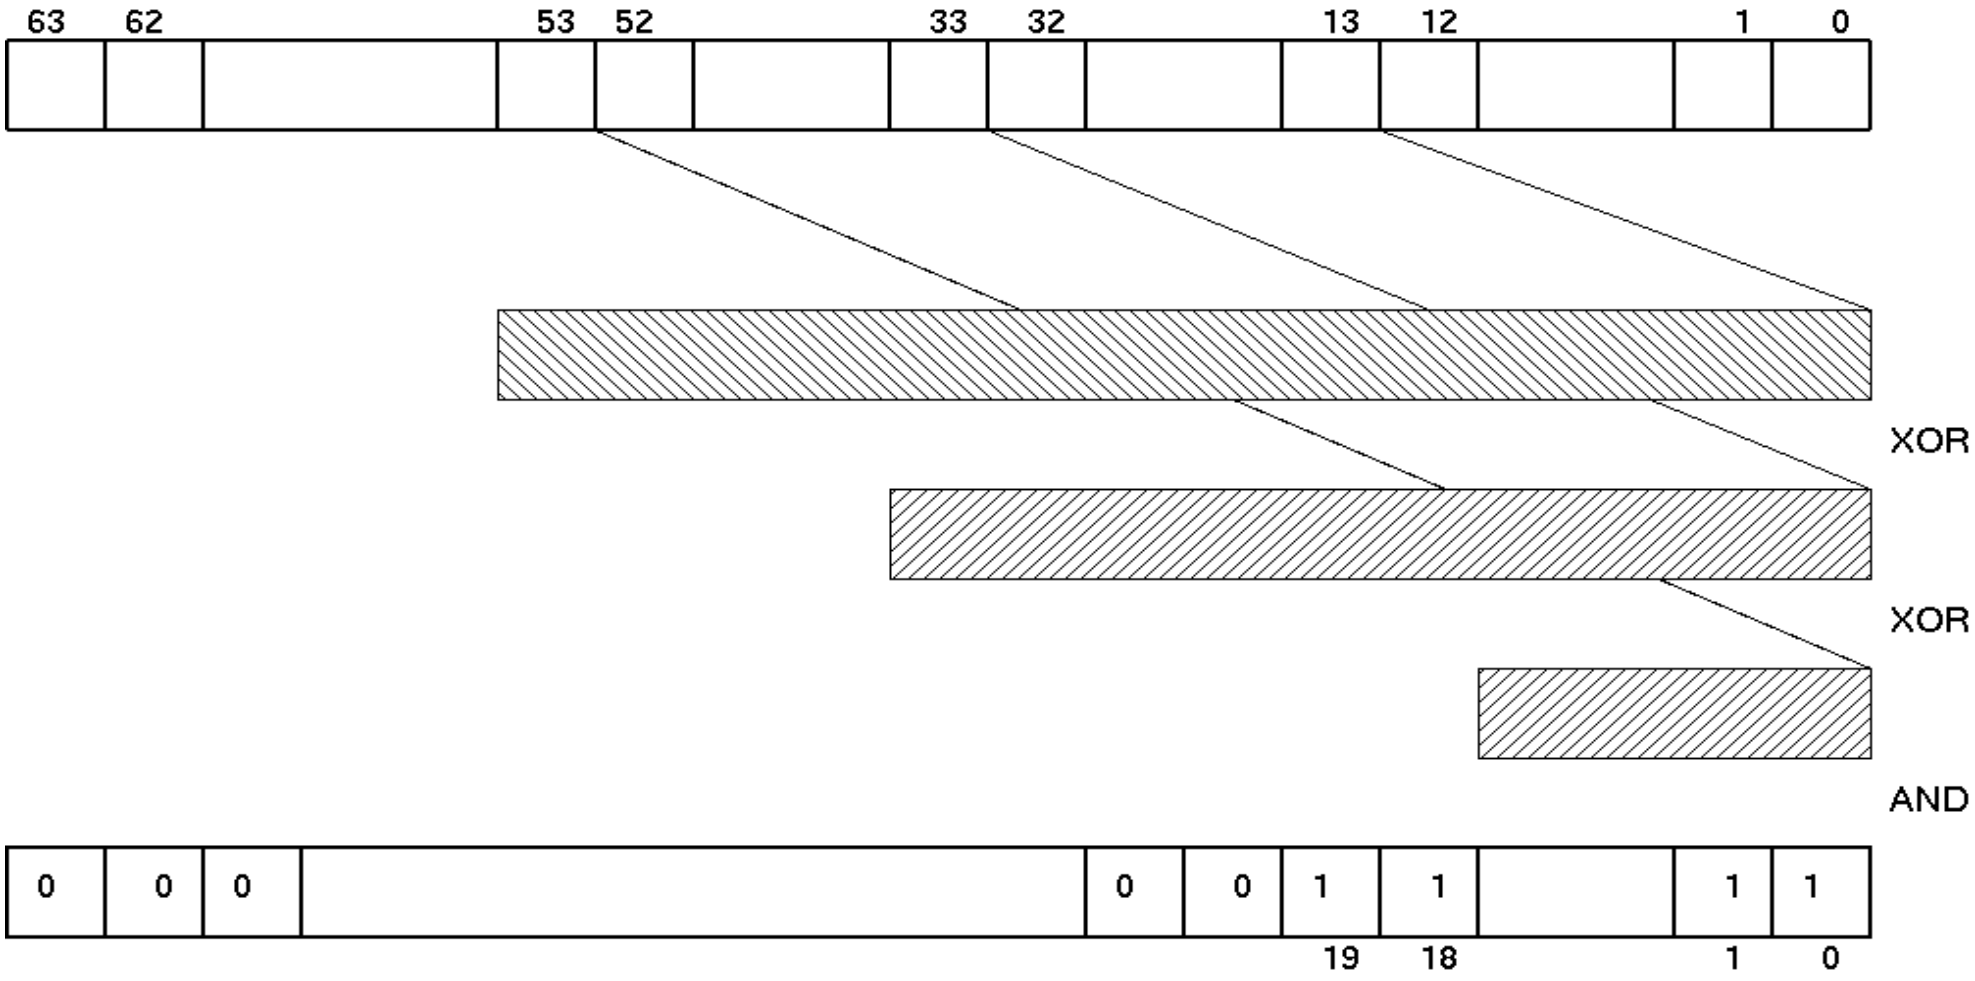

Beispiel-Implementierung in Java

Eine logische 64-Bit Adresse wird auf einen 20-Bit Hash-Wert abgebildet.

64-Bit Adresse -> 52 Bit Seiten-Adresse:

```
adr = adr >>> 12;
```

52-Bit Seiten-Adresse -> Hash-Wert:

```
index =   adr ^ (adr >>> 32);
index =  (index ^ (index >>> 20)) & 1048575;
```

Eintrag in der Seitentabelle

- gültig (present/valid): Seite ist (nicht) im RAM
- Kachelnummer: Physische Anfangsadresse
- dirty (M-Bit): Modifikation seit dem letzen Laden
- reference (R-Bit): Zugriff seit dem letzen Laden
- Schutz: read, write, execute
- auslagerbar: Seite darf (nicht) ausgelagert werden.
- ggf. PID

Paging - ein Beispiel

Physikalischer Adreßraum	4K	→ 4 Kacheln
Vorhanden:	4K	
Virtueller Adreßraum	8K	→ 8 Seiten
Seitengröße:	1K	

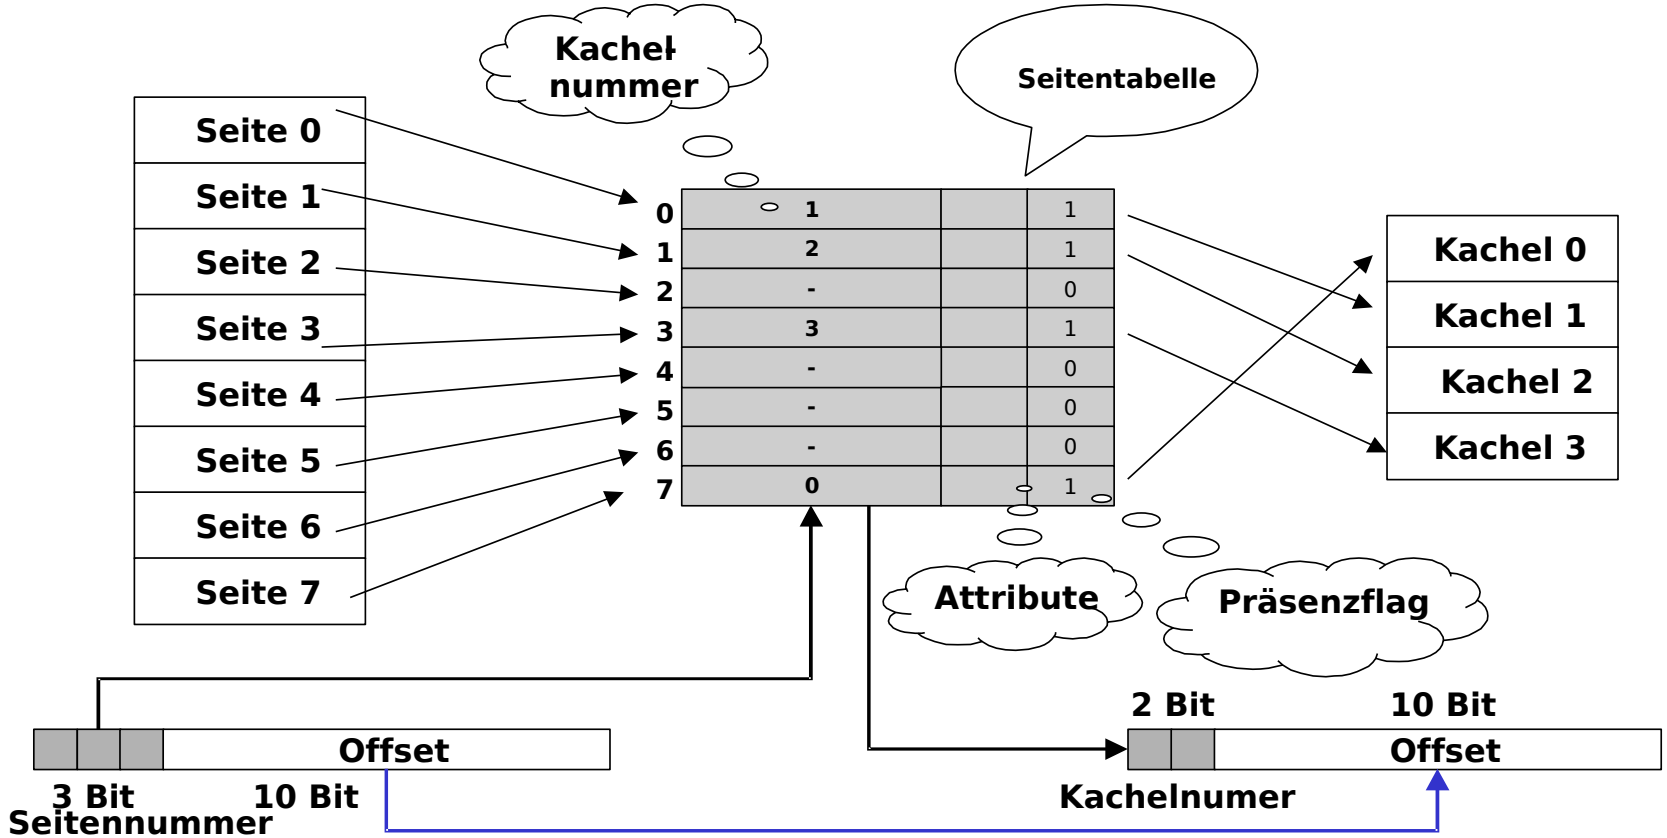

Gemeinsam genutzte Adressen

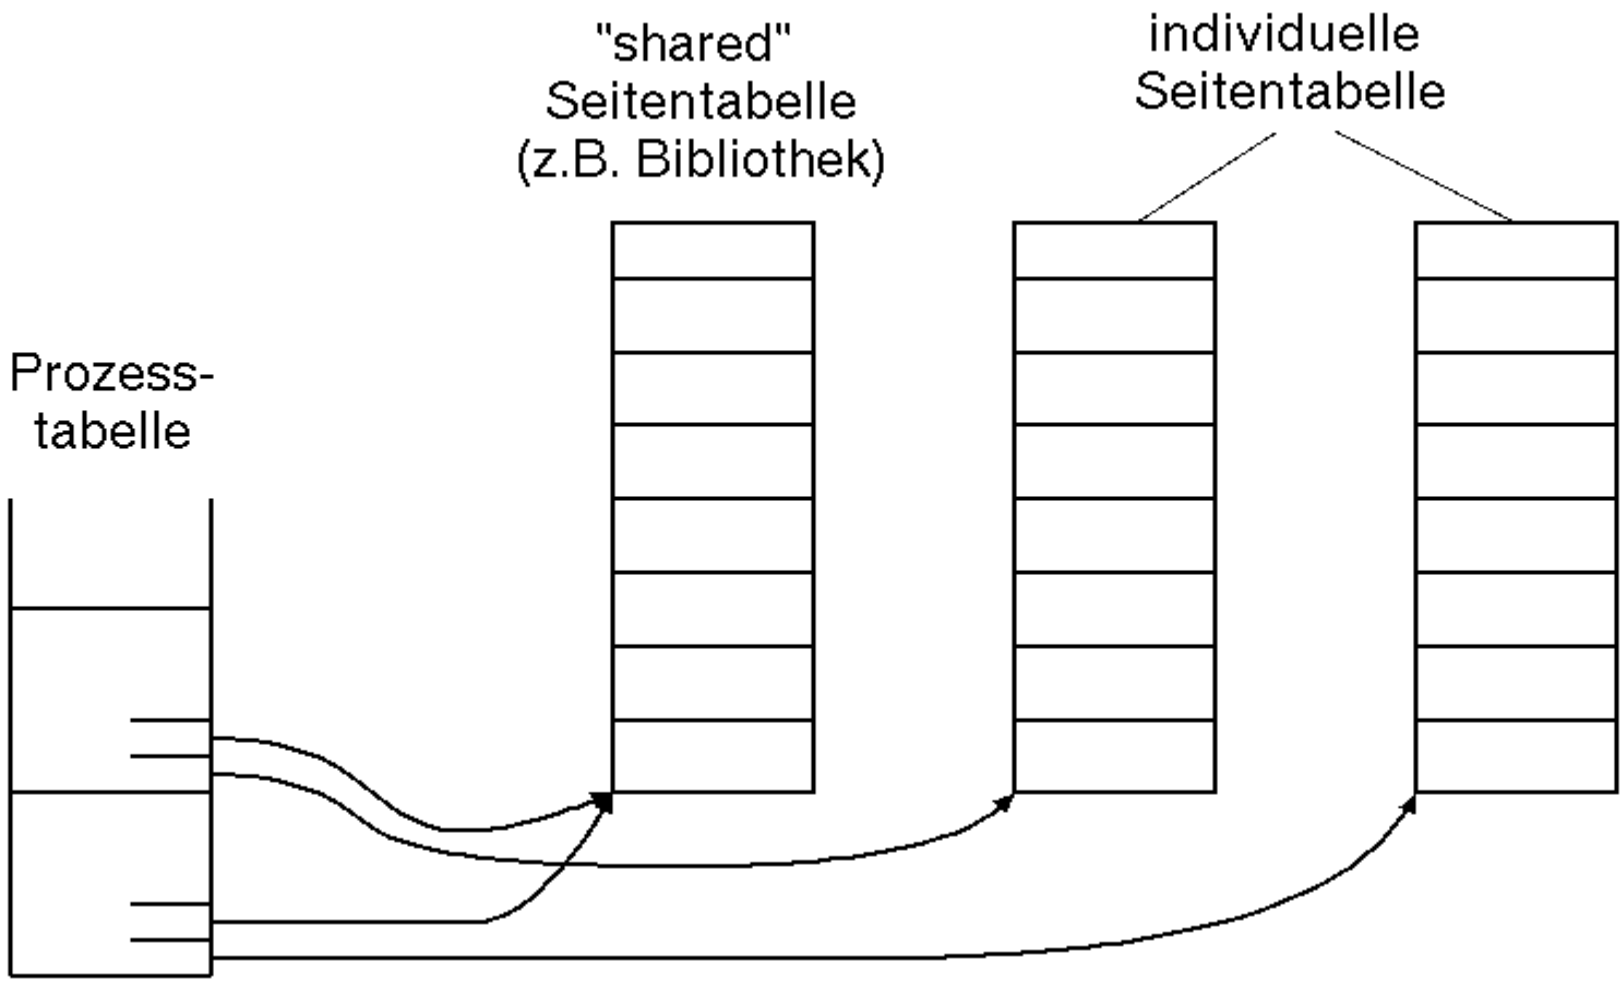

Paging: Drei-Stufen-Paging, die SPARC-Referenz

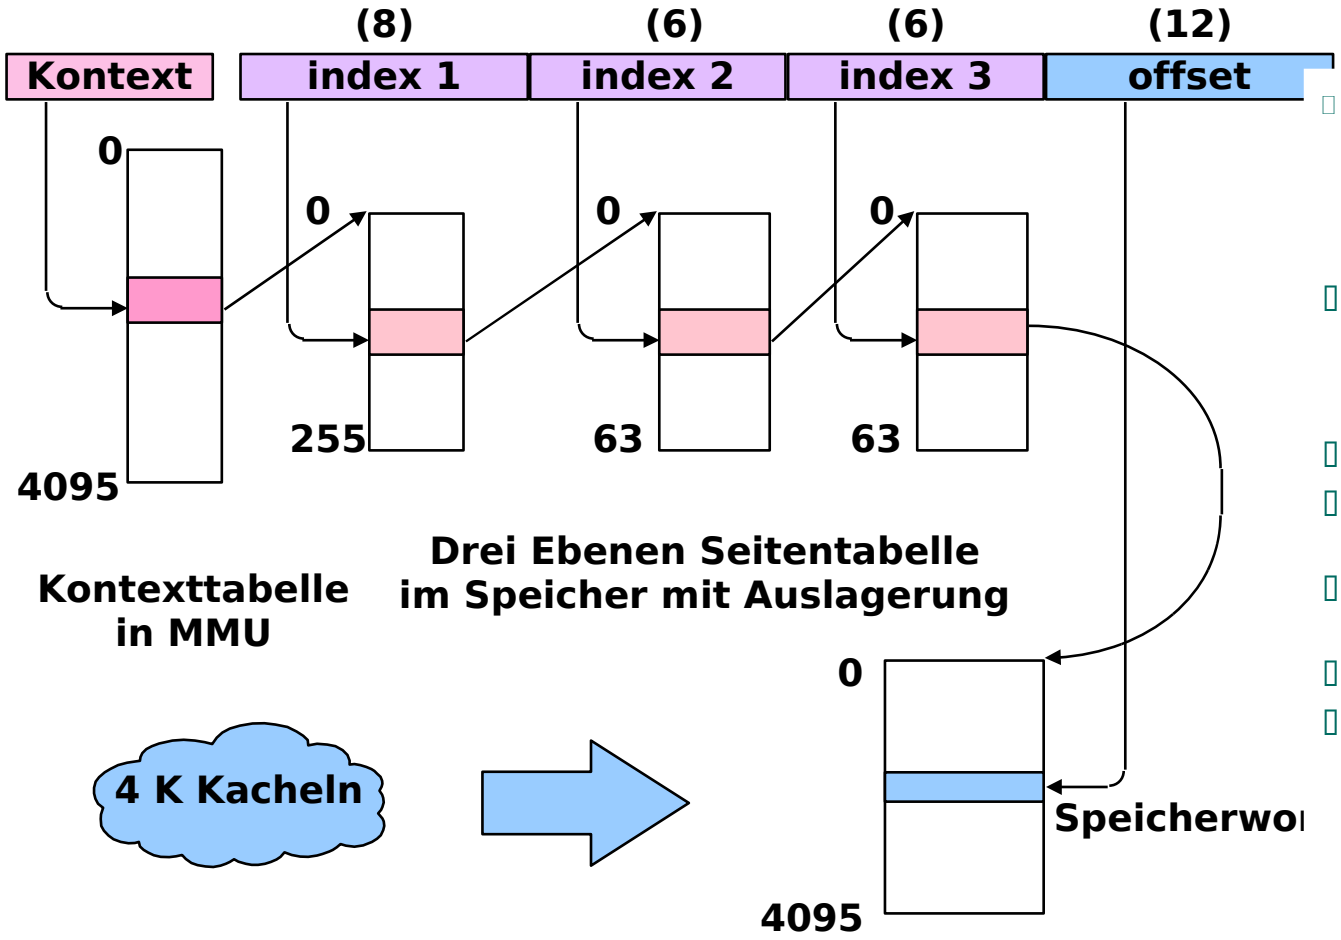

- Je Prozeß ein Prozess-kontextzeiger
  Kontextumschaltung durch neuen Kontextzeiger
- Kontextzeiger über die Lebensdauer in Kontext-Tabelle (MMU- Hardware) konstant
- Beschränkung auf 4K Prozesse
- Kontextzeiger und virtuelle Adresse physikalische Adresse
- 4 G virtueller Adressraum je Prozess
- 1 M Seiten je Prozess á 4 K
- 384 Einträge je process page table

Vier-Stufen-Paging, M68030

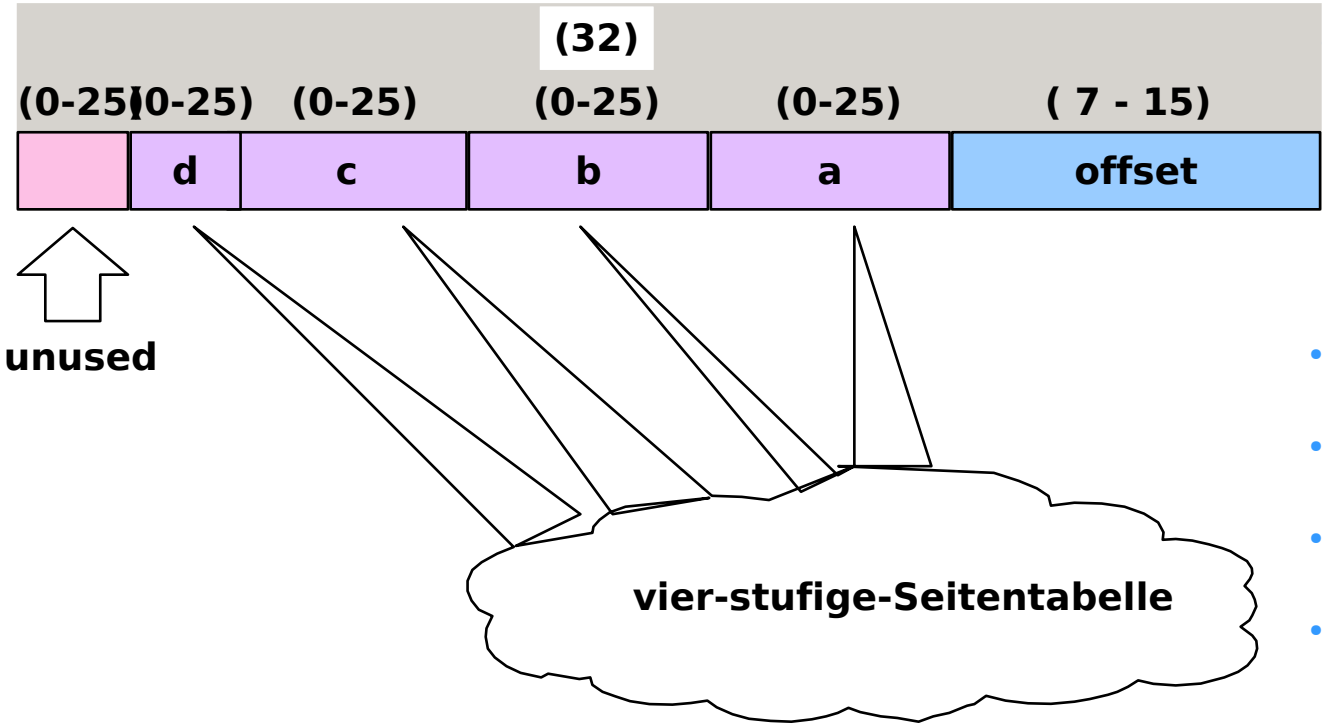

Paging kann durch das Betriebssystem mitbestimmt werden (parametrierbare Hardware- MMU

0 - 4 Stufen und Anzahl der Adressbits, die eine Stufe ausmachen sind SW-seitig einstellbar (Index - Breite) translation control register werden durch BS definiert

- BS legt die Interpretation der virtuellen Adresse fest
- virtueller Adressraum kann eingestellt werden ($< 2^{32}$)
- Seitengröße kann eingestellt werden (265 bytes bis 32 K)
- Einstellung wieviel Bit der Adressraum wirklich hat

- Die Eigenschaften des Paging werden ausschließlich durch das Betriebssystem bestimmt
- Kein bekanntes Betriebssystem nutzt die Flexibilität ernsthaft aus
- Prozess-spezifische Definitionen des virtuellen Adressraums denkbar und eventuell sinnvoll

Translation Lookaside Buffer (TLB)

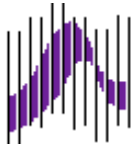

Seitenersetzungstabelle (page table)

- bei mehrstufigen Verfahren liegen die Seitentabellen im Arbeitsspeicher
  - die Adressumrechnung erfordert mehrere Speicherzugriffe
  - Verlangsamung gegenüber der physikalischen Adressierung

- die meisten Programme haben viele Speicherzugriffe in einer kleinen Zahl von Seiten
  - Caching der Seitentabelle in einem **Assoziativspeicher:** Translation Lookaside Buffer (**TLB**)

Assoziativspeicher

Suchmuster	0	1	1	0	1	0	0	0	1	0	1	1	0	0	1	0	1	
Maskierung	1	1	1	1	1	1	1	1	1	1	0	0	0	0	0	0	0	
Einträge	0	1	0	0	1	1	0	0	1	0	1	1	1	0	1	1	1	0
	0	1	1	0	1	0	0	0	1	0	0	0	1	0	1	1	0	1
	1	0	1	0	1	0	0	0	1	0	1	1	0	0	1	0	1	0
	0	0	0	0	1	0	1	0	1	0	1	1	0	0	1	0	1	0
	⋮																	
	0	1	1	0	1	0	0	0	1	0	1	0	0	0	0	0	1	1
	0	1	0	1	1	0	1	0	1	1	0	0	0	0	1	0	1	0

Treffer

Translation Lookaside Buffer (TLB)

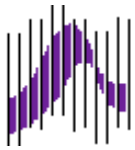

Assoziativspeicher

- Assoziativspeicher ist Teil der MMU
  (minimal 32 Speicherzellen, bis ca. 128)
- Im Assoziativspeicher werden die im Moment gebräuchlichsten Seiten mit ihrem Seitentabelleneintrag vorgehalten. Neben der Seitennummer enthält ein Speichereintrag auch die Kachelnummer
- Assoziativspeicher realisieren eine parallele Suche d.h. die virtuelle Adresse wird gleichzeitig mit allen Tabellen-einträgen verglichen. Die Suchzeit ist konstant.
- Wird eine virtuelle Seite im TLB gefunden (**TLB Hit**), steht dort die Kachelnummer und die Adressumrechnung kann direkt erfolgen
- War die Suche im TLB ohne Erfolg (**TLB Miss**), muss auf die Seitentabellen im Arbeitsspeicher zurückgegriffen werden

Translation Lookaside Buffer (TLB)

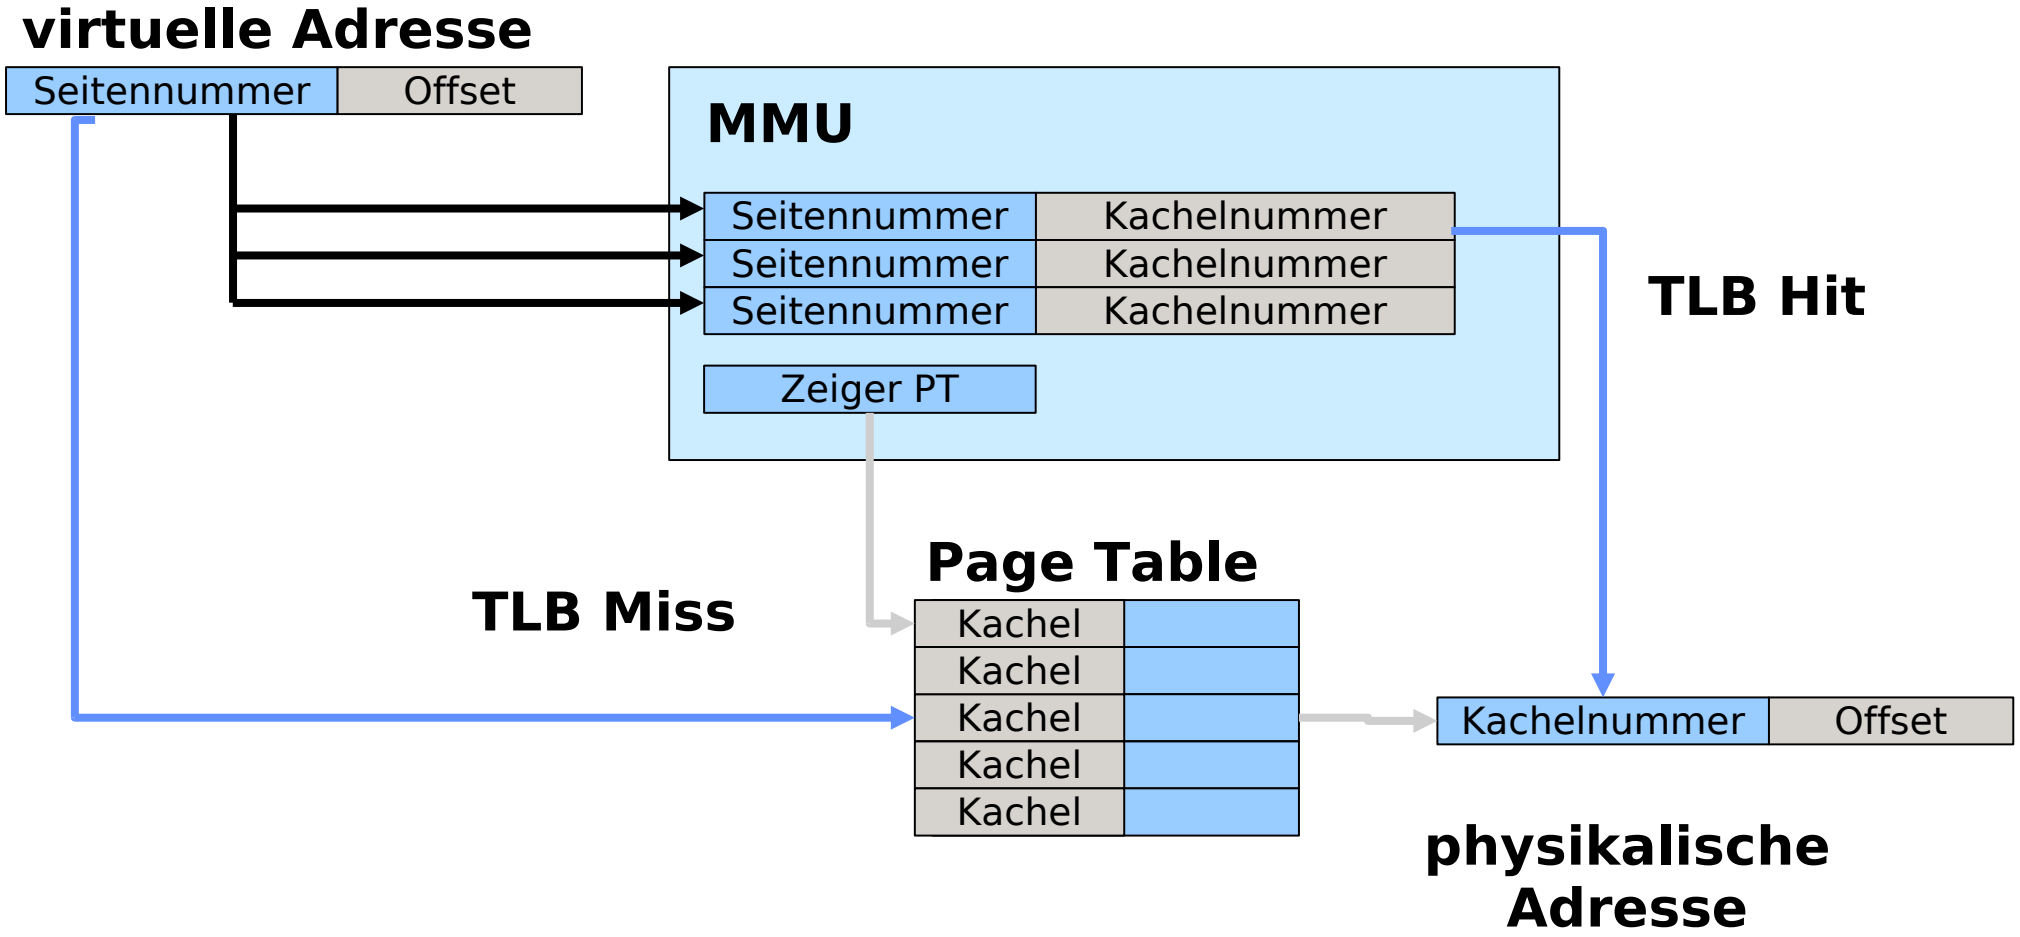

Überblick Speicherzugriff

Zugriff auf eine virtuelle Adresse

- Die MMU sucht Adresse im TLB
  - Erfolg (Gültigkeits-Flag): Zugriff im Hauptspeicher
  - Misserfolg ...
- ... Das Betriebssystem oder die MMU sucht die Adresse in der Seitentabelle
  - Erfolg und Seite im Hauptspeicher: Zugriff, TLB aktualisieren
  - Erfolg und Seite ausgelagert: Seite einlagern Seitentabelle und TLB aktualisieren, Zugriff
  - Misserfolg: „memory fault – core dumped“

Mehrstufiges Speichern der Adressen

(1) Hardware-Caching:
TLB innerhalb der MMU (Assoziativspeicher).
Parallele Suche durch Hardware.

(2) Software-Caching:
Hash-Tabelle (Invertierte Liste) ohne Kollisionsbehandlung.
Enthält mehr Adressen als der TLB aber nicht alle.

(3) Seiten-Tabellen ggf. mehrstufig (Digitalbaum) oder vollständige Hash-Tabelle.
Enthält alle vom Prozess (bzw. vom System) verwendeten Seiten-Adressen.

Ein-/Auslagern von Seiten

- MMU stellt fest, dass eine Seite P_1 ausgelagert ist. MMU erzeugt TRAP, d.h. Verzweigt zum BS.
- Das BS prüft, ob sich die Seite auf der Festplatte befindet, wenn nein wird der Prozess beendet.
- Das BS bestimmt eine Seite P_2 in der Kachel f, die ersetzt wird.
- Wenn nötig wird P_2 auf die Festplatte gespeichert.
- In der Seitentabelle u. im TLB wird die Seite P_2 als „not present“ markiert.
- P_1 wird in Kachel f kopiert.
- In der Seitentabelle u. im TLB wird für die Seite P_1 die Kachel f eingetragen.

Größe der Speicher-Seiten

Größere Speicher-Seiten (z.B. 4MB)

Vorteile:

- Größere Trefferwahrscheinlichkeit im TLB
- Seitentabelle benötigt weniger Einträge

Nachteile:

- Höherer Verschnitt bei teilweise genutzte Seiten
- Größerer Aufwand beim ersten Laden einer Seite
- Größerer Aufwand beim Schreiben einer Seite

Typische Seitengrößen

- Pentium, Athlon: 4K oder 4M
- UltraSPARC: 8K, 64K, 512K, 4M
- PowerPC: 4K . . . 4M?

Verdrängungsstrategien (1)

Eine Seite muss aus dem Hauptspeicher entfernt werden: welche?

- Die Seite, die am längsten ausgelagert bleiben kann (optimale Strategie).
- Die Seite, von der man hofft, dass sie am längsten ausgelagert bleiben kann.

Die optimale Strategie kann i. Allg. nur nachträglich ermittelt werden. Sie dient als Vergleichsmaßstab für andere Strategien.

Verdrängungsstrategien (2)

Annahme: Eine Seite, die in letzter Zeit häufig angesprochen wurde, wird voraussichtlich bald wieder angesprochen.

- FIFO
- LRU (Least Recently Used)
- NRU (Not Recently Used)
- Aging
- Second Chance/Clock, WS-Second Chance

Alle Strategien außer FIFO versuchen, die obige Annahme zu nutzen.

Least Recently Used

Die Seite, die am längsten nicht mehr referenziert wurde, wird ausgelagert.

Mögliche Implementierung:

- Prozess hält Liste aller Seiten.
- Eine referenzierte Seite kommt jeweils an den Anfang der Liste.
- Bei Bedarf wird die letzte Seite der Liste ausgelagert.

Not Recently Used

Eine Seite, die eine gewisse Zeitspanne nicht benutzt wurde, wird ausgelagert.

- Jede Seite erhält ein Markierungs-Bit (R-Bit).
- Bei jedem Zugriff wird das R-Bit der Seite gesetzt.
- Regelmäßig werden alle R-Bits zurückgesetzt.
- Eine Seite mit nicht gesetztem R-Bit wird ausgelagert.

Aging

Eine „gealterte“ Seite wird ausgelagert.

- Jede Seite erhält einen Zähler (Alter), z.B. 4 Bit.
- Bei jedem Zugriff wird das höchstwertigste Bit des Zählers gesetzt.
- Regelmäßig werden alle Zählerstände halbiert.
- Die Seite mit dem niedrigsten Zählerstand wird ausgelagert.

Clock/Second Chance

- Alle Seiten werden ringförmig verkettet.
- Jede Seite erhält ein R-Bit, das bei jedem Zugriff gesetzt wird.
- Ein Zeiger zeigt auf eine Seite.
- Auswahl der auszulagernden Seite:
  - Ist das R-Bit der Seite gesetzt, so wird es zurückgesetzt; der Zeiger rückt zur nächsten Seite weiter (second chance).
  - Ist das R-Bit der Seite zurückgesetzt, wird die Seite ausgelagert; der Zeiger rückt zur nächsten Seite weiter.

Das „Working Set“

Die meisten Prozesse verbringen einen großen Teil ihrer Zeit in einem kleinen Teil ihres Speichers: dem sog. „working set“.

- Das „working set“ kann sich von Zeit zu Zeit ändern.
- Das „working set“ eines Prozess kann nur mit hohem Aufwand ständig erfasst werden.
- Die „working sets“ aller aktiven Prozesse sollten in den Hauptspeicher passen. Ansonsten müssen zu viele Seiten ein- und ausgelagert werden.

WS-Clock-Algorithmus (1)

- Alle Seiten werden ringförmig verkettet.
- Das System hält eine Zeit-Konstante τ
- Jede Seite erhält ein R-Bit und einen Zeitstempel.
  R-Bit und Zeitstempel werden bei jedem Zugriff gesetzt.
- Jede Seite erhält ein M-Bit, das M-Bit wird gesetzt, wenn die Seite verändert wird.
- Ein Zeiger zeigt auf eine Seite.
- Auswahl der auszulagernden Seite:
  - Das R-Bit der Seite ist gesetzt: Es wird zurückgesetzt; der Zeiger rückt zur nächsten Seite weiter.
  - Das R-Bit der Seite ist zurückgesetzt: s. Nächste Folie

WS-Clock-Algorithmus (2)

- Die Zeit seit dem letzten Zugriff ist kleiner als τ:
  - Der Zeiger rückt weiter
- Die Zeit seit dem letzten Zugriff ist größer als τ:
  - Das M-Bit ist zurückgesetzt:
    - Die Seite wird ausgelagert.
  - Das M-Bit ist gesetzt:
    - Die Seite wird zum Speichern vorgemerkt (V-Bit).
    - Der Zeiger rückt weiter

Es gibt einen Prozess, der regelmäßig vorgemerkte Seiten speichert und deren M-Bit zurücksetzt.

Speicherverwaltung in Linux

Segmen-tierung

Der virtuelle Adreßraum wird in 4 Segmente eingeteilt (i.a. nicht zur Adressrechnung):

- Text-Segment (read-only, shared)
- Statische Daten (initialisiert, nicht initialisiert (BSS))
- Dynamische Daten, Heap - wächst von unten nach oben.
- Dynamische Daten, Stack - wächst von oben nach unten.

Swapping

Hintergrundprozess Swapper
Wird aktiviert zum Auslagern von Prozessen, wenn die Page Fault Rate zu hoch ist, oder kein Speicherplatz mehr vorhanden ist. Wird Periodisch aktiviert um nachzusehen, ob Prozesse wieder eingelagert werden können

Paging

- **Demand Paging WS-Clock Algorithmus**

Paging Daemon, Flush Daemon
Hintergrundprozess wird periodisch (ca. 1 – 4 mal pro Sekunde) aktiviert. Falls weniger als ca. 1/4 des Speichers frei ist, werden im Vorgriff Seiten ausgelagert. Der Flush Daemon schreibt veränderte Seiten auf die Festplatte und setzt das M-Bit zurück.

Speicherverwaltung bei Unix fork()

Mechanismus: copy-on-write (lazy copy)

- Kind-Prozess erhält Kopie der Seitentabelle.
- Alle Seiten werde als „read only“ markiert.
- Ein Schreibzugriff führt zu einem Interrupt.
- Die Seite wird kopiert und in beiden Prozessen als „read write“ markiert.

Virtueller Adressraum eines NT Prozesses

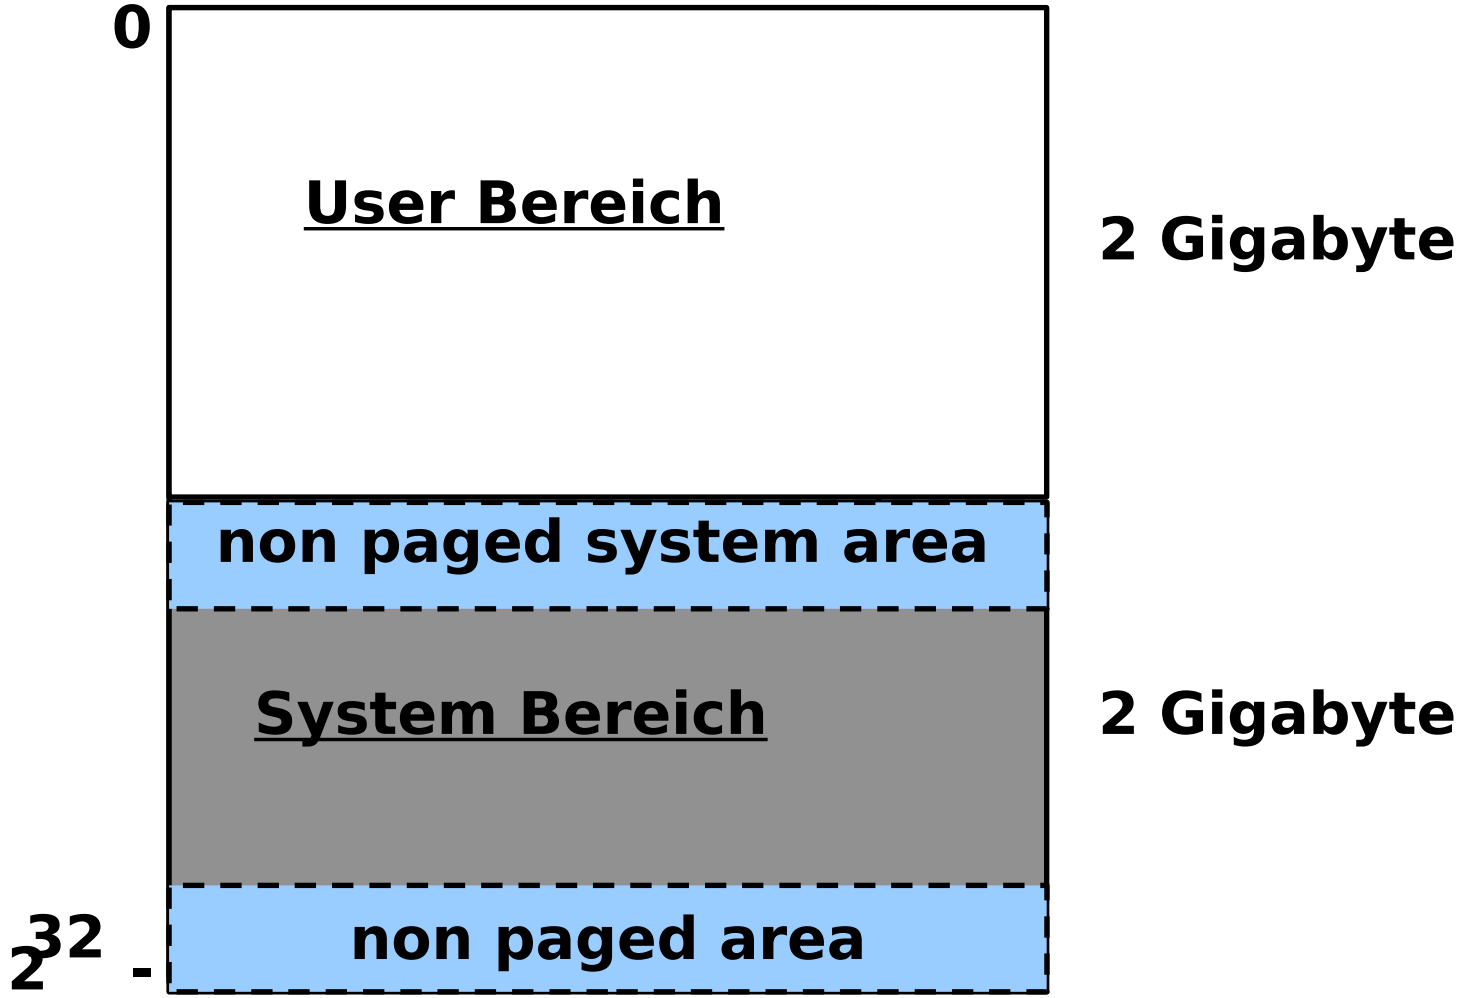

Synchronisation (1)

- Zugriff auf gemeinsame Ressourcen muss synchronisiert werden.
- Bsp: Mehrere Prozesse schreiben Dateien in eine Drucker-Warteschlange.
- So lange ein Prozess schreibt, darf kein anderer Prozess schreiben.

„Kritischer Bereich“: Der Teil eines Programms, der auf gemeinsam genutzte Ressourcen zugreift.

Synchronisation (2)

- Keine zwei Prozesse dürfen gleichzeitig in ihrem kritischen Bereichen sein.
- Es darf keine Annahme über die Geschwindigkeit und die Anzahl der CPUs gemacht werden.
- Kein Prozess, der außerhalb seines kritischen Bereichs läuft, darf einen anderen Prozess blockieren.
- Kein Prozess darf dauerhaft blockiert werden.

Zwei Prozesse mit kritischem Bereich

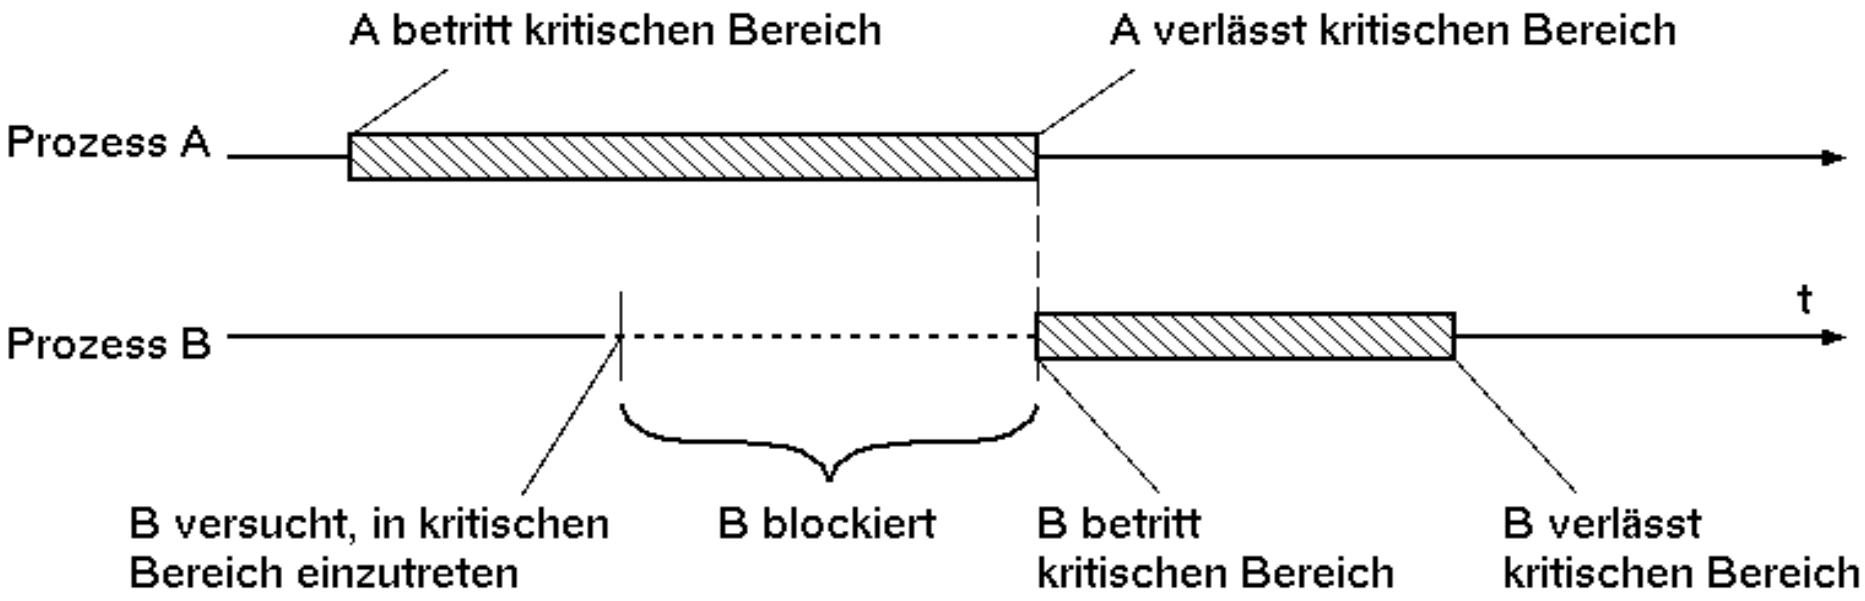

Deadlock

Deadlock durch Wettbewerb um Ressourcen

Notwendige Bedingungen:

- exklusive Nutzung von Ressourcen
- Nachforderung von Ressourcen
- zyklisches Warten möglich

Petrinetze

Ablaufmodell zur Beschreibung nebenläufiger Systeme

- bipartiter, gerichteter Graph
- Knoten:
  - Transition, aktive Komponente
  - Stelle, passive Komponente
- Kante: verbindet Transitionen und Stellen

Durch Markierungen und Schaltregeln entsteht ein dynamischer, abwickelbarer Graph, mit dem Systemzustände sichtbar gemacht werden können.

Petrinetze Marken

- Bedingungs-Ereignisnetz:
  Jede Stelle kann genau eine Marke aufnehmen
- Allg. Petri-Netz:
  Jede Stelle kann eine bestimmte Anzahl von Marken aufnehmen
- Die Belegung der Stellen mit Marken definiert den Systemzustand.

Petrinetze Schaltregeln

Schaltbereitschaft

- Eine Transition ist schaltbereit, wenn alle Eingangsstellen markiert sind und jede Ausgangsstelle [, die nicht auch Eingangsstelle ist,] eine Marke aufnehmen kann.

- Schalten
  - Eine Transition kann schalten, wenn sie schaltbereit ist.
  - Durch das Schalten wird von jeder Eingangstelle eine Marke entfernt. Zu jeder Ausgangsstelle wird eine Marke hinzugefügt.
  - Das Schalten einer Transition ist ein atomarer Vorgang.

Schalten führt zu einer Zustandsänderung (Marken verschwinden und/oder entstehen).

Beispiel: Milner Scheduler

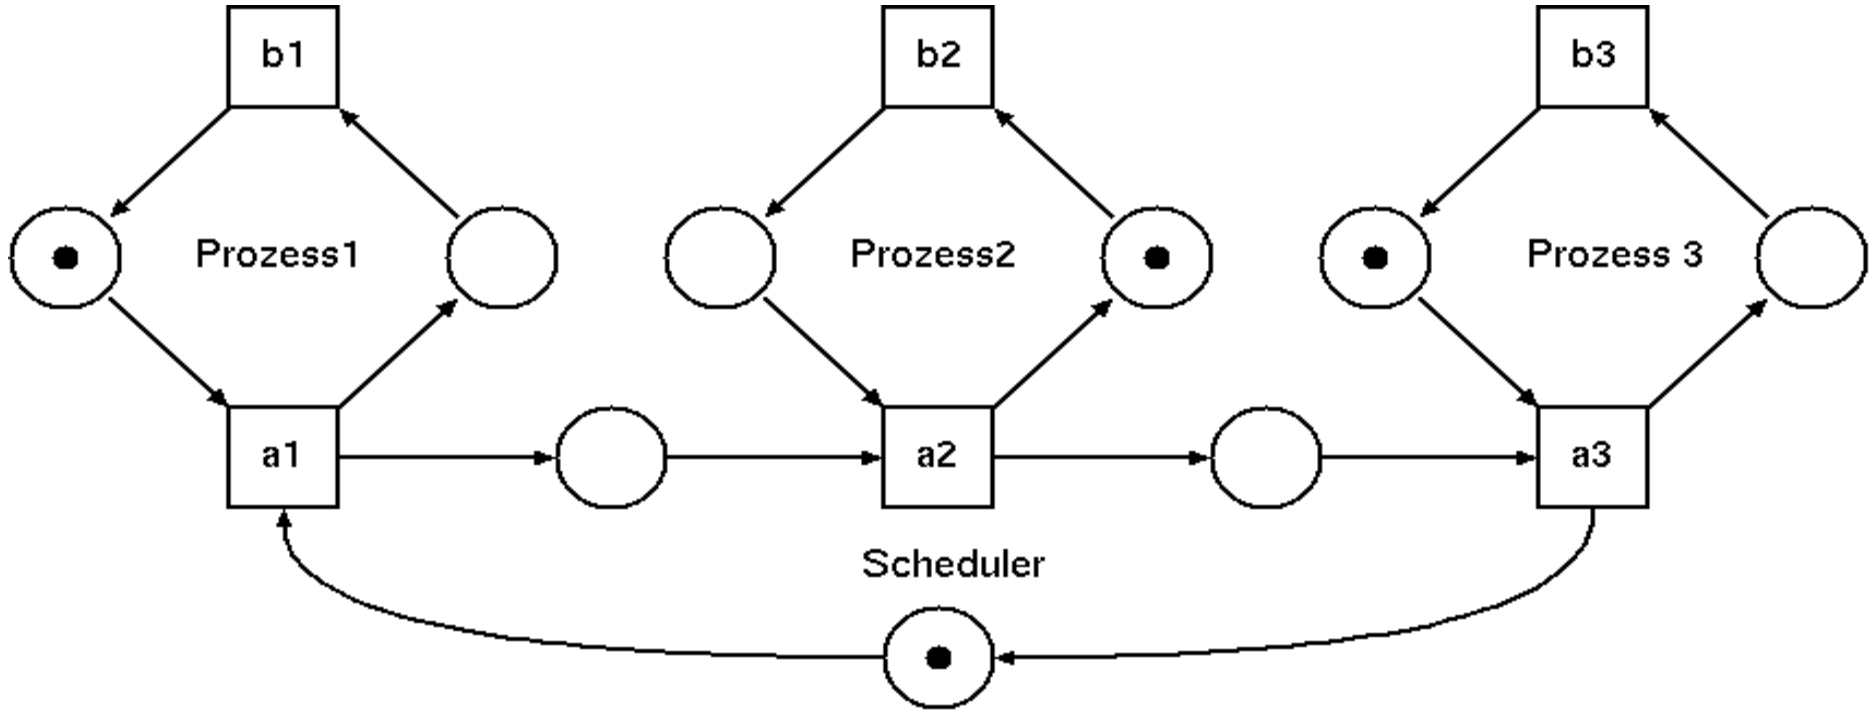

Die drei Prozesse laufen im gleichen Takt

Petrinetz: Ereignisgraph

- Knotenmenge:
  Jeder Zustand des Petrinetzes ist ein Knoten.

- Kantenmenge:
  Jeder Übergang von einem Zustand zu einem anderen ist eine Kante.

- Es genügt, die erreichbaren Zustände zu erfassen.

- Ein Zustand, aus dem keine Kante herausführt, entspricht einem Deadlock.

Petrinetz

- Unsicher markiertes Netz
- Ereignisgraph/Synchronisationsgraph/Zustandsgraph

Kooperation über gemeinsame Daten

Beispiel

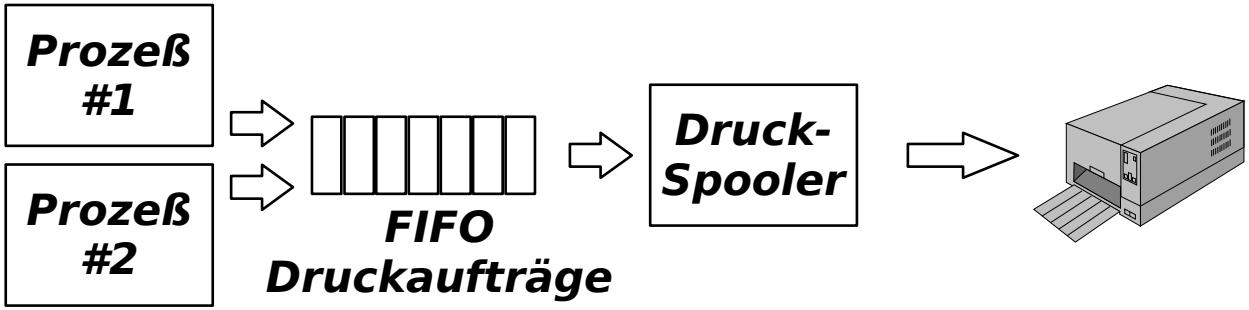

Problem

Zeitlicher Wettlauf zwischen Prozeß 1 und Prozeß 2

Kritischer Bereich

Teil des Prozsesses, in dem ein Zugriff auf gemeinsame Datenbereiche erfolgt

Ursache

Prozeßwechsel innerhalb kritischem Bereich.

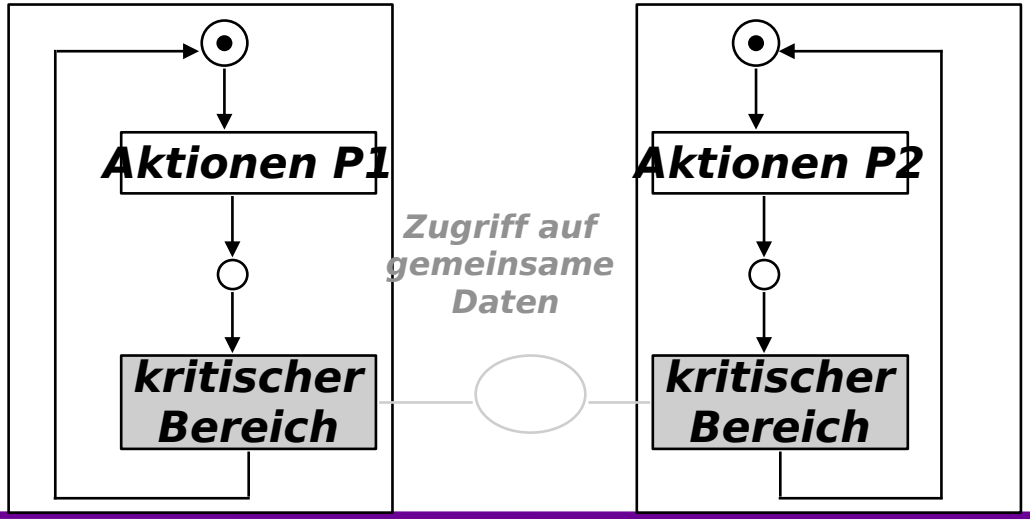

Kooperation über gemeinsame Daten

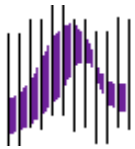

Lösung

Wechselseitiger Ausschluß (mutual exclusion)

Realisierung

Binäre Semaphore

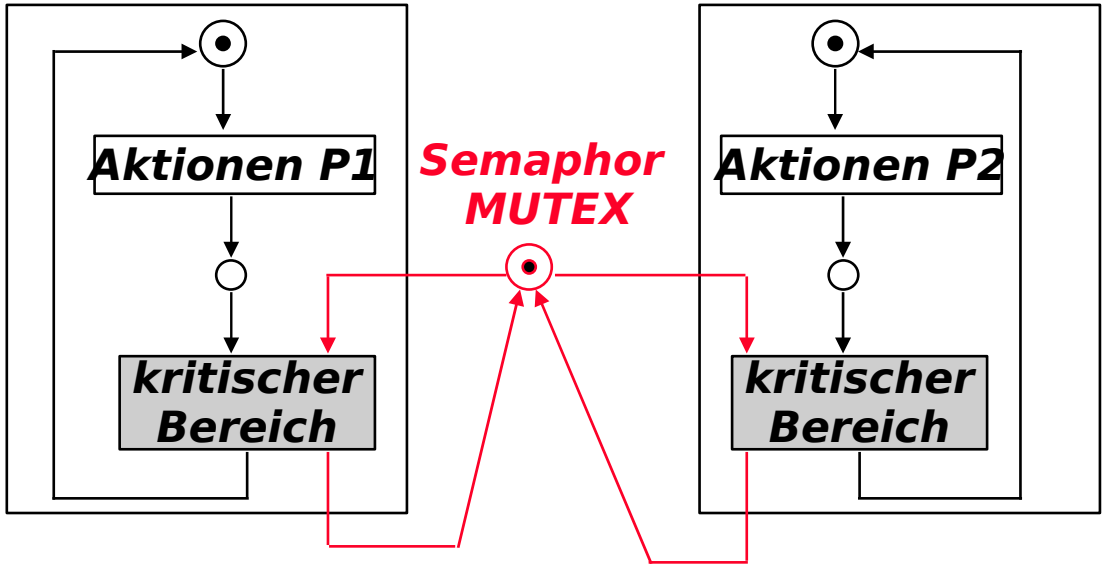

Semaphore

- Abstrakter Datentyp S
- Initialisierung mit ganzer Zahl n >= 0
  - n Element von {0, 1} binäres Semaphor
  - n Element von {0, ... k} allgemeines Semaphor
- Operationen
  - down(S) auch P(S), kann blockieren s.u.
  - up(S) auch V(S)

Ein Prozess ruft beim Betreten eines kritischen Bereichs down(S) auf, beim Verlassen up(S).
Zu jedem Zeitpunkt gilt:
Anzahl (down(S)) <= Anzahl(up(S)) + n

Implementierung - unsicher

```
void down(S){
    while (S == 0){
        wait();
    }
    S = S - 1;
}
```

```
void up(S){
    S = S + 1;
    notify();
}
```

Ein wartender Prozess wird geweckt

Wird ein Prozess in der Funktion down(S) zwischen dem Vergleich und dem Dekrementieren von S unterbrochen, so kann ein zweiter Prozess fälschlicherweise den kritischen Bereich betreten.

Implementierung - sicher

TSL: nichtunterbrechbare Anweisung,
holt *und* setzt einen Wert.

MUTEX: 0 ≡ frei, 1 ≡ belegt

```
mutex_lock:
      TSL REGISTER, MUTEX
      CMP REGISTER, #0
      JZE ok
      CALL thread_yield
      JMP mutex_lock
ok:   RET

mutex_unlock:
      MOVE MUTEX, #0
      RET
```

kopiere MUTEX in Register und setze MUTEX = 1

Vergleich auf 0

jump on zero

MUTEX belegt - warten

nächster Versuch

MUTEX frei - weiterlaufen

Producer - Consumer

```
typedef int semaphore;
semaphore mutex = 1, empty = 5, full = 0;
```

```
void producer (void){
   int item;
   while(true){
      item = produce();
      down(&empty);
      down(&mutex);
      insertItem(item);
      up(&mutex);
      up(&full);
   }
}
```

```
void consumer (void){
   int item;
   while(true){
      down(&full);
      down(&mutex);
      item = getItem();
      up(&mutex);
      up(&empty);
      consume(item);
   }
}
```

Producer – Consumer - Deadlock

```
void producer (void){
   int item;
   while(true){
      item = produce();
      down(&mutex);
      down(&empty);
      insertItem(item);
      up(&mutex);
      up(&full);
   }
}
```

Anweisungen sind vertauscht

Wenn ein Producer den Puffer füllt, blockiert er in down(&empty).

Ein Consumer blockiert aber in down(&mutex).

Kein Prozess kann weiterlaufen.

Semaphore

- Semaphore können grundsätzlich alle Synchronisationsaufgaben lösen.
- Semaphore sind schwierig in der Handhabung und Fehleranfällig.

Semaphore in POSIX/UNIX/Linux

- Semaphore werden zu Gruppen zusammengefasst.
- Eine atomaren Aktion manipuliert alle Semaphore der Gruppe: up() bzw. down() ggf. gemischt.
- Undo-Operationen können vom System mitgeführt werden. Beendet sich ein Prozess, so wird die Undo-Operation ausgeführt.

Monitore

Synchronisationsmethode nach Hoare (1974) und Hansen (1975), realisiert mutual Exclusion

- Ein Monitor besteht aus einer Menge von Prozeduren, Variablen und Datenstrukturen, die in einem Modul bzw. in einer Klasse zusammengefasst sind
- Ein Programm/Prozess kann nur über die Monitorprozeduren auf die Daten im Monitor zugreifen
- Nur genau ein Prozess kann in einem Monitor aktiv sein

Monitore

Monitore sind Konstrukte der Programmiersprache

- Der Compiler realisiert Monitore:
  - Ruft ein Prozess P2 eine Monitorprozedur auf, während gerade ein anderer Prozess P1 den Monitor (aktiv) benutzt, so wird P2 blockiert, bis der Prozess P1 den Monitor wieder verlässt.
  - Ist kein anderer Prozess im Monitor aktiv, so erhält P2 das Recht die Monitorprozedur zu benutzen und sperrt damit für andere Prozesse den Zugriff auf die Monitordaten.
- Der Compiler muss für einen Monitor den wechselseitigen Ausschluss umsetzen.
- Falls vorhanden verwendet der Compiler dazu binäre Semaphore

Monitore

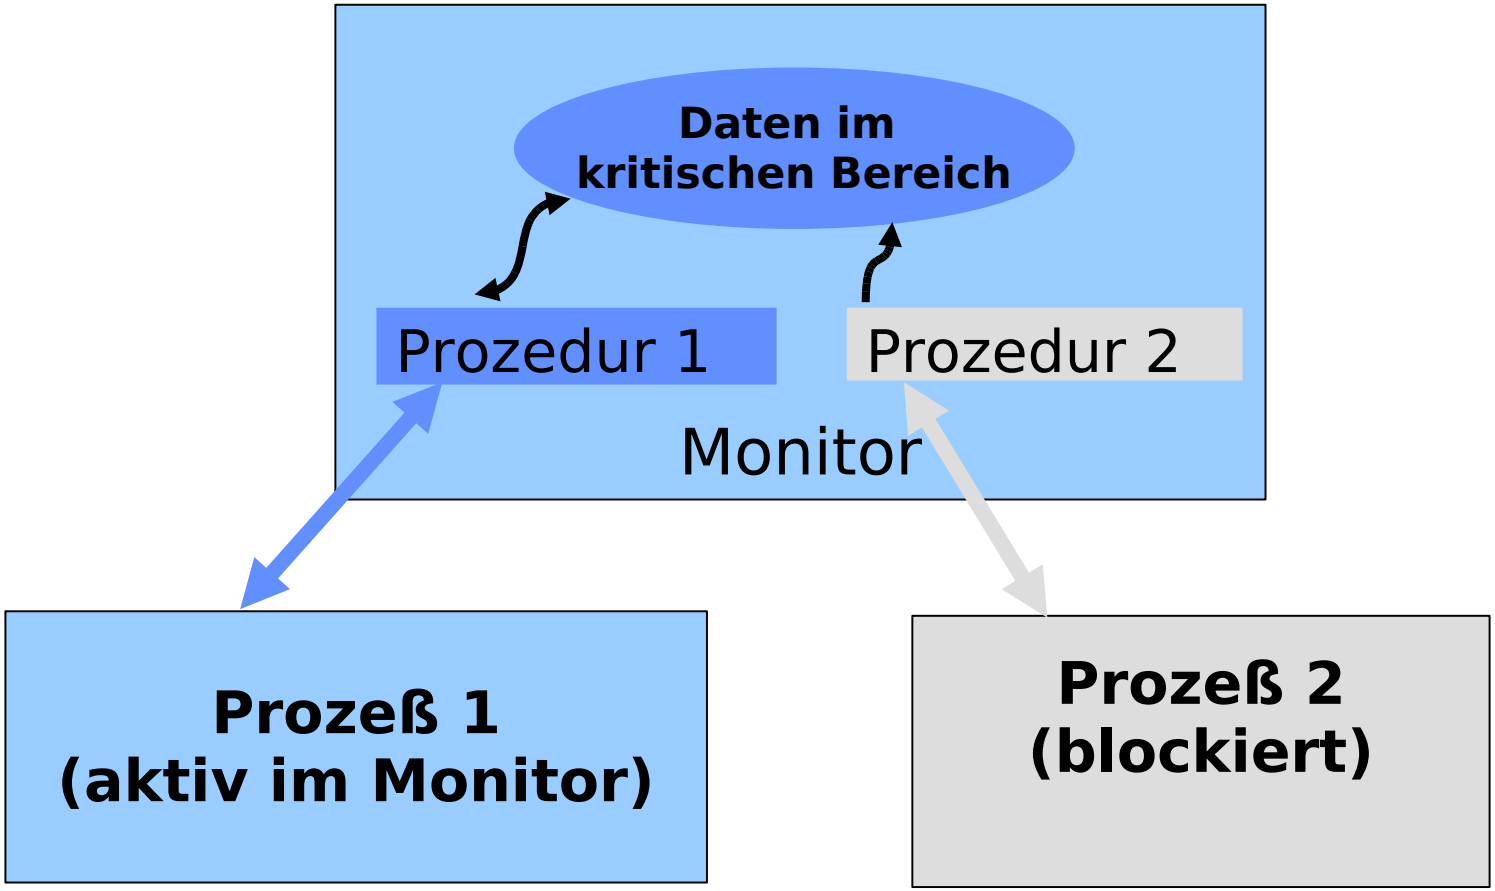
Daten im
kritischen Bereich
Prozedur 1
Prozedur 2
Monitor
Prozeß 1
(aktiv im Monitor)
Prozeß 2
(blockiert)

Monitor
Konstrukt der Programmiersprache

Vorteil

- Der Programmierer muss sich um mutual exclusion nicht selbst kümmern. Dies regelt der Compiler. Daher können auch keine Fehler durch zeitliche Wettläufe erfolgen.
- Der Programmierer muss „nur“ alle kritischen Bereiche in Monitore legen

Nachteil:

- Monitore sind Elemente einer Programmiersprache.
- C und C++ ermöglichen keine Monitore.
- JAVA unterstützt das Monitorkonzept

Monitore - Synchronisation

- In den meisten Fällen muss neben mutual exclusion zusätzlich ein Synchronisationsprotokoll zwischen den Prozessen implementiert werden, das einen Prozess blockiert, wenn eine bestimmte Bedingung nicht erfüllt ist, und den Prozess wieder deblockiert, wenn die Bedingung wieder erfüllt ist.
- Beispiel Druckspooler:
  - Der Zugriff auf die Druckwarteschlange (Einschreiben von Druckaufträgen, herausnehmen von Druckaufträgen) muss mittels mutual exclusion sicher implementiert werden.
  - Ist kein Auftrag in der Schlange muss der Druckspooler blockieren.
  - Ist die Druckerwarteschlange voll muss der druckende Prozess blockiert werden.

Synchronisation durch Monitore

Realisierung in Java: Ein Thread, der sich in einem Monitor befindet, kann die Funktionen wait() und notify() aufrufen.

- Die Funktion wait() bewirkt, dass der aufrufende Thread blockiert wird.
- Ein zweiter Thread kann nun den Monitor betreten.
- Die Funktion notify() bewirkt, dass (irgend) ein anderer Thread, der im gleichen Monitor blockiert ist, deblockiert wird, sobald der aufrufende Thread den Monitor verlässt.

Synchronisation durch Monitore

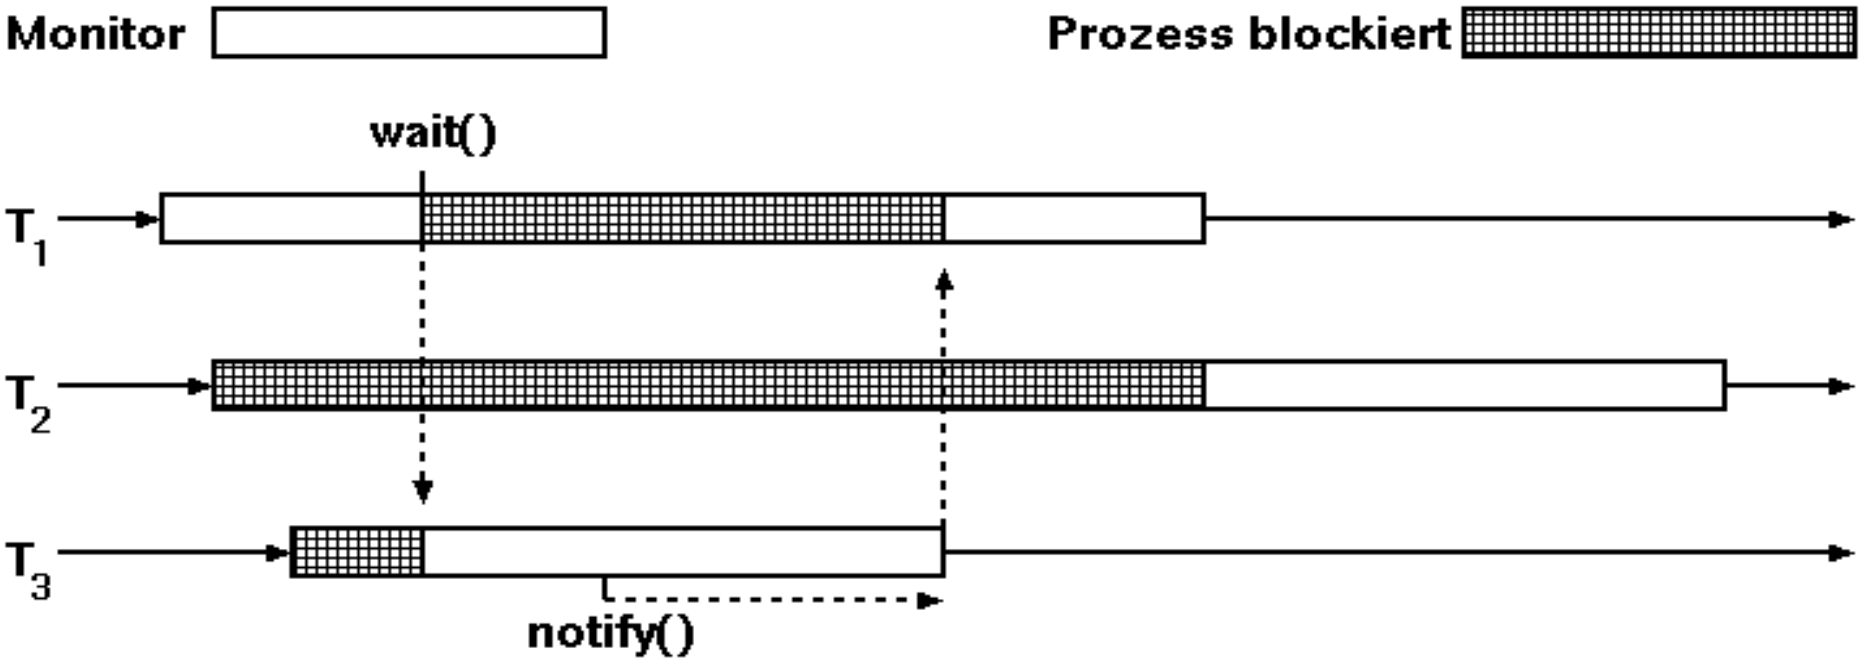

Synchronisation durch Monitore

Blockieren und Deblockieren wird innerhalb der Prozeduren des Monitors entschieden und realisiert.

- Warten auf Bedingungsvariablen bzw. Ereignissen
- Setzen von Bedingungsvariablen bzw. Ereignissen

Monitore - Synchronisation

- Wird in einer Monitorprozedur erkannt, dass eine Weiterverarbeitung nicht möglich ist, wird auf das Eintreten einer Bedingung gewartet: **wait(event)**
  - Dies bewirkt dass der **Prozess**, der sich in der Monitorprozedur befindet **blockiert** wird.
  - Darauf wird der Monitor für **einen** auf Zutritt in den Monitor wartenden Prozess freigegeben, der dann eine Monitorprozedur ausführen kann, die die Bedingung für die Weiterverarbeitung eines blockierten Prozesses herstellen kann (**notify bzw. signal(event)**).
- Damit nicht zwei Prozesse gleichzeitig den Monitor benutzen,
  - darf der jetzt deblockierte Prozess erst dann weiterlaufen, wenn der die Deblockierung auslösende Prozess den Monitor wieder verlassen hat.
  - Das Deblockieren eines Prozesses sollte daher die letzte Anweisung in einer Monitorprozedur sein. (In Java wird der Aufruf von notify() erst wirksam, wenn der Thread den Monitor verlässt).

POSIX Threads

Thread-Blibliothek gemäß POSIX-Standard

Thread-Management
- create
- yield
- exit

Synchronisierung
- join
- Mutex
- Condition Variable

NB.: Diese Funktionen steuern nur Threads eines Prozesses.

POSIX Threads

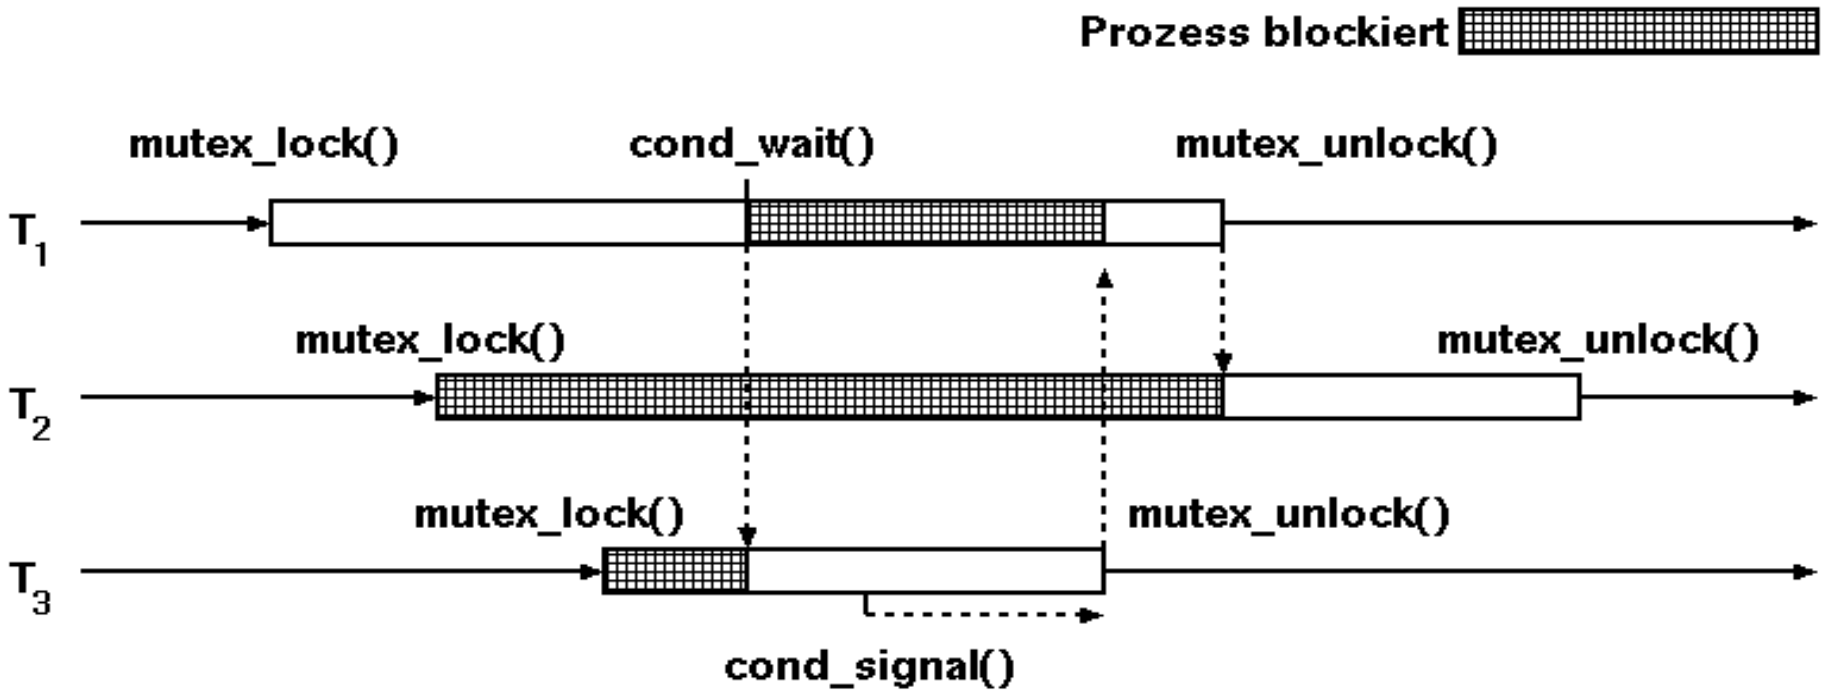

Verklemmungen

- Entdecken und Beheben
  - Protokollieren von Betriebsmittelanforderungen und Betriebsmittelbenutzung durch Aktualisieren des Betriebsmittelgraphen.
  - Prüfen des Graphen auf Zyklen und entfernen eines Prozesses aus dem Zyklus, so daß Zyklus aufgelöst wird.
- Was ist ein Betriebsmittelgraph?

Symbol für Betriebsmittel

Symbol für Prozeß

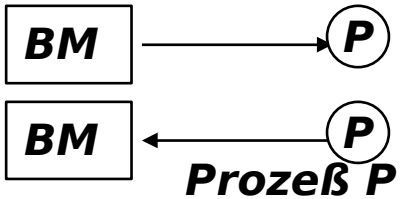

Prozeß P benutzt Betriebsmittel BM

Prozeß P ist blockiert und wartet auf Betriebsmittel BM

Beispiel

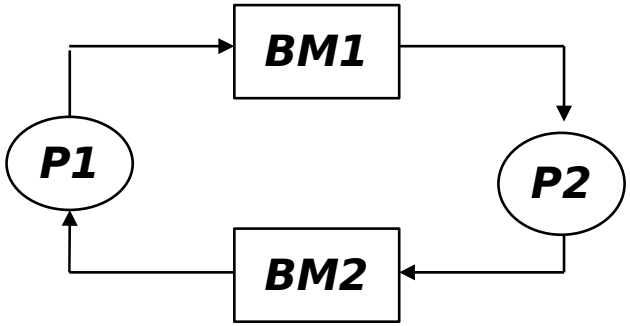

P2 benutzt BM1
P1 wartet auf BM1
P1 benutzt BM2
P2 wartet auf BM2

Zyklus ⇨ Verklemmung

Deadlock - Strategien

- Vermeidung
  - Vorbeisteuern: Anforderungsketten von vorneherein vermeiden
  - **Banker Algorithmus** (Dijkstra, 1965)
    (Quelle: Tanenbaum, Modern Operating Systems)
    - Jeder Prozess gibt zu Beginn an, welche Betriebsmittel er zur Laufzeit benötigt. In der Praxis nicht anwendbar
    - Variante: Prozess muss alle Ressourcen freigeben bevor er wieder Ressourcen anfordern kann
- Zyklen automatisch erkennen und durchbrechen
- Problem ignorieren:
  Wenn eine Verklemmung auftritt, muss ein Administrator (Nutzer) eingreifen

Interprozesskommunikation unter POSIX

- Signale
  - asynchrone Benachrichtigung
- Pipes
  - FIFO-Puffer-Speicher mit Stream-Interface
- Message-Queues
  - FIFO-Puffer-Speicher mit Zugriffsfunktionen
- Shared Memory
  - gemeinsamer Speicher, Zugriff über Pointer
- Sockets
  - Stream-Interface zu Kommunikationsprotokoll

Signale

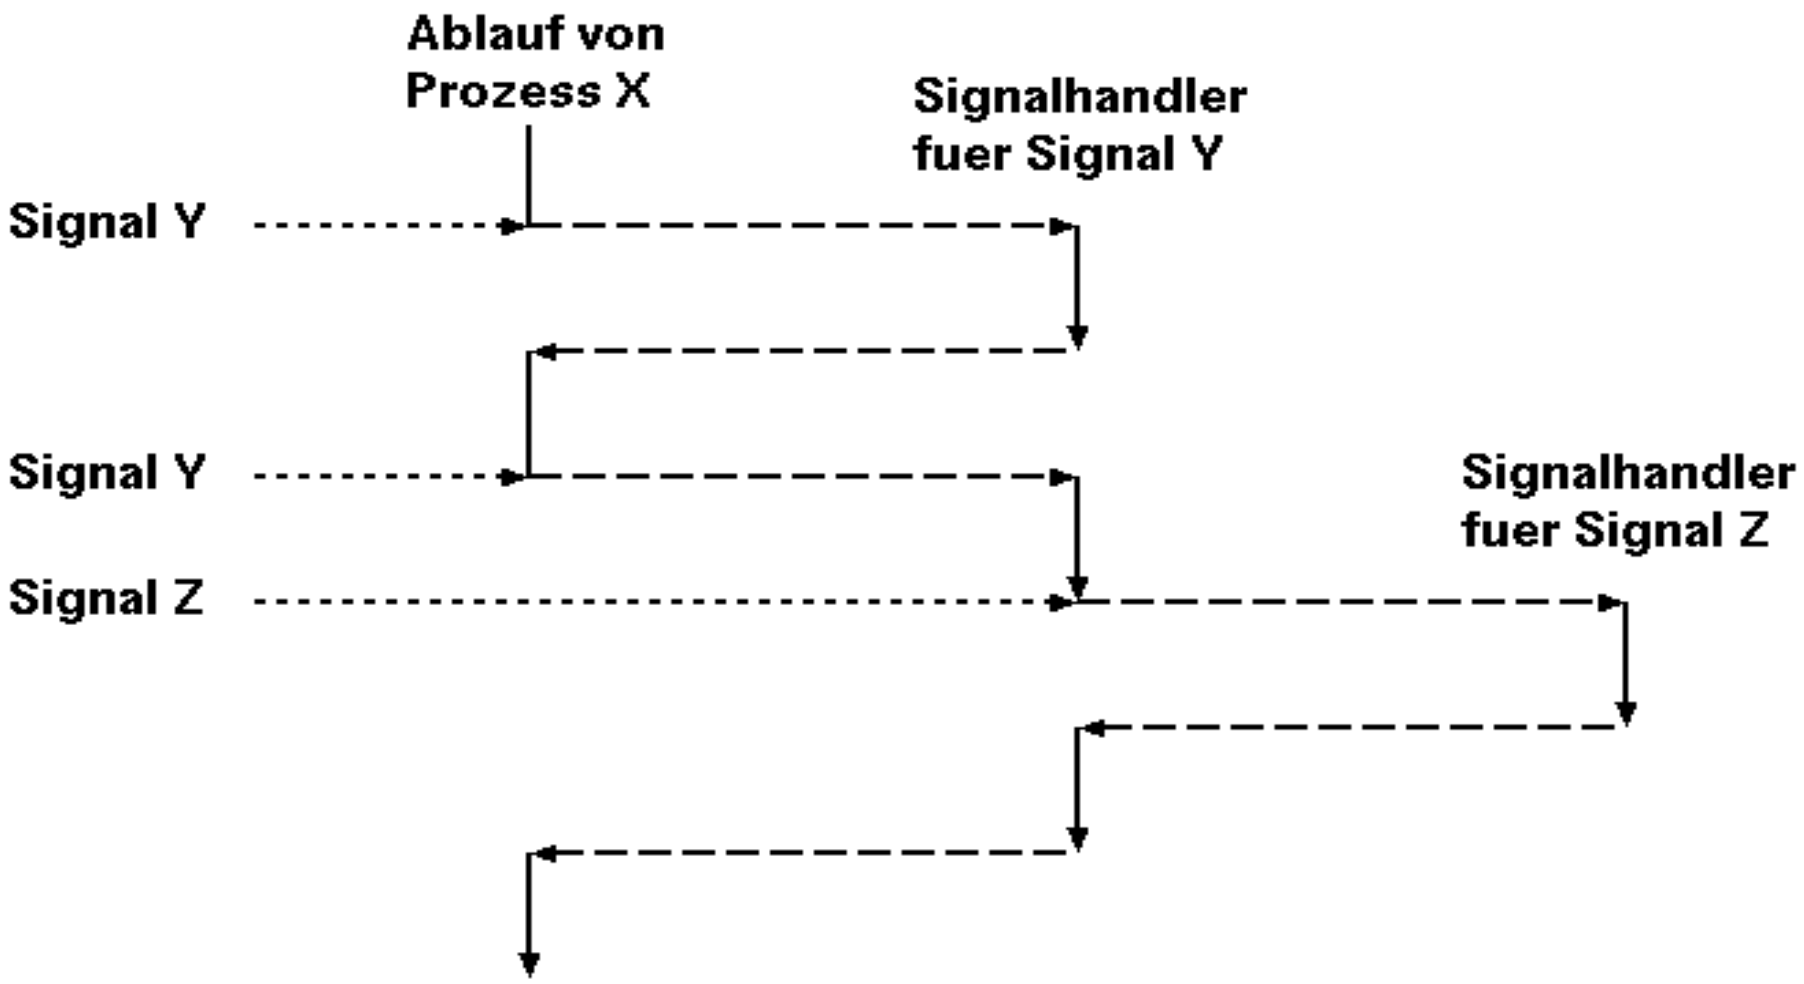
Ablauf von
Prozess X
Signalhandler
fuer Signal Y
Signal Y
Signal Y
Signalhandler
fuer Signal Z
Signal Z

Signale

- Der sendende Prozess muss die PID des Empfängers kennen.
- Der Empfänger muss Signalhandler-Funktionen einrichten
- Die Signalhandler-Funktionen müssen reentrant sein.
- Signale können keine Daten übertragen.
- Ein Prozess kann auf ein Signal warten. Prozesse können sich daher über Signale synchronisieren.

Signale

- Der Signalhandler kann eine globale Variable ändern, um „seinen“ Prozess zu informieren.
- Die globale Variable sollte (muss) atomar sein.
- Atomar les- und schreibbare Typen sind:
  - sig_atomic_t (ganzzahliger Datentyp)
  - i.Allg. int und Pointer

Funktionen: signal() aus dem ANSI-Standard, sigaction() (POSIX) unter Unix/Linux. Die Funktion signal() besitzt Schwächen.

Pipe zwischen Eltern und Kind

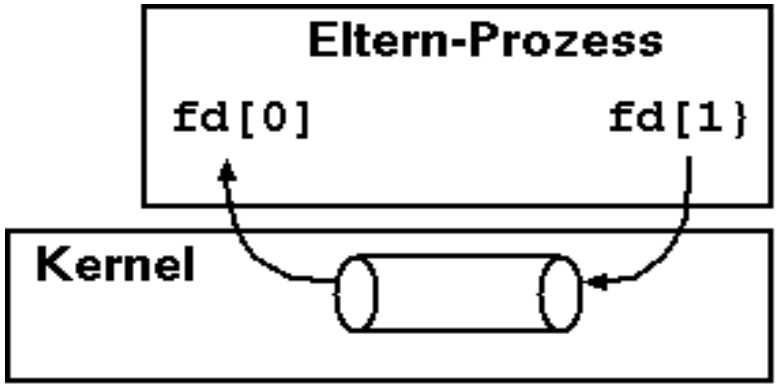

fork()

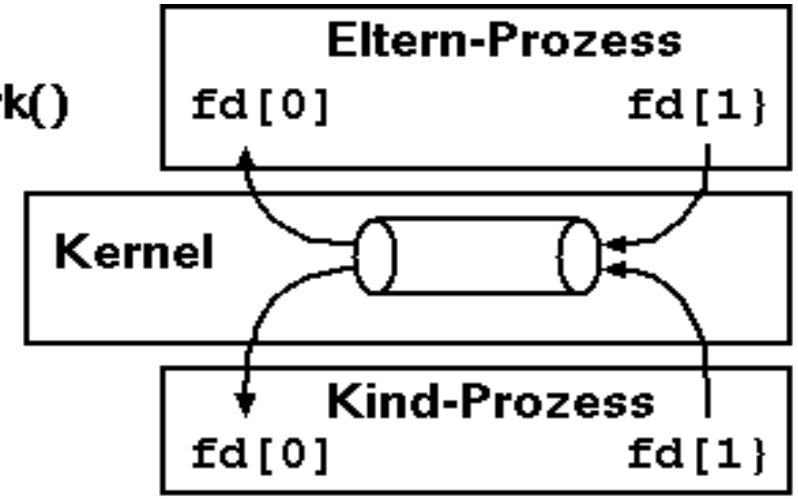

close()

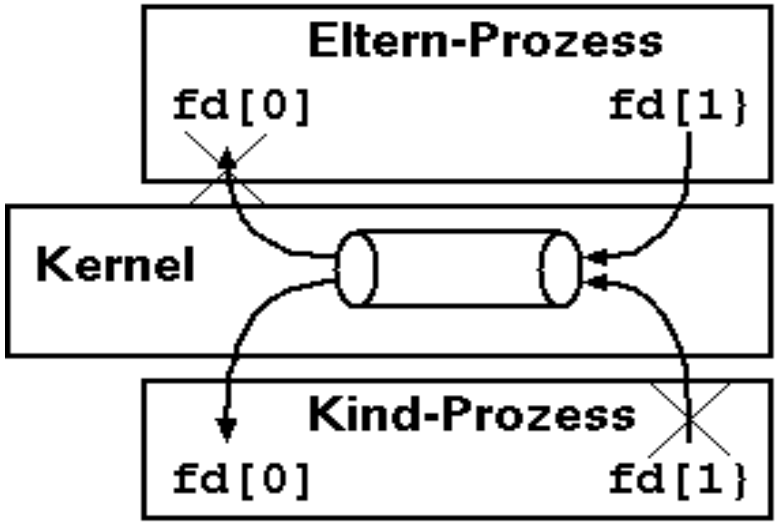

1 zu n Beziehung

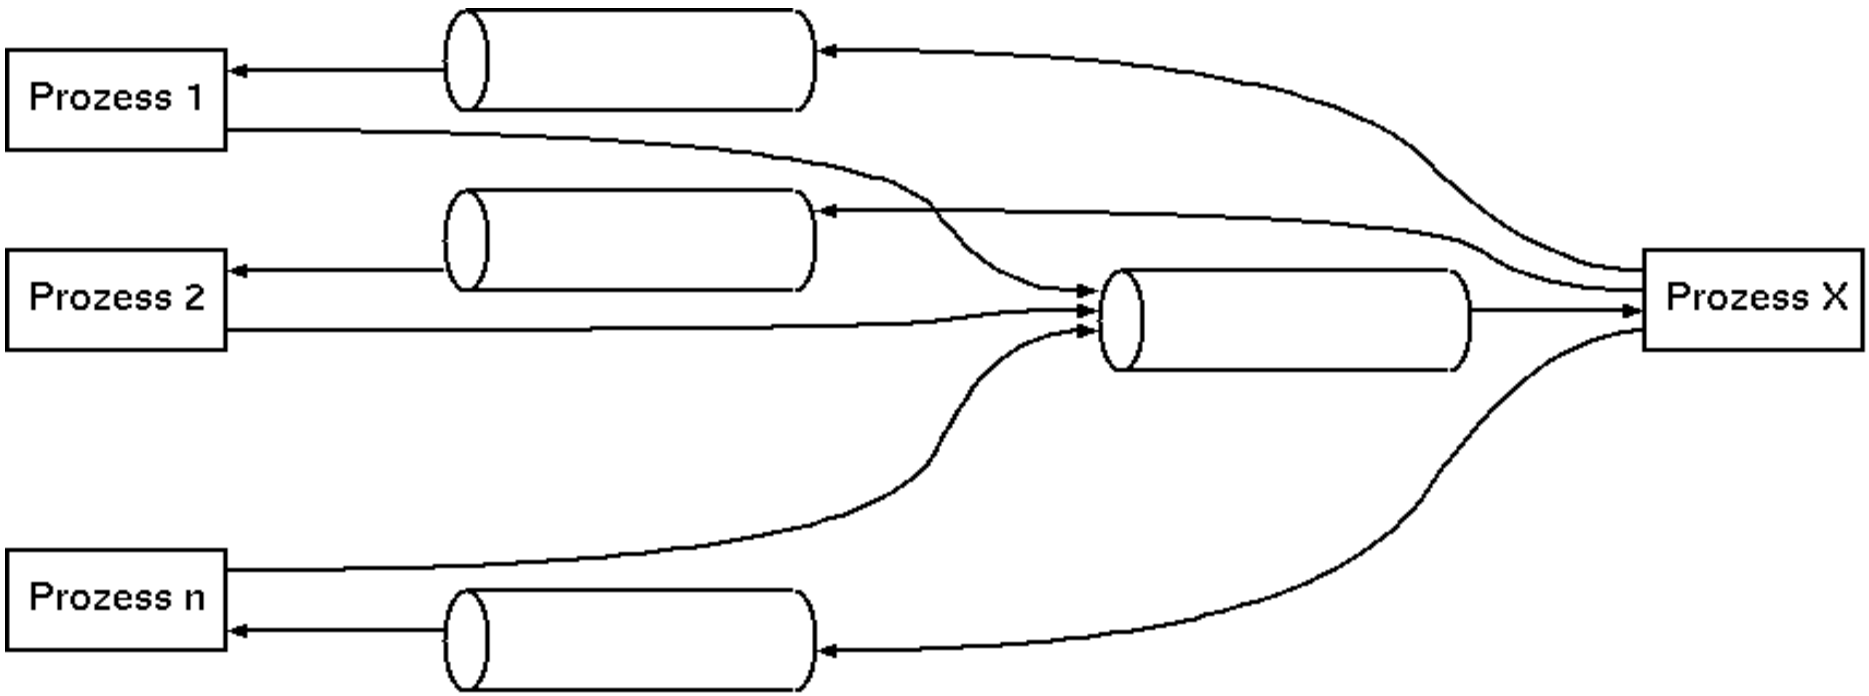

- Nachricht vom Client zum Server enthält die Client-PID
- Server wählt Rück-Kanal anhand der PID

Named Pipe / FIFO

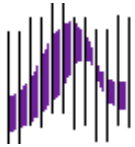

Pipe anlegen

Pipe verwenden

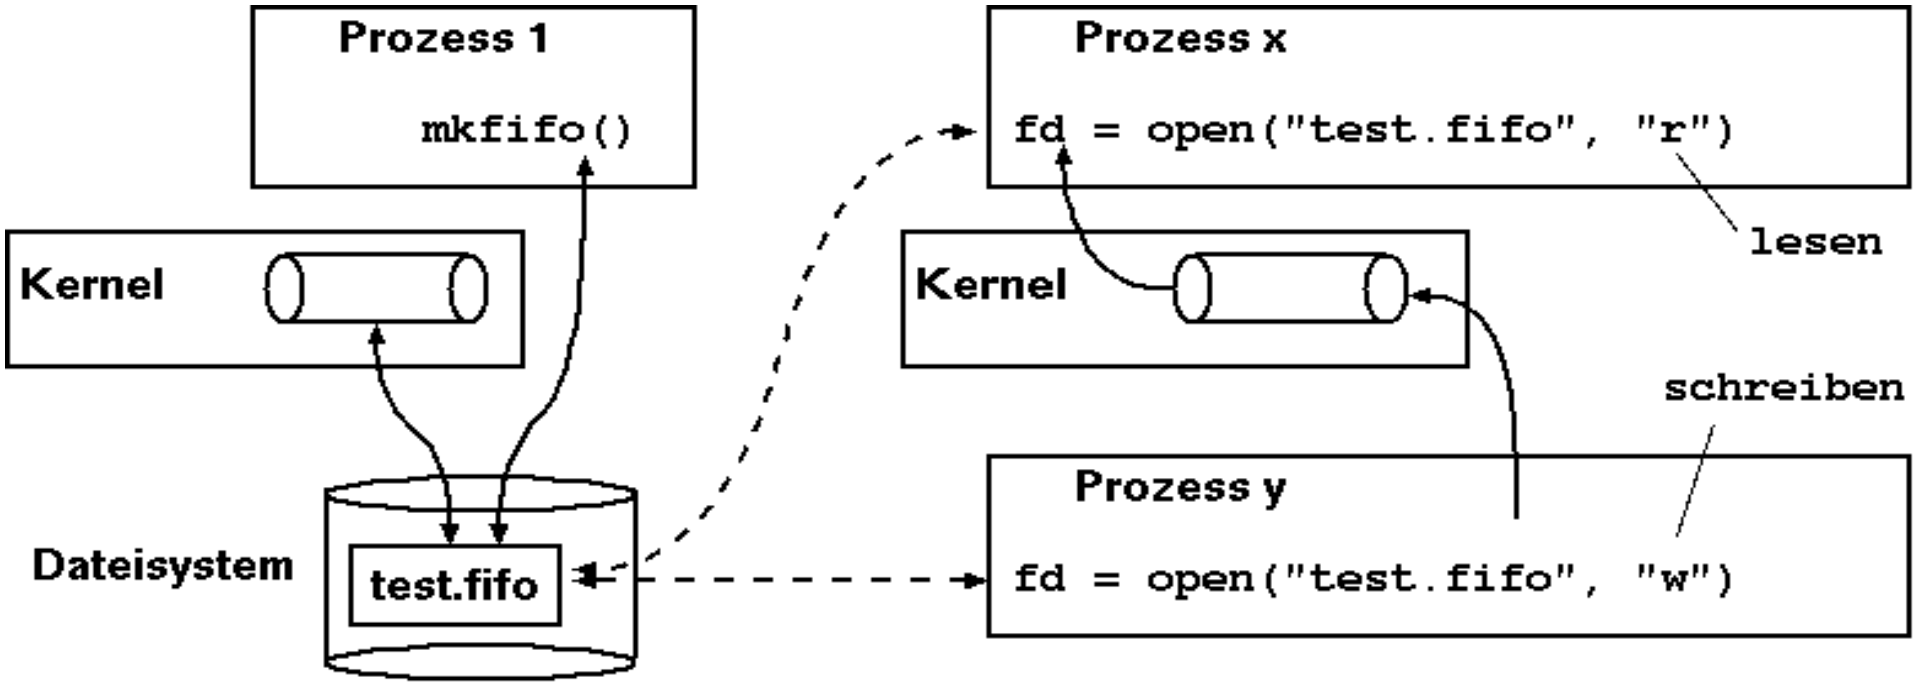

Zugriff auf Pipes

- Kernel synchronisiert „kurze“ Lese-und Schreiboperationen
- Maximale Länge: PIPE_BUF
- Längere Operationen:
  Synchronisation durch Anwendung
- Lesen entfernt Daten aus der Pipe
- Schreiben blockiert bei voller Pipe
- Lesen blockiert bei leerer Pipe

Message Queue

Nachrichten werden als Ganzes gesendet und empfangen.
Eine Nachricht besitzt ein gewisse Struktur:
Typ und Daten unmittelbar, die Länge wird beim Senden angegeben

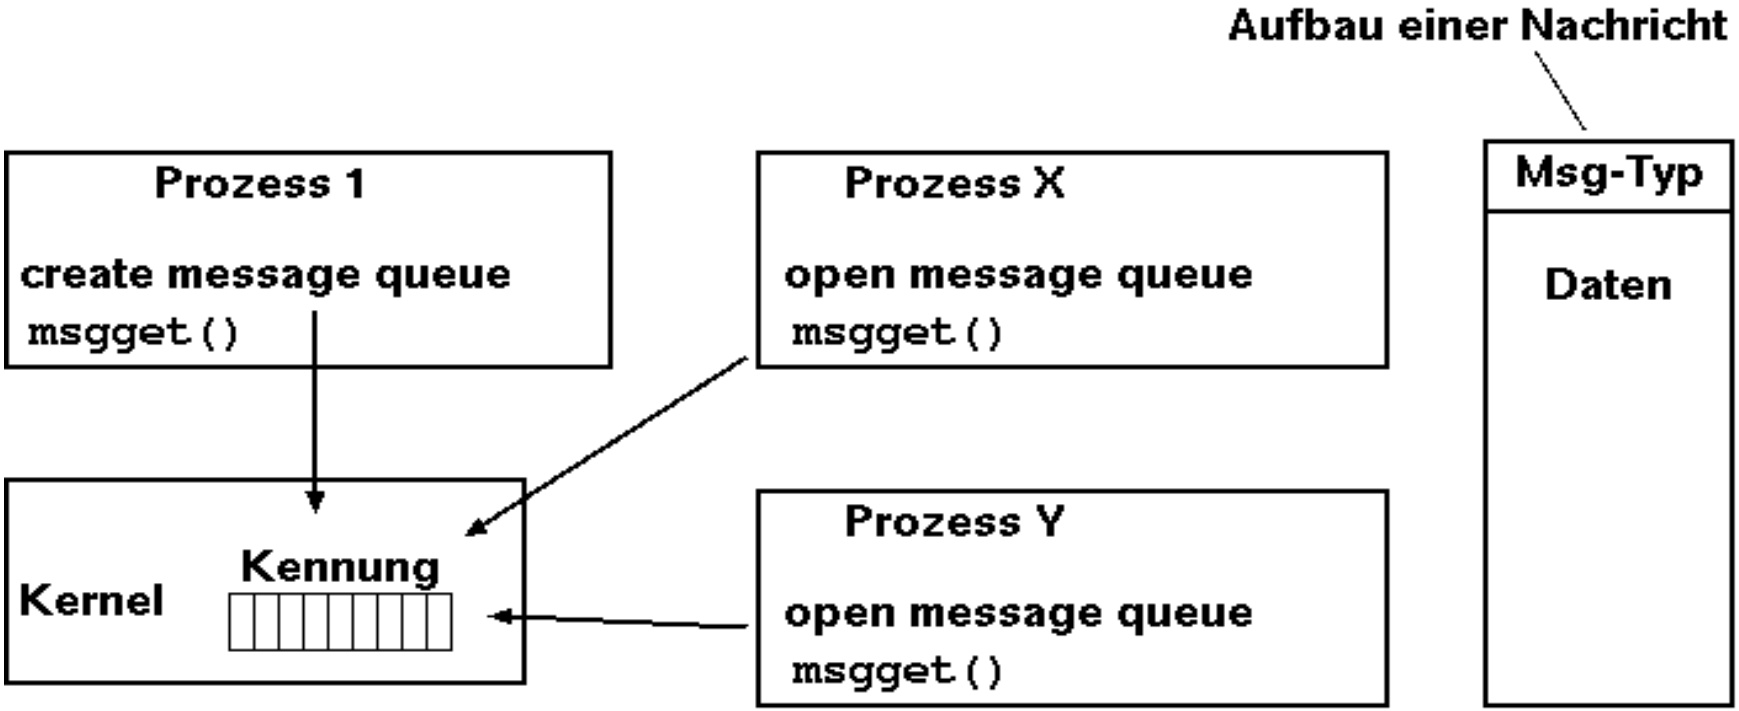

Message Queue

Funktionen zu Message Queues

- Erzeugen: system-global, Namenskonflikte können auftreten
- Löschen
- Open: Kennung muss bekannt sein
- Senden
- Empfangen
  - FIFO über alle Nachrichten
  - FIFO nach Msg-Typ getrennt

Shared Memory

- Gemeinsamer Speicherbereich für zwei oder mehrere Prozesse
- Zugriff muss synchronisiert werden
  - Semaphore
  - evtl. andere Mechanismen
- Prozesse besitzen einen Pointer auf den Anfang des Speicherbereichs.
- Synchronisation und Strukturierung bzw. Interpretation des Speicherbereichs ist Sache der Anwendung
- Schnellste Form der Interprozesskommunikation

Shared Memory

Funktionen:

- Einrichten Shared Memory Segment anlegen
- Anbinden (Pointer setzen)
- Löschen

Ggf. werden zwei Shared Memory Segmente angelegt, um die Synchronisation zu vereinfachen.

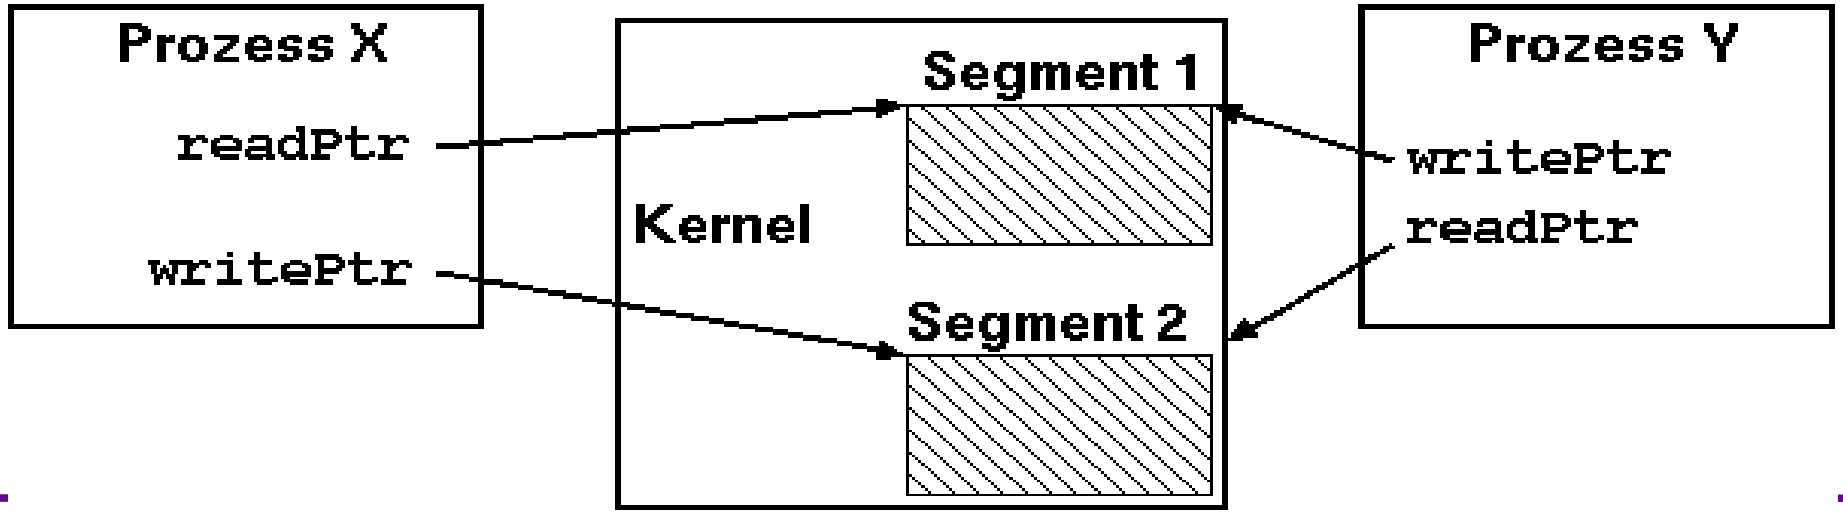

Shared Memory – Producer Consumer

Shared Memory Segment als Puffer eines Producer-Consumer-Systems

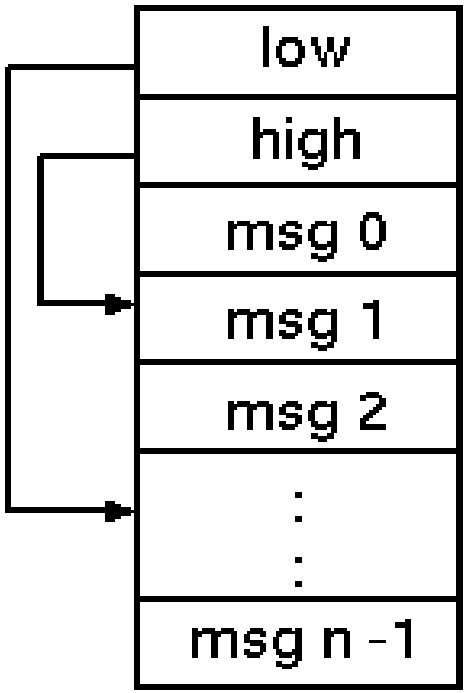

- Semaphore: Mutex, Full, Empty
- Zeiger auf erstes und letztes Element sind Teil des Shared Memory

```
struct shm_buffer{
    int high;
    int low;
    IPC_MSG messages[n];
};
```

Sockets

- Schnittstelle zwischen einem Prozess und einem Transportprotokoll
- Bidirektional, Stream-Schnittstelle
- Kommunikation innerhalb eines Rechners und über Netzwerk
- Transportprotokoll z.B. TCP oder UDP
  Unix Domain Sockets: Transport durch Kernel
- Adressierung z.B. über Host-Adresse und Port
  Unix Domain Sockets: Dateisystem

Sockets

- ServerSocket
  wartet auf Verbindungsanfragen
- ClientSocket
  versucht eine Verbindung herzustellen

Wenn der ServerSocket eine Verbindungsanfrage erhält, erzeugt er einen ClientSocket, der die Verbindung repräsentiert.

Sockets 2

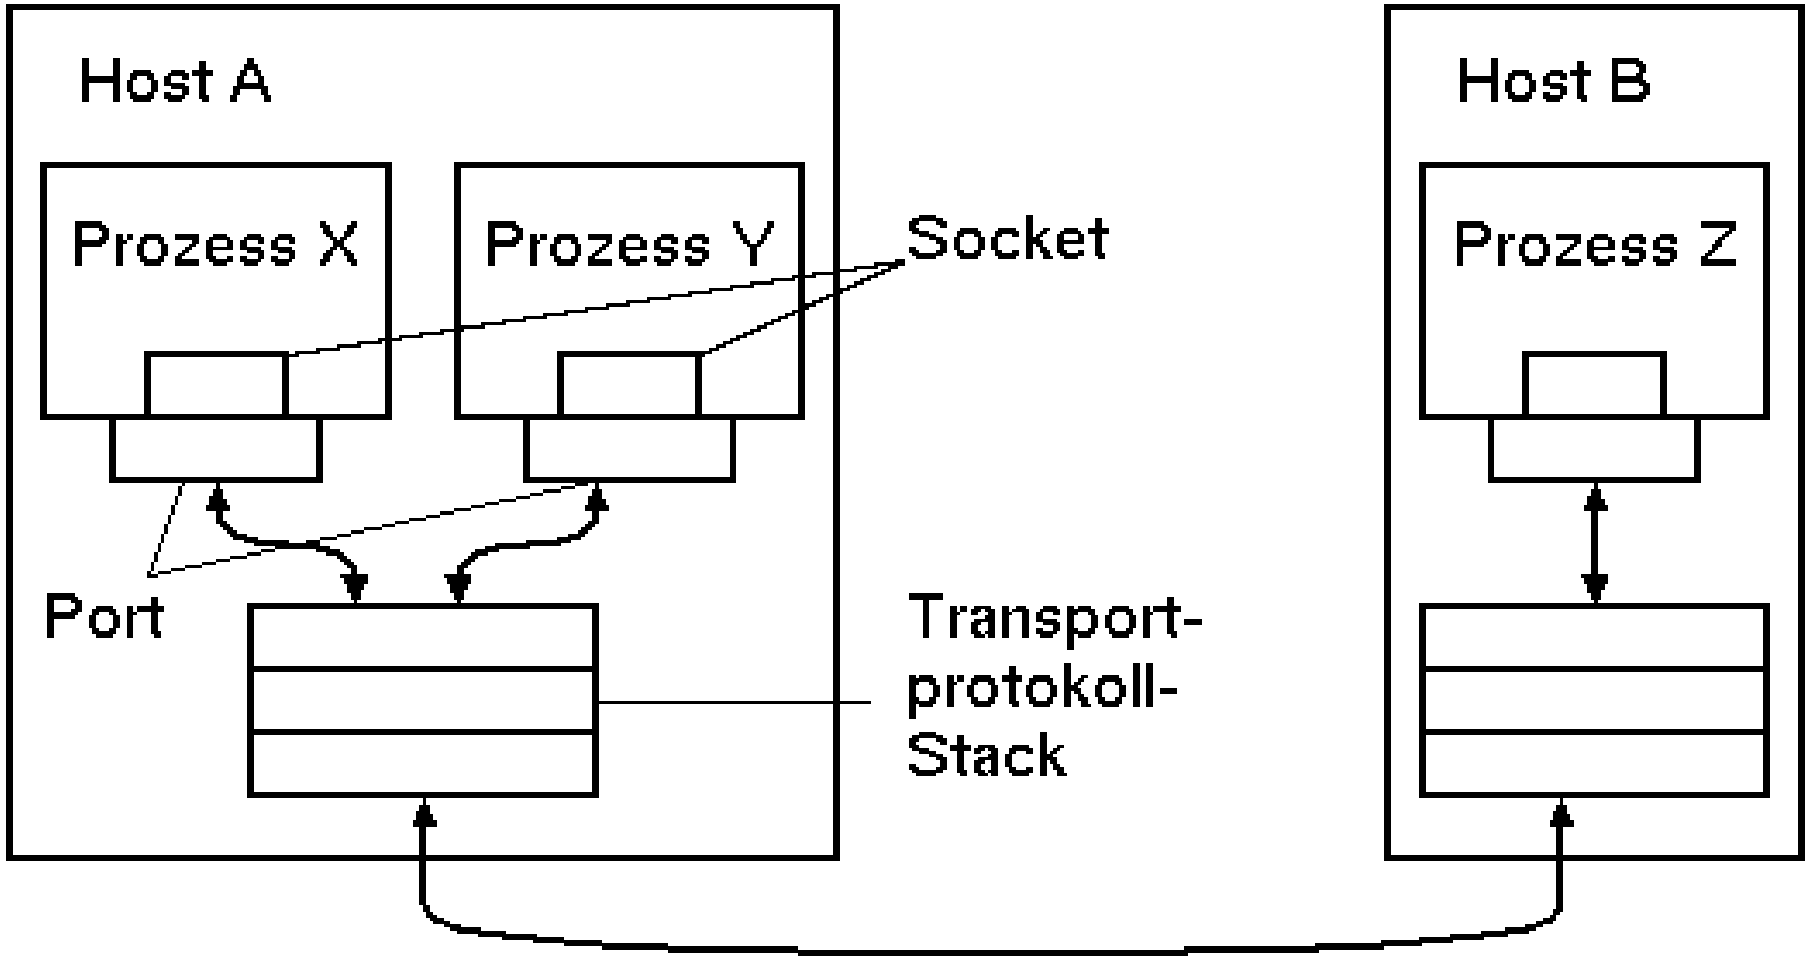
Host A
Prozess X
Prozess Y
Socket
Port
Transport-
protokoll-
Stack
Host B
Prozess Z

Sockets: Network Byte Order

- Austausch von Daten zwischen unterschiedlichen Systemen (Little Endian, Big Endian)
- Daten werden zur Übertragung einheitlich kodiert. Kodierung ist Sache der Anwendung.
- Umwandlungsfunktionen:
  hton (HostToNetwork) ntoh (NetworkToHost)
  für 32- und 16-Bit-Zahlen

Ein- und Ausgabe

Aufgaben des Betriebssystems

- Überwachung und Steuerung von Geräten
  - Befehle und Daten an Geräte übermitteln
  - Daten und Statusmeldungen entgegennehmen
- Schnittstellen für Anwendungsprogramme
  - möglichst alle Geräte einheitlich ansprechbar
  - Innerer Aufbau soll verborgen bleiben

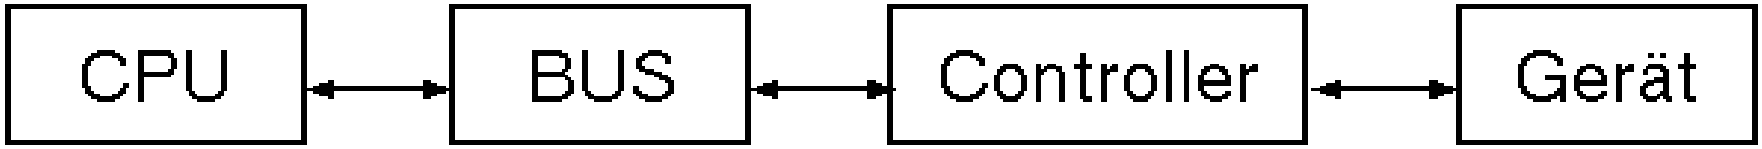

Aufbau eines Rechners

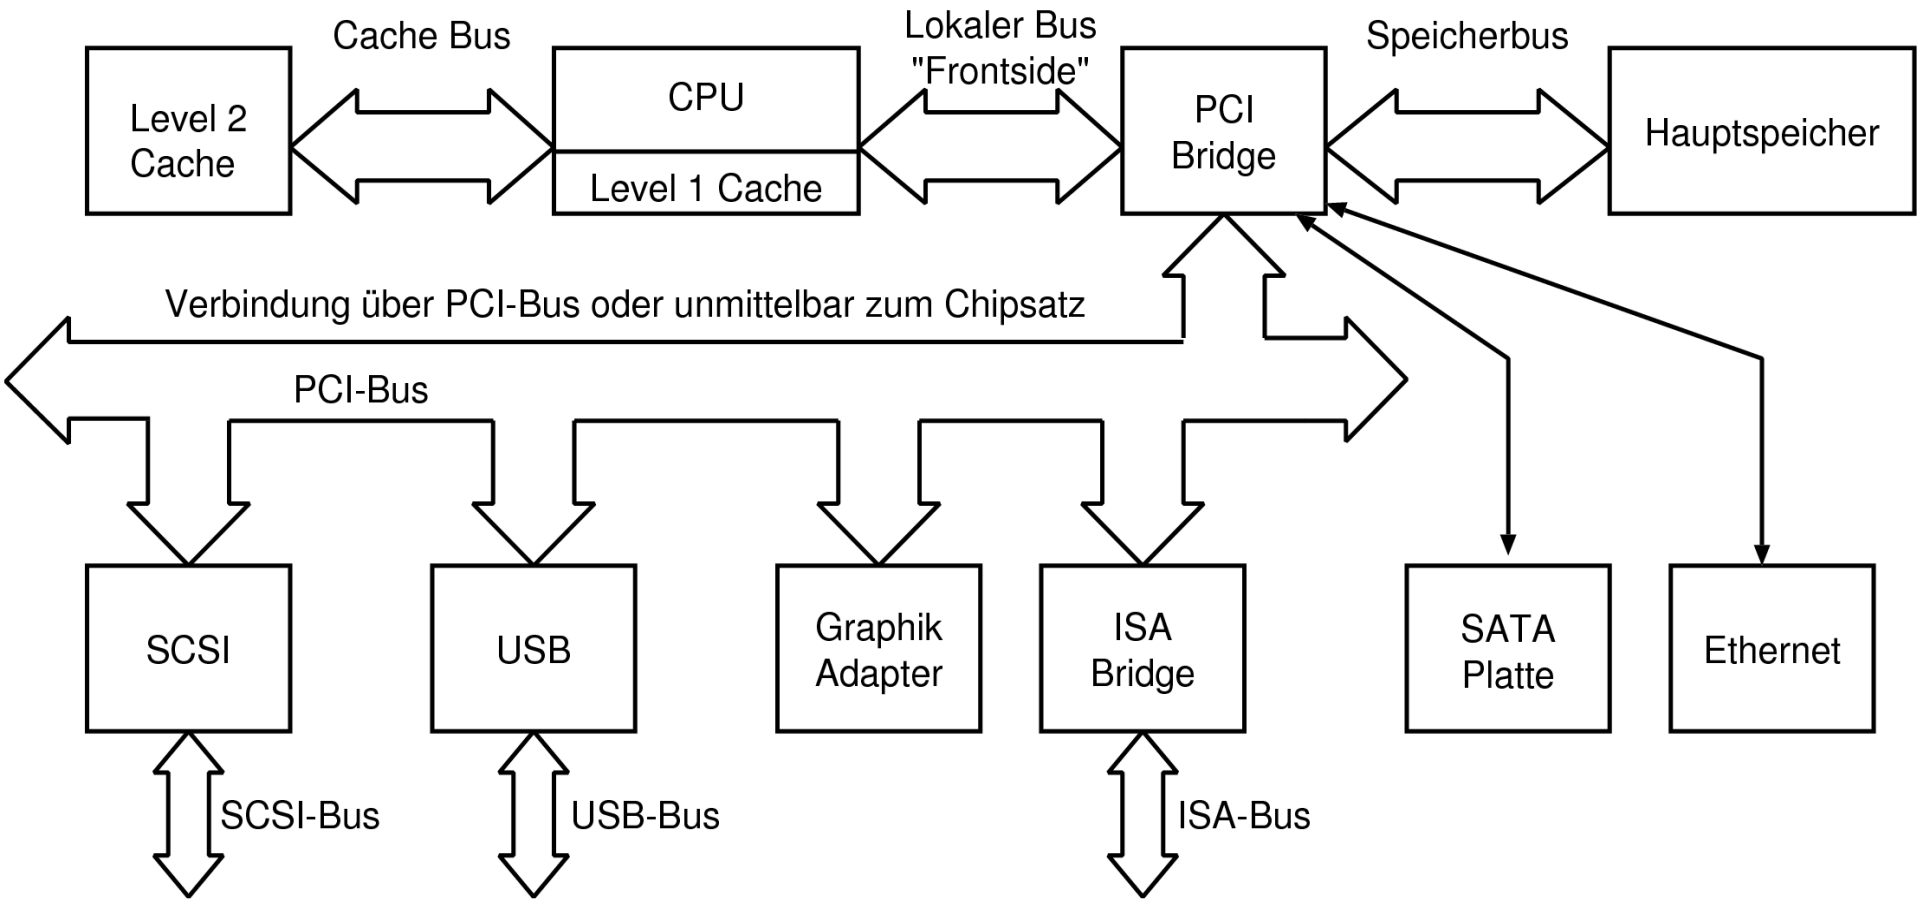

Ein- und Ausgabe Geräte

- Blockorientierte Geräte
  - Daten-Blöcke können adressiert werden
  - Festplatte, SSD
  - Memory-Stick, etc.
- Zeichenorientierte Geräte
  - Fortlaufende Ein- oder Ausgabe
  - Netzwerkkarte (unter Linux eine eigene Kategorie)
  - Drucker
  - Maus, Tastatur, etc.
- Sonstige Geräte
  - Uhr, Bildschirm

Ein- und Ausgabe Geräte

Geräte werden über Geräte-Register gesteuert

- I/O-Ports
  - Eigene Assembler-Befehle (Zugriff beschränken)
  - Eigener Adressraum
  - Programmierung mit Assembler („in/out <reg> <port>“)
- Memory mapped
  - Teil des Adressraums wird auf Geräte-Register abgebildet
  - in C programmierbar
  - Caching muss für I/O-Adressen ausgeschaltet werden
  - Adressen müssen erkannt werden
    (z.B. in der PCI-Bridge: I/O-Adressen beim Booten laden)

Schnittstelle zum Anwendungsprogramm

- Einheitlicher Namensraum
  - „mounten“ von Geräten (blockorientierte Geräte)
- Fehlerbehandlung
  - nur nicht-behebbare Fehler melden
- Pufferung
- Synchrone Schnittstelle für asynchrone I/O-Operationen
  - Lesefunktion blockiert, bis Daten verfügbar sind
- Gemeinsamer oder exklusiver Zugriff auf Geräte
  - z.B. Festplatte vs. Bandlaufwerk

Aufbau des I/O-Systems

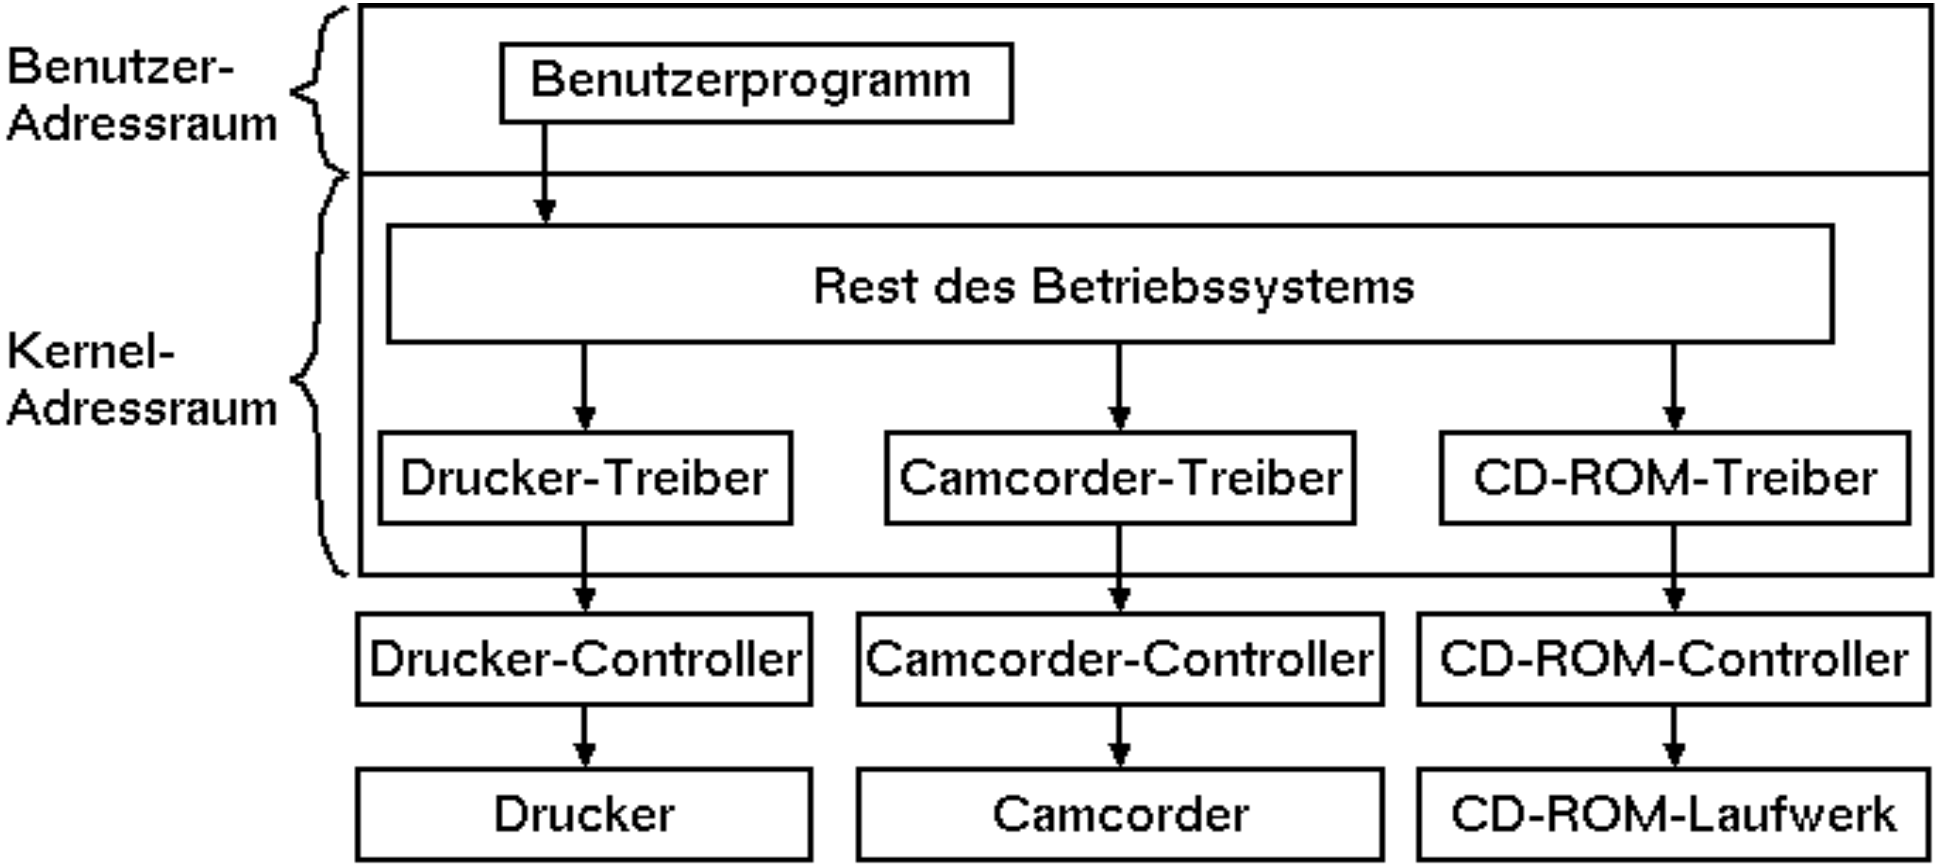

Alternativer Aufbau (Micro Kernel)

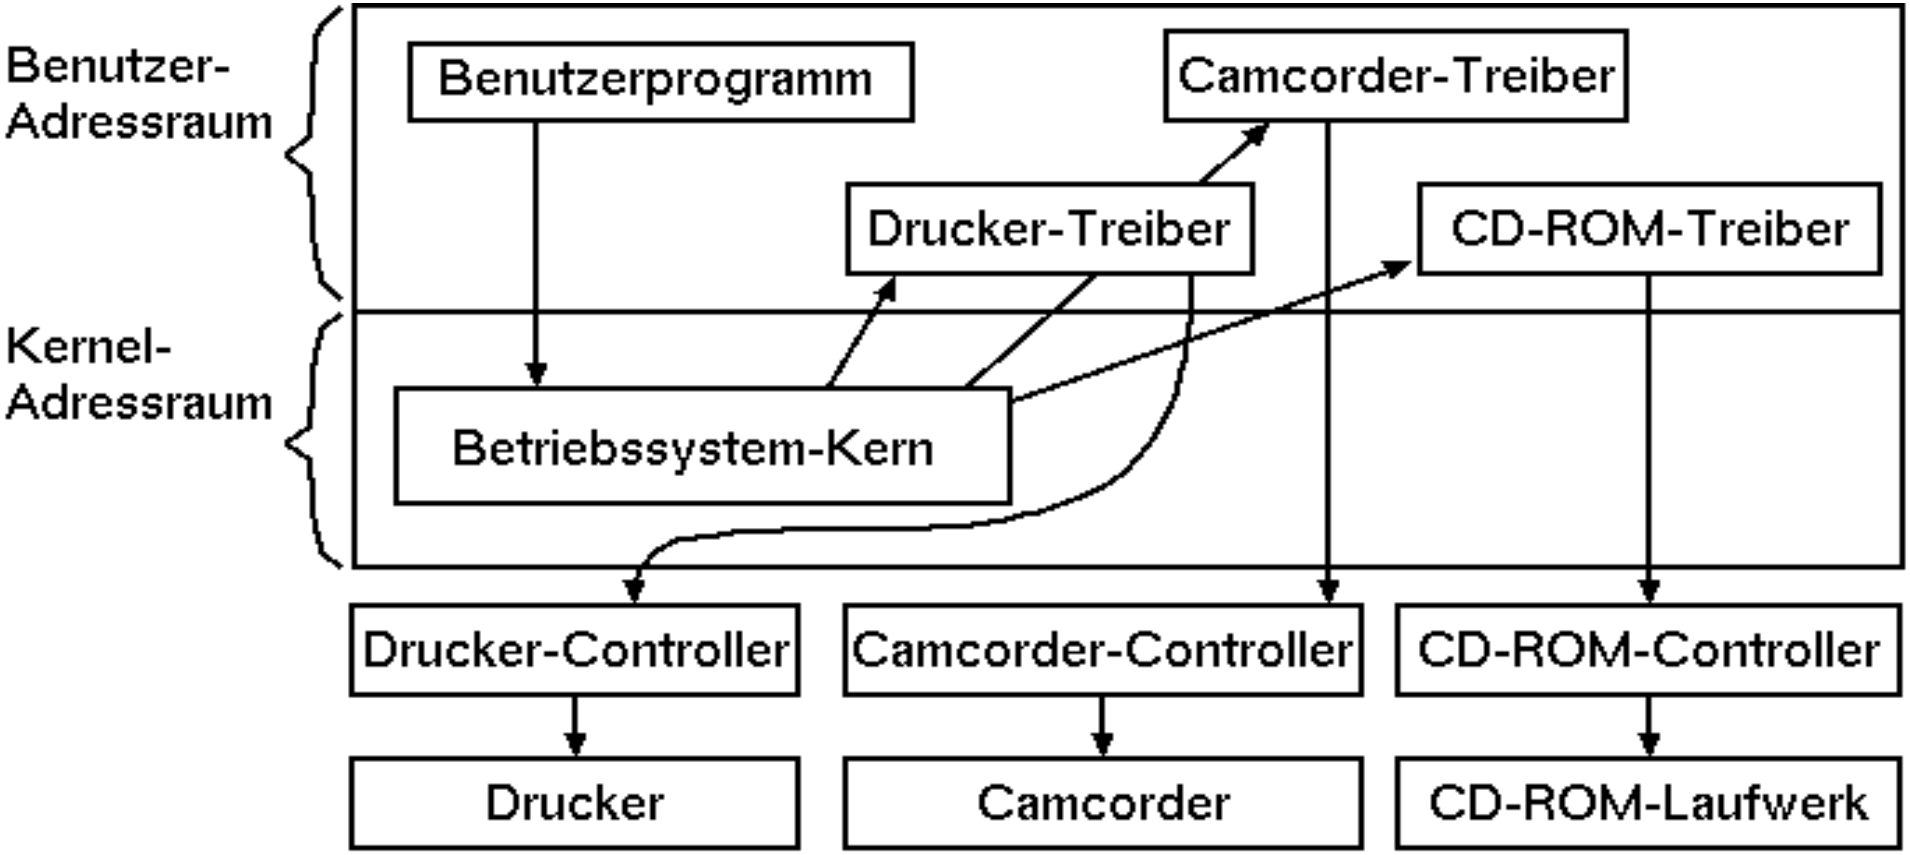

Ein-/Ausgabe-Konzepte

- Programmierte Ein-/Ausgabe
  (1) Der Prozess überträgt Daten-Wort zu Gerät
  (2) Der Prozess fragt Gerät ab und geht zu (1) oder (2)
- Interruptgesteuerte Ein-/Ausgabe
  Für jedes Gerät wird eine Interrupt-Routine eingerichtet
  (1) Prozess überträgt Daten in den Kernel
  (2) Der Prozess überträgt 1. Daten-Wort zu Gerät
  (3) Der Prozess lässt sich blockieren
  (4) Das Gerät sendet einen Interrupt
  (5) Eine Unterbrechungsroutine überträgt das nächste Wort zum Gerät (weiter mit (3)) oder fertig.
- Direct Memory Access
  Wie Programmierte Ein-Ausgabe mit eigenem Prozessor

Interrrupt gesteuerte Ein-/Ausg.

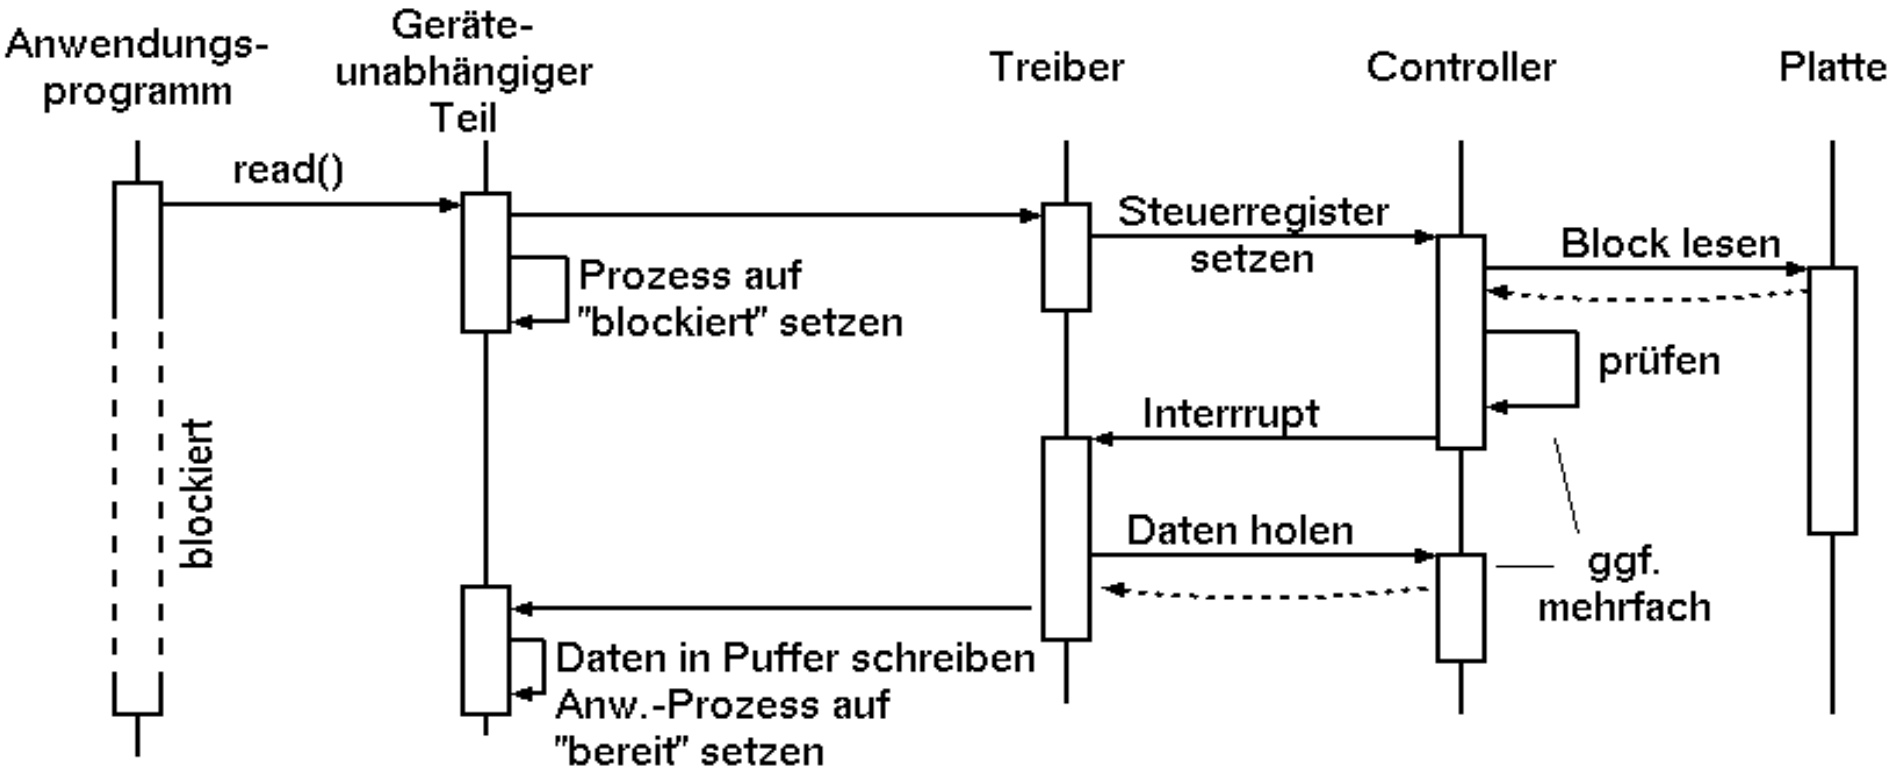

Direct Memory Access

Viele Rechner nutzen einen DMA-Controller, um den Prozessor von der Ein- und Ausgabe zu entlasten.
Funktionsweise:

(1) CPU beauftragt DMA-Controller
(meist mit physischen Adressen)

(2) DMA-Controller beauftragt Geräte-Controller

(3) Gerät überträgt Daten und meldet Ende an DMA-Controller

(4) Zurück zu Schritt (2) oder zu (5)

(5) DMA-Controller benachrichtigt CPU

Zu (3): Übertragung von einzelnen Worten oder von Seiten, direkt in den Speicher oder über den DMA-Controller

Direct Memory Access

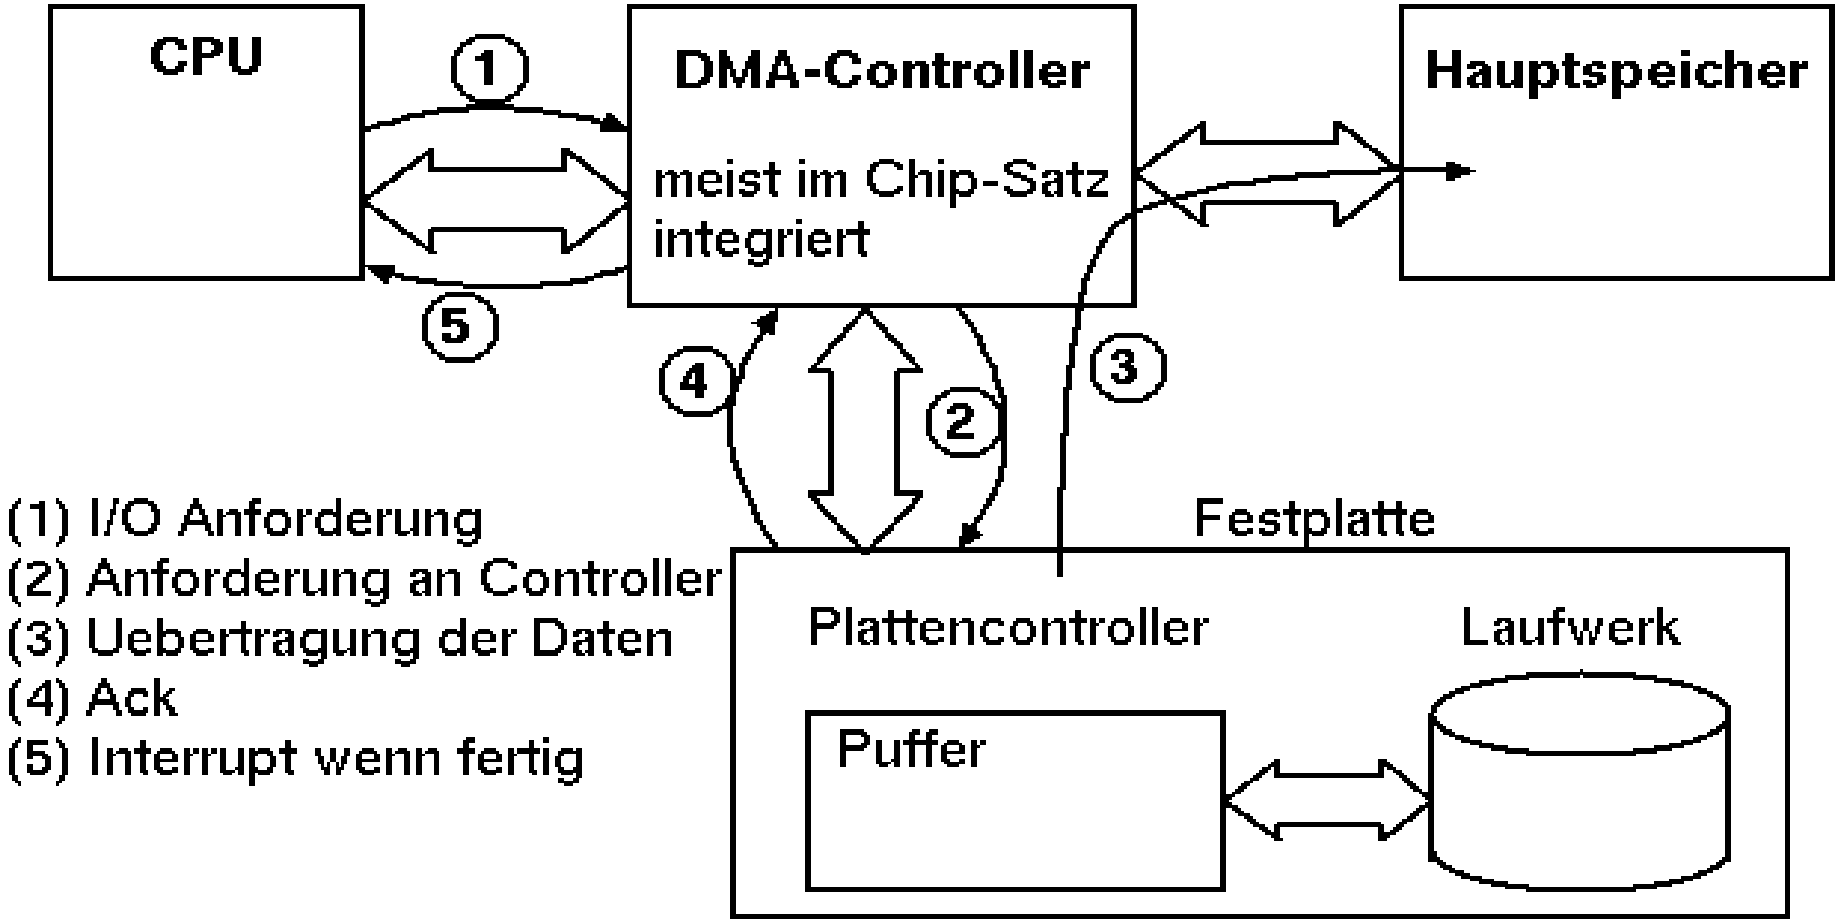

(1) I/O Anforderung
(2) Anforderung an Controller
(3) Uebertragung der Daten
(4) Ack
(5) Interrupt wenn fertig

Eingabe-Pufferung

- Keine Pufferung:
  Der Benutzerprozess empfängt jedes Wort einzeln.
- Pufferung im Benutzeradressraum:
  Die I/O-Routine kopiert Worte in den Puffer ohne, dass der Benutzerprozess läuft.
- Pufferung im Kernel:
  Die I/O-Routine legt die Daten in einen Kernel-Puffer. Wenn dieser voll ist, wird der Inhalt in den Benutzeradressraum kopiert
- Doppelte Pufferung im Kernel: Wenn der eine Puffer voll ist, schreibt die I/O-Routine in den zweiten. Währenddessen wird der 1. Puffer kopiert.

Pufferung der Eingabe

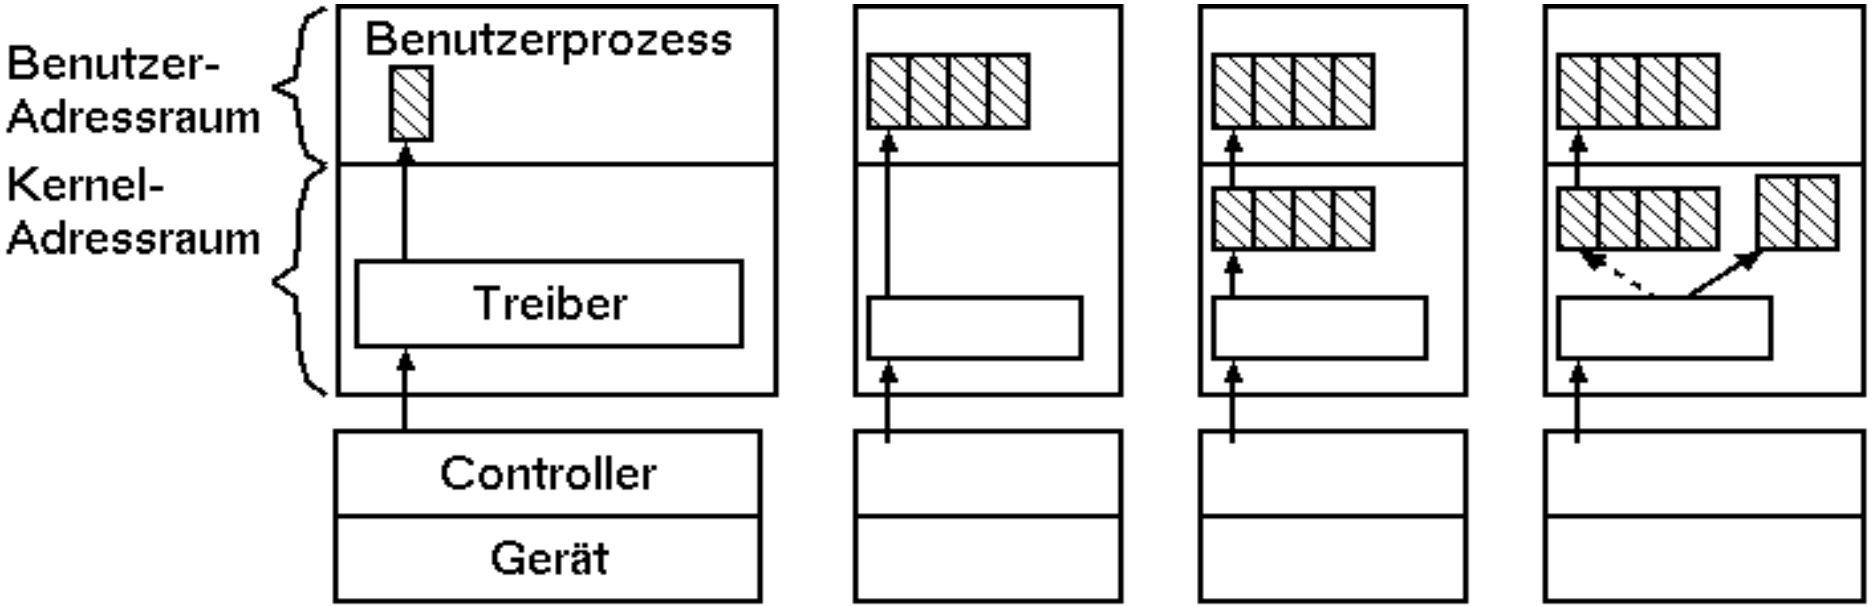

Datei-Systeme

Persistente Speicherung von Daten in Dateien

- Nutzersicht
  - Datei-Operationen
  - Benennung von Dateien (i.Allg. hierarchisch)
  - Typen von Dateien (strikte vs. nichtstrikte Typisierung)
  - Zugriffssteuerung (Rechte-Vergabe)
- Systemsicht
  - Abbildung der Geräte-Schnittstellen auf die Datei-System-Schnittstelle

Festplatten

Aufbau

- Mehrere Platten, magnetisch beschichtet
- Konzentrische Spuren auf jeder Plattenseite
- Jede Spur ist in Sektoren unterteilt
- Ein Zylinder ist die Zusammenfassung aller k-ten Spuren der n Plattenseiten

Typische Größen (2008)

- 2- 6 Platten d.h. 4 - 12 Plattenseiten
- 10000 Zylinder
- 100 – 200 Sektoren pro Spur
- 8 – 32 MB Pufferspeicher

Festplatten

Weitere typische Größen (2008)

- mittlere Zugriffszeit: 5 - 8ms
  (CPU: 10 - 20 Millionen Instruktionen)
- Transferrate: 50 - 100MB/s
- Caching für Schreibfunktionen abschaltbar
- Sektorgröße: 512Byte, 4KB

Formatierung

logisches Format

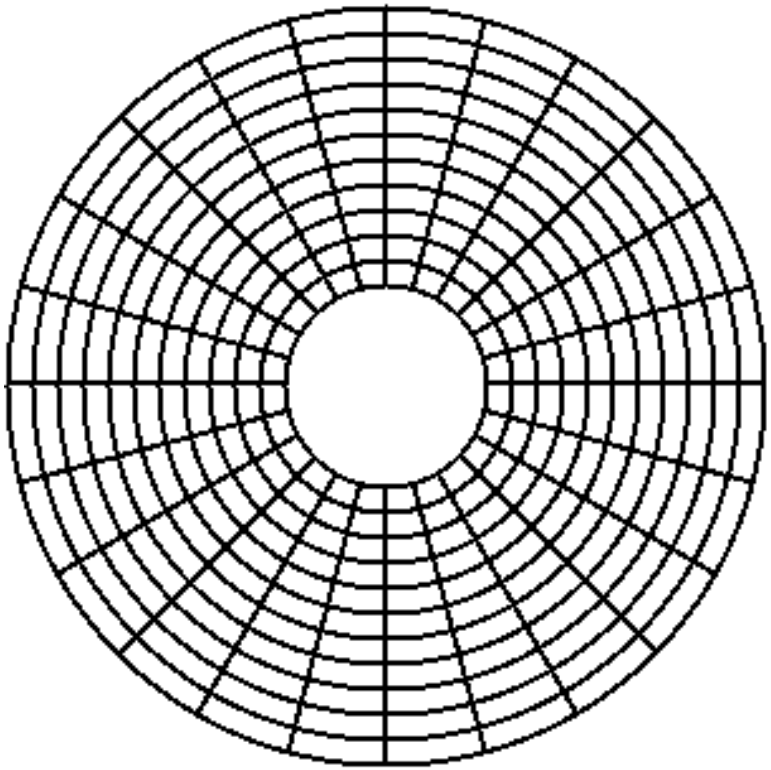

physikalisches Format

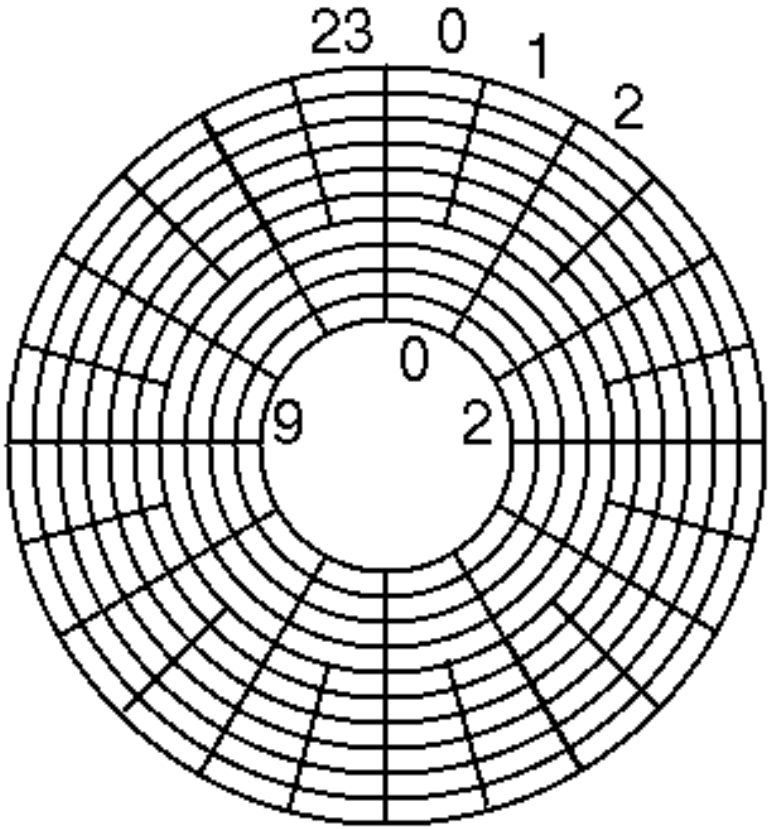

Festplatten

Pufferung im Controller

- Fehlererkennung bzw. Korrektur
- Angleichung der Übertragungsgeschwindigkeit
- Optimierung der Kopfbewegung
  - Aufzug-Algorithmus
  - Weitere Optimierungen

CD (ROM, RW)

Eine Spur als Spirale ca. 5,6 km

Einfache Geschwindigkeit ca. 4,3 km/h

Fehlererkennung und -korrektur in drei Stufen

1) Ein Byte wird in 14 Bit codiert
2) Ein Rahmen enthält 42 Byte (je 14 Bit) und 252 zusätzliche Korrektur-Bits
3) Ein Sektor enthält 98 Rahmen und 288 zusätzliche Korrektur-Bits (ein von zwei Layouts)
   Cross Interleaved Reed-Solomon-Code

Stufe 1) und 2) gemäß Audio-CD, Stufe 3) zusätzlich für Daten. Insgesamt belegt die Fehlerkorrektur ca. 72% der Kapazität.

Aufteilung einer Festplatte

Ein weit verbreitetes Layout für Festplatten:

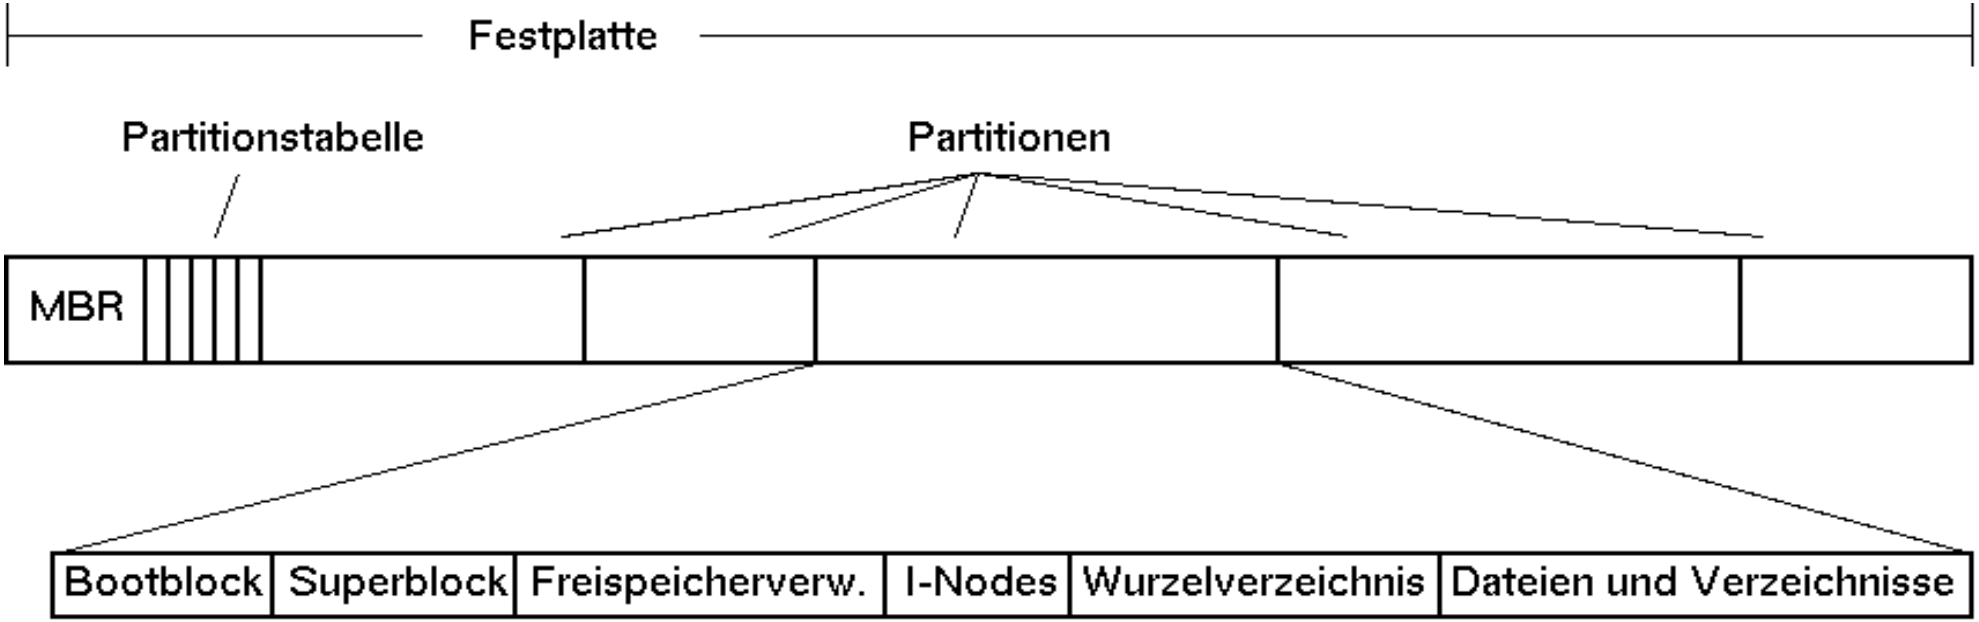

MBR: Master Boot Record
Der Superblock identifiziert den Dateisystemtyp

Partitionen

- Windows, Unix, MacOS, ...
  - 4 primäre Partitionen
  - 3 primäre Partitionen und mehrere logische Partitionen (i. Allg. bis zu 64)
- Jede Partition kann (maximal) ein eigenes Dateisystem enthalten.
- logical volume / storage pool
  - Zusammenfassung mehrerer Partitionen
  - Verwaltung durch *ein* Dateisystem

Booten von der Festplatte

- BIOS lädt MBR und führt ihn aus
- MBR-Prog. lokalisiert aktive Partition und lädt Boot-Block
- Der Boot-Block lädt das Betriebssystem oder einen Boot-Loader

Einordnung des Dateisystems

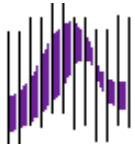

Anwendungsprogramm	
	open(), close(), fread() etc.
Dateisystem	
	blockorientierter Speicher, z.B. Gerät, Partition, Pool (read, write für Blöcke)
Treiber, LVM, Storage-Pool	
	logisches Layout
Controller	
	physisches Layout
Platte	

Datei-Operationen

- Erzeugen (auch Verzeichnisse)
- Löschen (auch Verzeichnisse)
- Öffnen
- Schließen
- Lesen
- Schreiben
- Anfügen
- Positionieren
- Attribute abfragen/setzen (auch Verzeichnisse)
- Umbenennen (auch Verzeichnisse)

Datei-Typen

- reguläre Dateien
  - z.B. für Daten des Benutzers
- Verzeichnisse
  - verwalten bzw. strukturieren das Dateisystem
- Links (hard- bzw. soft-)
  - Verweise auf andere Dateien
- spezielle Dateien
  - Schnittstelle zu zeichenorientiertem Gerät
  - Schnittstelle zu blockorientiertem Gerät
  - Pipes, Shared Files, . . .

Beispiele für Datei-Typen

- reguläre Datei
  -rw-r--r-- 1 martin martin 3,6K 2008-12-23 10:41 print.ps
- Verzeichnis
  drwxr-xr-x 5 martin martin 4.0K 2008-12-09 12:27 tmp
- Soft-Link
  lrwxrwxrwx . . . 11 2008-12-23 10:44 www -> public_html
- spezielle Dateien
  - Schnittstelle zu zeichenorientiertem Gerät
    crw-rw-rw- 1 root tty 5, 0 2008-12-22 10:35 /dev/tty
  - Schnittstelle zu blockorientiertem Gerät
    brw-rw---- 1 root disk 3, 2 2008-12-22 10:35 /dev/hda2
  - Named Pipe
    prw-r----- 1 martin martin 0 2008-12-09 12:29 test.fifo

Aufbau des Dateisystems - Verzeichnisse

Einstufiges Dateisystem

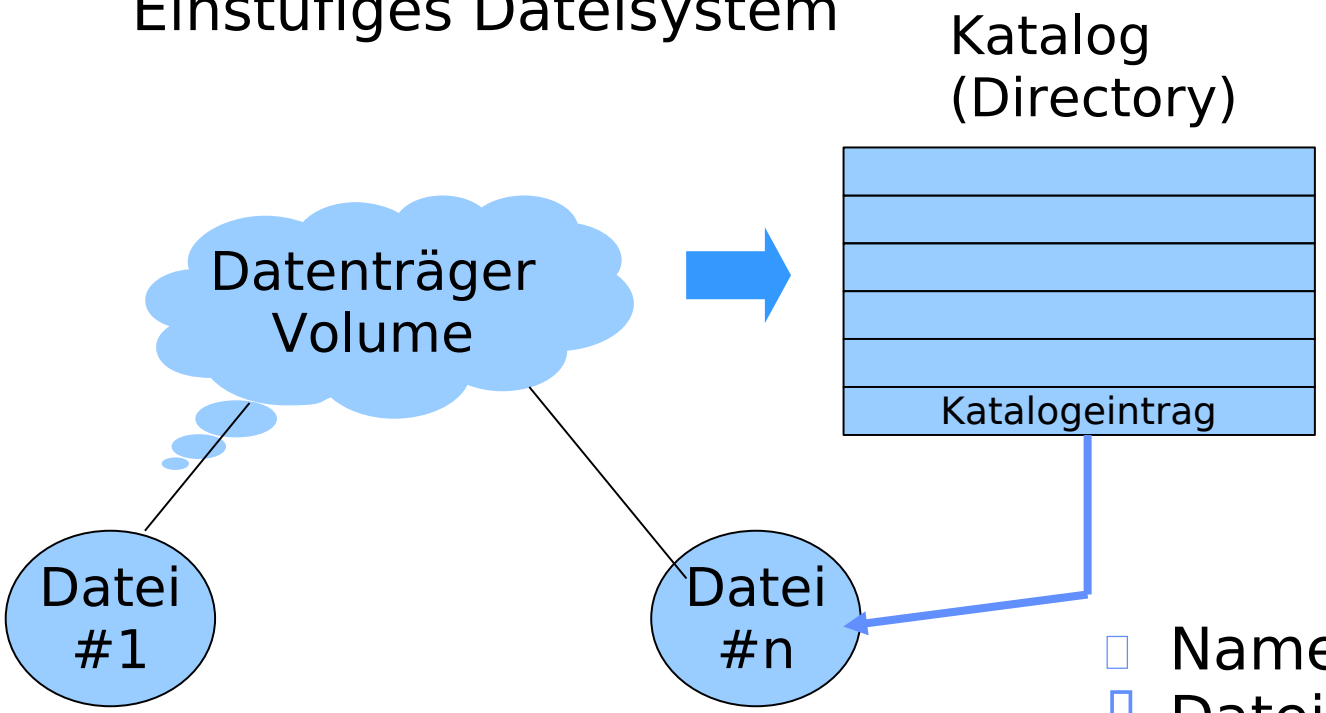

- Inhaltsverzeichnis des Volume
- Verwaltung der Dateien
- Pro Datei genau 1 Eintrag

- Name der Datei
- Dateiattribute
- Ort der Daten auf dem Volume

Aufbau des Dateisystems - Verzeichnisse

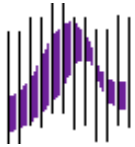

Zweistufiges Dateisystem

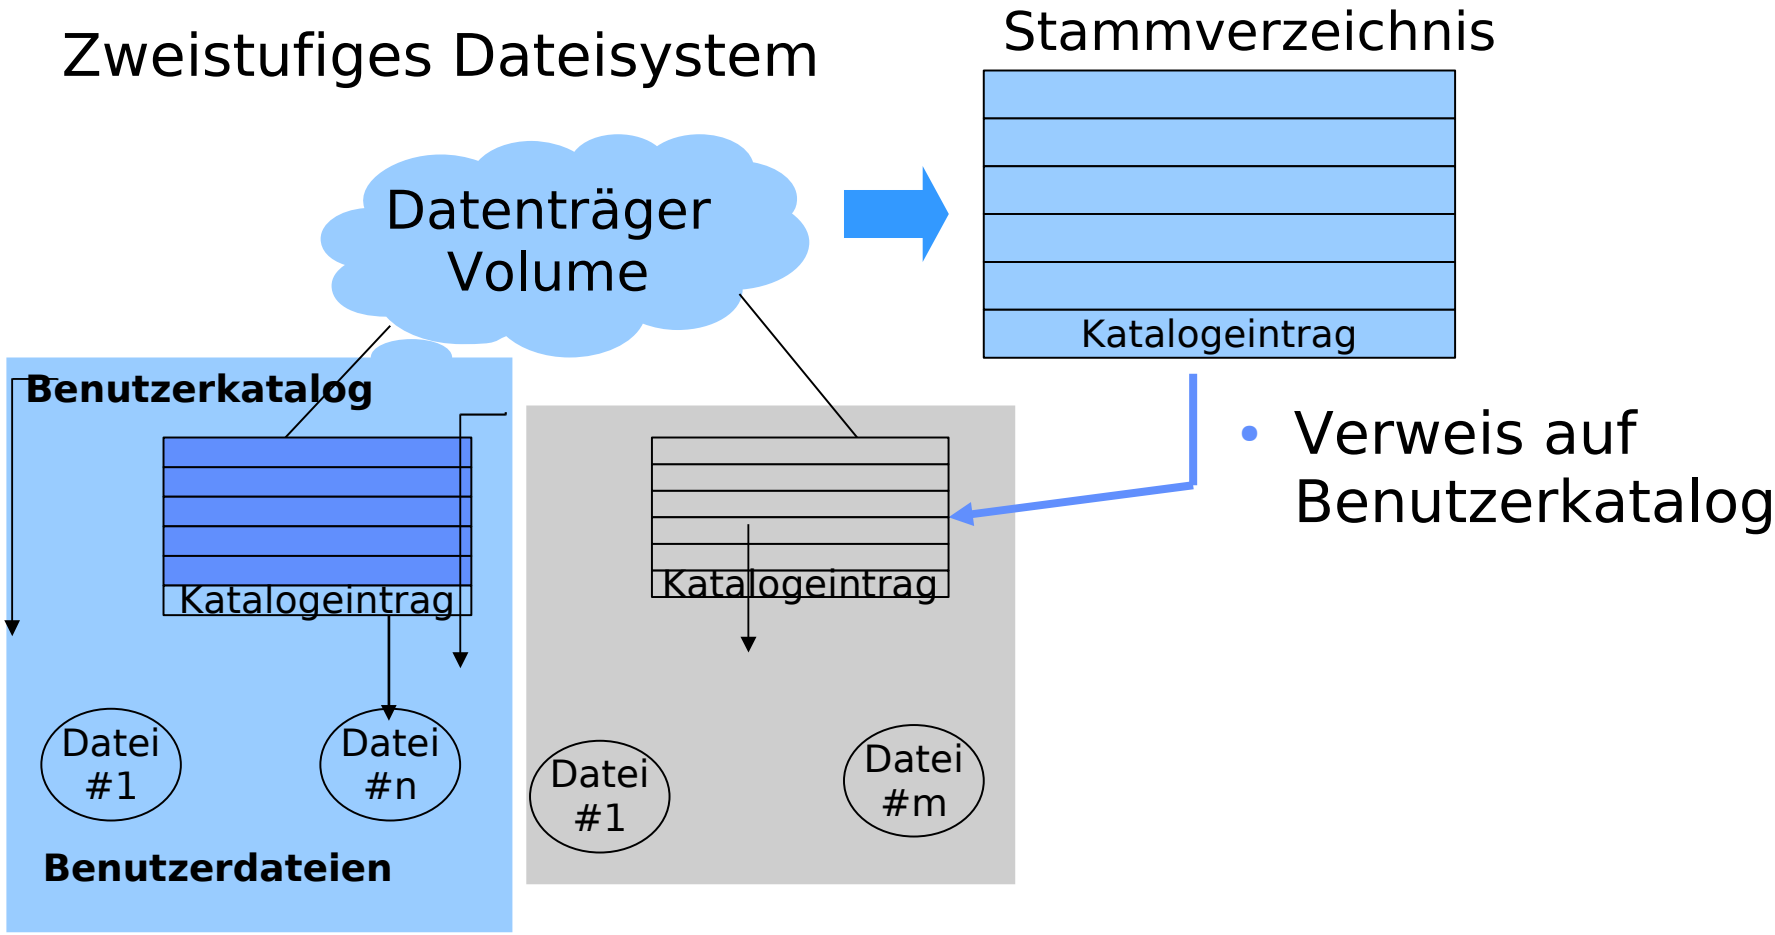

- Verweis auf Benutzerkatalog

Aufbau des Dateisystems - Verzeichnisse

Hierarchisches Dateisystem

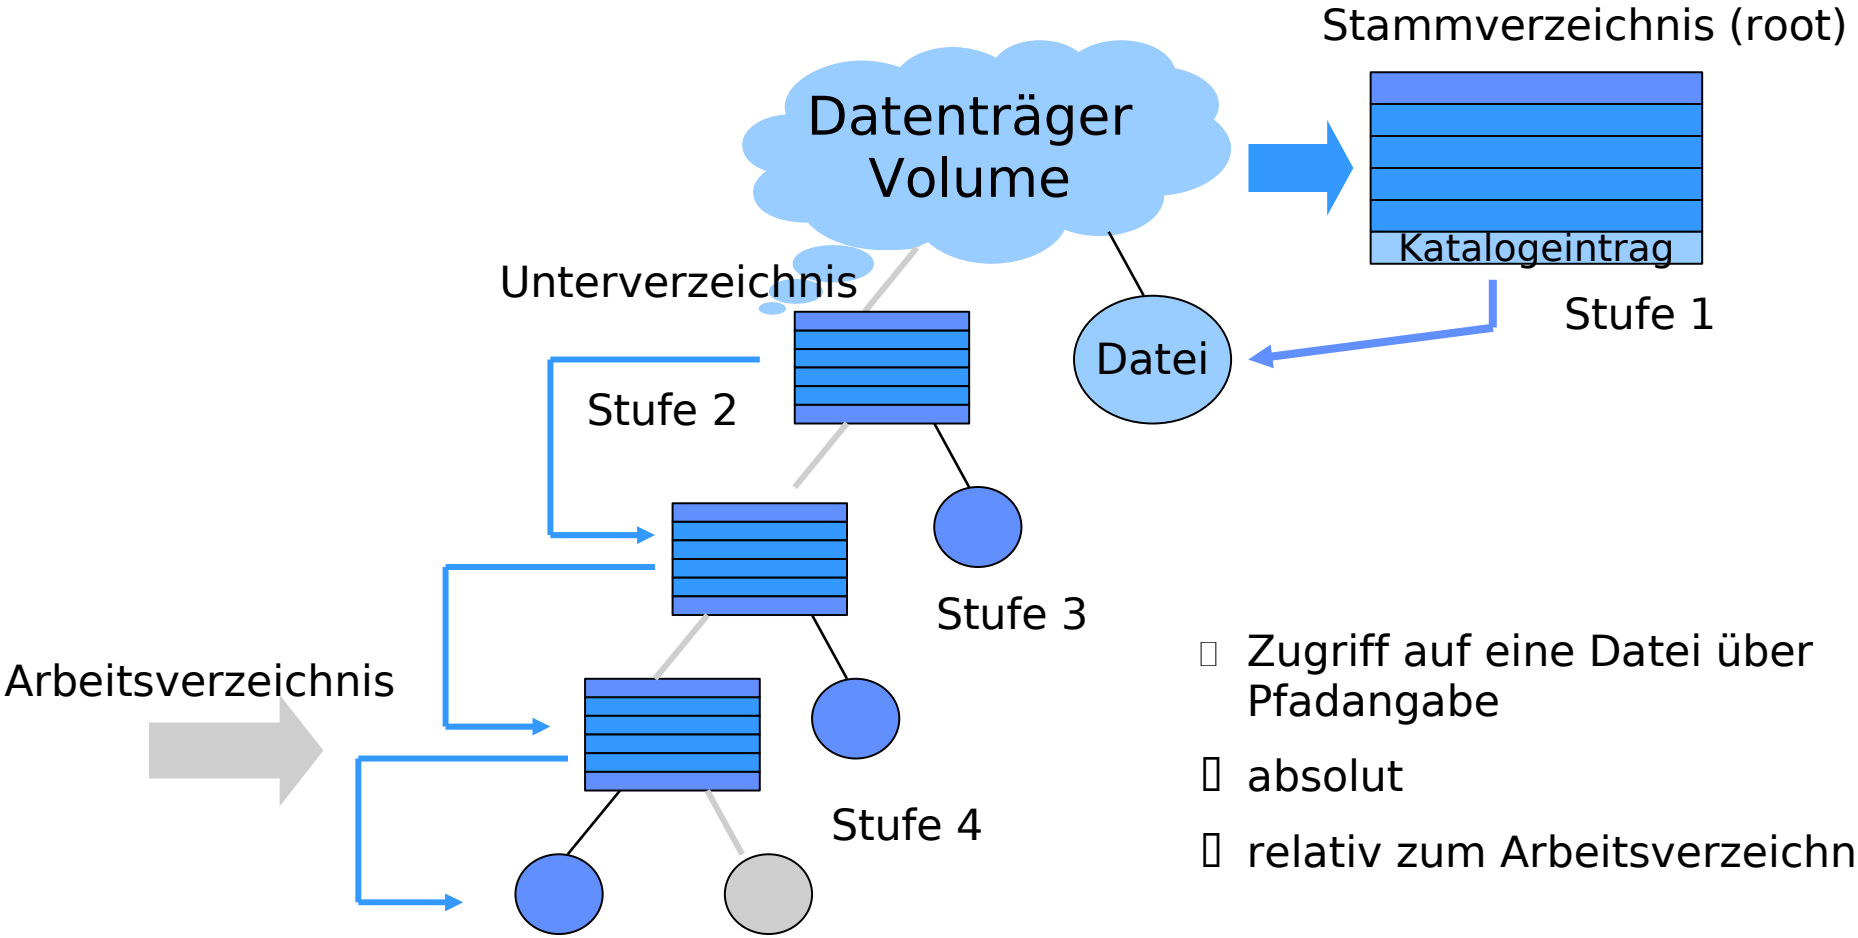

- Zugriff auf eine Datei über Pfadangabe
  - absolut
  - relativ zum Arbeitsverzeichnis

Aufbau des Dateisystems - Verzeichnisse

Hierarchisches Dateisystem mit Links

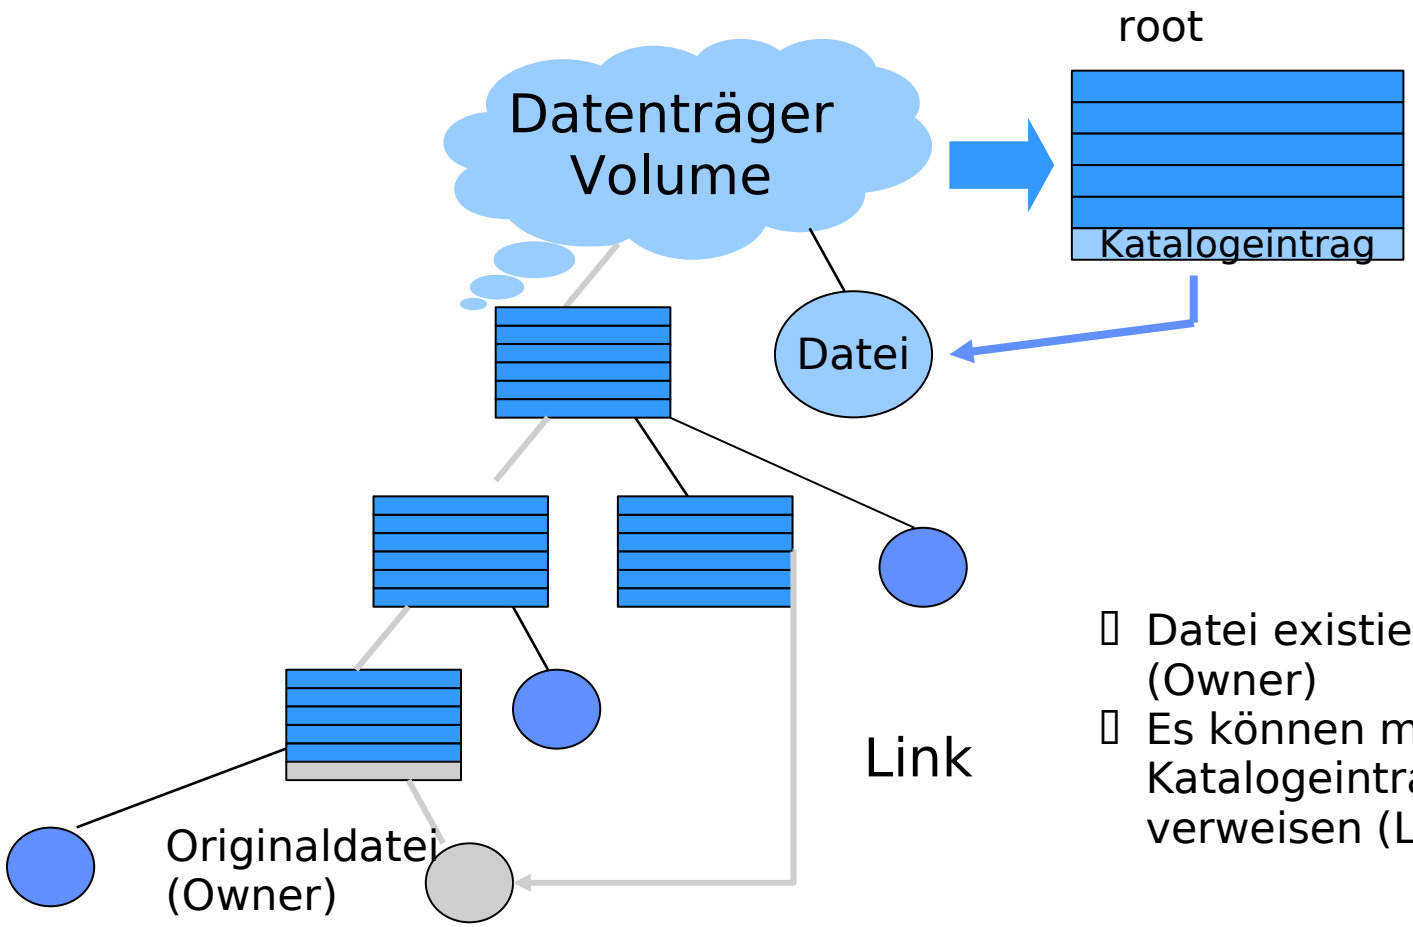

- Datei existiert genau einmal (Owner)
- Es können mehrere Katalogeintrage auf die Datei verweisen (Links)

Belegung von Blöcken

- Zusammenhängend
  - alle Blöcke einer Datei liegen unmittelbar hintereinander
  - einfach und performant
  - unflexibel und fragmentierend
  - wird für read-only Dateisysteme genutzt z.B. CD-ROM
- Verkettete Liste auf der Platte
  - keine Fragmentierung
  - wahlfreier Zugriff ineffizient
- Verkettete Liste mit Tabelle im Hauptspeicher FAT
  - effizient
  - hoher Verbrauch an Hauptspeicher;
    ein Eintrag für jeden (logischen) Block der Festplatte
- Baum-Struktur, Wurzel: I-Node, Uberblock, ...

Beispiel für eine FAT

Verzeichnis:

Datei A:
- erster Block: 4
- Länge: 2381

Datei B
- erster Block: 6
- Länge: 1942

Die FAT selbst wird in mehreren reservierten Bereichen der Platte gespeichert.

Beispiel FAT für 2 Dateien

physischer Block	
0	
1	
2	10
3	11
4	7
5	
6	3
7	2
8	
9	
10	12
11	14
12	
13	

Datei A: 4, 7, 2, 10, 12

Datei B: 6, 3, 11, 5

Beginn von Datei A

Beginn von Datei B

FAT Verzeichniseintrag

Ein Directory/Verzeichnis ist eine Datei.

Ein Eintrag enthält:

- Name der Datei
- Attribute
- Zeiger auf ersten Block
- Länge

Die Datei-Attribute stehen also im Verzeichnis.

I-Node (Prinzip)

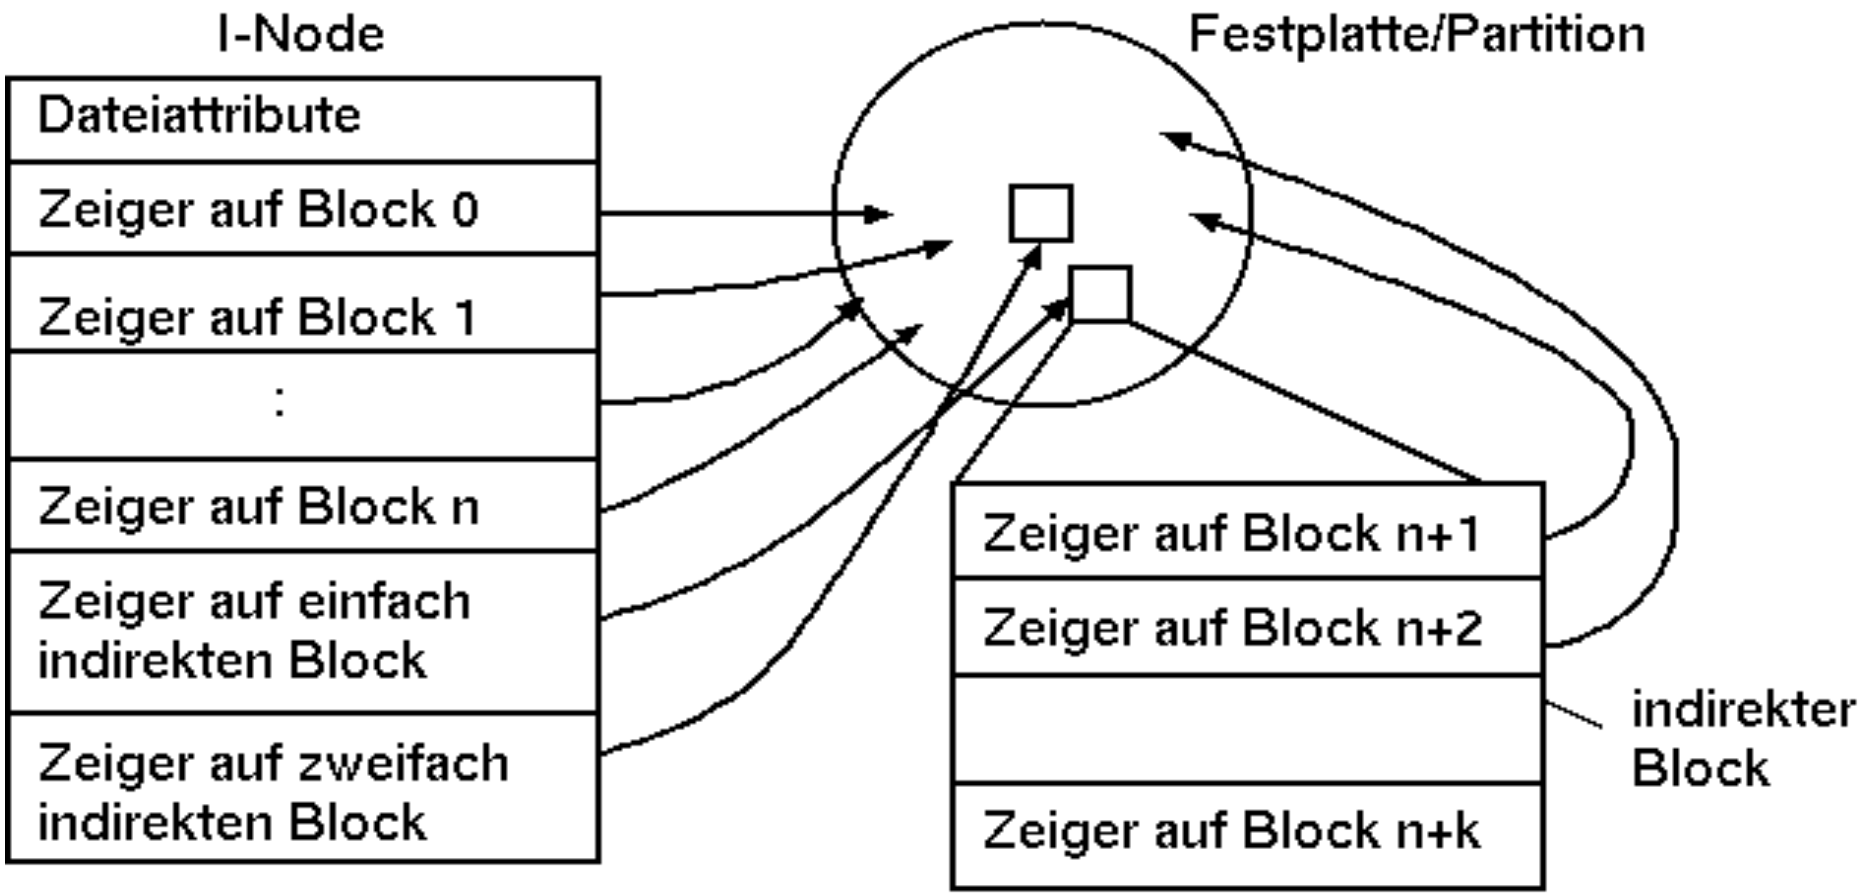

I-Node

Für jede geöffnete Datei wird der I-Node im Hauptspeicher gehalten.

Speicherbedarf ist nur abhängig von der Größe eines I-Nodes und der Anzahl der geöffneten Dateien.

- effizient und flexibel
- akzeptabler Speicherverbrauch

Ein I-Node belegt i.Allg. 64 oder 128 Byte

I-Node

Die Datei-Attribute werden im I-Node gespeichert (nicht aber der Namen und der Typ der Datei)

- Besitzer
- Gruppe
- Zugriffsrechte
- Zeitstempel (Änderung, Zugriff, Löschen)
- Größe der Datei in Bytes
- Anzahl der Verzeichniseinträge d.h. (Hard-)Links
- . . .

Verwaltung freier/defekter Blöcke

- Verkettete Liste
  - Ein freier Block enthält Verweise auf andere freie Blöcke und einen Verweis auf den nächsten Verwaltungsblock
- Bitmap
  - Für jeden Block des Dateisystems wird ein Bit belegt.
  - Benachbarte Bits bezeichnen benachbarte Blöcke; eine Datei sollte benachbarte Blöcke belegen.

Einige Dateisysteme reservieren für eine Datei mehrere sequentielle Blöcke, um Dateien möglichst kompakt zu halten.

Struktur einer Partition in ext2

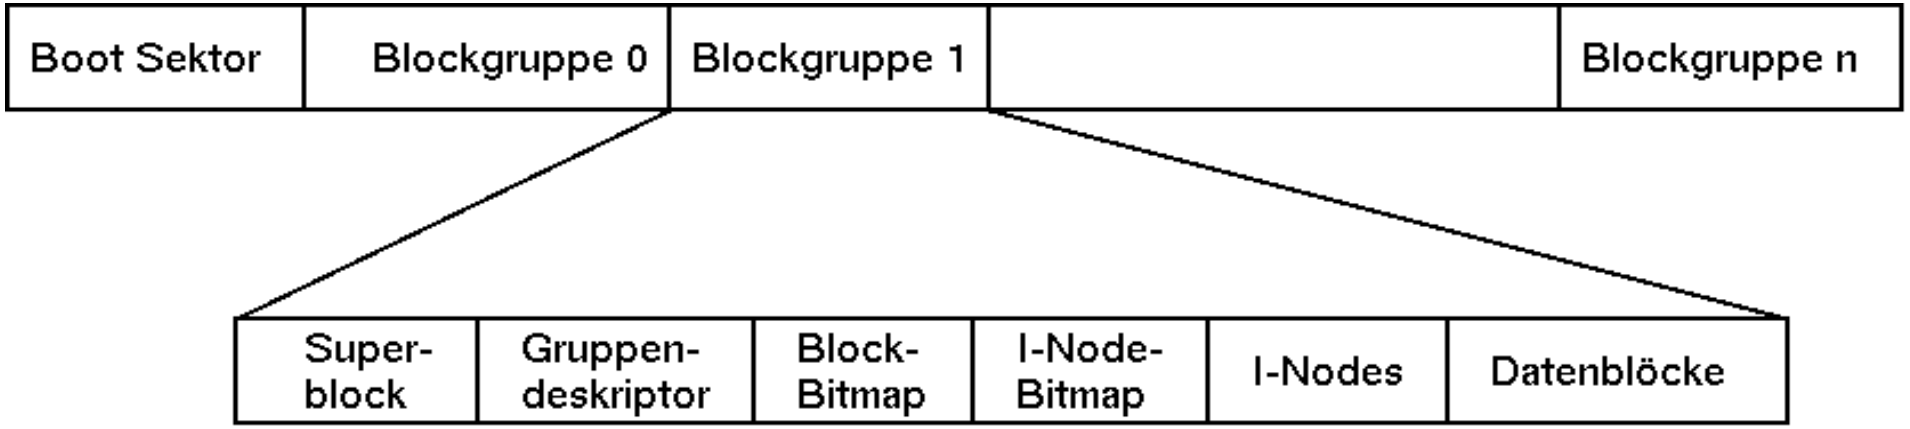

Gruppendeskriptor enthält:

- Position der Bitmaps (I-Nodes und Blöcke)
- Anzahl der freien Blöcke, der freien I-Nodes für die Blockgruppe
- Anzahl der Verzeichnisse
- . . .

Superblock in ext2

Superblock für das Dateisystem / die Partition:

- Magic Number
- Blockgröße
- Größe der Blockgruppen
- Anzahl der freien Blöcke, der freien I-Nodes (gesamte Partition)
- Versions-Nummer
- Mount Count, Zeitpunkt der letzten Überprüfung
- . . .

Verzeichnisse: Einträge fester Länge

Attribute im Verzeichnis (Redundanz bei hard-links)

Name	Attribute
Mail	
etc	
PROG	
SYSO	

Verweise auf I-Nodes mit Attributen. Das Verzeichnis selbst belegt weniger Blöcke; keine redundante Attribute.

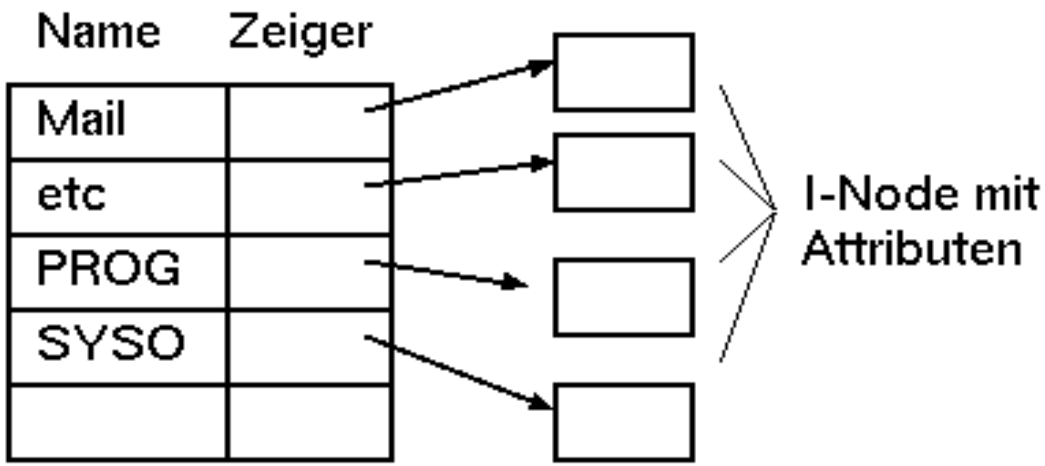

Verzeichnisse und I-Nodes

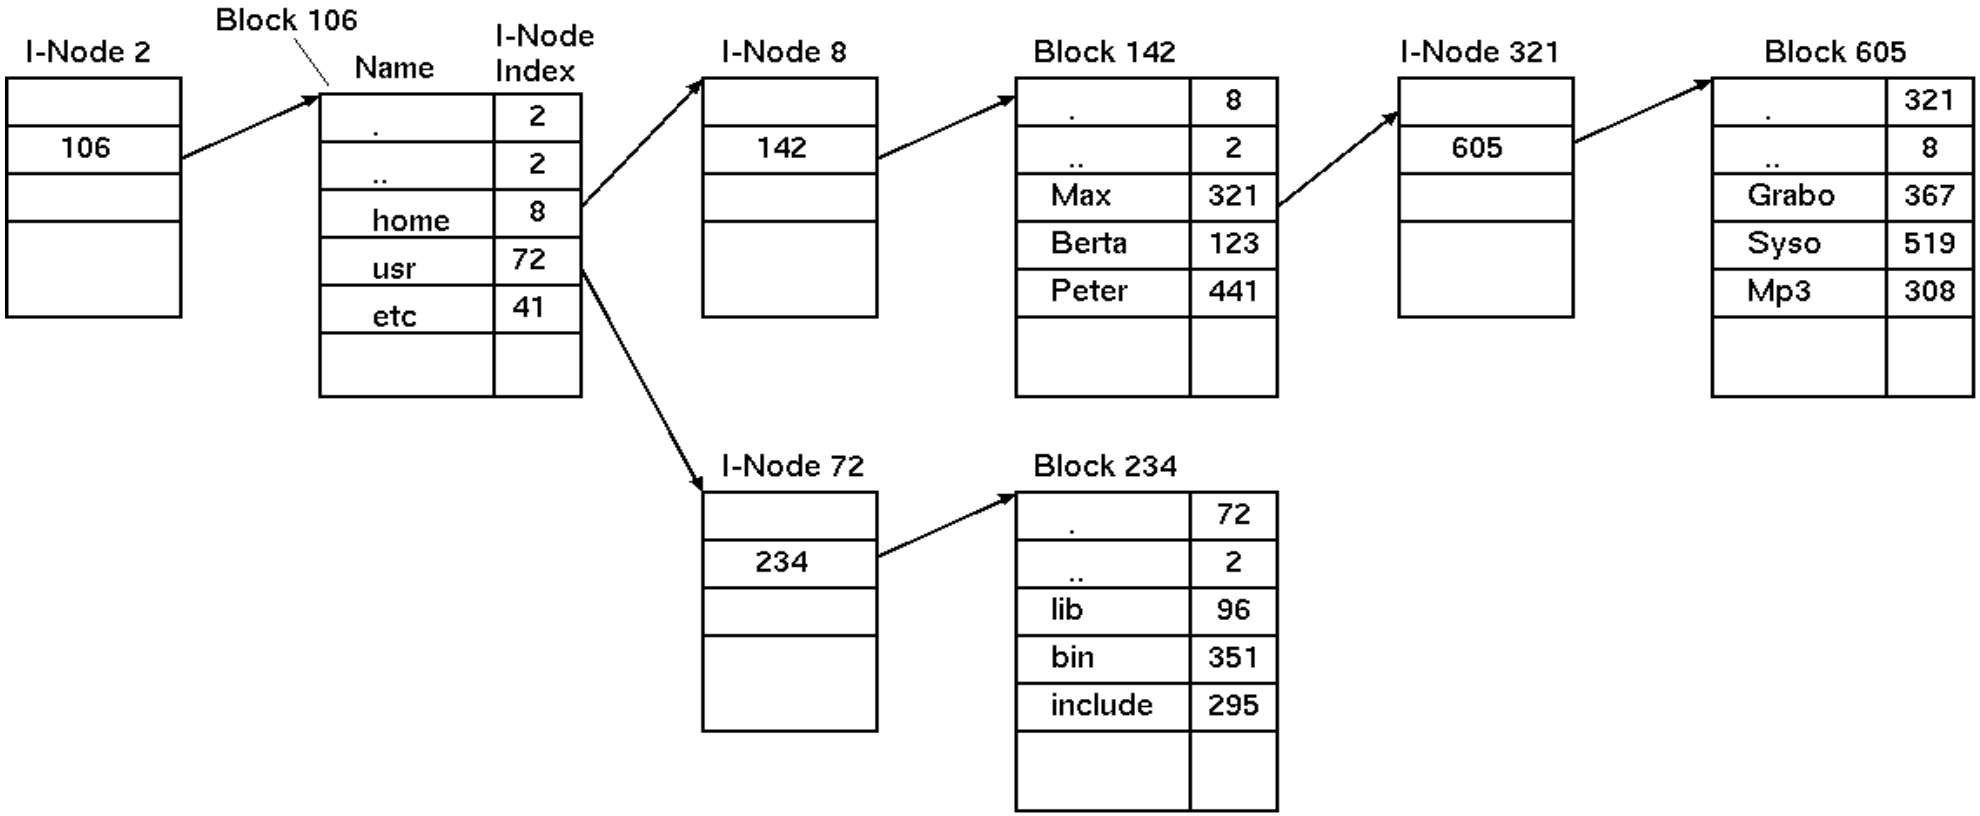

Hierarchisches Dateisystem mit Links

Logischer Link

- Der Link wird über eine zusätzliche (Link-)datei realisiert; die Datei ist als „Link-Datei“ gekennzeichnet.
- Die (Link-)datei enthält nur den Pfadnamen der verlinkten Datei
- Der Verzeichniseintrag verweist auf diese angelegte Link-datei.

Nachteil: Wird die Originaldatei gelöscht oder verschoben so existiert die (Link-)datei noch und enthält den alten unveränderten Pfadnamen. Der Link ist ist aber ungültig

Vorteil: Netzwerkfähig, da der Pfadname eine Netzwerkadresse beinhalten kann.

Beispiel: Unix, Linux, Windows

Hard-Link (Ext-2/3/4)

Der Link wird über eine zusätzlichen Verzeichniseintrag realisiert. Der zusätzliche Verzeichniseintrag verweist auf einen I-Node; er ist von einem „normalen“ Eintrag nicht zu unterscheiden.

Vorteil: Beim Verschieben oder Umbenennen der Datei bleibt der Link auf die Dateibeschreibung gültig. Beim Löschen wird der Linkzähler geprüft. Die Datei wird nur dann gelöscht wenn der Linkzähler auf 1 steht, sonst wird nur der Link-Zähler erniedrigt.

Nachteil: s. Nächste Folie

Beispiel: UNIX, Linux

Nebenwirkungen von Links

- Dateien und/oder Verzeichnisse werden evtl. mehrfach bearbeitet bzw. kopiert, z.B. bei einem Backup.
- Links, die auf Verzeichnisse verweise, können Zyklen im Verzeichniss-System erzeugen. Dies kann bei „naiven“ Programmen zu Endlosschleifen führen.
- Löscht der Erzeuger A die Datei während noch ein weitere Link von B existiert, wird nur der Verzeichniseintrag von A gelöscht. Die Datei existiert weiter, da der Link von B noch existiert. Jedoch wird der Besitzereintrag in der Dateibeschreibung nicht geändert. Besitzer bleibt also A.

Verzeichnisse mit langen Namen

- Verzeichnisse: Dateien, die vom Dateisystem selbst interpertiert werden.
- Problem: Speicherplatz und Zugriffszeit
- Verkettete Liste
  Die Einträge sind unterschiedlich lang, die Länge steht in jedem Eintrag an einer fest vereinbarten Stelle.
- Tabelle mit Pointern in Heap-Speicher
  Die Dateinamen werden in einem separaten Speicherbereich abgelegt.
- Suchstrukturen, z.B. Extendible Hashing
  Die Namen werden in einer Suchstruktur abgelegt.

Verzeichnisse: Einträge variabler Länge

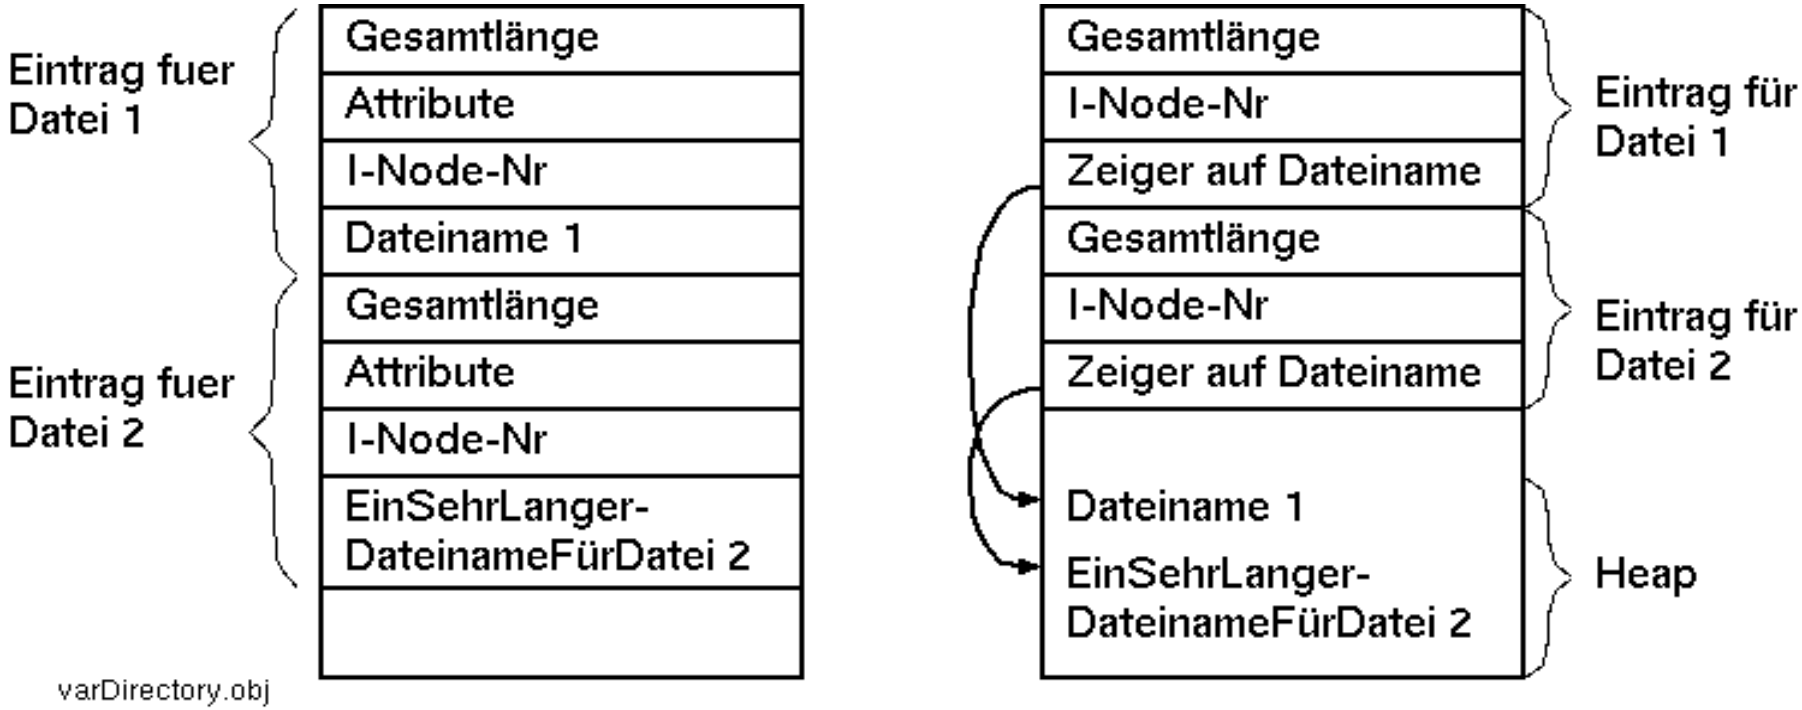

- Zugriff auf Dateinamen durch lineare Suche
- Beschleunigung durch Caching
- Alternativ: Hashing oder Suchbäume für Verzeichnisse mit vielen Einträgen

Konsistenzprüfung in Dateisystemen

Alle Verzeichnisse durchlaufen

- Blockverwaltung: Welche Blöcke sind in Dateien eingebunden?
  - Abgleich mit Freispeicherverwaltung
- I-Node-Verwaltung: Welche I-Nodes sind in Verzeichnissen aufgeführt?
  - Abgleich mit Freispeicherverwaltung
  - Link-Count prüfen, ggf. anpssen
  - I-Node ist belegt aber in keinem Verzeichnis: Datei in „ .../lost+found/“ eintragen.

Unix/Linux

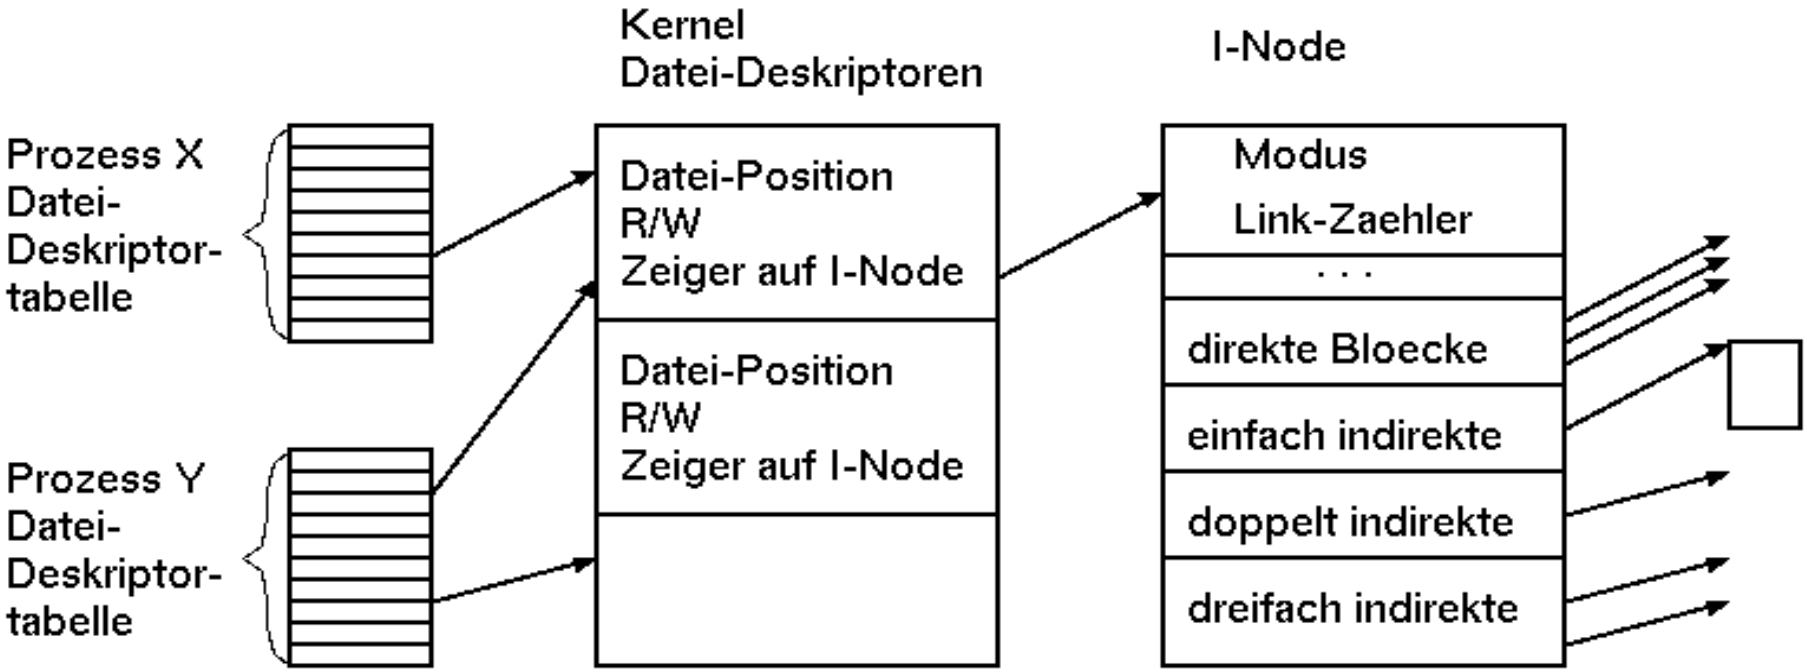

Verwandte Prozesse können eine Datei gemeinsam benutzen.

Verteilte Dateisysteme

Integration von Dateisystemen in Linux

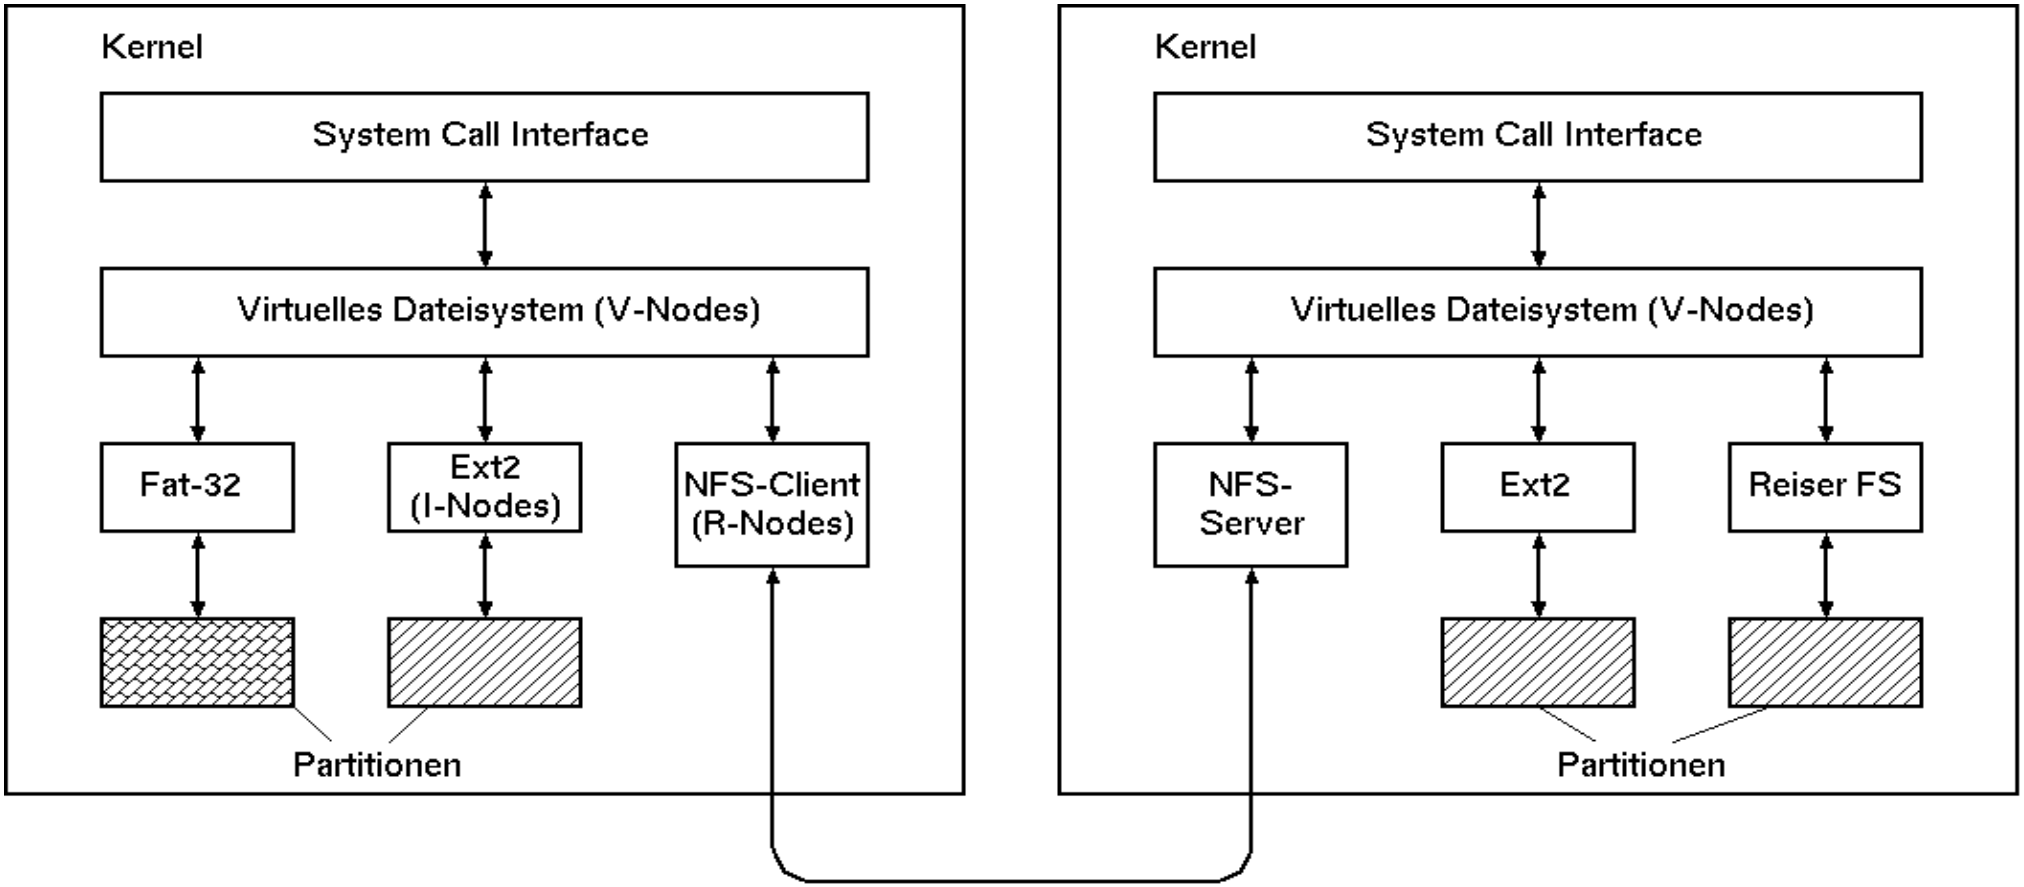

B-Baum: ZFS, BtrFS

- Jeder Knoten besitzt den maximalen Verzweigungsgrad t
- Die Wurzel besitzt den minimalen Verzweigungsgrad 0
- Jeder andere Knoten besitzt den minimalen Verzweigungsgrad $\lceil t/2 \rceil$
- Wird ein Kind zu einem „vollen“ Knoten hinzugefügt, so wird dieser Knoten geteilt. Ggf. wird der bzw. werden die darüberliegenden Knoten ebenfalls geteilt.
- Der Baum ist stets balanciert
- Suchen, Einfügen, Löschen in O(log(n)) Operationen

Digitalbaum

- Der Schlüssel wird in Komponenten zerlegt
- Ein Knoten enthält ein Array mit Zeigern auf Kind-Knoten bzw. Objekte
- Eine Komponenten des Schlüssel dient als Index in diese Array (s. z.B. mehrstufige Seitetabelle)

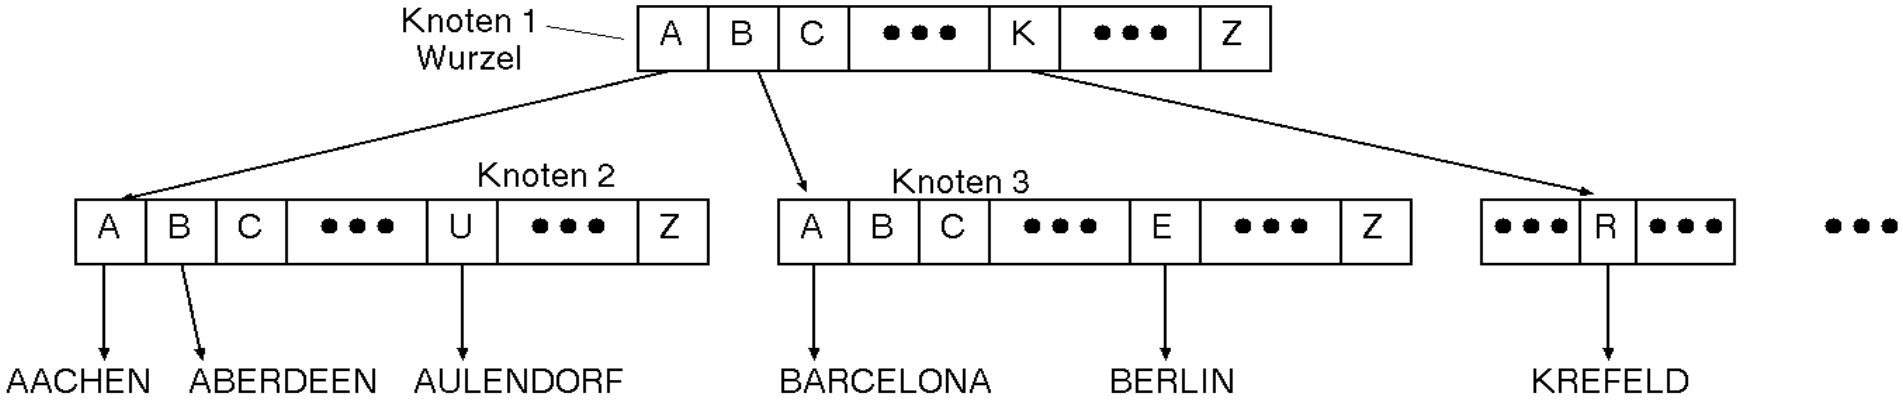

Digitalbaum - Wachstum

Tritt eine Kollision auf, kann der Baum nach unten wachsen. Auf unterster Ebene: Liste

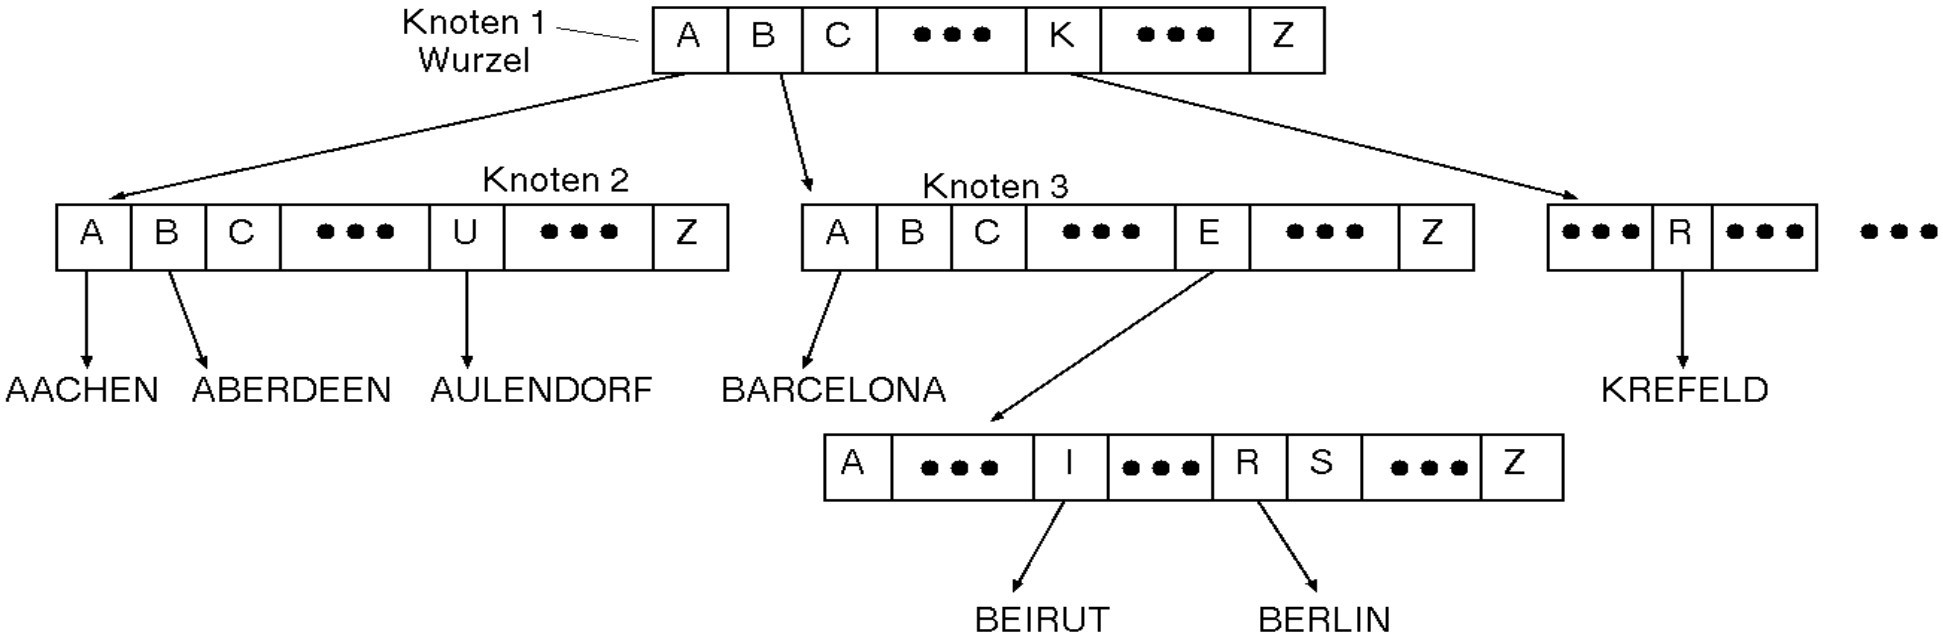

Extendible Hashing

- Objekte werden in einem Digital-Baum gespeichert
- Der Suchschlüssel wird aus dem Objekt-Schlüssel durch eine Hashfunktion errechnet
- Der Digital-Baum ist i.Allg. gut balanciert
- Auf der Ebene der Blätter können i.Allg. Kollisionen auftreten. Diese müssen aufgelöst werden, z.B. duch verkettete Listen.

Zuverlässigkeit von Dateisystemen

Dateioperationen benötigen oft mehrere Schritte von einem konsistenten Zustand zum nächsten.

Unterbrechungen oder defekte Blöcke können zu Inkonsistenzen führen.

- Regelmäßge Konsistenzprüfung;
  für große Partitionen/Volumes zeitaufwändig
- Journaling zur Beschleunigung der Tests
- RAID-Systeme
- Prüfsummen für die Konsistenz von Daten
- Transaktionsmechanismus beim Schreiben
  Copy on Write

Journaling File Systeme

- Um Inkonsistenzen zu entdecken muss das System die gesamte Platte/Partition prüfen.
- Journaling File Systeme
  - geplante Änderungen in das Journal schreiben
  - Änderungen ausführen, dann aus Journal löschen
- Nach einer Unterbrechung muss das System nur das Journal mit dem Ist-Zustand vergleichen.
- Problem: Block des Journals kann defekt sein.

RAID Disks

Redundant Arrays of inexpensive/independend Disks

Idee

Zusammenfassung mehrerer Festplatten zu einem "Platten-Array"

Für den Anwender erscheint das Array bestehend aus mehreren kleinen Platten als wäre es nur eine grosse Platte

Vorteile

Höhere Geschwindigkeiten durch zeitlich verschränktes Schreiben auf mehrere Platten

Fehlertoleranz

RAID
(Redunant Array of Independend Disks)

- **Hardwarelösungen**
  - Externe RAID-Boxen mit eigenem Controller, Platten, Lüftung und Stromversorgung
  - RAID-Controller im Rechner. Es sind mehrere Platten anschließbar. Die RAID-Levels werden im Contoller realisiert

- **Softwarelösungen**
  - Raid-Levels werden im Betriebssystemkern implementiert
    - Windows NT Raid 0,1,4,5
    - LINUX RAID 0,1,4,5

RAID-Level

- Raid 0: Dateien werden in „Stripes“ auf mehrere Platten verteilt.
- Raid 1: Wie Raid 0, jeder „Stripe“ wird auf zwei verschiedene Platten geschrieben.
- Raid 2 und 3: Bitweise paralleles Schreiben (kaum verwendet)
- Raid 4: Wie Raid 0 mit einem zusätzlichen „Parity-Stripe“ auf einer zusätzlichen Platte.
- Raid 5: Wie Raid 4, Parity-Stripes werden auf alle Platten verteilt.
- Viele weitere (Misch-)Formen existieren

RAID Level 0 und 1

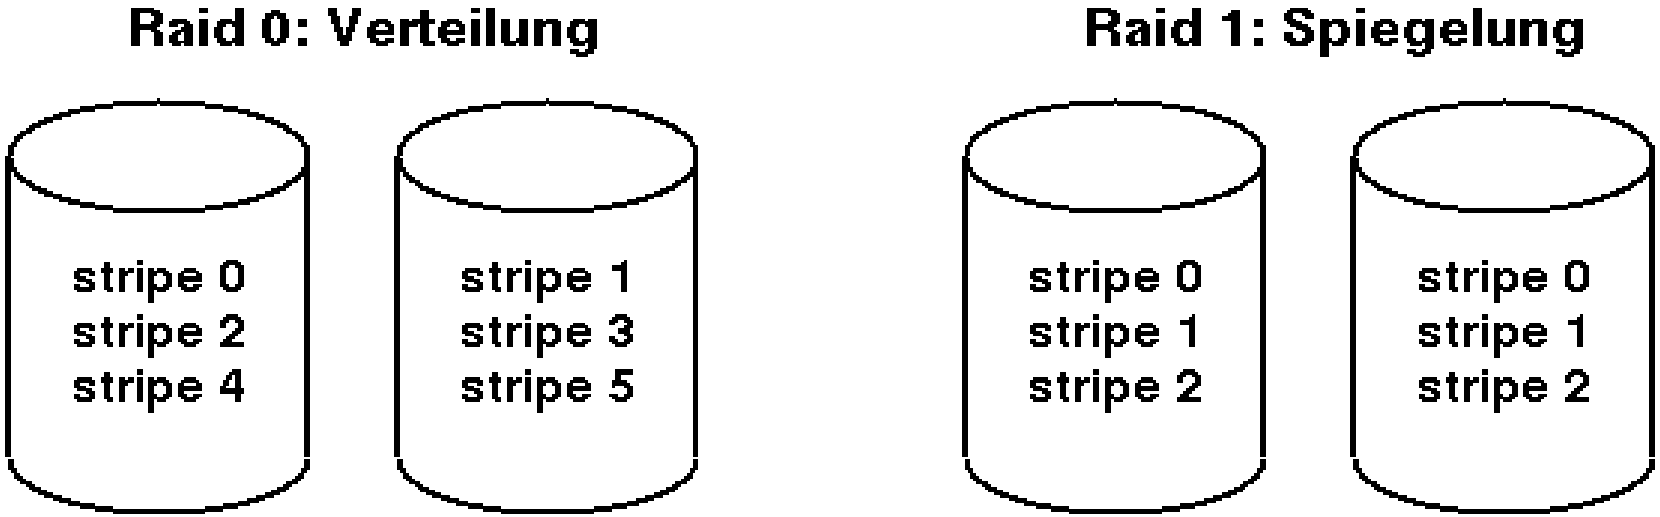

- Raid 0 (Striping)
  - Höherer Durchsatz durch parallelen Zugriff
  - Höhere Fehlerrate: Bei Ausfall einer Platte sind alle Dateien beschädigt
- Raid 1 (Spiegelung)
  - Höhere Zuverlässigkeit und höhere Lesegeschwindigkeit
  - Halbe Speicherkapazität

Raid 10

- Kombination von RAID 0 und Raid 1
- Spiegelung von RAID 0 System

➔ Höhere Geschwindigkeit
➔ Höhere Sicherheit
➔ Benötigt doppelte Speicherkapazität, mindestens vier Speichermedien

Raid Level 5

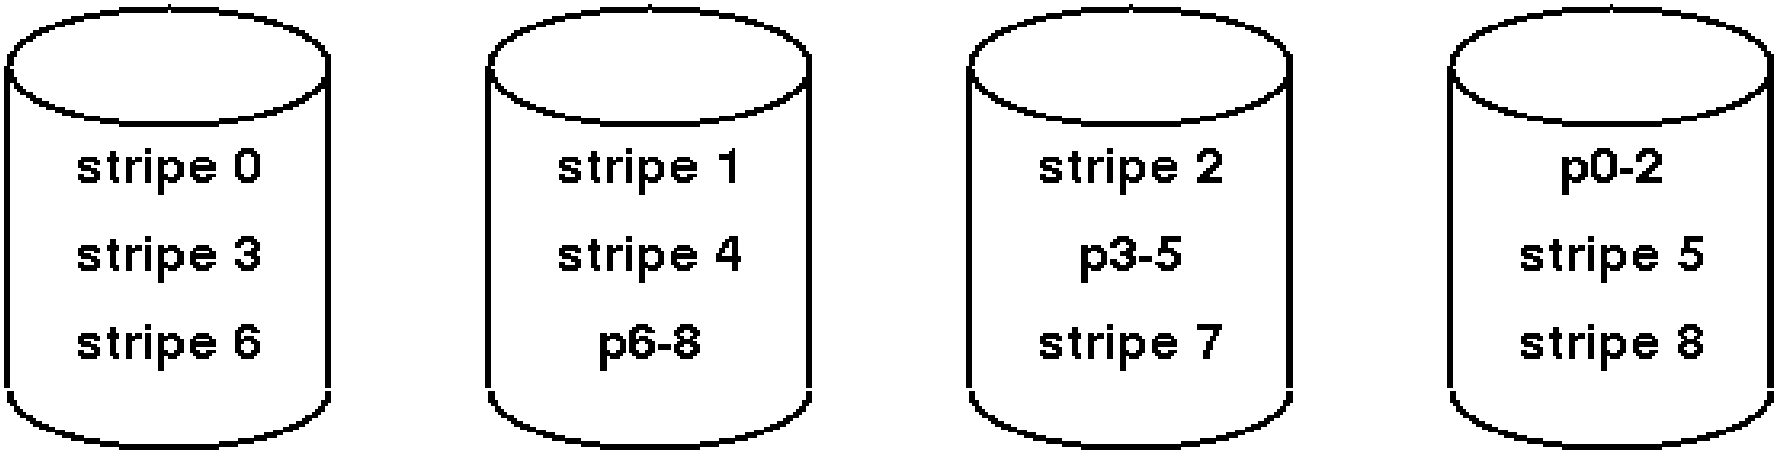

- Bei n Platten wird für n-1 Stripes ein Parity-Stripe auf eine Platte geschrieben (ein Stripe i.A. Ein Block) (XOR Verknüpfung der n-1 Stripes).
- Fällt eine Platte aus, kann der Inhalt aus den verbliebenen Daten rekonstruiert werden.
- Raid 4: Parity-Platte ist Flaschenhals.

RAID 4/5 vs. RAID-Z

- RAID 4/5: Sicherheitslücke
  - Alle Daten-Stripes und der Parity-Stripe bilden eine Einheit.
  - Stromausfall nach dem ersten und vor dem letzen Stripe führt zu Inkonsistenz. (Abhilfe USV: teuer)
- RAID 4/5: Kurze Schreibzugriffe langsam (partial stripe writes)
  - Bisherige Daten und Parity oder restliche Daten lesen, Parity berechnen, neue Stripes und Parity-Stripe schreiben
- RAID-Z (ZFS): RAID an Block-Größe anpassen
  - Jeder Schreibzugriff (ein log. Block) wird auf Daten- und Parity-Stripe aufgeteilt (full stripe write). Zufälliges Lesen ist langsam.
  - Sind die log. Blöcke zu klein wird nur gespiegelt.

Neuere Entwicklungen (z.B. ZFS, BtrFS)

- Copy on write: Aktuelle Daten werden nie überschrieben: Kopie schreiben, dann Zeiger umsetzen
- Prüfsumme für Daten und Meta-Daten (Zeiger etc.), Prüfsumme getrennt von Daten halten
- Größe des Dateisystems dynamisch (zur Laufzeit)
- Zusätzlich Platte „lazy“ in RAID-System integriert
- Anzahl der Dateien dynamisch (zur Laufzeit)
- Kompression, Verschlüsselung
- Snapshots
- Backups (zur Laufzeit)

Memory Mapped Files

- **Vorteil**: schneller Zugriff auf Daten

- **Nachteil**:
  - schreibende Zugriffe erfolgen im Arbeitspeicher und werden nicht sofort auf Platte übertragen. Bei Programmabsturz sind daher die Daten verloren.

    Abhilfe: Bei kritischen Daten kann ein Schreiben auf Platte erzwungen werden.

  - Besteht gleichzeitig ein lesender Zugriff auf die Datei können inkonsistente Zustände entstehen, da schreibende Zugriffe nicht direkt auf Platte erfolgen. Damit kann eine Änderung schon erfolgt sein, der lesende Prozess bekommt diese jedoch nicht mit.

Memory Mapped Files

- Benötigte BS-Funktionen:
  - mmap (Datei, Ausschnitt, Schutz, . . .)
    Liefert die Anfangsdresse des eingeblendeten Dateiausschnitts zurück
  - munmap(virtuelle Adresse)
- Entspricht Shared Memory mit persistenter Speicherung

Memory Mapped Files

- Dateien, die entweder vollständig oder in Ausschnitten in den virtuellen Adressraum des Prozesses eingeblendet werden.
  - Damit kann auf die Daten der Datei wahlfrei, wie auf Daten im Arbeitspeicher, zugegriffen werden.

- Bei einem Zugriff auf die virtuelle Seite wird der Inhalt der Datei von Festplatte in den Arbeitsspeicher gelagert. Lesen und Schreiben kann dann über Pointer im Programm ohne Dateifunktionen read() und write() erfolgen. Erst beim Auslagern der Seite aber spätestens beim Terminieren des Prozesses werden alle Daten im Speicher wieder in die Datei auf die Festplatte geschrieben.