1.2 Prozessorgattungen

Quelle: http://de.wikipedia.org/wiki/Mikroprozessor
http://mikroprozessor.know-library.net/

Definition: Prozessoren lassen sich zu Prozessorgattungen zusammenfassen. Kennzeichnung einer Prozessorgattung vor dem Hintergrund von Applikationen

- Mikroprozessoren
- Mikrocontroler
- Signalprozessoren

Worterklärung:

CPU: Der Hauptprozessor (englisch *Central Processing Unit* oder kurz *CPU*, im allgemeinen Sprachgebrauch oft auch nur als Prozessor bezeichnet, ist der zentrale Prozessor eines Computers, der alle anderen Bestandteile steuert.

Mikroprozessor

Allgemein

Der **Mikroprozessor** (*griech.* Mikro *für* Millionstel: ***Prozessor in sehr kleinem Maßstab***) ist ein elektronisches Rechenwerk, welches mit Befehlen in Maschinensprache gesteuert werden kann.

Währenddessen bis Ende der 1960er Jahre Prozessoren aus Einzelbauteilen und integrierten Schaltungen mit kleiner Integrationsdichte hergestellt wurden, war es folglich möglich, sämtliche Einheiten des Prozessors auf einem Chip unterzubringen, auf dem jeder Schalter als elementarer Baustein in dem Durchmesser ca. einige Mikrometer an Platz beansprucht - der Mikroprozessor war geboren. Zunächst waren dies noch recht einfache Schaltungen. Die Mikroelektronik brachte neben der Miniaturisierung und enormen Kostenersparnis noch weitere Vorteile wie Geschwindigkeit, Stromverbrauch, Zuverlässigkeit und später auch Komplexität. Dies führte dafür, daß vergleichsweise billige Mikroprozessoren mit der Zeit die teuren Prozessoren der Minicomputer und teilweise sogar der Großrechner verdrängten. Gegen Ende des zwanzigsten Jahrhunderts erhielt der Mikroprozessor Einzug in viele elektronische Geräte, vor allem als CPU von Personal Computern. Auch als die Strukturgrösse der Mikroprozessor-Chips auf einige Nanometer verkleinert wurde, blieb der Begriff Mikroprozessor bestehen

Steuerung durch Befehle

Sämtliche Computerprogramme liegen als binäres Bitmuster in dem Speicher vor. Diese Bitmuster sind prozessorspezifisch (das heißt konkrete Muster lösen bei verschiedenhen Prozessoren verschiedenhe elementare Befehle aus). Derartige elementare Prozessorefehle lassen sich prozessorspezifisch in Maschinensprache bzw. Assemblersprache programmieren, dennoch ist das Programm dann nicht portabel. Zur Umgehung dieses Problems benutzt man Hochsprachen, etwa C, C++, FORTRAN oder Pascal. Ein spezielles Übersetzungsprogramm (Compiler) setzt dann das Hochsprachenprogramm in für den Prozessor geeignete Maschinensprache um.

Aufbau

Ein Mikroprozessor besteht aus den Registern, einem Rechenwerk, einem Befehlsdecoder sowie einem Steuerwerk. Das Rechenwerk ist für arithmetische und logische Funktionen zuständig, Befehlsdecoder und Steuerwerk sind für die Ausführung der Befehle und die Koordination der Funktionseinheiten zuständig. Die Register bilden eine Art meist kleinen Spezialspeicher für Zwischenergebnisse von Rechenoperationen, auf den insbesondere schnell zugegriffen werden kann. Zur Erhöhung der Rechengeschwindigkeit können Prozessoren mit Caches oder besonderen (etwa einem Hardwaremultiplizierer) oder weiterhinen (etwa einem Fließkommarechenwerk) Rechenwerken ausgestattet sein. Zur effizienteren Bearbeitung von Befehlen werden Pipelines benutzt. Sämtliche Mikroprozessoren sind interruptfähig.

Worterklärung

Das **Steuerwerk** ist der Kern des Mikroprozessors. In dem Steuerwerk befinden sich Befehlsregister und Befehlsdecoder. Seine Aufgabe ist die Abarbeitung des Programms, das heißt Befehl für Befehl eines Programmes werden durch das Steuerwerk des Mikroprozessors ausgeführt. Für jeden Befehl wird ein Befehlszyklus durchlaufen. Ein Befehlszyklus hat drei Phasen: Befehl holen, Befehlsentschlüsselung, Befehl ausführen

Worterklärung

Eine **Arithmetic Logical Unit** (**ALU**, *zu deutsch* **arithmetisch-logische Einheit**) ist ein elektronisches Rechenwerk, welches in Prozessoren zu dem Einsatz kommt.

Die ALU berechnet, arithmetische und logische Funktionen. Sinnvollerweise kann sie mindestens folgende Minimaloperationen (siehe Disjunktive Normalform) durchführen:

- *Arithmetisch:*
  - Addition (ADD)
- *Logisch:*
  - Negation (NOT)
  - Konjunktion (Und-Verknüpfung, AND)

Typischerweise liegen dennoch auch noch weiterhin folgende Operationen vor, die aber auch anhand der oberen drei auf Kosten der Rechenzeit (in mehreren Takten) nachgebildet werden können:

- *Arithmetisch:*
  - Subtraktion (SUB)
  - Vergleich (compare, CMP)
- *Logisch:*
  - Disjunktion (Oder-Verknüpfung, OR)
  - Kontravalenz (Exklusiv-Oder-Verknüpfung, XOR, EOR)
- *Sonstige:*
  - Rechts- und Linksverschiebung (Rechts-, Linksshift, ASR, ASL, LSR, LSL)
  - Links- und Rechtsrotation (ROL, ROR)
  - Register-Manipulationen und Bit-Veränderungen (Bits setzen, löschen und testen)
  - Decimal adjust

Die meisten ALUs verarbeiten Festkommazahlen. Ca. einige besondere ALUs, vornehmlich auf Signalprozessoren und modernen PC-Prozessoren, können Fließkommazahlen oder beide Formate

direkt verarbeiten

Mikrocontrller

Quelle: http://www.mikrocontroller.net/articles/Mikrocontroller"

Was ist ein Mikrocontroller?

Ein Mikrocontroller ist ein Prozessor. Der Unterschied zu Mikroprozessoren besteht darin, dass bei einem Mikrocontroller Speicher, Digital- und Analog- Ein- und Ausgänge usw. meist auf einem einzigen Chip integriert sind, so dass eine Mikrocontroller-Anwendung oft mit ein paar wenigen Bauteilen auskommt.

Mikrocontroller werden häufig zuerst an der Bit-Zahl des internen Datenbusses unterschieden: 4bit, 8bit, 16bit oder 32bit. Diese Bit-Zahl kann man als die Länge der Daten interpretieren, die der Controller in einem Befehl verarbeiten kann. Die größte in 8 Bit (= 1 Byte) darstellbare Zahl ist die 255, somit kann ein 8 Bit-Mikrocontroller z.B. in einem Additionsbefehl immer nur Zahlen bis 255 verarbeiten. Zur Bearbeitung von größeren Zahlen werden dann mehrere Befehle hintereinander benötigt, was natürlich länger dauert.

Ein Mikrocontroller braucht, wie jeder andere Prozessor auch, zum Betrieb im Allgemeinen eine extern eingespeiste Taktfrequenz. Die maximale Frequenz, mit der ein Controller betrieben werden kann, reicht von 1 MHz bei alten Controllern bis hin zu über 100 MHz bei großen 32-"Bittern". Diese Taktfrequenz sagt jedoch noch nichts über die tatsächliche Geschwindigkeit eines Prozessors aus. So wird z.B. bei den meisten 8051-Controllern die Frequenz intern durch 12 geteilt, ein mit 24 MHz getakteter 8051 arbeitet also eigentlich nur mit 2 MHz. Benötigt dieser dann für einen Befehl durchschnittlich 2 Taktzyklen, so bleiben "nur" noch 1 Mio. Befehle pro Sekunde übrig - ein AVR, der ungeteilt mit 8MHz arbeitet und für die viele Befehle nur einen Zyklus braucht, schafft dagegen fast 8 Mio. Befehle pro Sekunde.

Wozu ist ein Mikrocontroller gut?

Hier ein paar Beispiele, für welche Aufgaben Mikrocontroller verwendet werden (können):

- Ladegeräte
- Motorsteuerungen (z.B. Schrittmotor-Controller (Stepper))
- Roboter
- Meßwerterfassung (z.B. Drehzahlmessung im Auto)
- Temperaturregelung
- MP3- und DVD-Player
- Schaltuhren
- ...

Welchen Mikrocontroller soll ich verwenden?

Ein Mikrocontroller für Hobbyanwender sollte idealerweise folgende Voraussetzungen erfüllen:

- gute Beschaffbarkeit
- niedriger Preis spielt bei den kleinen Stückzahlen keine so große Rolle
- handliche Bauform: ein Controller mit 20 Pins ist leichter handzuhaben als einer mit 128
- Flash-ROM: der Controller sollte mindestens 1000 mal neu programmiert werden können
- In-System-Programmierbarkeit (ISP): man benötigt kein teures Programmiergerät und muss den Controller zur Programmierung nicht aus der Schaltung entfernen
- kostenlose Software verfügbar: Assembler bekommt man praktisch immer kostenlos vom Hersteller des Controllers, C-Compiler seltener

Eine ausführliche Beschreibung der Entscheidungskriterien gibt es auf der Seite Entscheidung Mikrocontroller.

verbreitete Mikrocontrollerfamilien

- 1 Bit
  - MC14500B (Motorola, historisch!)

- 4 Bit
  - MARC4 (Atmel)
  - SM62 (Epson)

- 8 Bit
  - MicroConverter® (Analog Devices)
  - AVR (Atmel)
  - PIC (Microchip)
  - 8048 (Intel)
  - 8051 (Intel, versch. Hersteller)
  - H8 (Renesas, früher Hitachi)
  - 68HC05 (Freescale, früher Motorola)
  - 68HC08 (Freescale, früher Motorola)
  - 68HC11 (Freescale, früher Motorola)
  - ST62 (SGS-Thomson)
  - 78K0S (NEC)
  - Z8 (Zilog)
  - PSoC (Cypress)

- 16 Bit
  - C16x (Infineon)
  - M16C (Renesas, früher Mitsubishi)
  - R8C (Renesas)
  - H8 (Renesas, früher Hitachi)
  - 68HC12 (Freescale, früher Motorola)
  - 68HC16 (Freescale, früher Motorola)
  - dsPIC (Microchip)
  - MSP430 (Texas Instruments)

- 32 Bit
  - ADuC7xxx (Analog Devices) ARM-Core
  - AT91SAM (Atmel) ARM-Core
  - LPC2xxx (NXP ehemals Philips) ARM-Core
  - ElanSC520 (AMD)
  - TriCore (Infineon)
  - SuperH (Renesas, früher Hitachi)
  - FR50 (Fujitsu)

Signaltprozessor

- Ähnlicher Funktionsumfang wie Mikrocontroller, jedoch größere Rechenleistung
- Bereitstellung der Rechenleistung durch:
  - superscalarer Aufbau (Bereitsellung mehrer prozssorinterner Rechenwerke)
  - Befehlsformat sieht Programmierung mehrere parallel operierende Rechenwerke vor
  - typische Anwendung → Video- und Audio-Anwendungen mit großen Anforderungen an die Rechenleistung

<u>Anwendungsbereich</u>

Mikrocontroller: keine Grafiken, kann zwischen Mustern hin und her schalten

Mikroprozessor: Grafische Ausgabe, geringer Speicher

1.3 Rechnerarchitektur

Die von Neumann-Architektur
http://user.cs.tu-berlin.de/~icoup/archiv/3.ausgabe/artikel/neumann.html

Ein von Neumann-Rechner besteht aus folgenden Funktionseinheiten:

- einem Steuerwerk oder Befehlsprozessor, in dem die Anweisungen eines Programmes interpretiert und die Ausführung dieser Befehle gesteuert werden,
- einem Rechenwerk oder Datenprozessor, in dem die notwendigen datentransformierenden Operationen durchgeführt werden,
- einem Speicher, in dem Daten und Programme zusammen gespeichert werden und welcher für das Rechenwerk zugänglich ist und
- einer Ein-/Ausgabe-Einrichtung.

Als wesentliches Konzept der von Neumann-Architektur wird die gemeiname Speicherung von Befehlen, d.h. den Anweisungen eines Programmes, und Daten in einem gemeinsamen Speicher angesehen, wodurch Befehle identisch wie Daten durch das Rechenwerk behandelt werden können. Demzufolge erfolgt die Verarbeitung der einzelnen Speicherzellen unabhängig von den darin enthaltenen Informationen. Diese Konzeption ermöglicht es auch prinzipiell, Programme ebenso wie Daten durch den Rechner selbst manipulieren zu können, was zumindest in der Anfangszeit der Rechnerentwicklung durchaus gewollt war.

Dieses Konzept der von Neumann-Archtektur bedingt aber auch eine streng sequentielle Programmausführung. Die Anweisungen des auszuführenden Programmes können nur durch einzelne Zugriffe des Rechenwerkes auf den Speicher abgearbeitet werden, so daß zu jedem Verarbeitungszeitpunkt immer nur eine der elementaren Maschinenoperationen ausgeführt werden kann. Die streng sequentielle Programmausführung "erfordert eine totale Ordnung der Operationsanweisung, die normalerweise nicht durch die Natur des auszuführenden Algorithmus vorgeschrieben ist. Ein Algorithmus erfordert in der Regel nur eine Teilordnung der auszuführenden Rechenschritte; die von der Maschine verlangte Totalordnung wird daher vom Programmierer (mehr oder weniger willkürlich) eingeführt."

Die Nachteile der von Neumann-Architektur

Die Konzeption der von Neumann-Architektur enthält eine Reihe von Nachteilen, die sich vor allem durch gravierende Einschränkungen bei der Konzeption und der Anwendung des auf der von Neumann-Architektur basierenden Programmiersprachenkonzeptes bemerkbar machen. Diese Nachteile liegen vor allem in den bestehenden semantischen Lücken zwischen dem von Neumann-Rechner und dem dafür entwickelten Programmiersprachenkonzept, in der Möglichkeit von Seiteneffekten bei Anwendung der uneingeschränkten Zuweisungsmöglichkeiten der von Neumann-Architektur, vor allem aber in den durch den von Neumann-Flaschenhals entstehenden Nachteilen bei der Programmierung.

Die Semantischen Lücken

Die von Neumann-Architektur basiert auf einer generischen Informationsdarstellung, d.h. "die Objekte des (einzigen) Maschinen-Datentyps des von-Neumann-Rechners sind Bitketten, die im Prinzip jede Art von Information repräsentieren können und nicht dahingehend gekennzeichnet sind, welchen Informationstyp sie im Einzelfalle darstellen." [Giloi1984: 61]. Demzufolge werden bei der Verarbeitung eines Programmes maschinen-intern nur Bitketten manipuliert, unabhängig davon, ob die aktuelle Anweisung ein Datum oder einen Befehl repräsentiert. Darüber hiaus ist der von Neumann-Rechner nicht in der Lage, die von der auf ihm implementierten höheren

Programmiersprache verwendeten Typen-Attribute für Datenobjekte zu erkennen und zu verarbeiten. Dieser Sachverhalt wird als semantische Lücke bezeichnet.

Eine weitere semantische Lücke zwischen dem von Neumann-Rechner und der verwendeten höheren Programmiersprache besteht in den prinzipiell uneingeschränkten Zugriffsmöglichkeiten des von Neumann-Rechners auf jedes beliebige Speicherobjekt. Diesem muß dafür nur die entsprechende Speicheradresse in einer Instruktion übergeben werden. Dadurch ist der Rechner nicht in der Lage, "unerlaubte Zugriffe, die als Folge von Hardware- oder Software-Fehlern auftreten können, zu erkennen und zu verhindern." [Giloi1984: 61]. Beispiele dafür können das Erkennen von nicht-initialisierten Variablen oder das Referieren von nicht definierten Elementen eines Feldes sein.

Darüber hinaus besteht keine Möglichkeit, daß die für solche Fälle in den höheren Programmiersprachen vorgesehenen Kontrollmechanismen, die die erforderlichen Zugriffsbeschränkungen durchsetzen sollen, von dem von Neumann-Rechner erkannt und verarbeitet werden können.

Das Auftreten von Seiteneffekten

Da der von Neumann-Rechner intern auf typenlosen Bitketten arbeitet, besteht eine uneingeschränkte Zuweisungsmöglichkeit von Werten an Objektnamen. Wird diese Möglichkeit bei der Programmierung weitgehend ausgenutzt, kann dies zu nur schwer durchschaubaren Seiteneffekten bei der Programmausführung kommen.

Die Handhabung dieser uneingeschränkten Zuweisungsmöglichkeit ist letztendlich nur aufgrund der durch den von Neumann-Architektur vorgegebenen streng sequentiellen Programmverarbeitung beherrschbar.

Der von Neumann-Flaschenhals

Bei der Verarbeitung eines Programmes können von dem von Neumann-Rechner nur skalare Operationen ausgeführt werden, d.h. in jedem Rechenschritt kann immer nur der Zustand genau eines Speicherobjektes transformiert werden. "Um eine solche skalare Operation ausführen zu können, muß die Maschine zuerst einen Befehl für die auszuführende Operation aus dem Speicher holen, um mit dem Befehl dann den Datenzugriff vornehmen zu können. [...] Auch bei der Verarbeitung von (programm-mäßig gegebenen) Datenstrukturen transformiert der von Neumann-Rechner in jedem Rechenschritt immer nur ein skalares Element der Struktur, wobei sie sich in expliziter Weise um jeden einzelnen Transport eines skalaren Elements vom und zum Speicher kümmern muß." [Giloi1984: 61].

Für die Verarbeitung einer einzelnen Programmanweisung sind also in der Regel mehrere Zugriffe durch das Rechenwerk auf den Speicher erforderlich, weshalb diese Verarbeitungsweise als der von Neumann-Flaschenhals bezeichnet wird.

Die von Neumann-Sprachen

Die Nachteile der von Neumann-Architektur wirken sich gravierend auf die für den von Neumann-Rechner entwickelten höheren Programmiersprachen aus, die im folgenden als von Neumann-Sprachen bezeichnet werden sollen. Eine von Neumann-Sprachen zeichnet sich vor allem dadurch aus, daß sie ausschließlich auf Bitketten operiert und deshalb nur streng sequentielle Programmabläufe zuläßt.

Repräsentation der von Neumann-Architektur

Die von Neumann-Sprachen stellen eine abstrakte Sicht des von Neumann-Rechners dar, d.h. einzelne Sprachelemente repräsentieren die einzelnen Elemente der von Neumann-Architektur.

Das in den von Neumann-Sprachen verwendeten Variablenkonzept wird dazu verwendet, die Speicherzellen des von Neumann-Rechner zu imitieren, d.h. die Variablen stellen symbolisch benannte Speicherplätze dar. Mit dem Konstrukt der Zuweisung erfolgt die Wertzuweisung zu diesen Variablen und durch deren Bearbeitung eine entsprechende Zustands-transformation in der Programmverarbeitung. Da aufgrund der von Neumann-Architektur nur die Verarbeitung von skalaren Ausdrücken möglich ist, dient die Zuweisung letztendlich auch dazu, entsprechende Zerlegung eines komplexen Ausdrucks vorzunehmen. Demzufolge stellt die Zuweisung den linguistischen von Neumann-Flaschenhals dar.

Der konzeptionelle von Neumann-Flaschenhals der von Neumann-Architektur bewirkt, daß für jede zustandstransformierende Operation mehrere zusätzliche Instruktionen explizit angegeben werden müssen, um die gewünschte Zustandstransformation erzeugen zu können. Demzufolge muß ungefähr das dreifache an derartigen, ausschließlich der internen Verwaltung des von Neumann-Rechners dienenden, organisatorischen Operationen durchgeführt werden, um eine solche Zuweisung ausführen zu können.

Der von Neumann-Programmierstil

Der Nachteil der von Neumann-Architektur liegt vor allem in dem beschriebenen konzeptionellen Flaschenhals. Die Handhabung dieses Flaschenhalses macht es für den Programmierer erforderlich, zusätzlich zur eigentlichen Problemlösung auch die für die interne Verarbeitung erforderlichen organisatorischen Operationen bei der Programmerstellung zu berücksichtigen. Dadurch hat sich ein Programmierstil herausgebildet, der vor allem damit beschäftigt ist, die Programmbearbeitung durch den von Neumann-Rechner zu ermöglichen. Dem Programmierer geht damit die Zeit verloren, eine sinnvolle konzeptionelle Lösung für das umzusetzende Problem zu entwickeln. Die Lösung des Problems tritt also hinter der organisatorischen Handhabung des von Neumann-Rechners zurück.

Darüber hinaus bewirkt die skalare und streng sequentielle Progammverarbeitung durch den von Neumann-Rechner einen entsprechenden Denk- und Programmierstil, der zum einen der natürlichen Denkweise des Menschen widerspricht und zum anderen zur Lösung des umzusetzenden Problems nicht erforderlich ist.

Ansätze zur Beseitigung der Nachteile der von Neumann-Sprachen

Um die aufgezeigten Mängel der von Neumann-Sprachen zu beseitigen, wurden zunächst die bestehenden Programmiersprachen überarbeitet und erweitert. Dies hatte aber zur Folge, daß diese damit überdimensioniert, komplex und unflexibel wurden, da jede Programmiersprache aus Kompatibilitätsgründen grundsätzlich sämtliche Möglichkeiten der vorangegangenen Version beinhalten mußte, zu denen dann die als notwendig erachteten Erweiterungen hinzugefügt wurden. Da es sich aber bei den Nachteilen der von Neumann-Sprachen um grundsätzliche Probleme des Sprachkonzeptes in Verbindung mit der von Neumann-Architektur handelt, verfügen auch die solcherart erweiterten Programmiersprachen in der Regel nur über eingeschränkte Ausdrucksmöglichkeiten. Sie wurden vielmehr nur weiter aufgebläht und damit letztendlich immer weniger handhabbar.

Ein sinnvoller Ausweg aus dieser Problematik schien nur in der vollständigen Abkehr von dem Sprachkonzept der von Neumann-Sprachen zu liegen, wobei die Lösung vor allem in dem Konzept

der funktionalen Programmierung gesucht wurde. Es wurde allerdings schnell deutlich, daß eine endgültige Beseitigung der Nachteile vorhandener Programmiersprachen nur dann möglich war, wenn gleichzeitig eine veränderte Rechnerarchitektur eingesetzt wird. Aufgrund der Vormachtstellung der von Neumann-Architektur und der von Neumann-Sprachen konnte sich diese Konzeption allerdings nicht durchsetzen. Letztendlich stellt die Qualitätssicherung bei der Entwicklung von Software bis heute ein großes Problem dar

Konzept

Die von-Neumann-Architektur ist ein Schaltungskonzept zur Realisierung universeller Rechner (*Von-Neumann-Rechner*, VNR). Sie realisiert alle Komponenten einer Turingmaschine. Dabei ermöglicht ihre systematische Aufteilung in die entsprechenden Funktionsgruppen jedoch die Nutzung spezialisierter binärer Schaltwerke und damit eine effizientere Strukturierung der Operationen.

Im Prinzip bleibt es aber dabei, dass alles, was mit einer Turingmaschine berechenbar ist, auch auf einer Maschine mit *Von-Neumann-Architektur* berechenbar ist und umgekehrt. Gleiches gilt für alle höheren Programmiersprachen, die durch einen Compiler oder Interpreter auf die binäre Repräsentation abgebildet werden. Sie vereinfachen zwar das Handling der Operationen, bieten jedoch keine Erweiterung der von der Turingmaschine vorgegebenen Semantik. Dies wird daran deutlich, dass die Übersetzung aus einer höheren Programmiersprache in die binäre Repräsentation wiederum von einem binären Programm ohne Anwenderinteraktion vorgenommen wird.

Komponenten

Ein von-Neumann-Rechner beruht auf folgenden Komponenten, die bis heute in Computern verwendet werden:

- ALU (Arithmetic Logic Unit) - Rechenwerk, auch Prozessor oder Zentraleinheit genannt, führt Rechenoperationen und logische Verknüpfungen durch.
- Control Unit - Steuerwerk oder Leitwerk, interpretiert die Anweisungen eines Programmes und steuert die Befehlsabfolge.
- Memory - Speicherwerk speichert sowohl Programme als auch Daten, welche für das Rechenwerk zugänglich sind.
- I/O Unit - Eingabe-/Ausgabewerk steuert die Ein- und Ausgabe von Daten, zum Anwender (Tastatur, Bildschirm) oder zu anderen Systemen (Schnittstellen).
- Bus-System verbindet die Komponenten des Rechners untereinander.

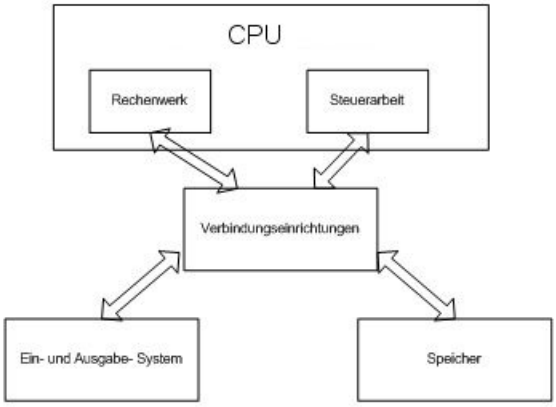

Programmablauf

Diese Komponenten arbeiten Programmbefehle nach folgenden Regeln ab.

- Prinzipien des gespeicherten Programmes:
  - Befehle sind in einem RAM-Speicher mit linearem (1-dimensionalem) Adressraum abgelegt.
  - Ein Befehls-Adressregister, genannt Befehlszähler oder Programmzähler, zeigt auf den momentan auszuführenden Befehl.
  - Befehle können geändert werden wie Daten.

- Prinzipien der sequentiellen Programm-Ausführung (s. a. Von-Neumann-Zyklus):
  - Befehle werden aus einer Zelle des Speichers gelesen und dann ausgeführt.
  - Normalerweise wird dann der Inhalt des Befehlszählers inkrementiert (d. h. um den Wert Eins erhöht).
  - Es gibt einen oder mehrere Sprung-Befehle, die dann den Inhalt des Befehlszählers um einen anderen Wert als +1 verändern.
  - Es gibt einen oder mehrere Verzweigungs-Befehle, die in Abhängigkeit vom Wert eines Entscheidungs-Bit den Befehlszähler inkrementieren oder einen Sprung-Befehl ausführen.

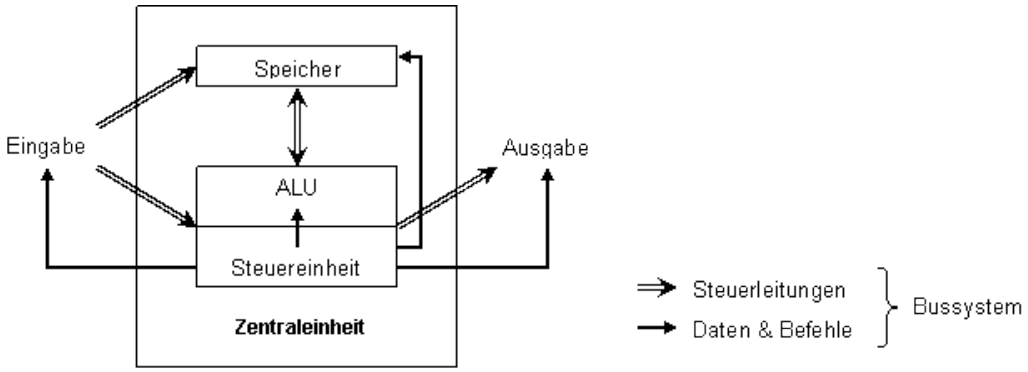

Die **Harvard-Architektur**

Die **Harvard-Architektur** bezeichnet in der Informatik ein Schaltungskonzept zur Realisierung besonders schneller CPUs und Signalprozessoren. Der Befehlsspeicher ist physisch vom Datenspeicher getrennt und beide werden über getrennte Busse angesteuert. Der Vorteil dieser Architektur besteht darin, dass Befehle und Daten gleichzeitig geladen, bzw. geschrieben werden können. Bei einer klassischen Von-Neumann-Architektur sind hierzu mindestens zwei aufeinander folgende Buszyklen notwendig.

Die Harvard-Architektur wurde zunächst überwiegend in RISC-Prozessoren konsequent umgesetzt. Moderne Prozessoren in Harvard-Architektur sind in der Lage, parallel mehrere Rechenwerke gleichzeitig mit Daten und Befehlen zu füllen. Bei Signalprozessoren der C6x-Familie von Texas Instruments ist dies beispielsweise für bis zu acht Rechenwerke möglich.

Ein weiterer Vorteil der Trennung ist, dass die Datenwortbreite und Befehlswortbreite unabhängig festgelegt werden kann. Damit kann auch, wenn erforderlich, die Effizienz des Programmspeicherbedarfs verbessert werden, da sie nicht direkt von den Datenbusbreiten abhängig ist, sondern ausschließlich vom Befehlssatz. Dies kann z.B. in eingebetteten Systemen oder kleinen Microcontroller-Systemen von Interesse sein.

Als besonders bekannte Vertreter sollten hier auch die Produkte der Firma *Microchip Technology Inc.* erwähnt werden, die ebenso auf dieser Architektur aufbauen (*PICmicro*).

Eine bedeutende Erweiterung der Harvard-Architektur wurde von der amerikanischen Firma *Analog Devices* Anfang der 1990er Jahre durch die Einführung der *SHARC-(Super-Harvard-Architecture)-*

Technologie vorgenommen, bei der die genannten Speichersegmente als Dual-Port-RAMs ausgeführt sind, die kreuzweise zwischen den Programm- und Daten-Bussen liegen.

Die Bezeichnung Harvard-Architektur wird auch auf Prozessoren in herkömmlichen von-Neumann-Systemen angewendet, deren Prozessoren zwar einen gemeinsamen Hauptspeicher für Code und Daten verwenden, diese jedoch in unterschiedlichen Caches platzieren

1.4 Entwurfskriterien der Rechnerarchitektur

Gestaltungsgrundsätze für Rechnersysteme

- Leistungsfähigkeit
  - Bestimmung der Leistungfähigkeit durch:
  - a. Benchmarkprogramme (spezielle Testprogramme)
  - b. Angabe von MIPS (million instructions per second) oder Angabe von MFLOPS
  - Angabe der Bewertungen nur sinnvoll unter Berücksichtigung späterer Anwendungsgebiete

- Ausfalltoleranz
  - Eigenschaft von Systemen, bei Ausfall von Komponenten einen Minimal-Betrieb zu garantieren
- Konsistenz
  - Eigenschaft zum folgrichtigen Aufbau z.B. Befehle zur Adressierung gleich, unabhängig von der Rechenoperation.
- Orthogonalität
  - Funktionell unabhängige Teilsysteme spezifizieren
  - Jedes Teilsystem kann komplette Funktionen anderer Teilsysteme verwenden, z.B Verwendung der Funktionen der Adressierungseinheit für Integer-ALU und floating point ALU

- Symmetrie
  - Mathematische symetrische Ausdrücke sollen entsprechend unterstützen werden, z.B. keine Unterscheidung des Wertebereichs von positiven oder negativen Zahlen
- Transparenz
  - Funktionen sollen überschaubar sein- Dokumentation des Ergebnisses der Funktion(Operation) als Statusmeldung
- Virtualiät
  - Physikalische Begrenztheit verbergen, z.B. Betrieb eines virtuellen Speichersystems in einem Rechner mit einer MMU (memory managment unit)
- Kompatibiliät
  - Gleicher Arbeitsauftrag führt bei verschiedenen Rechnern, unabhängig von Zeit und Ausrüstung, zu gleichem Ergebnis → Programmkompatibilität
- Dynamische Erweiterbarkeit
  - Erweiterung des Umfeldes des Maschinenbefehssatzes, z.B. Mikroprogrammierung des Steuerwerkes des Mikroprozessors

1.5 Darstellung von Zeichen und Zahlen

http://www.dualzahlen.de/

Dualsystem	Repräsentation im Rechner	Basis 2
Quinärsystem	Zählen mit einer Hand	Basis 5
Oktalsystem	Menschenlesbare Darstellung von Maschinenzahlen	Basis 8
Dezimalsystem	Zähen mit Finger	Basis 10
Doudezimalsystem	„Dutzend“, historisch bedeutsam	Basis12
Hexadezimalsystem	Menschenlesbare Darstellung von Maschinenzahlen	Basis 16
Vigesimalsystem	Zählen mit Fingern und Zehen	Basis 20
Sexagesimalsysmmatik	Astronomie, Mathematik	Basis 60

Vom Dualsystem ins Dezimalsystem

Um eine Dualzahl in die entsprechende Dezimalzahl umzurechnen, werden alle Ziffern jeweils mit ihrem Stellenwert (entsprechende Zweierpotenz) multipliziert und dann addiert.

Beispiel:

$$1010_{(2)} = 1 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 0 \cdot 2^0 = 1 \cdot 2^3 + 1 \cdot 2^1 = 8 + 2 = 10_{(10)}$$

vom Dezimalsystem ins Dualsystem

Es gibt mehrere Möglichkeiten der Umrechnung ins Dualsystem. Im Folgenden ist die Divisionsmethode (auch Modulo-Methode genannt) am Beispiel **41**$_{(10)}$ beschrieben:

$$\begin{array}{lllll} 41 & :2 & = & 20 & \text{Rest } 1 \\ 20 & :2 & = & 10 & \text{Rest } 0 \\ 10 & :2 & = & 5 & \text{Rest } 0 \\ 5 & :2 & = & 2 & \text{Rest } 1 \\ 2 & :2 & = & 1 & \text{Rest } 0 \\ 1 & :2 & = & 0 & \text{Rest } 1 \end{array} \uparrow$$

Die entsprechende Dualzahl ergibt sich durch Notation der errechneten Reste von unten nach oben: **101001**$_{(2)}$.

Grundrechenarten im Dualsystem

Analog zu den Zahlen im Dezimalsystem lassen sich mit Dualzahlen die gängigen arithmetischen Grundoperationen Addition, Subtraktion, Multiplikation und Division durchführen. Tatsächlich werden die benötigten Algorithmen sogar einfacher und lassen sich effizient mit logischen Schaltungen elektronisch realisieren. Die Einführung von Dualzahlen in der Rechentechnik brachte daher viele Vorteile.

Addition	Beispiel
0 + 0 = 0 0 + 1 = 1 1 + 0 = 1 1 + 1 = 10	$\begin{array}{r} 1011_2 \\ +\quad 11_2 \\ \hline 1110_2 \end{array}$

Subtraktion	Beispiel
0 - 0 = 0 0 - 1 = -1 1 - 0 = 1 1 - 1 = 0	$\begin{array}{r} 1011_2 \\ -\quad 111_2 \\ \hline 100_2 \end{array}$

Multiplikation	Beispiel
0 . 0 = 0 0 . 1 = 0 1 . 0 = 0 1 . 1 = 1	$\begin{array}{r} 1010_2 \\ \cdot\quad 11_2 \\ \hline 11110_2 \end{array}$

Division	Beispiel
0 / 0 = n.def. 0 / 1 = 0 1 / 0 = n.def. 1 / 1 = 1	$\begin{array}{r} 1010_2 \\ /\quad 10_2 \\ \hline 101_2 \end{array}$

Hexadezimalsystem (Sedezimalsystem)

- Basis: 16
- Zeichenvorrat:{0;1;2;3;4;5;6;7;8;9;A;B;C;D;E;F}
- In der Praxis können mit wenig Zeichen große Zahlen dargestellt werden
- Anwendung bei Programmiersprachen,Farbangaben bei Grafikprogrammen
- zweithäufigst genutztes Zahlensystem (n. DEZ)
- Verminderte Fehleranfälligkeit
- Wird auf maschinennaher Umgebung häufig in Assemblersprachen genutzt

Hexadezimalsystem - Zeichenvorrat

DEZ	0	1	2	3	4	5	6	7
BIN	0000	0001	0010	0011	0100	0101	0110	0111
HEX	0	1	2	3	4	5	6	7

DEZ	8	9	10	11	12	13	14	15
BIN	1000	1001	1010	1011	1100	1101	1110	1111
HEX	8	9	A	B	C	D	E	F

Umwandlung Hexadezimal- in Dezimalsystem

Die Stellenwerte des Hexadezimalsystems sind Potenzen zur Basis 16.

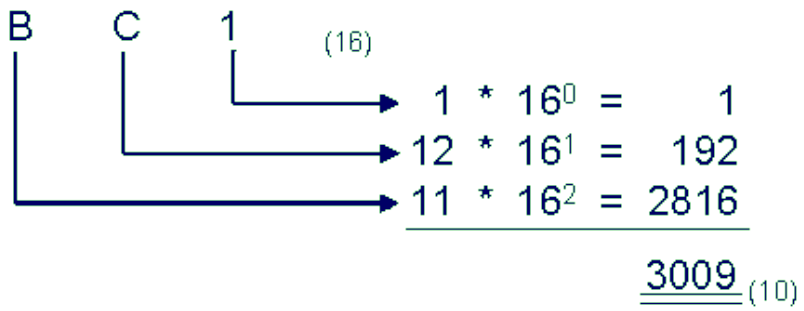

Umwandlung Dezimal- in Hexadezimalsystem

Zur Umwandlung von Dezimal- in Hexadezimalzahlen müssen die Reste von unten nach oben angeschrieben werden

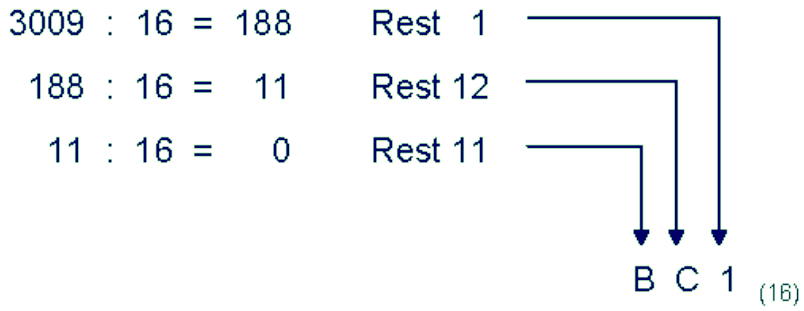

Oktalsystem

- Basis 8
- Zeichenvorrat {0;1;2;3;4;5;6;7}
- Erleichtert den Umgang mit Dualzahlen
- Aus 3-Bit-Worten können acht verschiedene Kombinationen dargestellt werden

Umwandlung Dual- in Oktalsystem

binär	000	001	010	011	100	101	110	111
oktal	0	1	2	3	4	5	6	7
dezi.	0	1	2	3	4	5	6	7

1. Zerteilen der Dualzeichenfolge in 3er-Gruppen von rechts beginnend
2. Umschreiben der Dualzahl in eine Oktalzahl

$$3009_{10} = 101111000001_2 = 5701_8$$

binär	101	111	000	001
oktal	5	7	0	1

Umwandlung Oktal - in Dezimalsystem

Zur Umwandlung von Oktal- in Dezimalzahlen einfach die Oktalzahl mit ihrem Stellenwert potenzieren und die Ergebnisse addieren:

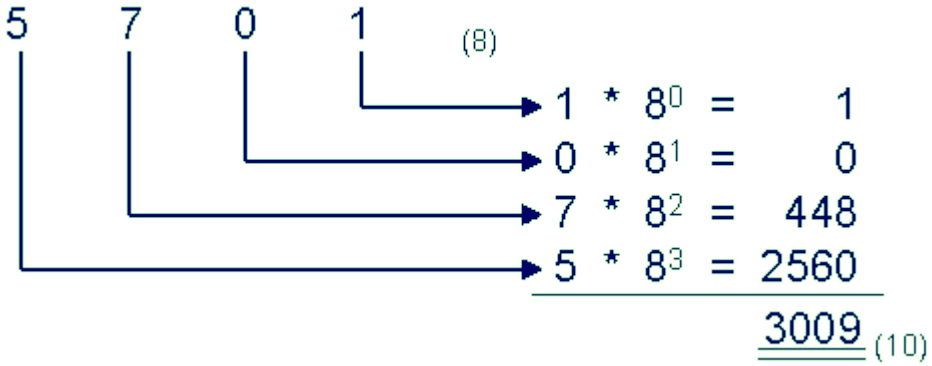

Umwandlung Dezimal- in Oktalsystem

Zur Umwandlung von Dezimal- in Oktalzahlen muss die Dezimalzahl mit Hilfe der Modulo-Operation umgewandelt werden und von der höchsten oktalen Stelle aus gelesen werden:

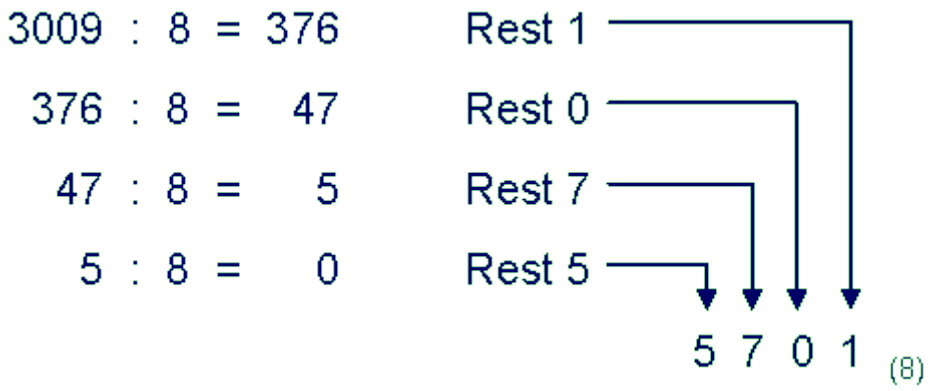

Darstellung negativer Zahlen

Mit dem Dualcode kann man alle positiven ganzen Zahlen einschließlich der Null darstellen. Wie kann man aber mit dem Dualcode negative Zahlen erzeugen? Im Dezimalsystem werden neben den Ziffern 0 bis 9 auch noch die beiden Vorzeichen + und - sowie das Komma verwendet. Bei der Darstellung von Zahlen in Rechnern wollen wir aber an dem Binärcode festhalten. Es steht uns also nur die beiden Zeichen 0 und 1 zur Verfügung. Die Vorzeichen und das Komma dürfen nicht als neue Zeichen eingeführt werden.

Zahlendarstellung mit Vorzeichen und Betrag

Analog zu dem Dezimalsystem bietet sich zunächst das Verfahren Vorzeichen und Betrag an. Dabei gibt das Bit, das am weitesten links steht, das Vorzeichen an. Da führende Nullen oder ein Pluszeichen eine Dezimalzahl nicht verändert, ergibt sich fast zwangsläufig folgende Definition für das Vorzeichenbit:

- 0 → positive Zahl
- 1 → negative Zahl

Bsp. (+91)10 = (**0** 101 1011)2

(-91)10 = (**1** 101 1011)2

Das linke Bit enthält also die Bedeutung eines Vorzeichens, ohne das wir ein zusätzliches Zeichen im Binärsystem aufnehmen müssen.

	Vorzeichen	Betrag	
+5	0	000 0101	positive Zahlen
+4	0	000 0100	
+3	0	000 0011	
+2	0	000 0010	
+1	0	000 0001	
+0	0	000 0000	
-0	1	000 0000	negative Zahlen
-1	1	000 0001	
-2	1	000 0010	
-3	1	000 0011	
-4	1	000 0100	
-5	1	000 0101	

Bei Programmbeginn kann man eine Zahl als unsigned bzw signed, also ohne bzw mit Vorzeichen, deklarieren. Dadurch ändert sich die Bedeutung des höchsten Bits, was wieder Auswirkungen auf das Rechenwerk hat :

- Bei der Addition von Zahlen ohne Vorzeichen (unsigned) werden alle Stellen addiert unabhängig davon, ob das höchste Bit jeweils 0 oder 1 ist
- Bei Zahlen mit Vorzeichen(signed) bedeutet eine 1 als höchstes Bit eine Subtraktion, also eine von der Addition abweichende Operation.
- Bei Subtraktion muss die betragsmäßig kleinere Zahl von der größten abgezogen werden. Unter Umständen muss man dazu die Operanden vertauschen und das beim Vorzeichen das Ergebnisses berücksichtigen. Bsp. 392-528= -(528-392) = -136

Zusammenfassend: Vorzeichen und Betrag

Zahlenbereich (für n =8): von 0111 1111 also +(2^7 -1) = +127
bis 1111 1111 also –(2^7 -1= -127.

Vorteile: Negative Zahlen kann man direkt darstellen und muss sie nicht erst errechnen (wie bei der Komplement-Darstellung)

Nachteile: 1) Für die Null gibt es zwei verschiedene Darstellungen 0000 0000 und 1000 0000. Es bedeutet einen gewissen Zusatzaufwand, dies als Gleichheit zu erkennen.
2) Bei der Subtraktion müssen die Operanden vertauscht werden, wenn der Betrag des Subtrahenden größer ist als der des Minuenden. Auch dafür ist eine zusätzliche Logik erforderlich.
3) Das Rechenwerk muss Zahlen mit und ohne Vorzeichen unterschiedlich verarbeiten.
4) Das Rechenwerk muss addieren und subtrahieren können.

Eine Umwandlung von positiven in negative Zahlen ist mit Hilfe des Einer- bzw. Zweierkomplement realisierbar

Einerkomplement

Das Einerkomplement wird in der digitalen Informationsverarbeitung unter anderen zur Darstellung negativer Zahlen verwandt. Es wird ganz einfach gebildet, indem jede 0 einer Bitfolge durch eine 1 und wiederum jede 1 gegen eine 0 ersetzt wird. Ein Beispiel:

Dualzahl: 11010110
Einerkomplement: 00101001

Hierbei ist jedoch zu beachten, dass die binäre Zahl 11010110 nicht der Dezimalzahl 214 entspricht, sondern der Dezimalzahl

Zweierkomplement

Auch das Zweierkomplement kann zur Darstellung negativer Dualzahlen genutzt werden. Es wird gebildet, indem zum Einerkomplement eine 1 addiert wird. Ein evtl. vorkommender Übertrag am linkesten Bit entfällt.
Ein Beispiel:

Dezimal 42 entspricht:	00101010	**Komplement**	**11010101**
Einerkomplement:	11010101	**1 addiert**	**1**
		Übertrag	1
			11010110

So ergibt das Zweierkomplement von 00101010 die negative Dezimalzahl - 42 bzw. in dualer Schreibweise 11010110.

Beispiel: Ergibt +5 + (-5)=0

	0000 0101	(+5)
+ (-)	1111 1010	(-5)
	1111 1111	(0)

Darstellung von Null:

0000 0000	(+0)
1111 1111	(-0)

Invertierung + Überprüfung

	0000 0101	(+5)
+	1111 1010	(Invertierung)
+	1	
	1111 1011	

Überprüfung:

0000 0101	(+5)
1111 1011	(invertiert)

1| 111 1 111
0000 0000

Gleitkommazahlen

(Floating-Point-Zahl)

- Zahl ist grundsätzlich normiert entsprechend :
  - **Zahl = Vozeichen * 1.Mantisse * 2^Exponent**
- Vorzeichen → Gesamtvorzeichen der Zahl (1. Bit)
- Mantisse → grundsätzlich positiv (23 Bit float, 52 Bit double)
- Exponent → vorzeichenbehaftet (8 Bit float, 11 Bit double)

- **Problem:** Die Zahl 0 ist nicht darstellbar

- **Lösung**: Verwendung einer Kombination aus dem Exponenten (negative Zahlen im Exponenten haben einen Wert mehr)

Exponent – 128 ←→ 0 ←→ +127 (-128 ist überzählige Kombination)
Addition Offset 127

Exponent (-127 ←→ 0 ←→ +127) → (0 ←→ 127 ←→254)
Kombination 255 frei und reserviert

- Exponent 0FFH (float) plus Mantisse zur Kodierung von Sonderzeichen (.B. 0, - unendlich +unendlich)

Rechnen mit Floating-Point-Zahlen

1. Addition / Subtraktion

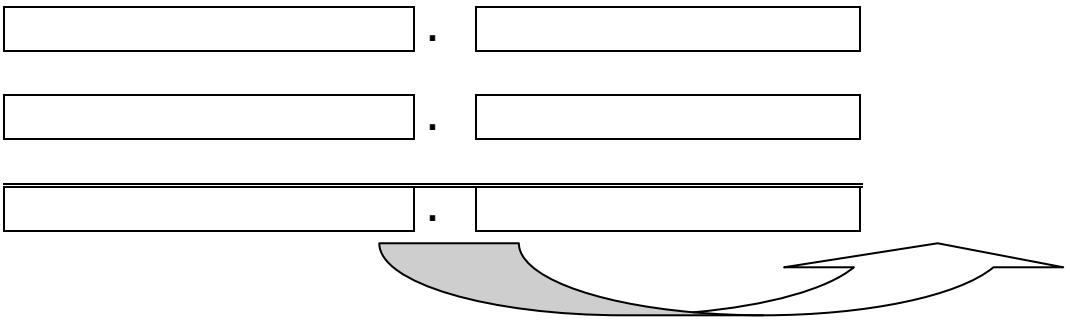

2. Multiplikation

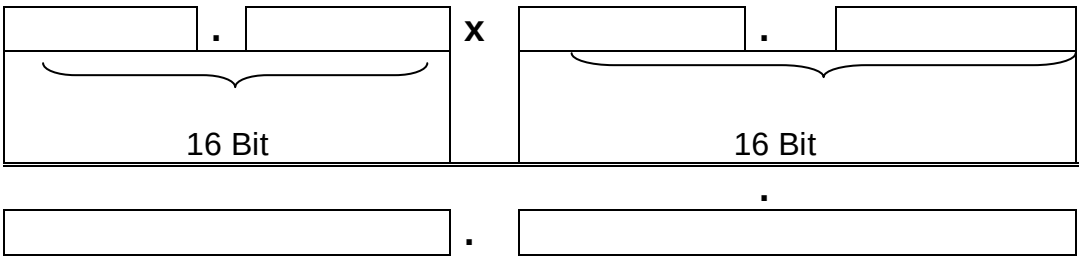

Festkommazahl

(Fix-Point-Zahl) (auf jedem Prozessor darstellbar)

- Komma an fester Position (meist zwischen zwei Byte oder zwei 16 Bit Worten)
- Eine Normierung findet nicht statt
- Der ganzzahlige Teil (Integer) enthält das Vorzeichen, die Mantisse ist immer positiv
    - Zahl = Integer.Mantisse
    - Zahl = 2^n-1….2^0.2^-1….2^-n
- Besonderheiten :
    - die Zahl 0 ist unmittelbar darstellbar
    - Multiplikationen bedeuten einer Verdoppelung der Wortbereite
    - Fix-Point-Zahlen können mit Standard-Maschinenbefahlssatz bearbeitet werden (kein FPU erforderlich)

Kapitel 2 : Prozessorinterne Speicher

2.1 Elektronischer Speicher

Unter der Elektronischen Speicherung sind alle Speichermedien zusammengefasst, welche Informationen in oder auf Basis von elektronischen Bauelementen speichern. Die elektronische Speicherung findet heute praktisch nur noch in Silizium realisierten integrierten Schaltkreisen statt. Die einzelnen Speichermechanismen können nach der Charakteristik der Datenhaltung unterschieden werden:

- *flüchtige* Speicher, deren Informationen verloren gehen, wenn sie nicht aufgefrischt werden oder wenn der Strom abgeschaltet wird,

- *permanente* Speicher, in denen sich eine einmal gespeicherte oder festverdrahtete Information befindet, die nicht mehr verändert werden kann und
- *semi-permanente* Speicher, die Informationen permanent speichern, in denen aber Informationen auch verändert werden können.

Um elektronische Speichermedien lesen zu können, bedarf es auch technischer Hilfsmittel.

- Flüchtig:
  - DRAM, dynamisches RAM (*dynamic random access memory*)
  - SRAM (*static random access memory*)
- Permanent:
  - ROM (*read only memory*)
  - PROM (*programable read only memory*)
- Semi-permanent:
  - EPROM (*erasable programable read only memory*)
  - EEPROM (*electrically erasable programable read only memory*)
  - Flash-EEPROM (USB-Stick)
  - FRAM
  - MRAM
  - Phase Change RAM

Elektronischer Speicher eines Rechner lässt sich einteilen in:

- Register
- Statischer Speicher (SRAM)
- Dynamischer Speicher (DRAM)
- Festwertspeicher(ROM)

Register (Computer)

Ein **Register** ist in der Digitaltechnik eine nach Funktion zusammengefasste Gruppe von einzelnen Speicherzellen – oft Flipflops, manchmal auch DRAM-Zellen – innerhalb eines Prozessors oder Peripheriebausteins.

Die Gesamtheit aller Register eines solchen Bausteins bezeichnet man als dessen Registersatz. Register werden allgemein für die Wahl der Betriebsmodi, im Prozessor zusätzlich zum Zwischenspeichern von Befehlen, Speicheradressen, Rechenoperanden und in Peripheriebausteinen auch zum Zwischenspeichern von Ein- und Ausgabewerten benutzt

Registertypen in der CPU

In CPUs stehen Register an der Spitze der Speicherhierarchie und sind daher die schnellste Möglichkeit, Daten zu manipulieren, da der Zugriff unabhängig vom Daten- oder Adressbus erfolgt.

Die Registersätze verschiedener Arten von Prozessoren unterscheiden sich in der Art, der Anzahl und der Größe der zur Verfügung stehenden Register.

Datenregister

Datenregister werden benutzt, um Operanden zu speichern. Prozessoren neuerer Generation besitzen oft Datenregister mit Akkumulatorfunktion.

In der Regel ist die Größe des Datenregisters zusammen mit der Breite des Datenbus mit ausschlaggebend für die Einordnung des Prozessors als 8-, 16-, 32- oder 64-Bit-Prozessor. Prozessoren mit 8-Bit-Datenbus und 8-Bit-Datenregistern werden als 8-Bit-Prozessoren bezeichnet, z. B. MOS Technologies 6502 oder Zilog Z80. Prozessoren mit unterschiedlicher Größe von Datenbus und Datenregistern werden häufig auch entsprechend bezeichnet, z. B. der Motorola 68000, der mit 16-Bit-Datenbus und 32-Bit-Datenregistern als 16-/32-Bit-Prozessor bezeichnet wird. Die derzeit (2005) neuesten Prozessoren sind meistens 64-Bit-Prozessoren, z. B. Alpha AXP, AMD Opteron, oder Intel-Prozessoren mit EM64T sowie Itanium.

Bei 8-Bit-Prozessoren waren Adressbus und Adressregister meistens 16 Bit groß. Bei den meisten heutigen Prozessoren sind die Adressregister genauso groß wie die Datenregister, der Adressbus meistens gleich groß oder kleiner.

Meistens sind die Datenregister nur mit der ALU verbunden, nicht jedoch mit der FPU. Das heißt, in den meisten Prozessoren können Datenregister nicht als Operanden für FPU-Operationen verwendet werden. In diesem Fall müssen Operanden für die FPU in speziell dafür vorgesehenen Registern, den Fließkommaregistern, gespeichert werden.

Adressregister

Die *Adressregister* spielen eine wichtige Rolle in der Adressarithmetik. Adressregister werden für die Berechnung von Speicheradressen eines Operanden oder Befehls genutzt. Sie haben Verbindung mit dem internen Datenbus und dem Adressbus.

Bei indizierter Adressierung, z. B. beim Intel 8086, werden zwei Typen von Adressregistern unterschieden, die Indexregister und die *Basisadressregister*, auf die bei den Spezialregistern eingegangen wird. Indexregister speichern den Offset zu einer Basisadresse, der oft vorzeichenbehaftet ist.

Für das Indexregister berechnet ein spezieller Addierer die Summe aus dem Indexregisterwert und einem Offset, der auf dem internen Datenbus anliegt. Die sich ergebende Summe wird auf dem Adressbus ausgegeben.

Bei linearer Adressierung, z. B. beim Motorola 68000, gibt es keine solche Unterscheidung bei den Adressregistern, auch wenn indirekte Adressierungsarten unter Umständen unterstützt werden.

Frei verwendbare Register

Moderne CPUs, z. B. PowerPC, besitzen frei verwendbare Register (engl. GPR für General Purpose Register). Diese Register lassen sich beliebig je nach Bedarf als Datenregister oder als Adressregister einsetzen.

Spezialregister

Spezialregister sind nur teilweise vom Anwender programmierbar. Sie speichern den Betriebszustand des Prozessors, außerdem erfüllen sie Hilfsfunktionen für den Prozessor.

Bei den meisten Architekturen sind folgende Spezialregistertypen anzutreffen:

- *Befehlszählregister*, auch *Programmzähler* oder *Befehlszähler*, (englisch *Instruction Pointer* (IP (16-Bit)) bzw. *Extended Instruction Pointer* (EIP (32-Bit)) oder *program counter* (PC)): das Befehlszählregister enthält je nach Systemarchitektur die Speicheradresse des derzeitigen oder des nächsten auszuführenden Befehls – ein *Sprungbefehl* setzt dieses Register direkt;
- *Befehlsregister* (Instruction register): speichert den aktuellen Befehl;
- *Basisregister*, z. B. für die Basisvektortabelle, es kann von einem Benutzerprogramm neu gesetzt werden;
- *Statusregister* (englisch: *Condition Code Register, CCR* oder auch *Processor Status Word, PSW*): geben bestimmte Zustände nach Ausführung eines Befehls an (bspw. Zero-Flag, Vorzeichen-Flag etc.) – ein Benutzerprogramm initialisiert einzelne Flags z. B. vor arithmetischen Operationen;
- *Interrupt-Steuerregister* (englisch: *Interrupt Control Register*): Bei komplexeren CPUs, wo diese Funktionalität nicht mit einem oder zwei Bits im Statusregister (s. o.) abgehandelt werden kann, kann hierüber sehr differenziert vorgegeben werden, auf welche Interrupts überhaupt bzw. mit welcher Priorität reagiert werden soll. Durch Lesen kann die Software herausfinden, welcher der verschiedenen Interrupts überhaupt vorliegt. Durch Schreiben kann sie (temporär) z. B. einzelne Interrupts sperren, die während einer bestimmten Operation stören würden.

Einige Mikrocontroller (z.B. Intel 8051-Familie sowie Siemens C167-Familie) organisieren diese Spezialregister und die Register zur Kontrolle der internen I/O-Ports in Form einer Registerbank, die sich mittels Memory Mapped I/O mit den gewöhnlichen Befehlen für den Arbeitsspeicherzugriff ansprechen lässt. Der durch diese Registerbank verdeckte Arbeitsspeicher lässt sich entweder gar nicht oder nur indirekt ansprechen.

Stackregister

Die *Stackregister* (englisch *stack pointer* (SP)) sind *Adressregister* zur Verwaltung von Stapelspeichern. Ein Stapelspeicher, auch Kellerspeicher oder nur Stack genannt, wird von einem *Stackregister* nach dem LIFO-Prinzip organisiert und kann mit Push- bzw. Pop-Operationen gefüllt bzw. geleert werden. Dabei zeigt das Stackregister immer auf die Speicheradresse am Ende des Stacks, je nach Architektur auf oder zumeist hinter das letzte Element. Auf den meisten Architekturen existiert ein System-Stack und ein Anwender-Stack. Das Betriebssystem nutzt den System-Stack zur Sicherung und Restauration des Prozessorstatus bei der Prozessumschaltung. Der Anwender-Stack kann vom Programmierer frei genutzt werden. Bei Aufruf eines Unterprogramms (Prozedur, Subroutine) wird typischerweise dynamisch ein separater Stackbereich für dessen Variablen angelegt, der bei Beendigung sofort wieder freigegeben wird.

Ein-/Ausgaberegister

Neben Pufferplätzen in der Zentraleinheit des Rechnersystems können Register auch in der Elektronik angeschlossener Peripheriegeräte oder -chips auftreten, aber auch die CPU selbst kann über integrierte Ein-/Ausgaberegister verfügen. Sie lassen sich in der Regel in die gleichen Unterkategorien einteilen wie die obige Liste für reine CPU-Register. Ein paar repräsentative Beispiele:

- Die Statusregister der Steuerwerke der externen Massenspeicher umfassen neben Zustands- und Datenregistern in der Regel Adressregister, die sich auf Adressangaben des Massenspeichers beziehen, heute meistens Sektornummern.
- In Video-Chips steuern die Bits in den Zustandsregistern z. B. die verschiedenen Video-Modi, Datenregister können z. B. Sprite-Daten enthalten.
- Bei einer parallelen Schnittstelle enthält ein Datenregister die eigentlichen Druckdaten und ein Zustandsregister die Handshake-Bits. Oft gibt es hier zusätzlich ein Zustandsregister namens DDR (für *data direction register*), über das die Datenrichtung (Ein- oder Ausgang) der Datenleitungen programmiert werden kann (z. B. bei bidirektionaler Verwendung).

Diese I/O-Register sind häufig über Portnummern als I/O-Ports auch vom Programm der Zentraleinheit erreichbar, oder werden in den Adressraum des Hauptspeichers eingeblendet (Memory Mapped I/O). Je nach Sichtweise hat sich dabei dennoch die begriffliche Unterscheidung von Speicherplätzen in den RAM-Speicherbanken und Registerplätzen an Logikbausteinen erhalten.

Von „http://de.wikipedia.org/wiki/Register_%28Computer%29“

Statisches RAM (SRAM)

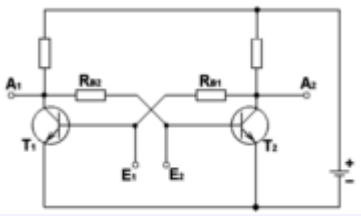

Bistabile Kippstufe mit Transistoren

SRAM steht für **statisches RAM** und bezeichnet einen elektronischen Speicherbaustein, der hauptsächlich in Computern als Cache eingesetzt wird und als integrierter Schaltkreis ausgeführt ist. Sein Inhalt ist flüchtig (volatil), das heißt, die gespeicherte Information geht bei Abschaltung der Betriebsspannung verloren. Die Informationen werden durch Zustandsänderung von bistabilen Kippstufen (Flipflops) gespeichert. Dies macht die Speicherzelle zwar extrem schnell, aber eine Speicherzelle ist verhältnismäßig riesig (über 100 F^2) und verbraucht viel Strom. SRAMs werden heutzutage als *6-Transistor-Zelle* in CMOS-Technolgie hergestellt. Der im Bild zu sehende Aufbau der Kippstufe mit Widerständen als Lastelementen wird nicht mehr eingesetzt, statt der Lastwiderstände werden heute auch Transistoren eingesetzt.

Dynamisches RAM (DRAM)

Prinzipieller Aufbau einer DRAM-Speicherzelle

Hauptartikel: Dynamisches RAM

DRAM steht für **dynamisches RAM** und bezeichnet einen elektronischen Speicherbaustein, der hauptsächlich in Computern eingesetzt wird und als integrierter Schaltkreis ausgeführt ist. Sein Inhalt ist flüchtig (volatil), das heißt, die gespeicherte Information geht bei Abschaltung der Betriebsspannung verloren. Die Informationen werden in Form des Ladezustandes eines Kondensators gespeichert. Dieser sehr einfache Aufbau macht die Speicherzelle zwar sehr klein (6 bis 10 F^2), allerdings entlädt sich der Kondensator bei den eingesetzten Kapazitäten durch die auftretenden Leckströme sehr schnell, und der Informationsinhalt geht verloren. Daher müssen die Speicherzellen regelmäßig wiederaufgefrischt werden.

ROM

Unter **Nur-Lese-Speicher** oder **Festwertspeicher** (engl. auch *Read-Only-Memory*, *ROM*) versteht man einen Datenspeicher, der nur lesbar ist, im normalen Betrieb aber nicht beschrieben werden kann und nicht flüchtig ist, das heißt: Er hält seine Daten auch in stromlosem Zustand. Das prädestiniert ihn zur Aufnahme von „fest verdrahteten“ Computerprogrammen wie z. B. dem BIOS. Das Einschreiben von Daten in ein ROM wird als Programmierung des Bausteins bezeichnet und ist nicht mit den Schreibzugriffen in einem *Schreib-Lese-Speicher* (Random Access Memory, Festplatte) vergleichbar. Zu unterscheiden ist zwischen Bausteinen mit reversibler und irreversibler Programmierung. ROM ermöglicht wie RAM einen wahlfreien Zugriff auf die Daten.

Ein PROM-Chip für einen PDA

Ursprünglich wurden ROMs nur bei der Fertigung „fest verdrahtet“. Da diese Verdrahtung mit einer „Maske“ (einer Art Filmnegativ) auf den rohen Chip direkt aufbelichtet wird, spricht man hierbei von einem *maskenprogrammierten* ROM oder kurz **Masken-ROM**. Da sich dieses Verfahren allerdings nur in Großfertigung rechnet, wurde eine – ständig wachsende – Familie weiterer Speicherbausteine dieses Typs entwickelt, die auch nach der Fertigung mit Informationen befüllt werden können.

Inzwischen gibt es eine recht große Anzahl verschiedener Arten von ROM:

- Masken-ROM – nur zum Fertigungszeitpunkt programmierbar, die preisgünstigste Version
- Programmable Read Only Memory (PROM), einmalig programmierbar
- Eraseable Programmable Read Only Memory (EPROM), löschbar mit UV-Licht
- Electrically Erasable Programmable Read Only Memory (EEPROM)

Als Ersatz für das ROM wird heute meist Flash-Speicher verwendet – als FLASH-EEPROM auch mit wahlfreier Adressierung erhältlich

Aufbau dynamisches Speicher

Dynamic Random Access Memory, oder der halb eingedeutschte Begriff Dynamisches RAM (DRAM), bezeichnet eine Technologie für einen elektronischen Speicherbaustein, der hauptsächlich in Computern eingesetzt wird, jedoch auch in anderen elektronischen Geräten wie zum Beispiel Druckern zur Anwendung kommt. Das speichernde Element ist dabei ein Kondensator, der entweder geladen oder entladen ist. Über einen Schalttransistor wird er zugänglich und entweder ausgelesen oder mit neuem Inhalt beschrieben. Der Speicherinhalt ist flüchtig (volatil), das heißt die gespeicherte Information geht bei fehlender Betriebsspannung oder zu später Wiederauffrischung verloren.

DRAM besteht nicht wie im Artikel *Halbleiterspeicher* vereinfacht gezeigt aus einer einzigen zweidimensionalen Matrix. Stattdessen sind die Speicherzellen, die auf der Oberfläche eines Dies angeordnet und verdrahtet sind, in einer ausgeklügelten hierarchischen Struktur unterteilt. Während die innere Sruktur herstellerspezifisch aufgebaut ist, ist die von außen sichtbare logische Struktur vom Industriegremium JEDEC normiert. Dadurch wird sichergestellt, dass sich Chips unterschiedlicher Hersteller und verschiedener Größen nach dem immer gleichen Schema ansprechen lassen.

Aufbau einer Speicherzelle

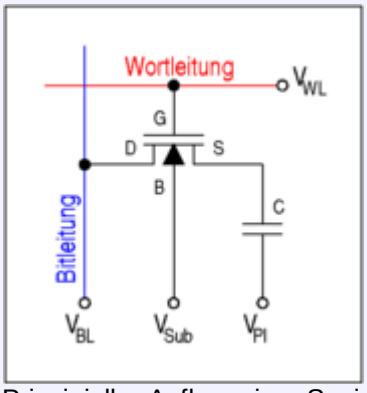

Prinzipieller Aufbau einer Speicherzelle aus einem Transistor und einem Kondensator (1T1C-Zelle)

Der Aufbau einer einzelnen DRAM-Speicherzelle ist sehr einfach, sie besteht nur aus einem Kondensator und einem Transistor. Heute verwendet man einen Feldeffekttransistor. Die Information wird als elektrische Ladung im Kondensator gespeichert. Jede Speicherzelle speichert ein Bit. Während früher meist Kondensatoren in Planartechnologie Verwendung fanden, werden aktuell zwei andere Technologien verwendet:

- Bei der "Stack"-Technologie wird der Kondensator über dem Transistor aufgebaut
- Bei der "Trench"-Technologie wird der Kondensator durch Ätzen eines ca. 5-10 Mikrometer tiefen Loches (oder Grabens) in das Substrat erzeugt.

Der in der nebenstehenden Abbildung eingezeichnete obere Anschluss wird entweder auf die Bitleitungsspannung V_{BL} aufgeladen oder entladen (0V). Der untere Anschluss aller Kondensatoren wird gemeinsam an eine Spannungsquelle angeschlossen, welche idealerweise eine Spannung von

V_{Pl}= 1/2 * V_{BL} besitzt. Dadurch lässt sich die Maximalfeldstärke im Dielektrikum des Kondensators halbieren.

Der Transistor - auch Auswahltransistor genannt - dient als Schalter zum Lesen und Schreiben der Information. Zum Beschreiben oder Auslesen der Zelle muss über die Wortleitung (*"wordline"*) an den Gate-Anschluss "G" des n-MOS-Transistors eine positive Spannung V_{WL} angelegt werden. Dadurch wird eine leitende Verbindung zwischen den Source- ("S") und den Drain-Gebieten ("D") hergestellt, welche den Zellkondensator mit der Bitleitung (*"bitline"*) verbindet. Der Substrat-Anschluss "B" ("Bulk") des Transistors ist entweder an das Massepotential oder an ein leicht negatives Potential V_{Sub} zur Unterdrückung von Leckströmen angeschlossen.

Durch ihren sehr einfachen Aufbau brauchen die Speicherzellen nur sehr wenig Chipfläche. Die konstruktionsbedingte Größe einer Speicherzelle wird gern als das Vielfache der Quadratfläche F^2 der kleinsten fertigbaren Strukturlänge („minimum Featuresize“ oder abgekürzt F) angegeben: Eine DRAM-Zelle benötigt heute 6 oder 8 F^2, während eine SRAM-Zelle mehr als 100 F^2 benötigt. Daher kann ein DRAM bei gegebener Chipgröße eine wesentlich größere Zahl von Bits speichern. Daraus resultieren weitaus niedrigere Herstellungskosten pro Bit als beim SRAM. Unter den heute üblichen elektronischen Speicherarten hat nur der NAND-Flash eine kleinere Speicherzelle mit ungefähr 4,5 F^2 (bzw. 2,2 F^2 pro Bit für Multilevel-Cells).

Aufbau eines statischen Speichers(SRAM)

http://www.geoinformatik.uni-rostock.de/einzel.asp?ID=-102645295

Bedeutung:
Statische Speicher werden aufgrund ihrer Schnelligkeit als Cache-Speicher eingesetzt. Im Gegensatz zu den dynamischen Speichern brauchen sie keinen Refresh (Auffrischung) des Speicherinhaltes. Ein statischer Speicher arbeitet pro Speicherzelle mit einer aus mehreren Bauelementen bestehenden Schaltung, die - ausgehend vom zu speichernden Datum - einen bestimmten Zustand einnimmt und sich dann selbst verriegelt, so dass eine Zustandsänderung nur von aussen vorgenommen werden kann. Ein statischer Speicher verliert seinen Dateninhalt erst, wenn die Versorgungsspannung zusammenbricht. Aufgrund des komplexeren Aufbaus der Speicherzelle können statische Speicher nur mit geringeren Dichten gebaut werden als dynamische Speicher. Ausserdem sind sie - bei vergleichbarer Speicherkapazität - wesentlich teurer als dynamische Speicher.

Festwertspeicher(ROM)

Festwertspeicher (ROM)

Ein **Festwertspeicher** (Synonym: **Festspeicher**, **Nur-Lesespeicher**) beziehungsweise ROM (Abkürzung für engl.: **read only memory**) ist ein Speicher, der während des normalen Speicherbetriebs nur gelesen werden kann. Man unterscheidet einige Varianten (FROM, PROM, EPROM, EEPROM) danach, ob der beliebig oft lesbare Inhalt irreversibel oder reversibel eingeschrieben wird und auf welche Weise dies geschieht.

Irreversible Festwertspeicher

Bei einem **irreversiblen Festwertspeicher**, dem sogenannten ROM, wird der Inhalt einmalig für immer fixiert und kann danach nur noch (beliebig oft) ausgelesen werden. Dies geschieht im Herstellerwerk nach den Kundenwünschen durch eine sogenannte Maskenprogrammierung (engl.: factory ROM, FROM) oder beim Anwender mit Hilfe spezieller Programmiergeräte (engl.: programmable ROM,PROM) durch „Einbrennen" der Schaltwege mit kurzen, kräftigen Stromstößen.

Reversible Festwertspeicher

Bei einem **reversiblen Festwertspeicher** kann der Inhalt beim Anwender gelöscht und einige Male neu programmiert werden (engl.: erasable PROM, EPROM). Der Löschvorgang erfolgt üblicherweise durch eine Bestrahlung mit ultraviolettem Licht. Für das Löschen und das erneute Programmieren eines EPROM ist meistens eine Demontage des Gerätes unumgänglich. Letzerer Nachteil entfällt, wenn nicht nur die Programmierung, sondern auch das Löschen durch elektrische Impulse erfolgen (EEPROM oder E^2PROM). Änderungen sind dann sogar über Telefonleitungen möglich. Der Unterschied zu RAM-Chips besteht darin, daß bei diesen die gespeicherte Information beliebig oft gelöscht werden kann (bei EEPROM-Chips nur einige Male).

FROM

Ein **FROM** (**factory ROM**) ist ein irreversibler Festwertspeicher.

PROM

Ein **PROM** (**programmable ROM**) ist ein irreversibler Festwertspeicher.

EPROM

Ein **EPROM** (**erasable ROM**) ist ein reversibler Festwertspeicher.

EEPROM

Ein **EEPROM** (**E^2PROM**)ist ein reversibler Festwertspeicher.

Nichtflüchtiger Speicher

Die genannten ROM-Halbleiterspeicher sind sämtlich **nichtflüchtige Speicher**, das heißt ihr Inhalt bleibt auch bei Stromausfall beziehungsweise -abschaltung erhalten.

Flash-Speicherchips

Flash-Speicherchips sind nichtflüchtige Bausteine für interne und externe Schreib-/Lesespeicher mit sehr geringen Zugriffszeiten (zwei Millisekunden). Sie sind funktionell mit einem EEPROM vergleichbar, müssen aber blockweise (mindestens 256 Bytes) beschrieben/gelöscht werden (während sich ein EEPROM byteweise löschen läßt). Flash-Speicherchips sind mit „Schreib-Lese-ROMs" vergleichbar und können die gespeicherten Daten 100 Jahre lang ohne Stromzufuhr halten. s.a.: Flash-Speicherkarten.

2.2 Adressierungsarten

- Unterscheidung zwischen drei prinzipiellen Möglichkeiten
    - Lineare Adressierung
    - Segmentierte Adressierung
    - Virtuelle Adressierung

http://de.wikipedia.org/w/index.php?title=Speicherverwaltung&printable=yes

http://de.wikipedia.org/wiki/Segmentierung_%28Speicherverwaltung%29

Die **Speicherverwaltung** ist derjenige Teil eines Betriebssystems, der einen effizienten und komfortablen Zugriff auf den physikalischen Arbeitsspeicher eines Computers ermöglicht. Je nach Einsatzbereich des Computers werden unterschiedliche Speicherverwaltungsmechanismen verwendet.

Inhaltsverzeichnis

- 1 Direkte Speicherverwaltung
- 2 Segmentierung
- 3 Virtuelle Speicherverwaltung
- 4 Siehe auch

Direkte Speicherverwaltung

In vielen eingebetteten Systemen wird nur ein Prozess, also nur ein Programm zur gleichen Zeit ausgeführt. Dieser Prozess hat dann exklusiven Zugriff auf den physikalischen Arbeitsspeicher und kann diesen direkt adressieren. Eine Verwaltung des Speichers ist in diesen Computern trivial und besteht darin, die angeforderte Adresse über den Datenbus zugänglich zu machen.

Segmentierung

In Systemen mit wenig Arbeitsspeicher aber mehreren aktiven Prozessen wird das System der Segmentierung angewendet. Dabei wird der Arbeitsspeicher in feste Segmente eingeteilt. Alle Prozesse haben Kenntnis über die feste Einteilung. Die Speicherverwaltung kann nun ganze Segmente, wie z.B. das Programmsegment, wenn ein Prozess gerade nicht rechnend ist, auf langsameren z.B. Festplattenspeicher auslagern. Diese Art der Speicherverwaltung war in den Anfängen der Entwicklung von Computern weit verbreitet. Das Betriebssystem MS-DOS nutzte anfangs ausschließlich die Segmentierung.

Bei heutigen Prozessoren findet man im allgemeinen die Kombination Segmentierung mit Seitenadressierung (Paged Segmentation).

Virtuelle Speicherverwaltung

Die beiden beschriebenen Varianten haben die Einschränkung, dass die aktiven Prozesse selbst niemals mehr Speicherplatz belegen dürfen als physikalisch zur Verfügung steht. Um dieses durch immer komplexere Programme entstandene Problem zu lösen, wurde das Prinzip der Virtuellen Speicherverwaltung entwickelt. Dabei verwenden Prozesse nur noch virtuelle und keine physikalischen Adressen mehr. Die Umsetzung der virtuellen Adresse in eine physikalische Adresse übernimmt die Memory Management Unit. Die Virtuelle Speicherverwaltung ist heute in beinahe jedem modernen Betriebssystem verwirklicht

2.3 Adressdekodierung

- Adressdekodierung ist eine logische Schaltung zur Auswahl bestimmter Adressbereich
  - Immer notwenig, wenn Adressbereich des Speichers kleiner ist als der des Prozessors
  - Verzicht auf Adressdekodierung bedeutet Spiegelungen des Speichers im Adressraum des Prozessors
  - Adressdekodierungen realisiert in:
    - Chipsatz(bei PS, Workstations)
    - FPGA, PLD (Signalprozessoren, Mikrocontroller)
    - Interne Register (Mikrocontroller)

Ein **FPGA** (**F**ield **P**rogrammable **G**ate **A**rray) ist ein mit Configware programmierbarer Halbleiterbaustein bzw. IC. Er beinhaltet programmierbare logische Komponenten (CLB: Configurable Logic Block, meist mit einer Pfadbreite von 1 Bit, weshalb FPGAs als feinkörnig rekonfigurierbar gelten) und programmierbare Verbindungen zwischen diesen Komponenten. Das ganze ist als Feld bzw. Matrix gefertigt. Die Komponenten können zu grundlegenden logischen Bausteinen wie AND, OR, NOR, NOT und NAND, programmiert werden. Sie können aber auch zu komplexerer Logik wie Decoder, Encoder oder mathematischen Funktionen programmiert und verknüpft werden. Der FPGA wird nach der Herstellung vom Anwender programmiert. Er kann meist im System, also in voll bestückter Platine, programmiert werden, um Firmware-Updates einzuspielen. Da die Funktion des FPGAs ausschließlich durch die Konfiguration festgelegt wird, kann der gleiche Baustein für viele verschiedene Schaltungen verwendet werden. Er kann deshalb in großen Stückzahlen produziert werden, was ihn bei Prototypen und Kleinserien sehr kostengünstig im Vergleich zu einer Anwendungsspezifischen Integrierten Schaltung (ASIC) macht. FPGAs sind im allgemeinen langsamer als ASICs und sie sind nicht beliebig tief bzw. kompliziert programmierbar. Vielmehr ist die Tiefe der programmierbaren Logik von der Vorbereitung des Herstellers abhängig. Gemessen wird dies an der Anzahl der logischen Komponenten, der I/O Ports, der Flipflops, der Gates usw.

Kapitel 3 : Sekundäre Speicher

3.1 Sekundäre Speicher

- Sekundärspeicher setzen sich in modernen Rechner aus folgenden Komponenten zusammen
    - Festplattenspeicher (Harddisk)
    - CDROM/CDRAM
    - DVD-ROM / DVVD-RAM

- Generelle Eigenschaften: (Betriebssystem + Treiber notwendig)
    - Nicht flüchtiger Speicher (Speicherinhalt bleibt nach Lesezugriff oder Ausschalten der Versorgungsspannung erhalten)
    - Speicherzugriff erfolgt blockweise (minimale Blockgröße → 1Byte, z.B. 2 oder 4 kByte)
    - Speicherzugriff unter Kontrolle des Betriebssystems
    - Dauer des Speicherzugriff sehr viel länger als Zugriff auf Arbeitsspeicher

3.2 Festpalttenspeicher (Harddisk)

Eine **Festplatte** (engl. ***h**ard **d**isk **d**rive* = **HDD**) ist ein ferro-magnetisches **Speichermedium** der Computertechnik, welches binäre Daten auf die Oberfläche einer rotierenden Scheibe schreibt. Dazu wird die hartmagnetische Beschichtung der rotierenden Plattenoberfläche entsprechend der aufzuzeichnenden Information magnetisiert. Durch die Remanenz erfolgt die Speicherung der Information. Das Auslesen der Information erfolgt durch Abtastung der Magnetisierung der Plattenoberfläche mittels des Lesekopfes.

Im Gegensatz zu Disketten (Floppy Disks) bestehen die Scheiben von Festplatten aus starrem Material.

Auf einer Festplatte können beliebige Dateien, z. B. die des Betriebssystems, der Anwendungsprogramme oder persönlicher Daten (Dokumente, Videos, Musik, Bilder) dauerhaft gespeichert werden.

In Abgrenzung zu sequentiell adressierbaren Speichermedien wie Magnetband oder Lochstreifen werden Festplatten den direktadressierbaren Speichermedien (engl. *direct access storage devices,* DASD) zugerechnet, da auf die Daten direkt zugegriffen werden kann (Vergleich: Tonband ↔ Schallplatte).

Allgemeine technische Daten

Speicherkapazität

Die Speicherkapazität einer Festplatte ist die Gesamtzahl an Bits (0 oder 1), die durch den „Anwender“ (gemeint ist dabei die ansteuernde Software, also meist das Betriebssystem bzw. dessen Gerätetreiber) angesprochen (adressiert) werden können. Diese Kapazität wird normalerweise in Byte (Oktetten, also in Vielfachen von 8 Bit) gemessen. Bei der Aufzeichnung erfolgt durch den (normalerweise im Festplattengehäuse eingebauten) Controller eine weitere Kodierung der Daten, weswegen kein unmittelbarer Zusammenhang zwischen den gespeicherten Daten und der daraus folgenden Magnetisierung der Plattenoberfläche besteht. Der Übersichtlichkeit halber wird die Anzahl Bits in Kilo-, Mega-, Giga- und Terabit bzw. -byte angegeben. Die heute üblichen Speicherkapazitäten werden meistens in Gigabyte (GB) angegeben.

Viele Computerprogramme zeigen die Kapazität in Einheiten mit binärem Präfix (z. B. Gibibyte) an, beschriften dies jedoch meist mit den traditionell benutzten Dezimalpräfixen (wie Gigabyte) bzw. deren Abkürzungen. Näheres zu dieser Problematik im Artikel „Binärpräfix“.

Im Januar 2007 kündigte Hitachi ein neues Modell für das erste Quartal 2007 an. Deren größtes Modell besitzt eine Kapazität von 1.000 GB (1 TByte) und stellt damit die größte momentan erhältliche Festplatte dar (Stand Januar 2007).

Schreib-/Lesekopf einer Festplatte

handelsübliche 3,5″-Festplatte (Western Digital WD400) von oben (links) und von unten (rechts)

1 GByte IBM MicroDrive (1″)

Baugrößen

Die physikalische Größe von Festplatten wird traditionell in Zoll angegeben und ist keine exakte Größenangabe, sondern ein Formfaktor. So sind beispielsweise 3,5″-Festplatten exakt 100 mm breit, was knapp 4 Zoll entspricht. Die Größe der Scheiben in diesem 100 mm breiten Gehäuse liegt aber um die 3,5 Zoll, wobei Serverplatten häufig etwas kleiner sind.

Die zur Zeit verwendeten Formfaktoren reichen von 5,25″ bis 0,85″, wobei der Trend zu kleineren Festplatten geht. Der 3,5″-Formfaktor ist im Desktop-Bereich der am weitesten verbreitete, in Laptops findet man meist 2,5″-Festplatten, in noch kleineren portablen Geräten (z. B. MP3-Player) häufig 1,8″-Festplatten.

- Die ersten Festplatten hatten Baugrößen von 24″ (IBM 350, 1956). Im Laufe der Zeit verringerten sich diese Größen.
- 5,25″-Baugrößen wurden 1980 von Seagate eingeführt, jedoch ist diese Gattung seit 1996/97 ausgestorben. Einige SCSI-Server-Platten sowie die LowCost-ATA-Platte *BigFoot* von Quantum waren die letzten Vertreter dieser Spezies. Man unterscheidet Geräte mit voller Bauhöhe (3,5″ bzw. ca. 88 mm), die zwei Steckplätze belegen, und halber Bauhöhe (1,75″ bzw. ca. 44 mm). Andere Höhen gibt es auch, die bereits erwähnte *BigFoot* beispielsweise hat in der 4-GB-Version eine Bauhöhe von nur 0,75″ (etwa 19 mm). Die Breite beträgt 146 mm, die Tiefe ist variabel und sollte nicht wesentlich oberhalb von 200 mm liegen.
- 3,5″-Baugrößen wurden ca. 1990 eingeführt und sind derzeit (2007) Standard in Desktop-Computern und Servern. Die meisten Platten haben halbe Bauhöhe (1″ bzw. ca. 25 mm). Im Serverbereich gibt es auch Platten bis 1,8″ Höhe (1,8″ bzw. ca. 44 mm). Die Breite beträgt 100 mm, die Tiefe ist variabel und sollte nicht wesentlich oberhalb von 150 mm liegen.
- 2,5″-Baugrößen finden Verwendung in Notebooks oder Spezialrechnern. Die traditionelle Bauhöhe war 0,5″ (12,7 mm), mittlerweile gibt es mit 0,375″ (9,5 mm) und 0,25″ (6,35 mm) flachere Festplatten – und auch Notebooks, die diese flachen Varianten benötigen. Die Breite beträgt 68 mm, die Tiefe 100 mm. Der Anschluss ist gegenüber den größeren Bauformen modifiziert, bei ATA wird z. B. ein 44-poliger Anschluss verwendet, der gleichzeitig die Betriebsspannung von +5 Volt zuführt (Pin 1 ist meist auf der Seite der Jumper). Im Gegensatz zu den größeren Platten kommen diese Platten auch ohne 12-Volt-Betriebsspannung (zusätzlich zu der 5-Volt-Spannung) aus. Seit 2006 bietet Seagate zudem auch 2,5″-Festplatten für den Einsatz in Servern an, die weniger Strom verbrauchen, Platz sparen und die Ausfallsicherheit erhöhen sollen.
- 1,8″-Baugrößen werden seit 2003 bei Sub-Notebooks sowie diversen Industrieanwendungen verwendet.
- 1″-Baugrößen sind seit 1999 unter dem Name MicroDrives im Einsatz. Die meisten MicroDrives wurden bis Mitte 2004 als „verkleidete“ CompactFlash-Typ-II-Speichereinheiten für Digitalkameras eingesetzt. Ob MicroDrives Bestand haben werden, ist fraglich. Flash-Speicher ist in diesem Bereich bereits bis 16 GB verfügbar und auf Wachstumskurs. Derzeit ist Flash-Speicher nur noch geringfügig teurer, aber wesentlich robuster, schneller, leichter, leiser und energiesparender.
- 0,85″-Baugrößen waren ab Januar 2005 nur in begrenzten Mengen über die Firma Toshiba verfügbar, welche diese Baugröße im März 2004 mit einer Kapazität von 4 Gigabyte (3,73 GiB) zum ersten Mal vorgestellt hat. Sie wurden durch Flash-Speicher wie zum Beispiel der SD Memory Card ersetzt, die mittlerweile (Januar 2007) bis 8 GB erhältlich sind.

Überblick über die Speicherkapazitäten der verschiedenen Baugrößen

Jahr	5,25″	3,5″	2,5″	1,8″	1,0″	0,85″	typ. Modell(e) mit hoher Kapazität	Quelle
1981	10 MB	-	-	-	-	-	Seagate ST-412 (Aus dem IBM PC XT)	
1988	360 MB	20 MB	-	-	-	-	Maxtor XT-4380E (5,25") bzw. Fuji FK309-26	
1990	676 MB	106 MB	-	-	-	-	Maxtor XT-8760E (5,25") bzw. Conner CP3104	
1992	2 GB	426 MB	120 MB	-	-	-	Digital (DEC) DSP-5200S ('RZ73', 5,25"), Seagate ST1480A (3,5") bzw. Conner CP2124 (2,5")	
1995	9,1 GB	1,6 GB	422 MB	-	-	-	Seagate ST410800N (5,25" FH), Conner CFS1621A (3,5") bzw. Conner CFL420A (2,5")	
1997	12 GB	16,8 GB	4,8 GB	-	-	-	Quantum Bigfoot (12 GB, 5,25″), Nov. 1997, IBM Deskstar 16GP (3,5") bzw. Fujitsu MHH2048AT (2,5")	[1]
2001	#	80 GB	40 GB	-	340 MByte	-	Seagate mit 80 GB	
2005	#	500 GB	120 GB	60 GB	8 GB	6 GB	Hitachi Deskstar 7K500 (500 GB, 3,5″), Juli 2005	[2]
2006	#	750 GB *	200 GB	80 GB	8 GB	6 GB	Western Digital WD5000KS, Seagate Barracuda 7200.10 750GB, u. a.	[3]
2007	#	1.000 GB *	200 GB	80 GB	8 GB	6 GB	Hitachi Deskstar 7K1000 (1.000 GB, 3,5″), Januar 2007	[4]

Anmerkungen:

- Die Angaben beziehen sich immer auf die im jeweiligen Jahr größte *käuflich erhältliche* Festplatte, unabhängig von ihrer Drehzahl oder Schnittstelle.
- Die Kapazitäten sind Herstellerangaben, d. h. ein Gigabyte ist definiert als $1000^3 Byte = 10^9 Byte = 1.000.000.000 Byte$, ein Megabyte als $1000^2 Byte = 10^6 Byte$
- * unter Verwendung von Perpendicular Recording
- # Baugröße veraltet; nicht mehr in Gebrauch

Aufbau und Funktion

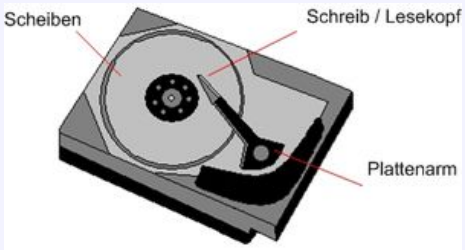

Skizze einer Festplatte

Geöffnete Festplatte

Einzelteile einer Festplatte

Physikalischer Aufbau der Einheit

Eine Festplatte besteht aus folgenden Bauelementen:

- einer oder mehreren drehbar gelagerten Scheiben (auch *Platter* genannt (eng.: *Platters*))
- einem Elektromotor als Antrieb für die Scheibe(n)
- bewegliche Schreib-/Leseköpfe (Heads)
- jeweils ein Lager für Platter (meistens Flüssigkeitslager) sowie für die Schreib-/Leseköpfe (auch Magnetlager)
- einem Antrieb für die Schreib-/Leseköpfe
- der Steuerelektronik für Motor- und Kopfsteuerung
- Hochleistungs-DSP für die Schreib/Leseköpfe.
- der Schnittstelle zur Verbindung mit dem Festplattenkontroller (auf der Hauptplatine)
- einem Festplattencache von 2 bis 32 MB Größe

Technischer Aufbau und Material der Scheiben

Die Scheiben bestehen meistens aus oberflächenbehandelten Aluminium-Legierungen, vereinzelt auch aus Glas. Sie müssen formstabil sein und eine geringe elektrische Leitfähigkeit aufweisen, um die Größe der Wirbelströme gering zu halten. Da die magnetisierbare Schicht besonders dünn sein soll, darf das Material der Scheiben selbst jedoch keine magnetischen Eigenschaften besitzen und dient nur als Träger der Magnetschicht. Auf die Scheiben wird eine Eisenoxid- oder Kobaltschicht von ungefähr einem Mikrometer Stärke aufgetragen. Diese wird zusätzlich von einer Schutzhülle aus Graphit ummantelt, um mechanische Beschädigungen zu vermeiden. Zusätzlich wurde eine Steigerung der Datendichte durch besseres Trägermaterial sowie durch die Optimierung der Schreibverfahren erreicht.

In älteren Desktopfestplatten von IBM (Deskstar 75GXP/40GV *DTLA-30xxxx*, Deskstar 60GXP/120GXP *IC35Lxxxx*) aus den Jahren 2000 bis 2002 kam Glas als Material für die Scheiben zum Einsatz. Neuere Modelle der Festplattensparte von IBM (2003 übernommen durch Hitachi) verwenden jedoch wieder Aluminium, mit Ausnahme der Festplatten für den Serverbereich. In dem Festplattengehäuse befindet sich eine oder mehrere übereinander liegende rotierende Scheiben. Verbaut worden sind bisher ein bis zwölf Scheiben, üblich sind ein bis vier. Allerdings geht eine höhere Scheibenanzahl in der Regel mit einem höheren Energieverbrauch und einer größeren Geräuschentwicklung einher. Manchmal werden aus Platzgründen nicht alle Scheibenoberflächen

genutzt, sodass Festplatten mit ungerader Schreib-/Lesekopfanzahl entstehen. Um die Nachfrage nach Festplattenmodellen mit kleinerer Kapazität zu befriedigen, können die Hersteller ebenfalls auf diese Weise die Kapazität künstlich beschränken bzw. verkleinern. Eine neuere Entwicklung (seit 2004) ist das Perpendicular Recording, das zur Zeit u. a. von Toshiba und Hitachi entwickelt wird, um die Datendichte weiter zu steigern.

Achsen-Lagerung und Drehzahlen (U/min)

Festplatten, welche in Arbeitsplatzrechnern oder in PCs für den privaten Gebrauch verwendet werden – momentan zum größten Teil Platten mit ATA- oder SATA-Schnittstelle – rotieren mit Geschwindigkeiten von 5.400 bis 10.000 Umdrehungen pro Minute. Vor der Zeit der ATA-Festplatten und im Bereich der Hochleistungsrechner und Server wurden bisher überwiegend Festplatten mit den technisch überlegenen SCSI, FC oder SAS-Schnittstellen verwendet, die inzwischen in der Regel 10.000 oder 15.000 Umdrehungen pro Minute erreichen. Bei den 2,5-Zoll-Festplatten, die hauptsächlich in Notebooks zum Einsatz kommen, liegen die Geschwindigkeiten im Bereich von 4.200 bis 7.200 Umdrehungen pro Minute. Die Achsen der Scheiben früherer Festplatten (bis 2000) waren kugelgelagert; heute (2006) werden überwiegend Flüssigkeitslager (engl. „fluid dynamic bearing“ – FDB) verwendet. Diese zeichnen sich durch eine höhere Lebensdauer und geringere Geräuschentwicklung aus.

Die Schreib-Lesekopfeinheit

Der Schreib-/Lesekopf (Magnetkopf) des Schreibfingers, im Prinzip ein winziger Elektromagnet, magnetisiert winzige Bereiche der Scheibenoberfläche unterschiedlich und schreibt somit die Daten auf die Festplatte. Die Schreib-/Leseköpfe schweben durch ein – durch Reibung der Luft an der rotierenden Scheibenoberfläche erzeugtes – Luftpolster über der Plattenoberfläche (vgl. Bernoulli-Effekt). Die Schwebehöhe liegt jedoch heutzutage (2006) nur im Bereich von etwa 20 Nanometern, sodass die Luft innerhalb des Festplattengehäuses keinerlei Verunreinigungen beinhalten darf. Bei neuesten Festplatten mit Perpendicular-Recording-Technik schrumpft dieser Abstand auf 10 Nanometer. Der Bodeneffekt ist in diesem Zusammenhang sehr nützlich zur Einhaltung der richtigen Flughöhe des Schreib-/Lesekopfes über der rotierenden Scheibe. Zum Vergleich: Ein Haar ist etwa 0,05 mm = 50 µm = 50.000 nm dick. Die Herstellung von Festplatten erfolgt deshalb wie die von Halbleitern in Reinräumen. Das Auslesen der Daten wurde bis ca. 1994 durch Induktion des Magnetfelds der magnetisierten Fläche in der Spule des Schreib-/Lesekopfes erreicht. Über die Jahre wurden jedoch die Flächen, auf denen einzelne Bits gespeichert werden, immer kleiner – die Datendichte wurde erhöht. Um diese Daten auszulesen, werden kleinere und empfindlichere Leseköpfe benötigt. Diese wurden nach 1994 entwickelt: MR-Leseköpfe sowie einige Jahre später GMR-Leseköpfe (Riesenmagnetowiderstand). Der GMR-Lesekopf ist eine Anwendung der Spintronik.

In der Anfangszeit der Festplatten wurden die Schreib-/Leseköpfe mit Schrittmotoren angesteuert, da die Spurabstände noch groß waren. Bei den zur Zeit üblichen Schreibdichten sorgen Tauchspulsysteme mit Lageregelung für die Positionierung. Bei der *Hitachi Deskstar 7K500* beträgt die Anzahl der Spuren pro Zoll (tpi) z. B. 135.000, während die Bitdichte in der Spur (bpi) 872.000 beträgt.

Zum Schutz der für Daten benutzten Oberflächen vor dem Aufsetzen der Schreib-/Leseköpfe fahren diese, noch bevor sich beim Ausschalten der Festplatten die Umdrehungsgeschwindigkeit merklich verringert hat, in die so genannte „Landezone“ („landing zone“), in der sie fixiert werden. Diese Parkposition kann sich außerhalb der Scheiben befinden (meist bei älteren Modellen) oder im Innenbereich der Platten (Stand der Technik). Dabei setzt der Schreib-/Lesekopf auf einem vordefinierten Bereich der Festplatte, der keine Daten enthält, auf. Die Oberfläche dieses Bereichs ist besonders vorbehandelt, um ein Festkleben des Kopfes zu vermeiden und so einen späteren Wiederanlauf der Festplatte zu ermöglichen. Die Fixierung geschieht z. B. über einen kleinen Magneten, der den Lesekopf festhält. Bei älteren Festplatten mussten die Köpfe explizit vor dem Ausschalten per Befehl vom Betriebssystem geparkt werden. Das Parken erhöht auch die Stoßfestigkeit der Festplatten für einen Transport oder Umbau. Doch auch moderne Festplatten müssen mitunter explizit geparkt werden, da der beschriebene automatische Parkmechanismus nach Wegfall der Versorgungsspannung zu einem erhöhten

Verschleiß führen kann.[5] Heutzutage wird dieser Befehl automatisch beim Herunterfahren des Systems vom Gerätetreiber abgesetzt.

Bei modernen Laptops sorgt ein Beschleunigungssensor für das Parken des Festplattenfingers noch während eines eventuellen freien Falls, um so den Schaden beim Sturz eines Rechners zu begrenzen.

Festplatten-Gehäuse

Lüftungsloch

Das Gehäuse einer Festplatte ist sehr massiv, es ist meist ein aus einer Aluminiumlegierung bestehendes Gussteil und mit einem Edelstahl-Blechdeckel versehen. Es ist staub-, aber nicht luftdicht abgeschlossen: Durch eine mit einem Filter versehene kleine Öffnung kann bei Temperaturänderungen Luft eindringen oder austreten. Diese Öffnung darf nicht verschlossen werden (siehe nebenstehendes Bild), vor allem wegen der Wärmeausdehnung der im Plattengehäuse vorhandenen Luft. Da der Luftdruck im Gehäuse mit zunehmender Höhe über dem Meeresspiegel abnimmt, zum Betrieb ein Mindestluftgehalt aber erforderlich ist, dürfen Festplatten nur bis zu einer bestimmten, maximalen Höhe betrieben werden. Diese ist in der Regel im zugehörigen Datenblatt vermerkt. Wird eine Festplatte in normaler, verunreinigter Luft geöffnet, so sorgen bereits kleinste Staub-/Rauchpartikel, Fingerabdrücke etc. für wahrscheinlich irreparable Beschädigungen der Plattenoberfläche und der Schreib-/Leseköpfe.

Speichern *(Schreiben)* und Lesen der Daten

Das Speichern der Daten auf einer Festplatte erfolgt durch die gezielte Magnetisierung kleinster – vom Schreibfinger angesteuerter – Flächen der permeablen Schicht ferromagnetischen Materials, die entsprechend ihrer Polarität (Nord/Süd) den elektronisch-binär interpretierten Wert 0 oder 1 annehmen. Beim Lesen der jeweiligen Sequenzen von 0- und 1-Werten werden die Informationen dekodiert und an das Betriebssystem übergeben. Sie werden vom Prozessor des Computers ausgewertet und weiterverarbeitet. Entsprechend umgekehrt geht das Schreiben der vorher vom Prozessor erstellten Daten vonstatten.

Vor dem Schreiben der Daten werden diese mittels spezieller Verfahren wie den früher üblichen GCR, MFM, RLL und heute üblichen PRML oder EPRML kodiert. Ein Bit der Anwenderdaten entspricht daher physikalisch nicht unmittelbar einem magnetischen Flusswechsel auf der Plattenoberfläche. Die Kodierung muss der Festplattencontroller vornehmen, zusammen mit dem Verwalten der Daten (Organisation der Daten in Blöcke) und dem Führen des Schreib-/Lesekopfes über die Spuren.

Sowohl beim Schreiben als auch beim Lesen muss vor dem Zugriff auf einen bestimmten Block der Schreib-/Lesekopf der Platte bewegt und anschließend abgewartet werden, bis durch die Rotation der Platte der Block unter dem Kopf vorbeigeführt wird. Diese mechanisch bedingten Verzögerungen liegen heutzutage bei ca. 5–10 ms, was nach Maßstäben anderer Computerhardware eine kleine Ewigkeit ist. Daraus ergibt sich die extrem hohe Latenzzeit von Festplatten im Vergleich zu RAM, die noch auf der Ebene der Softwareentwicklung und der Algorithmik berücksichtigt werden muss.

Lesekopf einer Festplatte in der Nahaufnahme

Um eine hohe Performance zu erreichen, muss eine Festplatte soweit wie möglich immer große Mengen von Daten in aufeinander folgenden Blöcken lesen oder schreiben, weil dabei der Schreib-/Lesekopf nicht neu positioniert werden muss.

Dies wird unter anderem dadurch erreicht, dass möglichst viele Operationen im RAM durchführt und auf der Platte die Positionierung der Daten auf die Zugriffsmuster abstimmt. Dazu dient vor allem ein großer Cache als Teil der Festplattenelektronik, auf dessen Inhalt mit RAM-Geschwindigkeit zugegriffen werden kann. Die Firmware der Festplatte sorgt für die korrekte Verwaltung und Aktualisierung des Cache-Inhalts.

Neben der Verwendung eines Caches gibt es weitere Software-Strategien zur Performancesteigerung. Sie werden vor allem in Multitasking-Systemen wirksam, wo das Festplattensystem mit mehreren bzw. vielen Lese- und Schreibanforderungen gleichzeitig konfrontiert wird. Es ist dann meist effizienter, diese Anforderungen in eine sinnvolle neue Reihenfolge zu bringen. Die Steuerung erfolgt durch einen Festplatten-Scheduler. Das einfachste Prinzip hierbei verfolgt dabei dieselbe Strategie wie eine *Fahrstuhlsteuerung:* Die Spuren werden zunächst in einer Richtung angefahren und die Anforderungen beispielsweise nach monoton steigenden Spurnummern abgearbeitet. Erst wenn diese alle abgearbeitet sind, kehrt die Bewegung um und arbeitet dann in Richtung monoton fallender Spurnummern usw.

Auf einer tieferen Ebene optimiert man den Datenzugriff durch Interleaving, was bei modernen Festplatten aber nicht mehr notwendig ist.

Logischer Aufbau der Scheiben

Die Magnetisierung der Beschichtung der Scheiben ist die eigentliche Trägerin der Informationen. Sie wird auf kreisförmigen, konzentrischen Spuren magnetisch aufgeprägt, während die Scheibe rotiert. Eine Scheibe enthält typischerweise einige tausend solcher Spuren, meist auch auf beiden Seiten. Die Gesamtheit aller gleicher, d. h. übereinander befindlicher, Spuren der einzelnen Platten(oberflächen) nennt man Zylinder. Jede Spur ist in kleine logische Einheiten unterteilt, die man Blöcke nennt. Ein typischer Block enthält 512 Byte an Nutzdaten (Anwenderdaten). Jeder Block verfügt dabei über Kontrollinformationen (Prüfsummen), über die sichergestellt wird, dass die Information auch korrekt geschrieben oder gelesen wurde. Die Gesamtheit aller Blöcke, die die gleichen Winkelkoordinaten auf den Platten haben, nennt man Sektor. Der Aufbau eines speziellen Festplattentyps, das heißt, die Anzahl der Spuren, Oberflächen und Sektoren, wird auch als Festplattengeometrie bezeichnet. Verwirrenderweise wird der Begriff Sektor häufig fälschlicherweise auch synonym für Block verwendet.

Da manche Betriebssysteme zu früh an Grenzen stießen, als die Nummerierung der Blöcke bei steigenden Festplattenkapazitäten die Wortgrenze (16 Bit) überstieg, führte man Cluster ein. Das sind Gruppen von jeweils einer festen Anzahl von Blöcken (s. o., Anzahl beispielsweise 32), die sinnvollerweise physisch benachbart sind bzw. zusammenhängend aufeinander folgen. Das Betriebssystem spricht dann nicht mehr einzelne Blöcke an, sondern verwendet auf seiner (höheren) Ebene diese Cluster als kleinste Zuordnungseinheit. Erst auf Hardwaretreiber-Ebene wird dieser Zusammenhang aufgelöst.

Bei modernen Festplatten ist normalerweise die wahre Geometrie, also die Anzahl von Sektoren, Köpfen und Zylindern, die vom im Festplattengehäuse integrierten Controller (im Folgenden „Festplatten-Intelligenz“ genannt) verwaltet werden, nach außen (d. h. für den Computer bzw. den Festplattentreiber) nicht mehr sichtbar. Der Computer, der die Festplatte benutzt, arbeitet dann mit einer virtuellen Festplatte, die völlig andere Geometriedaten aufweist. Dies erklärt, warum zum Beispiel eine Festplatte, die real nur vier Köpfe aufweist, vom Computer mit 255 Köpfen gesehen wird. Ein Grund für solch ein virtuelles Konzept ist, dass man Begrenzungen von PC-kompatibler Hardware überwinden wollte. Weiterhin kann die Festplatten-Intelligenz durch dieses virtuelle Konzept defekte Blöcke ausblenden, um dann einen Block aus einem Reserve-Bereich einzublenden. Für den Computer sieht es immer so aus, als wären alle Blöcke defektfrei und nutzbar. Es wird vermutet, dass besagter Reserve-Bereich bzw. Reserve-Spuren ca. 10–20 % des auf der Festplatte angegebenen Speicherplatzes ausmachen. Dieser Speicherplatz lässt sich durch spezielle Firmware-Versionen nutzen, was dann aber logischerweise die Lebensdauer der Festplatte (bzw. die Datensicherheit) reduzieren kann. Heute übliche Festplatten teilen weiterhin die Platten in Zonen auf, wobei eine Zone mehrere Spuren mit jeweils gleicher Anzahl an Blöcken enthält. Weitere Zonen können eine andere Anzahl von Sektoren besitzen.

Partitionen als Laufwerke

Aus Sicht des Betriebssystems können Festplatten durch Partitionierung in mehrere Bereiche unterteilt werden. Das sind keine echten Laufwerke, sondern die stellt das Betriebssystem als solche dar, sie sind Teilmengen des gesamten Laufwerkes. Man kann sich diese als virtuelle Festplatten vorstellen, die durch den Festplattentreiber dem Betriebssystem (und damit evtl. dem Benutzer) gegenüber als getrennte Geräte dargestellt werden. Es ist dabei im Verhalten (von zeitlichen Effekten sowie dem Verhalten im Falle des Festplattenausfalls abgesehen) nicht erkennbar, ob es sich tatsächlich jeweils um eine physikalisch getrennte Festplatte handelt oder lediglich um ein logisches Laufwerk auf einer gemeinsamen Festplatte.

Jede Partition wird vom Betriebssystem gewöhnlich mit einem Dateisystem formatiert. Unter Umständen werden, je nach benutztem Dateisystem, mehrere Blöcke zu Clustern zusammengefasst, die dann die kleinste logische Einheit für Daten sind, die auf die Platte geschrieben werden. Das Dateisystem sorgt dafür, dass Daten in Form von Dateien auf die Platte abgelegt werden können. Ein Inhaltsverzeichnis im Dateisystem sorgt dafür, dass Dateien wiedergefunden werden und hierarchisch organisiert abgelegt werden können. Der Dateisystemhandler verwaltet die belegten, verfügbaren und defekten Cluster. Ein Beispiel für ein Dateisystem ist das (von MS-DOS und Windows 9x ausschließlich unterstützte) FAT-Dateisystem.

Technische Neuerungen

Um die Lautstärke der Laufwerke beim Zugriff auf Daten zu verringern, unterstützen die meisten ATA- und SATA-Festplatten, die für den Desktop-Einsatz gedacht sind, „Automatic Acoustic Management“ (AAM). Wird die Festplatte in einem leisen Modus betrieben, werden die Schreib- und Leseköpfe weniger stark beschleunigt, sodass die Zugriffe leiser sind. Das Laufgeräusch des Plattenstapels wird davon nicht verändert, ebenso wird die Dauertransferrate durch das AAM nicht verringert; jedoch verlängert sich die Zugriffszeit.

Schnittstellen, Bussystem und Jumperung

Als Schnittstelle der Festplatte zu Laufwerks Computer-Komponenten werden heute hauptsächlich die parallelen Schnittstellen ATA (IDE, EIDE) (überwiegend bei Personal Computern), SCSI (bei Servern (Hosts), Workstations und höherwertigen Personal Computern) sowie Festplatten mit Fibre-Channel- oder SAS-Anschlüssen für Storage-Subsysteme verwendet. Ältere Schnittstellen wie ST506, ESDI und MFM (s. u. bei Geschichte/Chronologische Übersicht) sind nur noch von historischem Interesse. Die Mainboards, an denen die Festplatten bei Personal Computern angeschlossen werden können, waren bisher meist mit zwei ATA-Schnittstellen versehen, werden aber zunehmend – in einer Übergangszeit – mit SATA-(S-ATA)-Schnittstellen zusätzlich versehen. ATA wird zukünftig wahrscheinlich vom SATA-Bussystem abgelöst.

Ein vergleichbarer Wandel ist im Bereich der Server bzw. Speicher-Subsysteme zu erkennen. Neben den oft verwendeten SCSI-Festplatten werden mehr und mehr serielle Typen wie Fibre-Channel- oder SAS-Festplatten

eingesetzt. Bei den parallelen Übertragungen muss der Umstand berücksichtigt werden, dass es mit zunehmender Geschwindigkeit schwieriger wird, unterschiedliche Laufzeiten der einzelnen Bits durch das Kabel zu korrigieren. Daher kommen die parallelen Schnittstellen an ihre Grenzen; diese Einschränkung fällt bei seriellen Übertragungstechniken weg, womit höhere Übertragungsraten möglich werden.

Jumper an der Festplatte

Jumper sind kleine elektrische Kurzschlussstecker, mit denen man den Pegel an einem Pin verändern kann, um so verschiedene Laufwerkseinstellungen zu konfigurieren.

ATA (IDE)

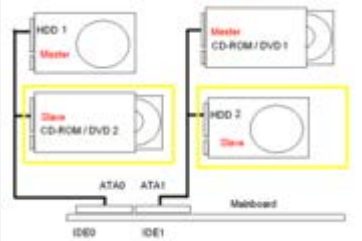

ATA-Konfiguration eines normalen bzw. privaten PCs

Bei einer ATA-Festplatte wird durch Jumper festgelegt, ob sie das Laufwerk mit Adresse 0 oder 1 der ATA-Schnittstelle ist *(Device 0* bzw. *1,* früher mit *Master* bzw. *Slave* bezeichnet). Manche Modelle erlauben auch eine Beschränkung der an das Betriebssystem bzw. BIOS gemeldeten Kapazität des Laufwerks, wodurch die Festplatte im Falle von Inkompatibilitäten dennoch (unter Verschenkung des nicht gemeldeten Plattenplatzes) in Betrieb genommen werden kann.

Durch die Festlegung der ATA-Bus-Adresse können zwei Festplatten an einer ATA-Schnittstelle des Mainboards angeschlossen werden. Es können maximal je zwei Festplatten an jeder ATA-Schnittstelle angeschlossen werden. Dazu werden sie mit dem oben beschriebenen Jumper an der Festplatte als *Device 0* oder *Device 1* bestimmt *(gejumpert)*. Die meisten Mainboards haben zwei ATA-Schnittstellen, genannt *primary ATA* und *secondary ATA*, also „erste“ und „zweite ATA-Schnittstelle“. Daher können insgesamt bis zu vier Festplatten an beide ATA-Schnittstellen des Mainboards angeschlossen werden. Ältere BIOS von Mainboards erlauben es nur, den Computer von der ersten ATA-Schnittstelle zu starten, und auch nur, wenn die Festplatte als *Device 0* gejumpert ist.

Sollen mehr Festplatten angeschlossen werden, als es die auf dem Mainboard vorhandenen ATA-Schnittstellen erlauben, so können weitere ATA-Schnittstellen per Einsteckkarte nachgerüstet werden, auch in Form eines nicht auf Spiegelung der anderen Festplatten eingestellten RAID-Controllers.

Die ATA-Schnittstellen von PCs werden jedoch nicht nur von Festplatten genutzt; auch CD-ROM- und DVD-Laufwerke nutzen sie. Somit ist (ohne Zusatzkarte) die Summenzahl an Festplatten plus ladbaren Laufwerken (CD-ROM, DVD) auf vier begrenzt (die Diskettenlaufwerke mit eigener Schnittstelle mal aus der Betrachtung gelassen). Es gibt sogar Adapter, mit denen Compact-Flash-Karten angeschlossen und wie eine Festplatte verwendet werden können.

In modernen privat genutzten PC findet sich in aller Regel zunächst nur eine Festplatte und ein DVD-Laufwerk; oft aber wird ein zweites DVD-Laufwerk (z.B. ein Brenner) nachgerüstet. Mit Erweiterung der Festplatten um eine zweite Platte ist dann die IDE-Schnittstellenzahl des Mainboards normalerweise ausgeschöpft.

Bei Erweiterungen an den IDE-Kabeln ist auf einige Dinge achtzugeben:

- a- es sollten keine freien Kabelenden bleiben; am einen Ende sitzt das Mainboard, am anderen Ende ein Laufwerk;
- b- das eine Laufwerk ist als „Master“ zu jumpern – in der Regel die Voreinstellung von Laufwerken; erst ein eventuell zweites Laufwerk an einem Kabel wird auf "Slave" gejumpert. Einige Laufwerke haben noch die dritte Option „Single Drive“. Diese wird dann benutzt, wenn das Laufwerk alleine am Kabel

hängt; kommt ein „Slave“-Laufwerk dazu, muss man das erste als „Master“ jumpern. Hierbei heißt die Option dann zur Erläuterung oftmals „Master with Slave present“.

- Wo dann (am Ende des Kabels oder "mittendrin") der Master oder der Slave sitzen, spielt keine Rolle (außer beide Laufwerke sind auf Cable Select gejumpert). "Slave allein" funktioniert zwar oft, gilt aber nicht als sauber konfiguriert und ist oft störanfällig. Ausnahme: Bei 80poligen Kabeln sollte der Slave in der Mitte angeschlossen werden; die Stecker sind dementsprechend beschriftet.

Diskussionen entstehen zur PC-Konfiguration darüber, ob es empfehlenswert sei, pro IDE-Kabel jeweils eine Festplatte und ein CD- oder DVD-Laufwerk zu haben, oder ob es vorteilhafter sei, zwei Festplatten an dem einen Kabel und ein oder zwei ladbare Laufwerke am anderen Kabel zu haben. Die Abbildung zeigt zwei Master an jeweils einem der beiden IDE-Anschlüsse; ein drittes und ein viertes Laufwerk (gelb gerahmt als optional) werden ggf. als Slave an einem der mittigen Kabelanschlüsse hinzugesteckt.

SCSI

SCSI-Festplatten kennen nicht nur zwei, sondern, je nach verwendetem Controller, acht oder sechzehn Adressen. Daher finden sich an SCSI-Laufwerken drei oder vier Jumper zur Bestimmung der Adressen – ID-Nummern genannt –, die es erlauben, bis zu sieben bzw. 15 Geräte zu adressieren (der Controller belegt eine eigene Adresse). Alternativ erfolgt die Adresseinstellung durch einen kleinen Drehschalter. Abhängig von den Kabelspezifikationen und Übertragungsmodi ist nicht in jedem Fall möglich, die maximal adressierbare Zahl von Geräten an einem Anschluss zu betreiben. Je nach Modell wird die Terminierung des SCSI-Anschlusses über steckbare Widerstandsarrays oder per Jumper aktiviert.

Dazu kommen noch andere Jumper wie der (optionale) Schreibschutzjumper, der es erlaubt, eine Festplatte gegen Beschreiben zu sperren. Weiterhin können je nach Modell Einschaltverzögerungen oder das Startverhalten beeinflusst werden.

S-ATA (SATA) löst den IDE-Bus ab

Hauptartikel: Serial ATA

Seit 2002 gewinnt das neue Verfahren *Serial ATA* (S-ATA oder SATA) an Bedeutung. Die Vorteile gegenüber ATA sind der höhere mögliche Datendurchsatz, vereinfachte Kabelführung und die Fähigkeit zum Austausch von Datenträgern im laufenden Betrieb (Hot-Plug). Im Jahr 2005 wurden erste Festplatten mit Serial Attached SCSI (SAS) als potentieller Nachfolger von SCSI für den Server- und Storagebereich vorgestellt. Über zwei Anschlüsse kann der Datenaustausch theoretisch mit bis zu 600 MByte/s erfolgen.

Queuing im SCSI- und S-ATA-Datentransfer

Vor allem bei SCSI-Platten und auch bei neueren S-ATA-Festplatten werden so genannte Queues (Warteschlangen) eingesetzt. Das sind Software-Verfahren als Teil der Firmware, die die Daten zwischen dem Anfordern von Computerseite und physikalischem Zugriff auf die Speicherscheibe verwalten und ggf. zwischenspeichern. Beim Queuing reihen sie die Anfragen an den Datenträger in eine Liste und sortieren sie entsprechend der physikalischen Position auf der Scheibe und der aktuellen Position der Schreibköpfe, um so möglichst viele Daten mit möglichst wenigen Umdrehungen und Kopfpositionierungen zu lesen. Der festplatteneigene Cache spielt hierbei eine große Rolle, da die Queues in diesem abgelegt werden (siehe auch: Tagged Command Queuing, Native Command Queuing).

FireWire und USB als Schnittstellen für externe Laufwerke

Es werden universelle Schnittstellen wie FireWire oder USB für den Anschluss von externen Festplatten verwendet. Hierbei sind jedoch die eingebauten Festplatten selbst mit herkömmlichen (meist ATA- oder S-ATA-)Schnittstellen ausgestattet. Die Signale werden mittels eines speziellen Chipsatzes, der auf einer Wandlerplatine in dem USB-Gehäuse sitzt, von ATA in USB-Signale transferiert und über die USB-Schnittstelle nach außen geführt. Eine reine USB-Festplatte, d. h. mit eigener USB-Schnittstelle, wird von keinem Hersteller gebaut. Es gibt auch externe CD- und DVD-Laufwerke mit USB-Schnittstelle, ebenfalls mit interner Wandlerplatine auf ATA/ATAPI.

Fibre-Channel-Interface

Die Kommunikation via Fibre-Channel-Interface ist noch leistungsfähiger und ursprünglich vor allem für die Verwendung in Speichersubsystemen entwickelt. Die Festplatten werden nicht direkt angesprochen, sondern über einen FC-Controller, FC-HUBs oder FC-Switche.

Serial Attached SCSI

Die SAS-Technologie basiert auf der etablierten SCSI-Technologie, sendet die Daten jedoch seriell. Neben einer höheren Geschwindigkeit im Vergleich zu herkömmlicher SCSI-Technik können mit über 16.000 Geräten deutlich mehr Laufwerke in einem Verbund angesprochen werden, als es beim SCSI-Protokoll der Fall ist. Ein weiterer Vorteil liegt dabei in der maximalen Kabellänge von 10 Metern.

Vorläufer der seriellen High-Speed-Schnittstellen

Die ersten verbreiteten seriellen Schnittstellen für Festplatten waren SSA (Serial Storage Architecture, von IBM entwickelt) und Fibre-Channel in der Variante FC-AL (Fibre Channel-Arbitrated Loop). SSA-Festplatten werden heute praktisch nicht mehr hergestellt, aber Fibre-Channel-Festplatten werden weiterhin für den Einsatz in großen Speichersystemen gebaut. Fibre Channel bezeichnet dabei das verwendete Protokoll, nicht das Übertragungsmedium. Deshalb haben diese Festplatten trotz ihres Namens keine optische, sondern eine elektrische Schnittstelle.

Datensicherheit

Ausfallrisiken und Lebensdauer

Zu den typischen Ausfallrisiken gehören:

Lüfter für 3,5″-Festplatten

- Die Anfälligkeit von Festplatten ist besonders bei den neuen, sehr schnell drehenden Systemen vorwiegend auf thermische Probleme zurückzuführen.
- Beim mechanischen Aufsetzen des Schreib-Lesekopfes kann die Festplatte beschädigt werden (Head-Crash, manchmal scherzhaft *spanabhebende Datenverarbeitung* genannt). Der Kopf schwebt im Betrieb über der Platte und wird nur durch ein Luftpolster am Aufsetzen gehindert, das durch die von der drehenden Scheibe mitgerissene Luft entsteht. Im laufenden Betrieb sollte die Festplatte daher möglichst nicht bewegt werden und keinen Erschütterungen ausgesetzt sein.
- Äußere Magnetfelder können die Sektorierung der Festplatte irreversibel zerstören. Eine Löschung mit einem Magnetfeld macht neuere Festplatten unbrauchbar.
- Fehler in der Steuerelektronik oder Verschleiß der Mechanik führen zu Ausfällen.
- Umgekehrt kann auch längerer Stillstand dazu führen, dass die Mechanik in Schmierstoffen stecken bleibt und die Platte gar nicht erst anläuft („*sticky disk*“). Dieses Problem trat akut in den 1990er Jahren auf, scheint seitdem aber durch bessere Schmierstoffe einigermaßen im Griff zu sein.

Die durchschnittliche Anzahl an Betriebsstunden, bevor eine Festplatte ausfällt, wird bei irreparablen Platten als MTTF (Mean Time To Failure) bezeichnet. Bei Festplatten, die repariert werden können, wird ein MTBF-Wert (Mean Time Between Failures) angegeben. Alle Angaben zur Haltbarkeit sind stets und ausschließlich statistische Werte. Die Lebensdauer einer Festplatte kann daher nicht im Einzelfall vorhergesagt werden, denn diese hängt von vielen Faktoren ab:

- Eine gute Kühlung erhöht die statistische Lebensdauer, da Mechanik und Elektronik weniger schnell altern und beansprucht werden.
- Anzahl der Zugriffe (Lesekopfbewegungen): Durch häufige Zugriffe verschleißt die Mechanik schneller, als wenn die Platte nicht genutzt wird und sich nur der Plattenstapel dreht.
- Vibrationen und Stöße: Starke Erschütterungen können zu einem vorzeitigen (Lager-)Verschleiß führen und sollten daher vermieden werden.
- Unterschiede zwischen verschiedenen Modellreihen eines Herstellers: Abhängig vom jeweiligen Modell lassen sich bestimmte Baureihen ausmachen, die als besonders zuverlässig oder fehleranfällig gelten. Um statistisch genau Angaben zu der Zuverlässigkeit machen zu können, sind allerdings eine große Anzahl von baugleichen Platten notwendig, die unter ähnlichen Bedingungen betrieben werden. Systemadministratoren, die viele Systeme betreuen, können so im Laufe der Jahre durchaus einige Erfahrungen sammeln, welche Festplatten eher zu auffälligem Verhalten und damit vorzeitigem Ausfall neigen.

Allgemein sind schnelldrehende Server-Festplatten für eine höhere MTTF als typische Desktop-Festplatten ausgelegt, sodass sie theoretisch eine höhere Lebensdauer erwarten lassen. Dauerbetrieb und häufige Zugriffe können jedoch dazu führen, dass sich dies relativiert und die Festplatten nach wenigen Jahren ausgetauscht werden müssen.

Notebook-Festplatten werden durch die häufigen Transporte besonders beansprucht und sind dementsprechend trotz robusterer Bauart mit einer kleineren MTTF als Desktop-Festplatten spezifiziert.

Eine genaue Lebensdauer wird von den Herstellern nicht angegeben. Sie dürfte sich aber wie auch bei Magnetbändern im Bereich von etwa 10 bis 30 Jahren bewegen, da magnetische Umwelteinflüsse (schon leicht wechselndes Magnetfeld der Erde) zu einer Entmagnetisierung führen. Lediglich magneto-optische Verfahren erreichen 50 und mehr Jahre.

Vorbeugende Maßnahmen

Als vorbeugende Maßnahmen gegen Datenverlust werden daher häufig folgende Maßnahmen ergriffen:

- Von wichtigen Daten sollte immer eine Sicherungskopie *(Backup)* auf einem anderen Datenträger (beachte den Hinweis zum Ausfall oben unter Partionierung) existieren.
- Systeme, die zwingend hochverfügbar sein müssen und bei denen ein Festplattenfehler keine Betriebsunterbrechung verursachen darf, verfügen meistens über ein RAID. Eine Konfiguration ist zum Beispiel das *Mirrorset* (RAID 1), bei dem die Daten auf zwei Festplatten gespiegelt werden und sich somit die Ausfallsicherheit erhöht. Effizientere Konfigurationen sind RAID 5 und höher. Ein *Stripeset* (RAID 0) aus zwei Festplatten erhöht zwar die Geschwindigkeit, jedoch steigt auch das Ausfallrisiko. RAID 0 ist deshalb keine Maßnahme, um Datenverlust zu verhindern oder die Verfügbarkeit des Systems zu erhöhen.
- ATA-Festplatten verfügen seit Einführung von ATA-3 im Jahr 1996 über S.M.A.R.T., eine interne Überwachung der Festplatte auf Zuverlässigkeit. Der Status kann von außen abgefragt werden. Ein Nachteil ist, dass S.M.A.R.T. kein Standard ist. Jeder Hersteller definiert seine Fehlertoleranz selbst, d. h. S.M.A.R.T. ist nur als allgemeines Richtmittel anzusehen. Außerdem gibt es Festplatten, deren S.M.A.R.T.-Funktion selbst dann noch nicht vor Problemen warnt, wenn diese sich bereits im Betrieb durch nicht mehr lesbare Blöcke bemerkbar gemacht haben. Man sollte sich also nicht auf S.M.A.R.T. verlassen.
- Um durch Überhitzung der Festplatte bedingte Ausfälle zu verhindern, muss diese entsprechend ihrer maximal erlaubten Betriebstemperatur gekühlt werden. In Servern kommen dazu mit Lüftern versehene Wechselrahmen und Backplanes zum Einsatz.

Datenschutz

Unabhängig vom verwendeten Speichermedium (in diesem Fall eine Festplatte) wird beim Löschen einer Datei lediglich im Dateisystem vermerkt, dass der entsprechende Datenbereich nun frei ist. Die Daten selbst verbleiben jedoch physisch auf der Festplatte, bis der entsprechende Bereich mit neuen Daten überschrieben wird. Mit

Datenrettungsprogrammen können gelöschte Daten daher oft zumindest zum Teil wiederhergestellt werden. Das wird auch häufig in der Beweissicherung zum Beispiel bei den Ermittlungsbehörden (Polizei etc.) eingesetzt.

Beim Partitionieren oder gewöhnlichen Formatieren wird der Datenbereich nicht überschrieben, sondern lediglich die Partitionstabelle oder die Beschreibungsstruktur des Dateisystems. Bei einer Low-Level-Formatierung dagegen wird der gesamte adressierbare Bereich einer Festplatte überschrieben.

Um ein sicheres Löschen von sensiblen Daten zu garantieren, bieten verschiedene Hersteller Software an, so genannte *Eraser,* die beim Löschen den Datenbereich überschreibt. Meistens kann aber auf eine (fast) beliebige und kostenlose Unix-Distribution zurückgegriffen werden, wie zum Beispiel Knoppix oder FreeSBIE, die praktischerweise direkt von CD gestartet werden kann. Des Weiteren gibt es verschiedene Opensource-Programme, die dies ebenfalls erledigen. Wurde die Datei bereits gelöscht, ohne die Daten zu überschreiben, kann auch der komplette freie Speicher der Festplatte überschrieben werden.

Verschiedene Festplatten bieten die Möglichkeit an, den kompletten Festplatteninhalt per Passwort direkt auf Hardwareebene zu schützen. Da diese im Grunde nützliche Eigenschaft jedoch kaum bekannt ist und die meisten BIOS die Funktion zum Setzen des Passworts nicht selbsttätig ausschalten, besteht rein theoretisch für Schadprogramme wie Viren die Chance, dem Benutzer durch Setzen dieses Passworts auf einen unbekannten Wert massiv zu schaden. Danach bestände keine Möglichkeit mehr, noch auf Inhalte der Festplatte zuzugreifen. Für weitere Infos bzgl. ATA-Festplatten siehe Passwortschutz unter ATA.

Langzeitarchivierung

Die Archivierung digitaler Informationen über längere Zeiträume (10 bis mehrere Hundert Jahre) wirft Probleme auf, da nicht nur die Informationen evtl. verloren gegangen sind, sondern weil auch die Computer, Betriebssysteme und Programme zum Bereitstellen der Informationen von damals nicht mehr verfügbar sind. Ansonsten sind die Daten in sich ständig wiederholenden Zyklen neu zu archivieren.

Nur analoge Verfahren, wie Microfilm oder Druck auf spezielles Papier, bieten zur Zeit die Möglichkeit auch über sehr lange Zeiträume auf Informationen zugreifen zu können.

Ein **RAID**-System (ursprünglich **redundant array of inexpensive disks**, heute **redundant array of independent disks**) dient zur Organisation mehrerer physischer Festplatten eines Computers zu einem logischen Laufwerk, das eine größere Speicherkapazität, eine höhere Datensicherheit bei Ausfall einzelner Festplatten und/oder einen größeren Datendurchsatz erlaubt als eine physische Platte. Während die meisten in Computern verwendeten Techniken und Anwendungen darauf abzielen, Redundanzen (das Vorkommen doppelter Daten) zu vermeiden, werden bei RAID-Systemen redundante Informationen gezielt erzeugt, damit beim Ausfall einzelner Komponenten das RAID als Ganzes seine Funktionalität behält.

Der Begriff wurde von Patterson, Gibson und Katz an der University of California, Berkeley in ihrer Arbeit "A Case for **R**edundant **A**rray of **I**nexpensive **D**isks (RAID)" zum ersten Mal verwendet (frei übersetzt: Redundanter Verbund kostengünstiger Festplatten). Darin wurde die Möglichkeit untersucht, kostengünstige Festplatten im Verbund als logisches Laufwerk zu betreiben, um die Kosten für eine große (zum damaligen Zeitpunkt teure) Festplatte einzusparen. Dem gestiegenen Ausfallrisiko im Verbund sollte durch die Speicherung redundanter Daten begegnet werden, die einzelnen Anordnungen wurden als RAID-Level diskutiert.

Die weitere Entwicklung des RAID-Konzepts führte zunehmend zum Einsatz in Serveranwendungen, die den erhöhten Datendurchsatz und die Ausfallsicherheit nutzen, der Aspekt der Kostenersparnis wurde dabei aufgegeben. Die Möglichkeit, in einem solchen System einzelne Festplatten im laufenden Betrieb zu wechseln, entspricht der heute gebräuchlichen Übersetzung: **R**edundant **A**rray

of **I**ndependent **D**isks (*Redundante Anordnung unabhängiger Festplatten*).

Der Betrieb eines RAID-Systems setzt mindestens zwei Festplatten voraus. Die Festplatten werden gemeinsam betrieben und bilden einen Verbund, der unter mindestens einem Aspekt betrachtet leistungsfähiger ist als die einzelnen Festplatten. Mit RAID-Systemen kann man folgende Vorteile erreichen:

- Erhöhung der Ausfallsicherheit (Redundanz)
- Steigerung der Transferraten (Performance)
- Aufbau großer logischer Laufwerke
- Austausch von Festplatten und Erhöhung der Speicherkapazität während des Systembetriebes
- Kostenreduktion durch Einsatz mehrerer preiswerter Festplatten
- hohe Steigerung der Systemleistungsfähigkeit

Die genaue Art des Zusammenwirkens der Festplatten wird durch den *RAID-Level* spezifiziert. Die gebräuchlichsten RAID-Level sind RAID 0, RAID 1 und RAID 5. Sie werden unten beschrieben

Hardware-RAID

Von *Hardware-RAID* spricht man, wenn das Zusammenwirken der Festplatten von einem speziell dafür entwickelten Hardware-Baustein, dem RAID-Controller, organisiert wird. Der Hardware-RAID-Controller befindet sich in physischer Nähe der Festplatten. Er kann im Gehäuse des Computers enthalten sein. Häufiger befindet er sich aber in einem eigenen Gehäuse, einem Disk Array, in dem auch die Festplatten untergebracht sind.

Vermehrt werden in den letzten Jahren auch Festplatten-Controller unter der Bezeichnung *RAID-Controller* auf Hauptplatinen (engl. *mainboards*) für den Heimcomputer- bzw. Personal Computer-Bereich verbaut sowie als Kartenerweiterung im Niedrigpreis-Sektor angeboten. Üblicherweise sind diese häufig auf RAID 0 und RAID 1 beschränkt. Um die Karten im nichtprofessionellen Bereich so erschwinglich wie möglich zu machen, überlässt man hier jedoch oft die RAID-Logik der CPU. Ein weiterer Nachteil ist bei diesen auch, dass man an den Controller gebunden ist und bei einer Fehlfunktion desselben die Gefahr eines Datenverlustes besteht. Solche Controller werden im Linux-Jargon daher oft auch als *Fake-RAID* bezeichnet (vgl. auch die sog. 'Win- oder Softmodems).

Software-RAID

Von *Software-RAID* spricht man, wenn das Zusammenwirken der Festplatten komplett softwareseitig organisiert wird. Auch der Begriff *Host based RAID* ist geläufig, da nicht das Speicher-Subsystem, sondern der eigentliche Computer die RAID-Verwaltung durchführt. Die meisten modernen Betriebssysteme, wie FreeBSD, Apple Mac OS X, HP HP-UX, IBM AIX, Linux, Microsoft Windows ab Windows NT oder SUN Solaris, sind dazu in der Lage. Die einzelnen Festplatten sind in diesem Fall entweder über einfache Festplattencontroller am Computer angeschlossen oder es werden externe Storage Geräte wie Disk Arrays von Firmen wie EMC, Promise, AXUS, Proware oder HDS an den Computer angeschlossen. Die Festplatten werden dann als sogenannte JBODs ("just a bunch of disks") ins System integriert.

Der Vorteil von Software-RAID ist, dass kein spezieller RAID-Controller benötigt wird. Die vom Betriebssystem mitgelieferte RAID-Software oder eine separat installierte Software wird dann genutzt. Der Festplatten-Cache bleibt aktiviert. Ein Nachteil ist die Abhängigkeit von einem bestimmten Betriebssystem bzw. einer bestimmten Plattform. Besonders bei der Disaster Recovery kommt dieses zum Tragen. Der Hauptprozessor (CPU) des Computers wird bei Festplattenzugriffen belastet, dies bringt Vor- und Nachteile mit sich. Storage Server sind in der Regel nie voll ausgelastet und somit sind Software-RAIDs auf diesen Servern schneller als Hardware-RAIDs. Leider entfällt aber die Möglichkeit, einen im RAID-Controller oder Disk Array vorhandenen Cache mit einem

Battery Backup Module auszustatten. Dies hat zur Folge, dass Daten, die bei einem ungeplanten Neustart im Cache liegen, verloren gehen.

Das Programm, welches die Verwaltung der Festplatten übernimmt, wird gemeinhin als *Volume Management Software* oder Logical Volume Manager bezeichnet, wobei sich die Terminologie und Aufteilung der Funktionen von System zu System stark unterscheiden.

RAID (redundant array of inexpensive disks)
• Grundidee: Verwendung mehrerer 'kleiner' parallel operierender Disks statt einer 'großen' Disk
• urspr¨unglich f¨ur Serverl¨osungen vorgesehen
• heute in bestimmten Varianten auch im PC anzutreffen
• durch parallel operierende Disks -> unterschiedliche Verhaltensweisen implementierbar
• Verk¨urzung der Zeit f¨ur den Datenzugriff
• Vergr¨oßerung der Speicherkapazit¨at
• Bereitstellung von Redundanz bei der Datenspeicherung (mirroring, Fehlercodes)
• RAID-Disks in verschiedenen Levels spezifiziert

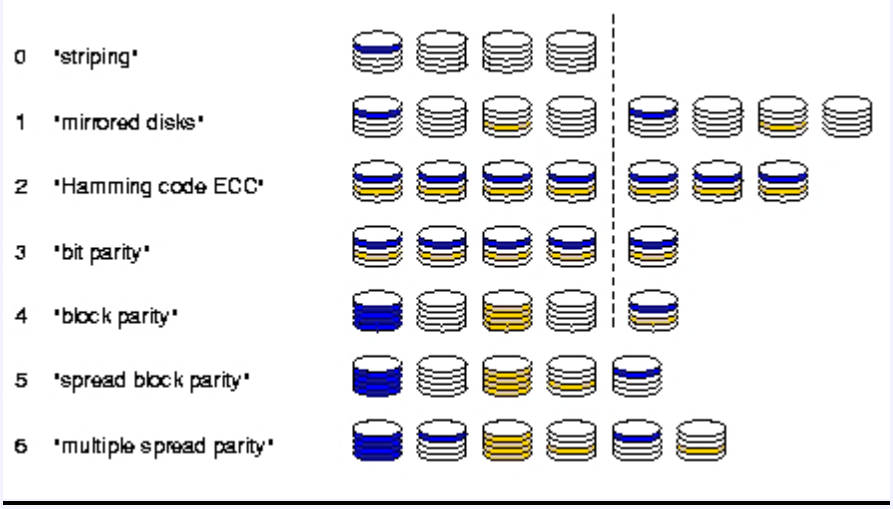

3.3 CD / DVD

CD-ROM (auch *CDROM*) ist die Abkürzung für *Compact Disc Read-Only Memory*. Eine CD-ROM speichert digitale Daten dauerhaft. Sie ist nach der Audio-CD die zweite Anwendung der Compact Disc.

Rohling Datenschicht

CD-Brenner

CD-ROM-Mechanik

Eine CD-ROM speichert zwischen 650 MB (entspricht 74 Minuten Musik – den herkömmlichen Audio-CDs) und 900 MB (100-Minuten-CDs, die aber nicht in allen CD-Brennern beschrieben und nicht in allen CD-Laufwerken gelesen werden können).

Fast alle heutigen Computersysteme verfügen über ein CD-ROM-Laufwerk, mit dem die Daten gelesen werden können. Die CD-ROM ist eines der wenigen Speichermedien, die von verschiedenen Computersystemen gelesen werden können, vorausgesetzt die Daten wurden nach der ISO-9660-Norm aufgezeichnet. Andere verbreitete Dateisysteme für CD-ROM sind zum Beispiel Rockridge (UNIX) und Joliet (Windows). Unterstützt eine CD-ROM die El Torito-Spezifikation, so ist sie ein bootfähiges Medium. Alle diese Spezifikationen setzen jedoch auf der ISO 9660-Norm auf.

Die erste CD wurde 1979 auf einer Messe in Tokio vorgestellt. Die CD-ROM ist das zur Zeit am weitesten verbreitete Medium zum Verteilen von Daten und Software.

Die *CD-ROM* ist eines der offiziellen CD-Formate, die in den so genannten „Bunten Büchern“ (*Rainbow Books*) spezifiziert sind, im Falle von CD-ROM im „Yellow Book“ (= Daten-CDs) und „Orange Book“ (= beschreibbare CD-Formate mit Multisession-Fähigkeit). Nur wenn die dort beschriebenen Spezifikationen eingehalten werden, darf die CD-ROM das von Philips vergebene offizielle Compact Disc-Logo tragen. Es existieren weitere spezielle Formate, z. B. CD-ROM XA, CD-Extra, CD-i usw. Da bei der Herstellung von CD-ROM (und deren Derivate) bestimmte Patente von Philips und/oder Sony genutzt werden, ist zu prüfen, ob dafür von den Patentrechtsinhabern Lizenzgebühren verlangt werden. Die Herstellung und der Vertrieb von unlizenzierten CD-ROMs kann in Deutschland oder anderen Ländern durch die Patentinhaber oder staatliche Stellen verfolgt oder verboten werden.

Aufbau des Datenträgers

Als Trägermedium verwendet man hier eine Kunststoffscheibe (aus Polycarbonat) mit einem Durchmesser von 12 cm und einer Stärke von 1,2 mm. Auf dieser Scheibe befindet sich, analog zur Schallplatte, eine spiralförmig verlaufende Datenspur. Die Informationsträger sind auch hier kleine Vertiefungen, die sogenannten „Pits“ und „Lands“, welche im Maßstab gegenüber der Schallplatte jedoch um ein Vielfaches verkleinert wurden, unterschiedlich lang sind und so konzipiert wurden, dass sie mit Hilfe eines Laserstrahls ausgelesen werden können. Der Wechsel von „Pit/Land“ bzw. „Land/Pit“ bildet eine 1, gleich bleibende Struktur „Land/Land“ oder „Pit/Pit“ eine 0. Da die „Pits“ und „Lands“ bei aufeinanderfolgenden Einsen zu kurz würden, muss dieser Fall ausgeschlossen werden. Daher ist eine Umkodierung notwendig, welche mit der 8-zu-14-Modulation realisiert wird. (Mit

weiteren 3 Merge-Channelbits getrennt ergeben sich 17 Kanalbits für ein Datenbyte.) Die „Tonspur“ (Datenspur) verläuft hier von innen nach außen. Am Anfang der Datenspur ist ein Inhaltsverzeichnis gespeichert. Bei Musik-CDs gibt dieses Inhaltsverzeichnis die Anzahl der Musiktitel, die Einspieldauer und die Gesamtspieldauer an. Bei Daten-CDs sind dort nicht die Positionen der Dateien und Verzeichnisse gespeichert, sondern nur die Positionen der Tracks, welche ihrerseits normalerweise ein Dateisystem (mit Positionen der Dateien und Verzeichnisse) enthalten. (Siehe auch Dateisystem oder CDFS.)

Die Drehzahl wird abhängig von der Stellung des Abtastsystems auf der spiralförmigen Spur reguliert, um eine gleich bleibende Datenabtastung zu gewährleisten. So wird vom Abtastsystem innen die Drehzahl etwa auf 520 U/min und außen etwa auf 210 U/min eingestellt. Bei einfacher CD-Geschwindigkeit werden etwa 150 KiB (CD-ROM Mode 1) bis 172,3 KiB (Audio-CD) Nutzdaten pro Sekunde ausgelesen. Dazu kommen noch Zusatzinformationen für Fehlerkorrektur, Codierung und Synchronisation.

Lebensdauer

Die Frage, wie lange die Daten effektiv gelesen werden können, ist offen. Schätzungen schwanken zwischen 10 und 50 Jahren, wobei die Alterung sehr stark von Temperaturschwankungen abhängig ist; auch Sonnenlicht lässt die Medien sehr viel schneller altern. Sicher ist, dass Daten auf CD-ROM bedeutend kürzer als auf Papier oder Pergament halten. Man geht davon aus, dass eine optimale Lebensdauer durch Lagerung bei konstant 20 Grad Celsius in absoluter Dunkelheit erreicht werden kann.

Herstellung

Eine CD-ROM besteht aus einem Kunststoffträgermaterial mit Aluminiumbeschichtung. Die digitale Information wird auf einer spiralförmigen Spur aufgebracht. Es werden stellenweise Vertiefungen in die Beschichtung gepresst, so genannte Pits. Diese reflektieren etwas früher als die unbeschädigten reflektierenden Stellen, die Lands genannt werden, da die CD-ROM von der Oberseite gepresst werden und von der Unterseite gelesen werden. Somit sind die Pits von der Lese-Seite nicht als Vertiefungen sichtbar, sondern als Hügel. Die Übergänge von Land zu Pit, und umgekehrt, reflektieren das Licht nicht. Beim Lesen tastet ein schwacher Laserstrahl die gespeicherte Information ab.

Die industrielle Herstellung einer CD-ROM beginnt mit dem **Premastering**. Dabei werden die auf einer CD-ROM zu speichernden Daten zusammengestellt, der dazugehörige Fehlererkennungscode (EDC/Fehlerkorrektur) wird berechnet. Der Fehlererkennungscode dient zum Beseitigen von Fehlern beim Lesen einer CD-ROM durch ein spezielles Korrekturverfahren (CIRC, *Cross-Interleaved Reed-Solomon Code*). Beim Premastering werden den eigentlichen Nutzdaten auch noch Synchronisationsbytes und Headerinformationen vorangestellt.

Beim nächsten Produktionsschritt, dem **Mastering**, werden mit Hilfe eines starken Laserstrahles die Daten vom Premastering auf eine photoresistente Schicht übertragen, ausgewaschen und versilbert. Das Negativ einer CD-ROM, ein so genannter Glasmaster entsteht. In den meisten Fällen wird der Glasmaster vor der CD-ROM-Herstellung mit Nickel galvanisiert, der so genannte „Vater“ entsteht.

Die eigentliche CD-ROM-Herstellung (**Pressung**) erfolgt in einem Spritzgussverfahren (genau: Spritzprägen). Das Ausgangsmaterial, flüssiges Polycarbonat, wird mit Hilfe des Masters in eine Form gepresst, anschließend mit Aluminium beschichtet und versiegelt. Meist wird noch ein CD-Label im Siebdruckverfahren auf die Oberseite der CD-ROM aufgetragen.

Normen und Standards

- ISO/IEC 10149, basiert auf dem Standard ECMA-130.

Spezielle Arten und Formate

Verschiedene Arten von Medien:

- CD-ROM (Compact Disc Read-Only Memory) – die industriell hergestellte, also „gepresste“ und unzählig vervielfältigte, klassische Compact Disc
- CD-R (Compact Disc Recordable) – übliche, einmal beschreibbare CD
- CD-RW (Compact Disc ReWritable) – mehrfach lösch- und wiederbeschreibbare CD
- DVD (Digital Versatile Disc) – Nachfolger der CD mit vielfacher Speicherkapazität

Verschiedene Formate und Dateisysteme respektive mögliche Inhalte auf den genannten Medien:

- CD-DA (Compact Disc Digital-Audio) – klassische Audio-CD
- CD-i (Compact Disc Interactive) – inzwischen veraltetes Multimedia-Format
- MiniDVD – Standard-CD, die mit DVD-konformen Daten beschrieben wurde
- CD-MRW (Compact Disc Mount Rainier Read/Write) – Verwendung von Standard-CD-R(W)-Medien zum Beschreiben in MRW-fähigen Laufwerken
- ISO 9660 – bei der CD-ROM übliches Dateisystem
- UDF (Universal Disk Format) – plattformunabhängiges Dateisystem für optische Medien, welches ISO 9660 ergänzt oder ersetzt

Sonstiges

Ursprünglich sollte die Kapazität nach Planung der Erfinder 60 Minuten Musik betragen und somit einen Durchmesser von genau 10 Zentimeter haben, die CD-ROM könnte somit in die Brusttasche eines Hemdes gesteckt werden. Die willkürlich erscheinenden 74 Minuten entstanden aber nicht, weil der Chef der Entwicklungsfirma gerne die 9. Sinfonie von Ludwig van Beethoven hörte, die jedoch 74 Minuten lang ist, und deshalb nicht auf einer Audio-CD Platz gefunden hätte. Vielmehr wurde der für die Spieldauer entscheidende CD-Durchmesser durch die Philips-Führung folgendermaßen begründet: Die Compact Cassette war ein großer Erfolg, die CD sollte nicht viel größer sein. Die Compact Cassette hatte eine Diagonale von 11,5 cm, die Ingenieure machten die CD 0,5 cm größer.

Das Loch in der Mitte der CD-ROM hat seinen Ursprung in der Größe einer alten niederländischen 10-Cent-Münze. Diese hatten die Entwickler von Philips ständig in ihrem Geldbeutel. Die Größe des Durchmessers dieser Münze schien für die Anwendung ideal zu sein.

DVD-RAM
aus Wikipedia, der freien Enzyklopädie

Logo

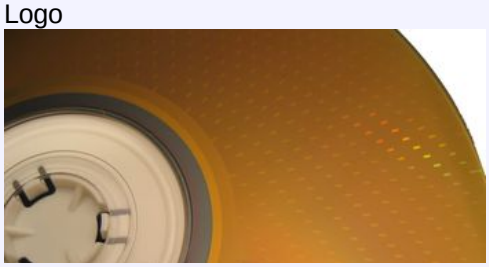

Durch ihre typischen kleinen Sektorierungs-Rechtecke, die auf der bespielten Seite verstreut sind, lässt sich eine **DVD-RAM** von anderen DVD-Formaten mit bloßem Auge unterscheiden. Die Sektorierung dient einer höheren Datensicherheit.

Als **DVD-RAM** wird eines der drei wiederbeschreibbaren DVD-Formate bezeichnet, das sich gegenüber den anderen beiden durch seine bessere Wiederbeschreibbarkeit und Datensicherheit auszeichnet. Die DVD-RAM wird sowohl bei Computern als auch in Camcordern und digitalen Videorecordern verwendet.

Inhaltsverzeichnis

- 1 Geschichte und Verbreitung
- 2 Unterschiede der DVD-RAM zur DVD-RW und DVD+RW
- 3 Unterschiede der DVD-RAM zur MO-Disk
- 4 Unterschiede der DVD-RAM zur DVD-Video
- 5 Spezifikation der Medien
- 6 Gerätetypen, Hersteller und RAMPRG
- 7 Einzelnachweise
- 8 Normen und Standards
- 9 Literatur
- 10 Weblinks

Geschichte und Verbreitung

Zuerst gab es nur reine Abspiel-DVDs wie die DVD-Video, DVD-Audio und die DVD-ROM. Daneben sollte es ursprünglich nur für den Computerbereich auch ein wiederbeschreibbares DVD-Format geben, die DVD-RAM. Das „-RAM“ steht für „Random Access Memory“. Inzwischen wird die DVD-RAM aber auch besonders erfolgreich für andere Bereiche wie etwa Video eingesetzt.

Die DVD-RAM ist zwar das älteste wiederbeschreibbare DVD-Format, aber sie ist weniger verbreitet als die anderen zwei wiederbeschreibbaren DVD-Varianten DVD-RW und DVD+RW. Das liegt daran, dass die Mitglieder der Industrievereinigung DVD-Forum sie zwar 1996 gemeinsam abgesegnet hatten, aber aus verschiedenen Marktinteressen die DVD-Formate DVD-RW und DVD+RW zusätzlich einführten. Beide Konkurrenzformate basieren ebenfalls auf der Phase-Change-Technologie, aber sie weisen einige Einsparungen auf, die zu Lasten einer guten Wiederbeschreibbarkeit und Datensicherheit gehen. Diese zwei DVD-Varianten DVD-RW und DVD+RW werden im Folgenden kurz als DVD±RW bezeichnet.

Die ersten Geräte zur DVD-RAM kamen 1997 auf den Markt. Seit 2002 erlangt die DVD-RAM eine steigende Marktbedeutung, weil sie sich im Bereich DVD-Videorekorder und DVD-Camcorder aufgrund ihrer Vorteile in der problemlosen Wiederbeschreibbarkeit und einfacheren Handhabung gegenüber DVD±RW als Standard etabliert hat. Über die größere Verbreitung der DVD-RAM sind die Medienpreise gesunken, so dass sie inzwischen auch für den Einsatz im Konsumentenbereich für Backups von Computerdaten interessant ist. Die größere Marktbedeutung der DVD-RAM im Computerbereich ist auch daran erkennbar, dass der frühere bekennende Verfechter der DVD-RW, der Hersteller Pioneer, inzwischen auch DVD-Brenner anbieten muss, die DVD-RAM verarbeiten können.

Im Computerbereich ist über die tatsächliche Verbreitung der DVD-RAM in der Anwendung keine exakte Angabe möglich, weil seit 2004 die DVD-Brenner, die auch DVD-RAM schreiben können, nur als sogenannte *Super-Multi-Brenner* angeboten werden. Ein Super-Multi-Brenner ist ein Gerät, das alle DVD-Formate verarbeiten kann. Diese DVD-Brenner werden seit 2004 zu ähnlichen Preisen angeboten wie gute DVD±RW-Brenner (ohne DVD-RAM) und überzeugen durch ihre technischen Leistungsdaten auch Kunden, die den DVD-Brenner ausschließlich nur für DVD±R und DVD±RW nutzen. Deutlichstes Kennzeichen dieser Situation ist, dass einige Händler zwar DVD-RAM-fähige

Brenner verkaufen, aber nur DVD±R-Rohlinge und DVD±RW-Medien anbieten und keine DVD-RAM-Medien.

Diese Situation ist eingetreten, da die Hersteller von DVD-RAM-Geräten kaum Öffentlichkeitsarbeit für die DVD-RAM leisten. Zum Beispiel finden sich auf den Internetseiten der Hersteller im Regelfall keine aufklärenden Darstellungen über die Vorteile der DVD-RAM. Auch in den Anleitungen der Geräte fehlen solche Darstellungen. DVD-RAM wird daher im Computerbereich nur von Insidern benutzt, obwohl sie eine viel größere Datensicherheit und eine einfachere Handhabung erlauben als eine DVD±RW.

Ende 2005 verdoppelte sich die Speicherkapazität der DVD-R durch Dual-Layer-Speichermedien. Technisch wäre die Speicherkapazität noch weiter ausbaubar durch weitere Schichten. Jedoch konzentrieren sich die Unternehmen auf die nächste Generation der optischen Medien. Für die DVD-RAM extistieren dazu die designierten Nachfolger BD-RE und HD DVD-RAM. Die Laufwerke sind abwärtskompatibel zur DVD-RAM, d.h. die Speichermedien DVD-RAM können direkt ohne Umkopieren weiter genutzt werden.

Unterschiede der DVD-RAM zur DVD-RW und DVD+RW

Neben der DVD-RAM gibt es noch zwei andere wiederbeschreibbare DVD-Formate, die DVD-RW und die DVD+RW. Trotz ähnlichen Aussehens, Namen und gleicher Kapazität, sind die Unterschiede gravierend. Ganz allgemein liegt der Hauptunterschied von der DVD±RW zur DVD-RAM darin, dass die DVD±RW auf eine *maximale Kompatibilität* mit der DVD-Video und DVD-ROM ausgelegt sind, während die DVD-RAM auf *Datensicherheit optimiert* ist. Die Unterschiede lauten im Detail:

Austauschbarkeit
: DVD-Geräte können im Regelfall eine DVD±RW abspielen, während dies bei der DVD-RAM im Jahre 2004 meist nur bei den höherwertigen DVD-Geräten gegeben ist, vergleiche Kapitel Gerätetypen, Hersteller und RAMPRG.

Sektorierung
: Die Medien von DVD-RAM sind mit bloßem Auge unmittelbar von anderen DVD-Varianten unterscheidbar anhand ihrer Sektorierung, die sich visuell als viele kleine verstreute Rechtecke auf der Rückseite einer DVD-RAM zeigen (vergleiche die erste Abbildung oben). Die Sektorierung dient unter anderem einer höheren Datensicherheit.

Formatierung
: DVD-RAMs sind im Gegensatz zu einer DVD±RW häufig schon ab Werk formatiert. Außerdem ist eine Neuformatierung einer DVD-RAM durch ihre Sektorierung in wenigen Sekunden möglich, im Gegensatz zur DVD±RW.

Defektmanagement
: Die DVD±RW hat kein Defektmanagement. Die DVD-RAM hingegen hat das gleiche bewährte Defektmanagement wie eine Festplatte: Wenn eine Speicherstelle (Sektor) auf der DVD-RAM nicht beschreibbar ist, so wird diese Stelle als defekt gekennzeichnet und der Inhalt woanders abgespeichert. Das Defektmanagement der DVD-RAM ist sehr zuverlässig, weil es wie bei der Festplatte von der Laufwerkselektronik vorgenommen wird. Für die DVD±RW bieten die Softwarehersteller von Brennerprogrammen nur eine Behelfslösung für das ihr fehlende Defektmanagement an. Hierbei findet nach dem Brennen einer DVD±RW eine optionale Leseprüfung auf unbemerkte Brennfehler statt. Die *nachträgliche Verifizierung der DVD±RW* ist eine Behelfslösung, weil im Fehlerfall der Fehler nicht korrigiert werden kann und das DVD±RW-Medium weggeworfen und alle Inhalte auf einem neuen DVD±RW-Medium gebrannt werden müssen. Das Defektmanagement der DVD-RAM lässt sich vereinfachend auch als „automatisierte Verifizierung mit Fehlerkorrektur“ bezeichnen, weil es schon während des Brennens stattfindet.

Geschwindigkeit
: Ein DVD-RAM-Medium wird ungefähr 50 Prozent langsamer beschrieben als ein DVD±RW-Medium. Dieser Geschwindigkeitsunterschied besteht aber nur bei oberflächlicher Betrachtung. Wird zur Zeit des Brennens einer DVD±RW auch die notwendige anschließende Verifizierung addiert, so ist die Gesamtzeit ungefähr gleich, aber ohne die Vorteile des Defektmanagements einer DVD-RAM (siehe oben).

Sehr geringe Systembelastung

Auch wenn in den Herstellerspezifikationen von DVD-RAM-Brennern für den Computer immer PCs mit hoher Prozessorleistung gefordert werden, so bezieht sich diese Angabe immer auf die mitgelieferte Multimediasoftware (unter anderem zum Abspielen von Videos). Der DVD-RAM-Brenner selber stellt keine besonderen Anforderungen an die Hardware. Egal wie ausgelastet die CPU oder die Festplatte des Computer ist, durch das Defektmanagement (siehe oben) in der Laufwerkselektronik des DVD-RAM-Brenners kann kein Brennfehler entstehen. Eine DVD-RAM eignet sich daher besonders für Backups, die nebenher erstellt werden sollen.

Wechselfestplatten-Nutzung

Alle drei wiederbeschreibbaren DVD-Formate DVD-RW, DVD+RW und DVD-RAM haben die Gemeinsamkeit, dass sie wie eine Wechselfestplatte genutzt werden können. Eine Wechselfestplatten-Nutzung bedeutet, dass Dateien wie bei einer Festplatte gewohnt abgespeichert, kopiert, gelöscht, umbenannt oder verschoben werden können − aus jedem beliebigen Programm heraus. Für den *Dauereinsatz* einer DVD als Wechselfestplatte eignet sich aber nur die DVD-RAM, weil der DVD±RW das Defektmanagement einer Festplatte fehlt.

Lebensdauer

Die DVD-RAM hat eine Lebensdauer von mindestens 30 Jahren. Diese lange Zeitspanne war schon bei der Spezifikation vorgesehen, um gesetzliche Vorgaben für Archivmedien einhalten zu können. Um über diese lange Zeitdauer auch Kratzer an der Oberfläche zu vermeiden, gibt es die DVD-RAM auch von Anfang an in einer Cartridge-Version (siehe unten).

Wiederbeschreibbarkeit

Die DVD-RAM gilt mit ihrer rund 100.000-maligen Änderbarkeit (gilt für 2x- und 3x-DVD-RAM) als nahezu beliebig oft wiederbeschreibbar. Dagegen ist eine DVD±RW bestenfalls 1.000 Mal wiederbeschreibbar, in der Praxis je nach Kombination aus Brenner und Medium oft sogar deutlich weniger. Es ist zu beachten, dass DVD-RAM Medien für Geschwindigkeit von 5x und darüber nur noch etwa 10.000 Mal beschrieben werden können, da der chemische Aufbau ein anderer ist. Wenn das UDF-Dateisystem verwendet wird, erreicht die DVD-RAM auch die angegebene Wiederbeschreibbarkeit, weil einzelne nicht mehr neu beschreibbare Sektoren auch im Verzeichnissystem korrigiert werden können (im Gegensatz zu einer DVD±RW).

Schreib-/Lesestrategie

Die DVD-RAM ist die einzige DVD, die gleichzeitig ausgelesen und beschrieben werden kann. So ist es beispielsweise möglich, sich mit einem DVD-RAM-Rekorder, der anstelle eines Videorekorders an den heimischen Fernseher angeschlossen ist, die schon seit einiger Zeit laufende Sendung von Anfang an anzusehen, während dessen der Rekorder die Sendung weiter aufnimmt. Dies ist sonst nur mit teuren Rekordern mit integrierter Festplatte möglich. Der DVD-RAM-Rekorder ist im Vergleich dazu sehr preisgünstig.

Keine organische Schicht

Um die hohe Lebensdauer von 30 Jahren zu erreichen, werden bei den DVD-RAM Medien keine organischen Schichten, wie sie bei DVD+R- und DVD-R-Medien Anwendung finden, verwendet. Als Material wird etwa Germanium, Antimon und Tellur (GeSbTe) bei 1x-, 2x- und 3x-Medien oder ein Bismuth-Coupling-Material (BCM) bei 5x- und 16x-Medien verwendet, anstatt des bei der DVD-RW verwendeten Materials Silber, Indium, Antimon und Tellur (AgInSbTe).

Unterschiede der DVD-RAM zur MO-Disk

Eine geöffnete MO an der die gleiche Sektorierung erkennbar ist wie bei der DVD-RAM.

In der Literatur wird die DVD-RAM oft fälschlicherweise als eine MO-Variante angesehen, weil beide die gleiche Sektorierung auf der Datenträgeroberfläche aufweisen (vergleiche hierzu die erste und zweite Abbildung; besonders in der Vergrößerung). Die Sektorierung dient einer höheren Lese- und Schreibgenauigkeit. Die Sektorierung lässt sich aber in verschiedenen Technologien verwenden: Die DVD-RAM verwendet als Lese- und Schreibverfahren die Phase-Change-Technologie, während die

MO-Disk die magnetooptische Technologie verwendet. Für weitere Unterschiede der DVD-RAM zur MO-Disk siehe unter dem Stichwort Magneto Optical Disk.

Unterschiede der DVD-RAM zur DVD-Video

Eine DVD-RAM lässt sich wie eine DVD-Video benutzen, also können auf ihr auch Videos abgespeichert und mit einem DVD-Menü ausgestattet werden. Auf DVD-Playern, welche auch DVD-RAM lesen können, können diese auch problemlos abgespielt werden.

Werden Videos **nicht** am PC, sondern über einen DVD-Videorekorder auf eine DVD-RAM geschrieben, so gibt es Unterschiede. Konkret: Eine über einen DVD-Videorekorder aufgenommene DVD-RAM ist nicht am PC auf eine DVD±R oder DVD±RW umkopierbar und danach auf jedem beliebigen DVD-Player nutzbar, weil dazu zunächst die Videodatei konvertiert werden muss.

Die DVD-RAM-Videorekorder verwenden zum Ersten eine andere *Verzeichnisstruktur*. Befinden sich die Videos der DVD-Video (wie bei DVD±R und DVD±RW) im Verzeichnis `VIDEO_TS`, so lautet dieses Verzeichnis bei der DVD-RAM hingegen `DVD_RTAV`. Zum Zweiten unterscheidet sich das verwendete *Dateiformat* für die Videodaten. Das Video wird nicht im Dateiformat VOB sondern in VRO (Video Recording Object) gespeichert. Das VRO-Dateiformat erlaubt eine bessere Aufzeichnung und Videobearbeitung, aber es ist nicht kompatibel zu klassischen DVD-Playern. Aktuelle DVD-Player-Software für den PC wie etwa WinDVD oder PowerDVD können mittlerweile DVD-RAM-Videodateien ohne Konvertierung direkt abspielen. Im Jahre 2004 gab es noch keinen einzigen DVD-Videorekorder mit DVD-RAM, welcher auf Wunsch des Benutzer direkt VOB-Dateien erzeugt, so dass diese durch einfache PC-Kopieraktionen in eine DVD±R umwandelbar sind.

Spezifikation der Medien

Das Wissen über die Spezifikation des Datenträgers ist nützlich bei der Bewertung der DVD-RAM-Technologie und beim Kauf von DVD-RAM-Geräten und -Medien. Im Folgenden werden nur die Informationen dargestellt, welche von unmittelbarem allgemeinen Interesse sind. Reine technische Details auf über 100 Seiten sind in den Quellen ersichtlich, welche im Kapitel Normen und Standards angegeben sind.

Die DVD-RAM-Medien gibt es in zwei verschiedenen Durchmessern: Einmal im Durchmesser einer CD von 120 mm und im Durchmesser einer Mini-CD von 80 mm. Zuerst soll die Spezifikation der *typischen DVD-RAM* anhand von Speicherkapazität, Ausstattung, Schreibschutz und Dateisystem behandelt werden.

a) Die klassische DVD-RAM mit 120 mm Durchmesser

1. **Speicherkapazität:** Das klassische DVD-RAM-Medium (120 mm Durchmesser) gibt es in unterschiedlichen Speicherkapazitäten. Die meisten aktuellen Geräte können die DVD-RAM 1.0 nicht mehr verarbeiten.
    - *DVD-RAM Version 1.0*:
        - einseitiges Medium mit einer Schicht und einer Kapazität von 2,58 GB (GigaByte)
        - zweiseitiges Medium mit je einer Schicht und einer Gesamtkapazität von 5,16 GB
    - *DVD-RAM Version 2.0*:
        - einseitiges Medium mit einer Schicht und einer Kapazität von 4,7 GB
        - zweiseitiges Medium mit je einer Schicht und einer Gesamtkapazität von 9,4 GB
        - Geschwindigkeit 2x
        - Revision 1.0: Geschwindigkeit 3x
        - Revision 2.0: Geschwindigkeit 5x
        - Revision 3.0: Geschwindigkeit 6x max
        - Revision 4.0: Geschwindigkeit 8x max

    - Revision 5.0: Geschwindigkeit 12x max
    - Revision 6.0: Geschwindigkeit 16x max
2. **Formatklasse für die Geschwindigkeit:** Die DVD-RAM-Medien sind für unterschiedliche Schreib- und Lesegeschwindigkeiten ausgelegt.
    - *Class 0:* Geschwindigkeiten von 2x bis 5x. Dies ist die ursprüngliche Formatklasse. Diese Medien können von Class-0- und Class-1-Geräten gelesen und beschrieben werden. Als Phase-Change-Material wird bei den 1x-, 2x- und 3x-Medien Germanium, Antimon und Tellur (GeSbTe) verwendet, die Farbe ist goldbraun. 5x-Medien bestehen aus dem gleichen Material wie Class-1-Medien, was eine Reduzierung der Schreibzyklen (siehe Class 1) zur Folge hat.
    - *Class 1:* Geschwindigkeiten von 8x bis 16x. Die älteren Class-0-Geräte können diese Medien zwar lesen, aber nicht beschreiben. Als Phase-Change-Material wird hier ein Bismuth-Coupling-Material (BCM) verwendet, wodurch die Schreibgeschwindigkeit zwar erhöht werden konnte, aber die Anzahl der möglichen Schreibzyklen von 100.000 auf 10.000 reduziert werden musste. Die Farbe dieser Medien ist dunkelgrün. Die Einführung dieser Formatklasse wurde im März 2005 zur Erhöhung der Geschwindigkeit angekündigt [1]. Obwohl inzwischen (Februar 2007) Laufwerke angeboten werden, die diese Formatklasse unterstützen und laut Herstellerangaben mit bis zu 12facher Geschwindigkeit beschreiben können, sind diese Medien jedoch bisher nicht erhältlich.
3. **Verpackung:** Die klassischen DVD-RAM-Medien gibt es in vier verschiedenen Verpackungen im Handel, die hier mit „Variante I“ bis „IV“ durchnummeriert sind, weil die Hersteller keine einheitliche Terminologie verwenden. Am verbreitetsten ist die preiswerte Variante III.
    - *Variante I*: Dieser DVD-RAM-Medientyp war der erste existierende. Bei ihm befindet sich die ein- oder zweiseitige DVD-RAM fest in einer Schutzverpackung, die einer 3,5″ Diskette ähnelt. Diese Verpackung wird auch als Caddy oder Cartridge bezeichnet und schützt die DVD-RAM primär gegen Kratzer und Verschmutzungen. Die Cartridge schützt nicht vollkommen gegen Sonnenlicht und Staub, weshalb sie bei längerer Lagerung in die mitgelieferte Schutzhülle (aus dünnem Kunststoff oder Pappe) eingeschoben werden kann. Variante I ist besonders bei DVD-RAM-Videorekordern verbreitet, weil hier der Konsument die DVD-RAM recht sorglos anfassen und ablegen kann. Die Variante I bzw. Variante II werden auch als **Type I** bzw. **Type II** bezeichnet.
    -

      Variante II. Deutlich erkennbar ist der rote Schiebeschalter für den Schreibschutz.

    - *Variante II*: Wie Variante I, aber die DVD-RAM kann aus der Cartridge bei Bedarf herausgenommen werden. Dies ist nützlich, weil viele neuere DVD-RAM-Geräte, besonders im Computerbereich, für eine preiswertere Mechanik auf die Fähigkeit, eine DVD-RAM mit einer Cartridge lesen zu können, verzichten.
    - *Variante III*: Bei dieser Variante wird das DVD-Medium in einem schlichten Jewelcase oder Slimcase ausgeliefert. Bei einem sorgsamen Gebrauch stellt der fehlende permanente Schutz der DVD-RAM durch eine Cartridge kein Problem dar, ähnlich wie dies bei den bekannten CD-R und DVD±R der Fall ist. Die „Variante III“-Medien sind deutlich preiswerter als diejenigen für die Varianten I oder II. Gegen einen Aufpreis gibt es diese Ausführung auch mit kratzfester Oberfläche, um mehr Langlebigkeit im Alltagsgebrauch zu gewährleisten.
    - *Variante IV*: Inzwischen gibt es vereinzelt auch DVD-RAM-Medien in der Cakebox, welche preislich nochmals etwas billiger sind, weil bei Ihnen die Jewelcases oder Slimcases fehlen. Inwiefern das Stapeln der Medien diese in der Qualität beeinträchtigen, ist noch unklar. Sicher ist zumindest, dass die Medien nach dem

erstmaligen Gebrauch nicht wieder gestapelt werden sollten, für eine maximale Datensicherheit sind sie dann einzeln in Schutzhüllen aufzubewahren.

4. **Schreibschutz:** Im Folgenden ist nicht der typische Schreibschutz gemeint, den das Dateisystem bereitstellt und der sich immer nur auf einzelne Dateien oder Verzeichnisse erstreckt, sondern die speziellen Schutzmöglichkeiten einer DVD-RAM, die für das gesamte DVD-RAM-Medium gelten. Ein DVD-RAM-Medium lässt sich auf drei verschiedene Weisen gegen ein unbeabsichtigtes Verändern schützen: Per Betriebssystem oder Treiber (Software), per Schiebeschalter (Medium) und per Laufwerk (Hardware).
    - *Treiber:* Jedes DVD-RAM-Medium besitzt ein Schreibschutz-Bit, das unabhängig vom Dateisystem einen Schreibschutz für das gesamte Medium erlaubt. Dieser Schreibschutz wird vom Laufwerk hardwareseitig beachtet. Für die Aktivierung oder Deaktivierung dieses Schreibschutzbits ist eine spezielle Software oder ein Treiber erforderlich. In einer virenverseuchten Umgebung bietet das Schreibschutz-Bit keinen Schutz, wenn das Medium noch ungeschützt ist und es zur Aktivierung erst in ein Laufwerk eingelegt werden muss. Kurzum: Für solche Fälle ist ein Schreibschutz geeigneter, der mit der Hand ohne Zuhilfenahme von Software aktiviert werden kann, wie der Schiebeschalter oder per speziellem Laufwerk.
    - *Schiebeschalter:* Ein DVD-RAM-Medium besitzt selber keinen mechanischen Schreibschutz. An Cartridges gibt es jedoch einen Schreibschutz-Schiebeschalter ähnlich wie bei der 3,5″ Diskette. Dieser Schalter ist natürlich nur dann wirksam, wenn die DVD-RAM mit Cartridge genutzt wird. Neuere Laufwerke können ein DVD-RAM-Medium aber oft nur ohne Cartridge laden, so dass der elegante Schiebeschalter nicht in allen Fällen schützt.
    - *Laufwerk, 1:* Bei DVD-RAM-Medien, die immer nur ohne Cartridge verwendet werden, besteht ein sehr sicherer und in der Handhabung einfacher Behelfs-ad-hoc-Schreibschutz darin, ein zweites Laufwerk zu verwenden, das eine DVD-RAM nur lesen kann, aber nicht schreiben. Bei diesem zweiten Laufwerk handelt es sich um ein DVD-ROM-Laufwerk, das auch das DVD-Format DVD-RAM lesen kann, vgl. Kapitel über Gerätehersteller (siehe unten).
    - *Laufwerk, 2:* Da die DVD-RAM ein auf Datensicherheit ausgelegtes Medium ist, hatten einige Laufwerke (z.B. Panasonic LF-D201) einen in der Geräte-Firmware persistent einstellbaren Schalter, der gemäß der Fabrik-Einstellungen Medien ohne Cartridge (oder aus ihr entnommene Medien) wegen möglicher Verschmutzungen als nur-lesbar behandelten. Diese Einstellung kann man als Anwender mit vom Geräte-Hersteller gelieferter spezieller Software nach eigenen Bedürfnissen einstellen (z. B. Panasonic LF-D201: RAMDiscTool).
5. **Dateisystem:** Ein DVD-RAM-Medium lässt sich in unterschiedlichen Dateisystemen formatieren. Von den Herstellern wird das Dateisystem UDF empfohlen, und manche Hersteller bieten auch DVD-RAM-Medien ohne Aufpreis bereits fertig in UDF formatiert an (ansonsten dauert die UDF-Formatierung ungefähr eine Minute). Eine ausführliche Darstellung der Vor- und Nachteile der verschiedenen Dateisysteme und Tipps zur Zusatzsoftware und Treibern siehe im Wikibook DVD-RAM.
6. **Farbe:** Die Rückseite der DVD-RAM ist produktionstechnisch bedingt immer goldbraun bzw. bei Hochgeschwindigkeitsmedien dunkelgrün (vgl. weiter oben „Formatklasse für die Geschwindigkeit“). Nach dem Beschreiben (nicht Formatieren) der DVD-RAM verfärbt sich der veränderte Speicherplatz von goldbraun nach dunkel-goldbraun bzw. dunkelgrün in schwarzgrün.

b) Die Mini-DVD-RAM mit 80 mm Durchmesser

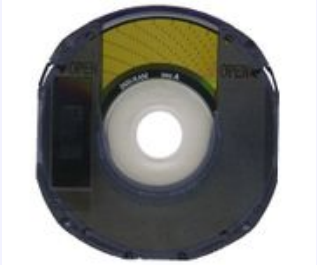

Eine Mini-DVD-RAM die in einem U-förmigen *DVD Round Holder* eingelegt ist.

Die Mini-DVD-RAM kam später heraus und wird primär bei Camcordern eingesetzt. Die Mini-DVD-RAM erlaubt eine kleinere und kompaktere Bauweise eines Camcorders. Bei DVD-Camcordern fehlt der Platz für das übliche Schubladensystem zum Einlegen einer DVD, weshalb die Mini-DVD mit Hilfe eines sogenannten „DVD Round Holder“ eingeführt werden muss (vgl. rechte Abbildung). Dieser „DVD Round Holder“ ist keine Cartridge und wird daher

in eine 3,5″ Hülle eingepackt, welche in Aufbau und Größe identisch ist mit einer Hülle für die MO-Disk.
Im asiatischen Raum wird eine Mini-DVD-RAM auch in einer Mini-Cartridge aufbewahrt.
Die Mini-DVD-RAM hat bei doppelseitiger Nutzung eine Speicherkapazität von 2,8 GB, was für eine Videoaufzeichnung von bis zu 120 min (bei verlustbehafteter Kompression mit MPEG-2-Kodierung) ausreicht.

Gerätetypen, Hersteller und RAMPRG

Es gibt vier grundsätzliche DVD-Gerätetypen: DVD-RAM-Abspielgeräte, DVD-RAM-Brenner, DVD-RAM-Camcorder und DVD-RAM-Videorekorder. Details hierzu siehe DVD-RAM-Wikibook.

Eine aktuelle Liste von Herstellern von DVD-RAM ist über die so genannte *RAM Promotion Group* (RAMPRG) möglich, welche sich seit der Internationalen Funkausstellung 2003 darum bemüht, DVD-RAM gemeinsam aktiver zu vermarkten. Der RAMPRG gehören unter anderem folgende Hersteller an: Hitachi, JVC, Toshiba, Maxell, LG Electronics, Panasonic (Matsushita), Samsung und TEAC.

DVD ist ein digitales Speichermedium, das optisch einer CD ähnelt, aber über eine deutlich höhere Speicherkapazität verfügt und vielfältiger nutzbar ist. Sie zählt zu den optischen Datenspeichern. Das Kunstwort „DVD“ ging auf die Abkürzung von **Digital Video Disc** und später **Digital Versatile Disc** (engl. für *digitale vielseitige Scheibe*) zurück, ist seit 1999 aber nach Angaben des DVD Forums ein eigenständiger Begriff ohne Langform. In der Alltagssprache wird der Ausdruck „DVD“ im Zusammenhang mit Filmen häufig im Sinne des logischen Formats DVD-Video verwendet.

Seit einigen Jahren gibt es auch Nachfolger des DVD-Standards. Diese heißen HD DVD (High Definition DVD) und Blu-ray Disc. Sie verfügen über eine wesentlich größere Speicherkapazität, die u. a. für hochauflösende Videos verwendet werden kann. HD-DVD und Blu-ray stecken jedoch noch in den Kinderschuhen und am Markt gibt es nur wenige Laufwerke und Wiedergabegeräte, die die DVD-Nachfolger unterstützen.

Dieser Artikel vermittelt einen Überblick zur Geschichte der DVD, ihrer Varianten und den Herstellungverfahren. Spezielle Details finden sich in den Artikeln DVD-Video, DVD-Audio, DVD-ROM, DVD-RAM, DVD±R.

Inhaltsverzeichnis

- 1 Geschichte und Verbreitung
- 2 Geschwindigkeit
- 3 DVD-Formate
  - 3.1 DVD-Datenstrukturen
    - 3.1.1 Physische Hybrid-DVD
  - 3.2 Beschreibbare DVD-Formate
    - 3.2.1 Doppelte Formate
    - 3.2.2 Klassifikation von beschreibbaren DVDs
- 4 Technik der DVD
  - 4.1 Lebensdauer
  - 4.2 Speicherkapazität und Zugriffstechnik
    - 4.2.1 Neue Technologien
    - 4.2.2 Datenkodierung
    - 4.2.3 Brenner
  - 4.3 Duplikationsverfahren
  - 4.4 Serienanfertigung
  - 4.5 DVD-Brennen
  - 4.6 Labelaufdruck / Beschriftung
- 5 DVD-Alternativen und mögliche Nachfolger
  - 5.1 Einweg-DVD
  - 5.2 DIVX

- 6 Siehe auch
- 7 Literatur
- 8 Weblinks

Geschichte und Verbreitung

Anfang der 1990er Jahre konnte sich die Compact-Disc als Massenspeicher-Medium bei Computern durchsetzen. Dadurch wuchsen nicht nur die Anwendungsfelder, sondern auch die Bedürfnisse der Verbraucher und der Unterhaltungsindustrie auf der ganzen Welt. Gewünscht wurde ein Medium, mit dem Videos ähnlich komfortabel gehandhabt werden können wie Musik- und Sprachaufnahmen mit der CD. Zwar gab es dies bereits als *Video-CD* (VCD) und *LaserDisc* (LD), jedoch konnten auf der VCD maximal 74 Minuten und auf der LD maximal 128 Minuten Videomaterial in knapp VHS-Qualität untergebracht werden. Dies führte bei Spielfilmen dazu, dass die VCD/LD mitten im Film gewechselt/umgedreht werden musste, ähnlich wie früher eine Musikkassette oder Langspielplatte.

Die Unterhaltungsindustrie arbeitete daran, die Speicherkapazität der CD weiter zu erhöhen. Hierbei gab es zwei unterschiedliche Konzepte: Sony und Philips betrieben die Entwicklung der *Multimedia-CD* (MMCD), Toshiba und Time Warner favorisierten die *Super Density CD* (SD). Auf Druck der Film-Industrie, die nicht mehr wie bei der Markteinführung der Videorekorder mehrere Standards unterstützen wollte, einigten sich die Konkurrenten Ende 1995 auf einen gemeinsamen Standard. Da die DVD zunächst als reines Speichermedium für Videodaten gedacht war, stand DVD anfangs für „Digital Video Disc“. Dies wurde jedoch geändert, als andere Verwendungsmöglichkeiten abzusehen waren. Als Alternative wurde „Digital Versatile Disc“ (*versatile* „vielseitig“) ins Spiel gebracht, konnte sich aber nicht durchsetzen. Der aktuelle offizielle Standpunkt des DVD-Forums ist, dass DVD einfach drei Buchstaben ohne exakt festgelegte Bedeutung sind.

Ein Jahr später kamen die ersten Abspielgeräte und DVD-Medien in den Handel. Zuvor mussten Unstimmigkeiten bezüglich der Kopierschutz-Verfahren ausgeräumt werden. Zudem gelang es der Film-Industrie, mit einem Regionalcode Marktkontrolle zu gewinnen. Mit dem Code soll verhindert werden, dass zum Beispiel eine DVD aus den USA auf einem europäischen Gerät abspielbar ist. Die Film-Industrie fürchtete hier Umsatzeinbußen, da Filme in den USA oft schon auf dem Videomarkt erhältlich sind, während sie in Europa noch gar nicht im Kino gezeigt wurden. Als Vertriebstrategie der Anbieter ist auch bekannt, dass durch die regionalen Beschränkung der Anwendbarkeit in unterschiedlichen Regionen unterschiedliche Preise („Marktpreise“) erzielt werden können.

Sowohl der verwendete Wiedergabeschutz Content Scrambling System als auch der Regionalcode sind mittlerweile leicht zu umgehen. Die Industrie reagierte darauf einerseits mit rechtlichen Maßnahmen und andererseits mit dem Druck auf die Hersteller von DVD-Laufwerken, die Abfrage des Regionalcodes gerätetechnisch zu implementieren.

1999 kamen die ersten DVD-Brenner in den Handel, die Preise lagen jedoch bei weit über 5.000 DM.

Mittlerweile werden HD DVD (High Density DVD) und Blu-ray Disc als Nachfolger der DVD beworben. Bei ihnen werden durch Abtastung der noch enger gesetzten Pits und Lands mit einem blau-violetten Laserstrahl noch höhere Datenmengen untergebracht.

In Konkurrenz hierzu haben sich einige Firmen (darunter Sony) zusammengefunden, die eine *Blu-ray Disc* (BD) entwickelt haben. Welches Format sich letztlich durchsetzen wird, ist noch unklar. Zwar ist die HD-DVD leichter herzustellen, der Blu-Ray Disc jedoch technisch in mancher Hinsicht unterlegen. So ist zum Beispiel bei der Blu-Ray Disc die Datenmenge auf einer Scheibe erheblich größer. Zudem ist bei ihr die Fehlerkorrektur (ein Muss bei derartiger Packdichte der Daten) zumindest theoretisch viel robuster. Siehe Vergleich optischer Datenträger.

Geschwindigkeit

Die Standard-Datenrate 1X entspricht bei DVDs einer Geschwindigkeit von 1,35 MByte/Sek. bzw. 10,8 MBit/Sek. und damit in etwa einem CD-Laufwerk mit dem Geschwindigkeitsfaktor 9X.

Die zwei grundsätzlichen DVD-Gruppen lassen sich anhand der Farbe ihrer Rückseite unterscheiden.

DVD-Formate

Die DVD gibt es in zahlreichen Varianten, welche als *DVD-Formate* bezeichnet werden:

- Spezielle DVD-Formate, die für bestimmte Verwendungszwecke optimierte *Datenstrukturen* aufweisen (und ursprünglich nur einen Lesezugriff erlaubten): DVD-Video, DVD-Audio und DVD-ROM, Hybrid-DVD
- Für den Konsumenten *beschreibbare DVD-Formate*: DVD-RAM, DVD-R, DVD+R, DVD-RW, DVD+RW, DVD-R DL, DVD+R DL

Die sieben letzteren Formate lassen sich mit dem bloßen Auge von den erstgenannten anhand ihrer Rückseite unterscheiden. Die vom Konsumenten selbst beschreibbaren DVDs besitzen keine graue Rückseite (wie die CD), sondern sind farbig wie etwa blau, violett oder braun. Die DVD-RAM hat außerdem charakteristische aufgedruckte Sektormarken.

DVD-Datenstrukturen

Die DVD wird für folgende drei Verwendungszwecke eingesetzt, für die jeweils eigene DVD-Formate für spezielle Datenstrukturen geschaffen wurden:

- *DVD-Video* ermöglicht die Wiedergabe von Bewegtbildern und Ton mit DVD-Video-fähigen Abspielgeräten.
- *DVD-Audio* ermöglicht die Wiedergabe von Standbildern und Ton in sehr hoher Qualität mit DVD-Audio-fähigen Abspielgeräten.
- *DVD-ROM* ermöglicht das Lesen von allgemeinen Daten (Computerdaten).

Der `AUDIO_TS`-Ordner spielt bei Audio-DVDs eine zentrale Rolle. Bei der *DVD-Video* sind jedoch auch die Audiodaten im `VIDEO_TS`-Ordner zu finden, genauso wie die diversen Sprachversionen, Untertitel, Kapitelinformationen und Sonderfeatures (alle innerhalb der so genannte „*.VOB*-Dateien“). Das bei DVDs üblicherweise eingesetzte Kompressionsformat ist MPEG-2, nach dem DVD-Standard ist jedoch auch noch das qualitativ weit unterlegene MPEG-1-Format vorgesehen, das ansonsten vor allem bei Video-CDs Anwendung findet. Der *MPEG-2-Videostream* (Fernsehbild) wird bei der Erstellung einer Video-DVD gemeinsam mit dem *Audiostream* und gegebenenfalls mit anderen Datenblöcken verwoben („gemuxt“, s. Multiplexing) und in einer *.VOB*-Datei („Video Object“) angelegt, die laut DVD-Standard nie größer als 1 Gigabyte sein darf. Wird die Datenmenge von 1 GB überschritten, wird in den Programmen zur DVD-Erstellung (*DVD Authoring Software*) automatisch eine neue *.VOB*-Datei angelegt. Die *.VOB*-Datei dient also als „Containerdatei“ aller Programmströme.

Beim Wechsel der Dateien ist der Übergang wegen des in den DVD-Playern integrierten Buffers nicht wahrnehmbar. Beim Abspielen werden abwechselnd Video-, Audio- und gegebenenfalls Steuerungsinformationen ausgelesen, zwischengespeichert und wiedergegeben. Der `VIDEO_TS`-Ordner enthält außerdem die *.IFO*-Datei mit der Menüführung und meist mehrere *.BUP*-Dateien, die jedoch nur als Backup der *.IFO*-Datei dienen.

Als Tonspuren sind mehrere Formate zugelassen, neben dem datenintensiven – weil unkomprimierten – LPCM-Verfahren gibt es noch mehrere Komprimierungsverfahren: mp2 (meist 192–256 kbit/sec.) in beliebigen Bitraten, AC3-Komprimierung bei Dolby Surround/Mehrkanalton

(meist 448 kbit/sec.) oder DTS bei 6.1 Surround Sound. Auch SDDS ist für die DVD spezifiziert, es gibt jedoch für den Heimbereich weder entsprechende Decoder, noch DVDs mit SDDS-Tonspur.

Insgesamt stehen für den gesamten Datenstrom 10,08 Mbit/sec. zur Verfügung, für den Audiostrom maximal 6144 kbit/sec. Die Bildqualität der Video-DVD hängt nicht so sehr von der Bandbreite des Video-Streams als vielmehr von der Effizienz der Komprimierung ab. Oft wird mittels *MPEG-Encoder* in mehreren Durchläufen kodiert, um ein Höchstmaß an Effizienz zu erreichen. Bei *MPEG-2* können die Datenströme im VBR-Verfahren komprimiert werden, d. h., dass die Bandbreite an verschiedenen Stellen des Films stark abweichen kann (variable Bitrate).

Die Bitrate hängt dabei von der gerade anfallenden Datenmenge ab, sodass zum Beispiel bei bewegungsarmen Szenen Bandbreite und damit Speicherplatz auf der DVD gespart werden kann. Bei *MPEG-2* werden bei aufeinanderfolgenden Bildern in der Regel nur die „Unterschiede“ zum vorausgehenden Bild gespeichert (*P*- oder *B-Frames*), um auf der Disc Platz zu sparen. Mehr Informationen dazu im Artikel DVD-Video.

Daten-DVDs (DVD-ROM) sind anders als Video-DVDs keinen Restriktionen unterworfen und können beliebige Ordner und Dateien enthalten. Als Dateisysteme werden entweder die im Computerbereich vorherrschenden Formate ISO 9660 und ISO/Joliet oder UDF verwendet, beide Systeme können innerhalb des *UDF Bridge*-Formates (ISO 9660 Level 3 Layer) kombiniert werden. Ebenso wie CDs können auch DVDs in mehreren Sessionen (Sitzungen) beschrieben werden (Multiborder, analog zu Multisession bei CDs). Einige ältere Betriebssysteme oder DVD-Player können jedoch nur auf die erste Session zugreifen, weshalb es sich in diesem Falle empfiehlt, die DVD in einem Zuge zu beschreiben. Zum Auslesen der restlichen Sessions dienen Zusatzprogramme wie IsoBuster, die auch unter älteren Betriebssystemen laufen.

Physische Hybrid-DVD

Daneben gibt es auch die *Hybrid-DVD*, als einseitige Alleskönner welche die Eigenschaften einer DVD-Video, DVD-Audio oder DVD-ROM in einer DVD kombiniert. Eine solche Hybrid-DVD enthält Videos, Musik und Computerdaten und präsentiert im DVD-Spieler, DVD-Rekorder oder DVD-Laufwerk des Computers die jeweils abspielbaren Inhalte.

Technisch lässt sich eine Hybrid-DVD sehr einfach realisieren, weil die DVD-Video und DVD-Audio auf der DVD-ROM basieren. Die DVD-ROM speichert alle Inhalte als Dateien nach dem UDF-Dateisystem ab. Für die DVD-Video und DVD-Audio müssen nur zwei weitere Festlegungen vorgenommen werden: Die erlaubten Dateiformate und der Ablageort auf der DVD. Für die Hybrid-DVD ist besonders der Ablageort interessant. Wird eine DVD-Video oder Hybrid-DVD zum Beispiel in einem DVD-Rekorder eingelegt, so sucht dieser die Filmdateien im Unterverzeichnis `VIDEO_TS`. Nach dem gleichen Schema sucht ein DVD-Player die Audiodaten im Unterverzeichnis `AUDIO_TS`. Im DVD-Laufwerk eines Computers sind hingegen alle Dateien einer DVD ersichtlich, weil dieser jede DVD als eine DVD-ROM behandelt.

Sony DCR-DVD201E HDV-Camcorder mit direkter Aufzeichnung auf eine 8cm DVD

Beschreibbare DVD-Formate

Der Endbenutzer kann nicht nur käufliche DVDs abspielen (die im Presswerk hergestellt wurden), sondern er kann mit einem DVD-Brenner auch eigene DVD-Videos, DVD-Audio oder DVD-ROMs erstellen. DVD-Brenner sind beispielsweise in Computern und Hifi-DVD-Rekordern eingebaut und benötigen beschreibbare DVD-Formate. Historisch haben sich aus Kostengründen die fünf verschiedenen DVD-Formate DVD-R, DVD+R, DVD-RW, DVD+RW und DVD-RAM entwickelt mit einfacher und doppelter Speicherkapazität (DL). Sie werden nach folgender Systematik bezeichnet:

Logo	**DVD**	Die Bezeichnung *DVD* tragen alle Scheiben der DVD-Familie.
	–	Am „–“ sind alle DVD-Formate erkennbar, welche vom DVD Forum stammen. Nur bei diesem Format kann *Time Search* verwendet werden.
	+	Am „+“ sind alle DVD-Formate erkennbar, welche von der DVD+RW Alliance stammen.
	±	Mit einem „±“ wird ausgedrückt, dass hier sowohl die DVD-Formate des DVD Forums wie der DVD+RW Alliance gemeint sind.
	R	„Recordable“, das heißt einmal beschreibbar.
	RW	„Rewritable“, das heißt wiederbeschreibbar (gewöhnlich bis ca. 1000 Mal veränderbar/korrigierbar).
	RAM	„Random Access Memory“, das heißt freier, direkter Schreib-/Lesezugriff auf alle Daten (Details siehe Text).
	DL	Dual (-) bzw. Double (+) Layer, das heißt zwei Datenschichten pro Seite.

Die drei DVD-Formate, die vom DVD-Forum stammen, werden auch als *Minus-Standard* bezeichnet. Nur diese Formate dürfen auch das offizielle DVD-Logo tragen. Entsprechend werden die zwei DVD-Formate von der DVD+RW-Allianz mit einem „+“ auch als *Plus-Standard* bezeichnet. Die DVD-Formate nach dem Plus-Standard sind technisch einfacher aufgebaut, wodurch zum Beispiel die DVD+RW andere Schreibmethoden als die DVD-RW unterstützt. Auch sind die Lizenzgebühren für die Patentnutzung bedeutend niedriger. Diese anfänglichen Preisvorteile des Plus-Standards gibt es inzwischen durch den harten Wettbewerb mit dem Minus-Standard nicht mehr.

Die Formatvielfalt führte anfangs zu einer Kaufzurückhaltung bei den Konsumenten, da unklar war, welches beschreibbare DVD-Format die größere Investitionssicherheit aufweist. Die Industrie reagierte seit 2003 darauf mit (preisgünstigen) Multi-Brennern, die sowohl das Minus- als auch das Plus-Format unterstützten.

Doppelte Formate

Seit 2004 werden auf dem Massenmarkt auch DVDs mit zwei anstatt nur einer Datenschicht angeboten. Sie werden mit „DL“ bezeichnet, was im Minus-Format für „Dual Layer“ (*DVD-R DL*), im Plus-Format dagegen für „Double Layer“ (*DVD+R DL*) steht. Beiden Formaten gemein sind die zwei übereinander geklebten Schichten *auf derselben Seite* der Platte, die gewisse Veränderungen im Aufbau der DVD notwendig machten. Nur so kann auch die zusätzliche Schicht beschrieben und gelesen werden. Die DVD±R DL bietet 8,5 GB Fassungsvermögen pro Medium, also etwa das 1,8fache einer Singlelayer-DVD. Ihre zusätzliche Kapazität reicht oftmals aus, um große Einzeldateien (etwa hochauflösende Videos) auf einen einzigen Datenträger zu brennen, anstatt sie auf zwei herkömmliche DVDs aufzuteilen. Für RW-Medien dagegen sind diese Änderungen hin zum DL-Datenträger derzeit (Stand April 2007) nicht möglich. Zu geringe Reflexionseigenschaften verhindern die zuverlässige Nutzung der zweiten Datenschicht.

Daneben existieren auch noch *doppelseitige* Medien in den Formaten DVD-R, DVD+R und DVD-RAM. Diese fassen tatsächlich 2x 4,7 GB, also 9,4 GB pro Medium, da sie im Prinzip aus zwei einzelnen DVDs bestehen. Nachteilig wirkt sich dies besonders bei großen Dateien aus, da diese nicht wie bei ±DL-DVDs zusammenhängend gespeichert werden können. Jede Seite repräsentiert einen eigenständigen Datenträger, und um auf den jeweils anderen Datenbestand zugreifen zu können, muss die DVD entnommen und gewendet werden. Laufwerke, die beide Seiten gleichzeitig nutzen können (Schreib-/Lesezugriff) existieren nicht. Da die Doublelayer/Duallayer-DVDs trotz geringerer Gesamtkapazität diverse Vorteile bieten (Höhere maximale Dateigröße, Platz für ausführliche Beschriftung, etc.), sind doppelseite DVD-R und +R Medien völlig vom Markt verschwunden. Lediglich doppelseitige DVD-RAM sind noch erhältlich, da auch bei ihnen derzeit keine DL-Medien verfügbar sind.

Klassifikation von beschreibbaren DVDs

Eine DVD-RAM ist mit dem bloßen Auge unmittelbar von anderen DVD-Formaten unterscheidbar anhand der vielen kleinen verstreuten Rechtecke, die von ihrer typischen Sektorierung herrühren (erkennbar in der Vergrößerung). Die Sektorierung dient einer höheren Datensicherheit.

Die beschreibbaren DVD-Formate lassen sich unterscheiden nach ihrer Veränderbarkeit und Datensicherheit.

1. Einerseits lassen sie sich nach ihrer Veränderbarkeit in zwei Gruppen unterteilen:
    - *DVD-Rohlinge*, die nur einmal beschreibbar sind: DVD-R und DVD+R. Bei diesen Medien wird die Information in einen Dye geschrieben. Dies ist ein organischer Farbstoff, meist violetter Farbe.
    - *DVD-Medien*, die nachträglich veränderbar sind: DVD-RW, DVD+RW, DVD-RAM. Die RW-Medien verwenden als funktionelle Schicht anstatt des bei den DVD-Rohlingen verwendeten Dyes eine metallische Schicht. Bei den DVD-Medien ist die DVD-RAM 100 Mal öfter wiederbeschreibbar (circa 100.000 Mal) als die DVD-RW bzw. DVD+RW, die etwa 500 bis 1.000 Schreibvorgänge überstehen.
2. Weiterhin ist die *Datensicherheit* ein weiteres wichtiges Unterscheidungsmerkmal der einzelnen beschreibbaren DVD-Formate:
    - Die *DVD±R* reagieren aufgrund ihrer organischen Farbstoffe viel empfindlicher auf Sonnenlicht und Hitze als die DVD±RW mit ihren anorganischen Farbpigmenten.
    - Andererseits ist bei der *DVD±RW* erst nach mehrfachem Schreiben (2–10 mal) sichergestellt, dass die Daten stabil gespeichert bleiben, weil sich erst danach die chemischen Eigenschaften nicht mehr so leicht verändern.
    - Die *DVD-RAM* weist von allen beschreibbaren DVD-Formaten die höchste Datensicherheit auf, weil sie zusätzlich folgende zwei Eigenschaften aufweist:
        1. *Sektorierung:* DVD-RAM-Medien besitzen eine eingeprägte Sektorierung, die sich visuell als ein Muster von kleinen verstreuten Rechtecken auf der

Unterseite einer DVD-RAM zeigen (siehe Abbildung). Sie dienen einer höheren Lese- und Schreibgenauigkeit.

2. *Defektmanagement* Die DVD-RAM besitzt dasselbe bewährte Defektmanagement wie Festplatten. Jede geschriebene Information wird von der Hardware kontrollweise gelesen (verifiziert) und ggf. verbessert. Es gibt daher keine versteckten Schreibfehler wie bei der DVD±R oder DVD±RW.

Technik der DVD

DVDs benötigen zu Abspielen einen eigenen DVD-Spieler. Zur Unterscheidung zu normalen CD-ROM Laufwerken ist dieser auf der Vorderseite mit dem DVD-Emblem gekennzeichnet.

Lebensdauer

Der Medienhersteller Imation gibt die voraussichtliche Lebensdauer bei optimaler Luftfeuchte und Temperatur wie folgt an: 3,5-Zoll-Diskette, CD-R und DVD 100 Jahre; CD-RW 70 Jahre und DVD±R sowie DVD±RW 70–100 Jahre. Dies gilt allerdings nicht für die Daten sondern für haptischen Bauteile. Die realistische Haltbarkeit der Daten hängt von der Brenngeschwindigkeit sowie der Lagerung und dem verwendeten Material ab, im "normalen" Hausgebrauch ist der Verfall deutlich schneller als 70 Jahre und kann im negativen Fall auch nur wenige Monate betragen.

Speicherkapazität und Zugriffstechnik

Die Spezifikationen sehen die folgenden DVD-Typen in der Version 2 vor. Auf die Darstellung der seltenen Version 1 wird verzichtet.

Format	Kapazität	Schichten Vorderseite/Rückseite	Bemerkung
DVD-5	4,7 GB (4,38 GiB)	1/0	
DVD-9	8,5 GB (7,95 GiB)	2/0	Durch Neufokussieren des Lasers auf die zweite Schicht kann diese gelesen werden (*Dual-Layer-DVD*).
DVD-10	2 × 4,7 GB	1/1	Zweiseitig beschrieben, muss gedreht werden (*Flipper*).
DVD-14	8,5 GB + 4,7 GB	2/1	Eine Seite *Dual Layer* (zwei Schichten) und eine *Single Layer* (eine Schicht).
DVD-18	2 × 8,5 GB	2/2	Beide Seiten werden in zwei Schichten beschrieben. Selten.
DVD-plus (DualDisc)	4,7 GB + 650 MB	1/1	DVD-5 wird mit einer normalen CD kombiniert. So kann der CD-Teil auf CD-Playern abgespielt werden. Die CD-Seite und die DVD-Seite sind unterschiedlich, die Medien sind nicht normgerecht, sondern zu dick; daher wird meist vom Abspielen solcher Medien in Laufwerken mit Einzugsschlitz, wie man sie etwa von Autoradios kennt, abgeraten. Wird von Sony unter dem Begriff *DualDisc* vermarktet.

Angabe der Brutto-Speicherkapazität in GiB bzw. GB statt in Byte. Die tatsächlich verwendbare Speicherkapazität hängt vom verwendeten Dateisystem der DVD ab.

Zwei Gründe erklären die im Vergleich zur herkömmlichen CD erheblich größere Speicherkapazität der DVD:

- Zum einen sind die Datenspuren mit ihren Vertiefungen (*Pits and Lands*) schmaler und enger nebeneinander gereiht als auf einer CD. Zudem sind die möglichen Vertiefungslängen kleiner. Das bedeutet vor allem, dass auf weniger Raum mehr Daten gespeichert werden können, erhöht aber zugleich die Anfälligkeit gegenüber Kratzern oder anderen Verunreinigungen der Oberfläche.
- Zum anderen ist es möglich, auf einer (zweilagigen) DVD zwei Datenschichten übereinander zu lagern.

Neue Technologien

Zur Anwendung beider erweiterter Techniken braucht es höherfrequente (das heißt, die Farbe des Lasers ist in Richtung Blau verschoben) und genauere Laser als zum Auslesen einer CD. Um die zweite Datenschicht lesen zu können, muss der Laser dazu noch leicht anwinkelbar sein. Zusammen mit der veränderten Laserfokussierung ist es so möglich, die untere („verdeckte“) Schicht lesen zu können.

Datenkodierung

Die Binärdaten auf einer DVD werden nach der „Eight-to-Fourteen-Modulation-plus” (EFMplus) geschrieben. Diese stellt sicher, dass alle 2 bis 10 Takte sich die Polarität des ausgelesenen Signals ändert. Das geschieht, wenn der Laser in der Spur einen Übergang von einer Vertiefung („pit”) zu einem Abschnitt ohne Vertiefung („land”) passiert oder umgekehrt.

Der Hintergrund ist hierbei folgender: Die Abschnitte mit Vertiefungen bzw. ohne Vertiefungen müssen lang genug sein, damit der Laser die Veränderung erkennen kann. Würde man ein Bitmuster direkt auf den Datenträger schreiben, würden bei einem alternierenden Signal (1010101010101010…) falsche Werte ausgelesen werden, da der Laser den Übergang von 1 nach 0 beziehungsweise von 0 nach 1 nicht verlässlich auslesen könnte. Die EFMplus-Modulation bläht das Signal von 8 Bit auf 16 Bit auf und wählt die Füllbits so, dass die oben erwähnte Forderung, dass alle 2 bis 10 Takte sich die Polarität ändert, also ein Übergang von 1 nach 0 oder umgekehrt geschieht, erfüllt wird.

Brenner

Nachdem die ersten DVD-Brenner (DVD-Schreiber) nur eine Datenmenge von 3,4 GiB auf einen einmal beschreibbaren DVD-Rohling speichern konnten, wurde die Kapazität später auf die volle Größe einer DVD-5 (4,38 GiB) angehoben und zusätzlich wiederbeschreibbare Medien mit diesem Fassungsvermögen vorgestellt. Seit Mitte 2004 beherrschen DVD-Brenner auch die Doppelschicht-Technik (*dual layer*), welche die Speicherung von Daten auf einem zweischichtigen Rohling ermöglicht. Die zweite Datenschicht besitzt weiter gesetzte Pits und Lands, um ein Lesen durch die untere Schicht hindurch zu ermöglichen und ist somit kleiner. So fasst ein solcher Rohling statt 8,76 GiB (die Kapazität zweier DVD-5) lediglich ca. 7,95 GiB.

Duplikationsverfahren

- *DVD-Pressung:* Die Herstellung einer DVD oder einer CD (ROM und Video) besteht aus vier Schritten nach Anlieferung der Master-DVD-R beziehungsweise eines Streamer-Tapes („DLT“-Format) an das Presswerk.
- *Premastering:* Zuerst wird geprüft, ob der Standard (das Book) erfüllt ist, das heißt ob der Datenträger den Spezifikationen entspricht. Danach wird mit der Berechnung des EDC (Error Detection Code) und ECC (Error Correction Code) begonnen. Dies dauerte ursprünglich zwischen 5 und 16 Stunden. Anschließend werden Time-Code, Inhaltsinformation der Tracks und TOC (*Table of contents*) usw. generiert und ein Image der DVD/CD erstellt. Die Daten können nun dem Mastering zugeführt werden.
- *Mastering:* Die aufbereiteten Daten aus dem Premastering werden auf einen Glasmaster (eine Glasscheibe) übertragen, indem ein modulierter Laserstrahl die darauf aufgetragene Substratschicht

(ein Farbstoff) von innen nach außen belichtet. Im Entwicklungsbad werden dann die belichteten Stellen ausgewaschen, die Pits entstehen. Anschließend wird der Glasmaster mit einer 100 nm dicken Silberschicht bedampft. Im Anschluss daran folgt ein erstes Auslesen als Qualitätsprüfung. [Nur nebenbei: Die Kosten für die Glasmasterproduktion (zwischen 300 € und etwa 3.000 €) werden bei geringen Auflagen von den meisten Presswerken extra berechnet; darauf ist bei der Kalkulation zu achten!]

- *Galvanik:* Es werden nun Negative des Glasmasters erstellt, die für die Pressung als Stempel verwendet werden können.

DVD mit Absplitterung eines Layers am Innenring

Generell werden die Discs aller DVD-Formate aus zwei einzelnen aus Polycarbonat gespritzten Kunststoffscheiben von etwa 0,6 mm Dicke hergestellt. Dabei hat die untere „Halbscheibe“ (Layer 0) einen Stapelring als Abstandshalter. Die obere „Halbscheibe“ (Layer 1) trägt bei dem Format DVD-5 keine nutzbaren Informationen und wird daher als „Dummy“ bezeichnet. Die eigentliche DVD entsteht, wenn beide Hälften mit unter UV-Licht aushärtendem Lack verklebt werden („bonden“, Schichtdicke etwa 50 µm). Um eine gleich bleibende Qualität der hergestellten Scheiben zu gewährleisten, sind in den Produktionsanlagen üblicherweise hochauflösende Kamerasysteme integriert. Stichprobenartig kommen auch offline-Messlaufwerke zum Einsatz. Sollte sich beim Verkleben der zwei Layers Luft einschleichen, kann die DVD schnell Schaden nehmen. So kann beispielsweise beim Einlegen der DVD ein Teil eines Layers absplittern. Hierdurch kann eine Unwucht entstehen, die zu weiteren Schäden an der DVD oder sogar am Abspielgerät führen kann.

Beim Herstellvorgang gibt es große Unterschiede zwischen prerecorded discs („Kauf-Videos“) und recordable/rewritable discs („Rohlinge“). Die Formate DVD-5, -9 und -10 können meist auf derselben Maschine hergestellt werden. Dabei werden die Informationen mit Matrizen („Stamper“) in das heiße Polycarbonat gepresst (Spritzprägen). Um die Daten für die Laufwerke lesbar zu machen, werden die Halbscheiben mit Metall beschichtet („sputtern“). Bei DVD-5, DVD-10 und dem Layer 1 bei DVD-9 wird Aluminium voll reflektierend gesputtert (etwa 50 nm). Da bei DVD-9 beide Informationsschichten von einer Seite gelesen werden, wird die untere („Layer 0“) halb-transparent mit Gold, Silizium oder Silber-Legierungen beschichtet (etwa 10–15 nm). DVD-14 und DVD-18 erhält man, indem zwischen die Halbscheiben eine mit DVD-Strukturen versehene Folie eingebracht wird.

DVD-Brennen

Beim Brennen ist kein Glasmaster erforderlich, sondern nur ein Computer, ein DVD-Brenner und Brenn-Software.

Für das Brennen benötigt man DVD-Rohlinge, die in unterschiedlichen Qualitäten als DVD-R, DVD+R, DVD-RW und DVD+RW erhältlich sind. Durch die verschiedenen DVD-Formate besteht eine gewisse Wahrscheinlichkeit, dass die gebrannte DVD auf einigen DVD-Playern nicht abspielbar sein wird. Deswegen sollte man sich nach der Kompatibilität des Brenners und der gewünschten Abspielgeräte vor dem Kauf der Rohlinge genau erkundigen. Einige DVD-Brenner bieten die Möglichkeit, DVD+R- und DVD+RW-Rohlinge mit dem Book Type DVD-ROM zu kennzeichnen und dadurch deren Akzeptanz durch DVD-Abspielgeräte deutlich zu erhöhen.

Labelaufdruck / Beschriftung

Für den Labelaufdruck bei der DVD stehen ebenso wie bei der CD verschiedene Drucktechniken zur Verfügung:

- *Siebdruck*: Im Siebdruck sind bis zu 6 Labelfarben möglich, es können Schmuckfarben (HKS oder Pantone) gewählt werden. Siebdruck ist derzeit die gängigste Variante, um CDs oder DVDs zu bedrucken, wird aber zunehmend vom Offsetdruck verdrängt. Der Siebdruck ist geeignet für gepresste CDs und DVDs, auch die Rohlingsbedruckung im Siebdruck ist

möglich. Im Siebdruck sind die Farben sehr brillant.

- *Trockenoffsetdruck*: Im Trockenoffset sind 4 Labelfarben möglich (CMYK), kombiniert mit dem Siebdruck bis zu 6 Labelfarben (CMYK im Offset und zusätzlich weiß Vollfläche und eine Schmuckfarbe oder Glanzlack im Siebdruck). Auf Grund der höheren Auflösung als im Siebdruck ist der Offsetdruck ideal für fotorealistische Darstellungen. Seit Anfang 2004 ist der Offsetdruck nicht nur für gepresste CDs und DVDs, sondern auch für CD-Rohlinge und DVD-Rohlinge möglich.
- *Thermotransferdruck*: Bei diesem Druckverfahren wird mit einem speziellen Drucker Farbe von einem Farbband durch Erhitzung des Druckkopfes auf die CD oder DVD übertragen. Technisch bedingt ist das Druckverfahren eher für Schriften und Logos geeignet. In der Praxis wird dieses Verfahren bei kleinen Auflagen (gebrannte CDs und DVDs) angewendet.
- *ThermoREtransferdruck*: Der ThermoREtransferdruck ist die Weiterentwicklung des Thermotransferdrucks. Das Labelmotiv wird im Thermotransferdruckverfahren auf ein Übertragungsband gedruckt und davon dann eine Folie auf die CD oder DVD aufgebracht. Durch diese Technik ist eine bessere Auflösung möglich. So kann bereits bei Kleinauflagen ein fotorealistischer Druck erreicht werden.
- *Tintenstrahldruck*: Es gibt spezielle DVD- bzw. CD-Rohlinge, welche gegenüber der Datenseite eine weiße Druckseite besitzen. Diese besteht aus einem speziellen, saugfähigen Material, welches ein Verlaufen der Tinte verhindern soll. Zum Bedrucken sind spezielle Drucker nötig, deren Technologie sich kaum von der unterscheidet, die zum Bedrucken von Papier genutzt wird. Entsprechend gibt es auch Drucker, die sowohl CDs, DVDs als auch Papier bedrucken können. Praktisch findet dieses Verfahren nur bei Heimanwendern und sehr kleinen Auflagen von gebrannten Medien eine Anwendung.
- *Aufklebe-Label*: Diese Methode ist für den Heimanwender nicht zu empfehlen. Wie bei einem Bimetall wölbt sich die DVD bei Temperaturunterschieden, da sich der Aufkleber und die Polycarbonat-Scheibe unterschiedlich stark ausdehnen. Im Gegensatz zu normalen CDs reichen bei einer DVD schon geringe Verzerrungen aus, dass der Player die Daten nicht mehr lesen kann. Dieser Effekt wird durch die Wärme im Inneren des DVD-Players noch verstärkt, so dass beklebte DVDs häufig erst nach einer gewissen Spieldauer ausfallen. Um dies zu verhindern, sind spezielle DVD-Aufkleber aus Kunststofffolie erhältlich, die sich gleichmäßig mit der Scheibe ausdehnen sollen. Nachteilig ist zudem dass in der Regel durch den Aufkleber eine Unwucht entsteht. In DVD Laufwerken kann diese Unwucht bei hohen Drehzahlen zu einer Ablösung des Aufklebers oder sogar einem Zerreißen der DVD führen.
- *Manuelle Beschriftung*: Mit Folienstiften, CD-Markern und anderen Schreibern für glatte Flächen können DVDs natürlich auch von Hand beschriftet und bemalt werden. Dies ist die günstigste und schnellste Methode. DVDs sind – anders als CDs – recht unempfindlich gegen Stifte, die die Oberfläche verkratzen oder chemisch angreifen, da ihre Datenschicht mittig liegt und somit von einer relativ dicken Kunststoffschicht geschützt ist.
- *Laser-Label*: Beschriftung des Datenträgers durch den Laser direkt im Laufwerk. Dies setzt einen speziellen Brenner und geeignete Rohlinge voraus, die ein solches Verfahren beherrschen.
    - *Lightscribe*: Das erste Laser-Beschriftungssystem hat Hewlett Packard unter dem Namen Lightscribe entwickelt, bei dem eine komplette bronzefarbene Beschriftung je nach Qualitätsstufe zwischen 17 und 32 Minuten dauert.
    - *Labelflash*: An dieses Verfahren anknüpfend, hat Yamaha eine ähnliche Technologie namens Labelflash entwickelt. Auch mit ihr wird der Rohling im Brenner per Laser beschriftet, erzeugt jedoch einen blauen Aufdruck auf der Label-Seite. Die Beschriftungsdauer liegt bei 5 Minuten in der besten Qualität, welche 1000 dpi mit 256 Helligkeitsstufen bietet.
    - Vorteile: Bedrucken auch in mobilen Betrieb, keine zusätzliche Investition für Drucker notwendig, Drucken in mehreren Sessions möglich (Lightscribe)
    - Nachteile: technisch nur monochromer Druck möglich, geringe Qualität (Kontrast/Brillanz), langsamer Druck, teure Rohlinge

DVD-Alternativen und mögliche Nachfolger

- Die MiniDVD ist eine kleine Bauvariante der DVD
- Enhanced Versatile Disc (EVD) – aus *China*
- Finalized Versatile Disc (FVD) – aus *Taiwan*
- Blu-ray Disc (Blu-ray)
- High Density Digital Versatile Disc (HD-DVD) – von der *HD-DVD Promotion Group*
- Professional Disc for Data (PDD) – von *Sony* (Entwicklung eingestellt)
- Professional Disc for Broadcast (PDB) – von *Sony*
- Ultra Density Optical (UDO) – von *Plasmon*

- Holographic Versatile Disc (HVD)
- Protein-basierte DVD – Eine DVD, beschichtet mit dem veränderten Protein Bacteriorhodopsin, die bis zu 50 Terabyte Daten fassen soll (Serienproduktion *NEC* ab 2008).
- Versatile Multilayer Disc (VMD) – chin. Format ohne DRM (Digitale Rechteverwaltung)

Einweg-DVD

Seit Jahren hört man immer wieder in regelmäßigen Abständen von einer neu erfundenen *Einweg-DVD*, welche besonders den Spielfilmverleih von Videotheken revolutionieren soll. Dem Vorteil, dass man diese DVDs der Videothek nicht mehr zurückbringen muss und somit auch Verzugsgebühren kein Thema mehr sind, steht der Nachteil gegenüber, dass das Konzept nicht ökologisch ist. Sobald die DVD aus der luftdichten Hülle entfernt wird und mit Sauerstoff in Berührung kommt, erfolgt eine chemische Reaktion, welche die DVD innerhalb von acht bis 48 Stunden unbrauchbar macht. Nach Ablauf dieser Zeit kann die DVD vom Kunden einfach weggeworfen werden, weswegen diese DVDs auch *Wegwerf-DVDs* genannt werden.

Die Firma Flexplay hat eine solche Einweg-DVD unter dem Namen *EZ-D* herausgebracht. Diese wurde ab September 2003 von Buena Vista Home Entertainment am US-Markt getestet. Es erschienen Datenträger mit einem Film für etwa fünf bis sieben US-Dollar kurz vor der eigentlichen Premiere desselben. Das Produkt fand jedoch nicht genug Käufer, so dass dieses Anfang 2004 bereits wieder aus den Verkaufsregalen verschwand. Ein ähnliches Verfahren hatte auch schon die Firma SpectraDisc zuvor vorgestellt, nach deren Prinzip die Einweg-DVDs jedoch aufgrund von Lichtempfindlichkeit unbrauchbar wurden.

DIVX

Während heutzutage das DivX-Format als Videokompressionsalgorithmus bekannt ist, bezeichnet DIVX eine spezielle Pay-Per-View Variante in den USA, die heute nicht mehr existiert. Im Jahr 1998 kam die Idee auf, zu den damals noch erheblich teureren DVDs eine Billigvariante anzubieten, die 48 Stunden lang abgespielt werden konnte, jede darüber hinausgehende Nutzung war kostenpflichtig. Zur Dekodierung und Abrechnung der Filme wurden spezielle, mit einem Modem ausgestattete Player benötigt, die sich regelmäßig mit einem speziellen Server verbanden, um Abrechnungsdaten zu übertragen.

DIVX benutzte ein MPEG-4-Derivat, welches mit speziellen DIVX-Flags zur Identifizierung und Dekodierung des Films versehen war. Letzten Endes konnte sich das System der DVD gegenüber nicht durchsetzen und endete nach nur einem Jahr als Flop.

Kapitel 4: Bussysteme und Schnittstellen

4.1 Serielle Datenübertragung (Com-Port)

In modernen Rechnsystem gibt es eine Vielzahl von Schnittstellen und einige wichtige Bussysteme. Bei dem Bussystemen kann man zwischen rechnerinterne Bussysteme und rechnerexterne Bussysteme unterscheiden. Rechnexterne Bussysteme, die in unseren Betrachtungen im Vordergrund stehen, dienen dazu, periphere Komponenten an den Rechner anzuschließen. Als einer der wichtigsten Bussysteme der diese forderung erfüllt hat sich der USB-Bus etabliert. Neben diesem seriellen Bus gibt es auch noch eine weitere serielle Schnittstelle, das COM-Port.

Serielle Datenübertragung

- im Rechner vorliegende Daten sind grundsätzlich parallel
- kleinste parallele Einheit → Byte

- Kern jeder seriellen Datenübertragung → zeitlich serielle Übertragung der parallelen Daten mit Wandlung von paralles in serielle und umgekehrt
- Neben den Daten muss das zugehörige Taktsignal bereitstehen
- Behandlung des Taktsignals unterscheidet die verschiedene Arten der seriellen Datenübertragung

    - Asynchrone serielle Datenübertragung
        A) nur Übertragung von Daten
        B) Taktsignal wird von zwei unabhängigen Taktgenaratoren bereitgestellt
        C) Typisches Beispiel → COM-Port

- Synchrone serielle Datenübertragung
  A) Übertragung von Daten und Taktsignalen
  B) Typisches Beispiel → serielle Schnittselle bei Mikrocontroller
- Serielle Datenübertragung mit Taktrückgewinnung
  A) Übertragung von Daten
  B) Typisches Beispiel USB-Bus, CAN-Bus

Asynchrone serielle Datenübertragung

Die **Asynchrone Datenübertragung** ist ein Verfahren der Nachrichtentechnik, seine Anwendung ist im Standard UIT 34.13 geregelt.

Bei diesem Verfahren wird der Gleichlauf zwischen Sender und Empfänger nur für die Dauer eines Zeichens hergestellt und aufrechterhalten. Das Verfahren wird auch Start-Stop-Verfahren genannt. Bedingt durch die Zeit, die für das Erreichen des Gleichlaufs jedesmal erforderlich ist, ist die Bitrate geringer als bei der synchronen Datenübertragung.

Die einzelnen Zeichen werden seriell, das heißt bitweise übertragen. Die Übertragung erfolgt assynchron. Das heißt, der vom Sender verwendete Schiebetakt wird nicht synchron mitübertragen. Im Empfänger muß der Takt aus den Daten zurückgewonnen werden. Dies geschieht mit einem Digital Phase Loocked Loop (DPLL), das mit den Flanken aus RxD synchronisiert wird.

Es wird zeichenweise übertragen. Zwischen den Zeichen wird kein Synchronisiersignal gesendet. Bei jedem Zeichen muß das DPLL im Empfänger deshalb neu synchronisiert werden. Dies wird durch Start- und Stopbits sichergestellt.

In Ruhe (kein Zeichen wird gesendet) ist TxD high (entspricht TxD = -12V an der Schnittstelle). Wird ein Zeichen übertragen, so wird zunächst als Startbit eine 0 ausgegeben (der Empfänger erkennt nun eine Flanke und synchronisiert seinen Empfänger-Schiebetakt darauf). Darauf folgen die Datenbits (5 bis 8 Bits, je nach Mode). Den Datenbits kann noch ein Paritätsbit folgen (außer bei none Parity). Am Schluß werden 1, 1,5 oder 2 Stopbits gesendet. Danach kann sofort das nächste Zeichen folgen. Die Stopbits sind nötig, damit TxD vor dem nächsten Startbit eine minimale Zeit high ist, um das Startbit erkennen zu können.

```
     ---|---+    +---------+         +----+    +----+    +---------|-----
            |    |         |         |    |    |    |    |         |
TxD         |    |         |         |    |    |    |    |         |
            |    |         |         |    |    |    |    |         |
            +----+         +---------+    +----+    +----+         |

            |    | d0 | d1 | d2 | d3 | d4 | d5 | d6 | p  |    |    |
            |    |                                     |    |         |
            Start          7 Datenbits              Parity  2 Stop
```

Beispiel für Übertragung des Zeichens 'S' mit 7 Datenbits, even Parity und 2 StopBits (an der Schnittstelle liegen bei einer logischen 1 in TxD -12V).

Das Low-Bit des Zeichens wird zuerst übertragen. Werden nur Zeichen des Standart-ASCI Codes übertragen, so genügt es, mit 7 Datenbits zu senden. Beim erweiterten ASCI Code sind 8 Datenbits nötig. 5 und 6 Datenbits werden beim PC kaum verwendet.

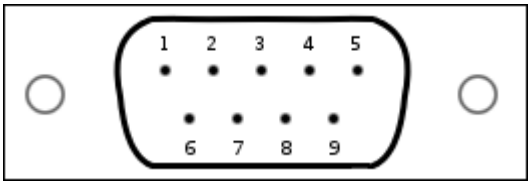

1. DCD
2. RxD
3. TxD
4. DTR
5. Masse
6. DSR
7. RTS 7
8. CTS 8

PIN	***Bedeutung***
TxD	Serielle Sendedaten (transmit data)
RxD	Serielle Empfangsdaten (receice data)
CTS	Senderfreigabe (clear to send)
RTS	Sendeteil einschlaten (request to send)
DSR	Betriebsbereitschaft eines Modem (data set ready)
DTR	Datendeinrichtung bereit (data terminal ready)
GND	Massenverbindung

Der Universal Serial Bus (USB)

ist ein serielles Bussystem zur Verbindung eines Computers mit externen Geräten. Mit USB ausgestattete Geräte oder Speichermedien können im laufenden Betrieb miteinander verbunden *(Hot-Plugging)* und angeschlossene Geräte und deren Eigenschaften automatisch erkannt werden.

USB-Symbol (Zertifizierung nicht notwendig)

Moderne Computer haben meist eine große Anzahl von USB-Schnittstellen; stehen zu wenig USB-Anschlüsse zur Verfügung, kann man über Hubs bis zu 127 USB-Geräte an einer Schnittstelle betreiben, wobei zu beachten ist, dass jeder Hub auch eines der Geräte darstellt.

USB eignet sich für viele Geräte wie Massenspeicher (etwa Festplatte, Diskette, DVD-Laufwerk), Drucker, Scanner, Webcams, Maus, Tastatur, aber auch Dongles. Einige Geräte, zum Beispiel USB-Speichersticks, sind überhaupt erst mit USB entstanden. USB kann für Geräte mit geringem Stromverbrauch wie Mäuse, Telefone, Tastaturen, aber auch einige CIS-Scanner oder manche 2,5″-Festplatten die Stromversorgung übernehmen, wobei in einigen Fällen spezielle Anschlusskabel eingesetzt werden, die die Stromversorgung auf zwei USB-Anschlüsse aufteilen.

Seit der Einführung der USB-2.0-Spezifikation sind relativ hohe Datenübertragungsraten möglich, dadurch ist USB zum Anschluss weiterer Gerätearten wie Festplatten, TV-Schnittstellen und Foto-Kameras geeignet. USB ersetzt zunehmend ältere serielle und parallele Anschlüsse, aber auch PCI-Bussysteme und PCMCIA-Slots.

Die USB-Schnittstelle hat die SCSI-Schnittstelle bei vielen externen Geräten, wie beispielsweise Scannern, weitgehend abgelöst, steht unter anderem bei externen Massenspeicherlösungen jedoch in Konkurrenz zu iSCSI, FireWire und eSATA.

USB ist ein bitserieller Bus, die einzelnen Bits des Datenpaketes werden also nacheinander übertragen. Die Datenübertragung erfolgt differentiell über zwei verdrillte Leitungen, die eine überträgt das Datensignal unverändert, die andere das invertierte Signal. Der Signalempfänger bildet die Differenzspannung beider Signale; der Spannungshub zwischen 1- und 0-Pegeln ist dadurch doppelt so groß. Das erhöht die Übertragungssicherheit, unterdrückt Gleichtaktstörungen und verbessert damit die elektromagnetische Verträglichkeit.

Zwei weitere Leitungen dienen zur Stromversorgung der angeschlossenen Geräte. Durch die Verwendung von nur vier Adern in einem Kabel können diese dünner und preiswerter als bei parallelen Schnittstellen ausgeführt werden. Eine hohe Datenübertragungsrate ist mit relativ geringem Aufwand zu erreichen, da nicht mehrere Signale mit identischem elektrischen und zeitlichen Verhalten übertragen werden müssen.

Die Bus-Spezifikation sieht einen zentralen Host-Controller (den sogenannten *Master*) vor, der die Koordination der angeschlossenen Peripherie-Geräte (den sog. Slave-Clients) übernimmt. Daran können bis zu 127 verschiedene Geräte angeschlossen werden. An einen USB-Port kann immer nur ein USB-Gerät angeschlossen werden. Wenn an einen Host mehrere Geräte angeschlossen werden sollen, muss deshalb ein Verteiler (Hub) für die Kopplung dieser Geräte sorgen. Durch den Einsatz von Hubs entstehen Baumstrukturen, die alle im Host-Controller enden.

Der USB ersetzt die älteren PC-Schnittstellen RS-232 (seriell), Gameport, die Centronics-Schnittstelle sowie die PS/2-Schnittstelle für Tastatur und Maus. Im Vergleich zu diesen bietet USB deutlich höhere Datenübertragungsraten. USB überträgt seine Daten jedoch in Paketen, für manche zeitkritische Anwendungen ist er deshalb weniger geeignet – etwa bei nur mit wenigen Bytes belegten Paketen, die die Übertragungsrate senken, oder wenn das Sammeln von Bytes zum Füllen eines Pakets die Übertragung verzögern würde.

Trotz seines Namens – Universal Serial *Bus* – ist der USB kein physischer Datenbus. Bei einem solchen werden mehrere Geräte parallel an eine Leitung angeschlossen. Die Bezeichnung „Bus“ bezieht sich auf die logische Vernetzung, die tatsächliche elektrische Ausführung erfolgt nur mit Punkt-zu-Punkt-Verbindungen.

Geschichte und Entwicklung

Den universellen seriellen Bus *(USB 1.0)* entwickelte Intel, die Markteinführung erfolgte 1996. Der Bus war zum Anschluss von Peripheriegeräten an den PC konzipiert. Er sollte die Nachfolge einer ganzen Reihe damals verwendeter PC-Schnittstellen antreten und diese vereinheitlichen. Deshalb war die USB-Spezifikation nicht auf Tastatur und Maus begrenzt, sondern schloss auch andere Peripheriegeräte wie Drucker und Scanner mit ein. Massenspeicher – wie etwa Festplatten – wurden bereits von USB 1.0 unterstützt, aufgrund der maximalen Datenrate von 12MBit/s war die Brauchbarkeit aber relativ eingeschränkt.

Intel war Vorreiter bei der Markteinführung. Als erste Chipsätze unterstützten 1997 die Intel-Produkte *430HX* und *430VX* das USB-Protokoll. 1998 wurde die Schnittstelle mit der Entwicklung des iMac bei der Firma Apple eingeführt. Bei diesem Computer ersetzte Apple den hauseigenen ADB durch den USB – damit war die systemübergreifende Akzeptanz dieser Schnittstelle etabliert.

altes USB-Logo, das nicht mehr verwendet werden soll

Ab Ende 1998 folgte die überarbeitete Spezifikation *USB 1.1*, die in erster Linie Fehler und Unklarheiten in der 1.0-Spezifikation behob und den *Interrupt Out Transfer* hinzufügte. Die Geschwindigkeit erhöhte sich nicht. USB 1.x stellte deshalb keine Konkurrenz zu Apples FireWire-Standard *(IEEE 1394)* dar, der von Anfang an (1995) eine Datenrate von bis zu 400 MBit/s bot und im April 2003 auf bis zu 3200 MBit/s beschleunigt wurde.

Im Jahr 2000 folgte die Spezifikation für *USB 2.0*, die vor allem die Datenrate auf bis zu 480 MBit/s (60 MByte/s) erweiterte und so den sinnvollen Anschluss von Festplatten oder Videogeräten ermöglichte. Produkte dafür erschienen jedoch erst ab 2002 am Markt. Zu beachten ist hierbei allerdings, dass pro Anschluss nur max. 500 mA (High Power) oder 100 mA (Low Power) zur Verfügung stehen. Das reicht aber für externe Festplatten meist nicht aus, weswegen oft ein externes Netzteil benötigt wird. Aktuelle 2,5″-Festplatten benötigen zum Beispiel einen Startstrom, der über einem Ampere liegt und daher auch bei Anschluss der Festplatte über 2 USB-Ports außerhalb der Spezifikation liegt.

USB-Stecker und -Kabel

USB-Stecker

USB-Stecker Typ A

Verschiedene USB-Stecker. Von links nach rechts: Typ A, Typ B, Typ Mini-B 5-polig (Standard), Typ Mini-B 4-polig (Mitsumi), Typ Mini-B 4-polig (Aiptek)

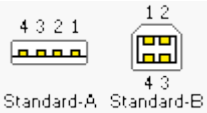

USB-Standardstecker Typ A und B. Nicht maßstabsgetreu, mit Pinnummern, Draufsicht

USB-Ministecker Typ A und B. Nicht maßstabsgetreu, mit Pinnummern, Draufsicht. Es gibt noch Mini-AB Buchsen welche sich automatisch umschalten.

Die Stecker eines USB-Kabels sind verpolungs- und vertauschungssicher gestaltet. In Richtung des Hostcontrollers *(Upstream)* werden flache Stecker *(Typ A „DIN IEC 61076-3-107“)* verwendet. Zum angeschlossenen Gerät hin *(Downstream)* werden die Kabel entweder fix montiert oder über annähernd quadratische Stecker *(Typ B „DIN IEC 61076-3-108“)* angeschlossen, vereinzelt auch mit Typ A-Steckern. Für Geräte mit geringerem Platzangebot (z. B. digitale Kameras) existieren auch kompaktere Steckervarianten, die Mini-USB-Stecker. Derer gibt es je nach Gerätehersteller verschiedene Bauformen mit verschieden vielen Anschlusspins (bis zu 8, siehe Bild). Im USB-Standard verankert ist lediglich der fünfpolige, entfernt dachähnliche Stecker (auf dem Foto in der Mitte abgebildet).

Für den industriellen Einsatz gibt es noch (nicht offiziell standardisierte) USB-12-V und USB-24-V, bei denen neben dem USB-Typ-A-Stecker die Spannungsversorgung mitgeführt wird. Diese Stecker sehen nicht rechteckig aus, sondern mehr quadratisch (wie zwei Stecker in einem gemeinsamen Gehäuse, der USB-Teil ist unverändert USB Typ A). Mittels eines außen angebrachten

Verpolungsschutzes wird verhindert, dass USB-12-V-Stecker in USB-24-V-Buchsen gesteckt werden können.

Speziell für Mobiltelefone und andere mobile Geräte wurde mit Micro-USB im Januar 2007 ein noch kleinerer Stecker vorgestellt. Dieser ermöglicht so eine besonders kompakte Bauform. Die Micro-USB-Spezifikation kann USB On-The-Go (OTG) unterstützen, was Verkabelung und Kommunikation auch ohne PC als Host ermöglicht.[1]

USB-Kabel

USB-Verlängerungskabel (nicht in der USB-Spezifikation)

In einem USB-Kabel werden vier Adern benötigt. Zwei Adern übertragen dabei die Daten, die anderen beiden versorgen das angeschlossene Gerät mit einer Spannung von 5 V. Der USB-Spezifikation entsprechende Geräte dürfen bis zu 100 mA oder 500 mA aus dem Bus beziehen, abhängig davon wie viel der Port liefern kann, an den sie angeschlossen werden. Geräte mit einer Leistung von bis zu 2,5 W können also über den Bus mitversorgt werden.

Die Kabel müssen je nach Geschwindigkeit unterschiedlich abgeschirmt werden. Kabel, die lediglich der Spezifikation *low speed* entsprechen, dürfen über keinen B-Stecker verfügen, sondern müssen fix am Gerät montiert sein oder einen herstellerspezifischen Stecker verwenden. Der Grund dafür ist, dass die geringe Abschirmung des Kabels zu Problemen bei Geräten mit höheren Geschwindigkeiten führen kann.

Die Länge eines Kabels vom Hub zum Gerät ist auf fünf Meter begrenzt. Low-Speed-Kabel werden von der Spezifikation auf drei Meter beschränkt, das ist technisch jedoch unbegründet und wird voraussichtlich in einer zukünftigen Fassung der Spezifikation entfallen. Die Spezifikation schließt Verlängerungen aus. Trotzdem werden diese angeboten und bei vielen USB-Geräten mitgeliefert. Längere Strecken kann man überwinden, indem USB-Hubs zwischengeschaltet werden. Sogenannte *Aktive USB-Verlängerungskabel* entsprechen in ihren Funktionen einem *Bus-Powered-Hub* (s. u.) mit einem einzigen Downstream-Port und einem fest angeschlossenen Kabel am Upstream-Port. Da die elektrischen Auswirkungen dieser Kabel im USB-Bus denen eines Bus-Powered USB-Hubs mit fünf Meter Kabel entsprechen, sollten bei ihrer Verwendung zusätzlich die Beschränkungen beim Verschachteln von USB-Hubs beachtet werden.

USB arbeitet mit einem differentiellen Widerstand von 90 Ω, direkte Verbindungskabel sollten daher auch in diesem Wellenwiderstandswert ausgeführt sein.

Keine echte Alternative zum Überbrücken von Längen über 30 Metern sind die sogenannten USB-Line-Extender. Ein USB-Line-Extender besteht aus zwei Komponenten: einem Base-Modul, welches an den Computer angeschlossen wird, und einem Remote-Modul für den Anschluss des USB-Gerätes. Zur Distanzüberbrückung zwischen diesen beiden Komponenten werden meist Ethernetkabel oder Lichtleiter eingesetzt. Da sich diese Line-Extender jedoch immer auf bestimmte, nicht vom Standard vorgeschriebene Verhaltensdetails der angeschlossenen Geräte verlassen und zudem bei langen Kabelstrecken die Signallaufzeit zu Protokollverletzungen führt, sind derartige Geräte nicht empfehlenswert.

Eine bessere Möglichkeit, USB-Geräte weiter entfernt vom Rechner anzuschließen, sind Lösungen, die einen "remote host" verwenden, also einen USB-Hostcontroller, der außerhalb des PCs liegt. Dabei geschieht die Kommunikation zwischen PC und Hostcontroller z.B. über Ethernet, das Ethernet ersetzt dabei den lokalen Bus, an dem sonst der Hostcontroller angeschlossen wäre. Auf dem PC muss also nur ein entsprechender Treiber installiert werden, der die Kommunikation mit dem Hostcontroller übernimmt, alle Treiber für die USB-Geräte erkennen dann keinen Unterschied zu einem lokal angeschlossenen Gerät. Ein Beispiel für ein solches Gerät ist der USB-Server von Keyspan.

Farbcodierung und Pinouts

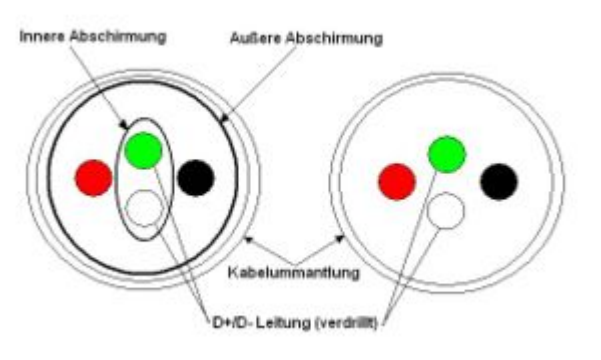

Adernkodierung von USB-Kabeln

Der USB-Standard legt neben der Belegung der Schnittstelle auch die Namen der einzelnen Stecker-Pins und die Adernfarbe fest. Die Nummer eines Stecker-Pins kann in den oben angeführten Schemazeichnungen abgelesen werden.

Ministecker			
Pin	**Name**	**Farbe**	**Beschreibung**
1	VCC	Rot	+5 V
2	D−	Weiß	Data −
3	D+	Grün	Data +
4	ID	keine	erlaubt Unterscheidung von Mini-A- und Mini-B-Stecker Typ-A GND, Typ-B N/C
5	GND	Schwarz	Masse

Standardstecker

Pin	Name	Farbe	Beschreibung
1	VCC	Rot	+5 V
2	D−	Weiß	Data −
3	D+	Grün	Data +
4	GND	Schwarz	Masse

Geschwindigkeiten und Datenraten

Logo für USB-LowSpeed- oder -FullSpeed-zertifizierte Geräte

Logo für USB-HighSpeed-zertifizierte Geräte

USB erlaubt es einem Gerät, mit 1,5 Mbit/s (**Low Speed**), 12 Mbit/s (**Full Speed**) oder mit 480 Mbit/s (**High Speed**, ab USB 2.0 verfügbar) Daten zu übertragen. Diese Raten basieren auf dem Systemtakt der jeweiligen USB-Geschwindigkeit und stellen die physikalische Datenübertragungsrate dar. Die tatsächlich nutzbare Datenrate liegt – z. B. durch Protokoll-Overhead – darunter; bei aktuellen Systemen in der Größenordnung von 320 Mbit/s.

Wird die Schnittstelle eines Geräts mit „USB 2.0“ angegeben, heißt das nicht unbedingt, dass dieses Gerät auch die hohe Datenrate von 480 MBit/s anbietet. Standpunkt der Anbieter ist dabei, dass ein USB-2.0-kompatibles Gerät grundsätzlich jede der drei Geschwindigkeiten benutzen kann und die 2.0-Kompatibilität in erster Linie bedeutet, dass die neueste Fassung der Spezifikation eingehalten wird. 480 MBit/s dürfen also nur erwartet werden, wenn ein Gerät mit dem Logo „*Certified USB Hi-Speed*“ ausgezeichnet ist.

Die Kommunikation bei USB wird vom Hostcontroller gesteuert, der in der Regel im PC sitzt. Nur dieser kann Daten von einem Gerät lesen oder zu einem Gerät senden. Ein Gerät darf nur dann Daten zum Hostcontroller senden, wenn es von diesem abgefragt wird. Bei zeitkritischen Datenströmen, wie etwa bei Mausbewegungen, muss sich der Hostcontroller häufig genug beim Gerät erkundigen, ob es Daten senden will, um ein Ruckeln zu verhindern.

Eine direkte Kommunikation zwischen USB-Geräten ist gemäß dem USB-Standard eigentlich nicht möglich; dies wurde erst durch die Erweiterung *USB On-the-go* gewissermaßen ermöglicht (die Geräte können hier wahlweise Host oder Endgerät sein, ein echter bidirektionaler Austausch ist damit aber nicht möglich). Der FireWire-Standard, der für ähnliche Einsatzzwecke wie USB geschaffen wurde und mit diesem in Konkurrenz steht, bietet im Gegensatz zu USB die Möglichkeit einer Peer-to-

Peer-Kommunikation zwischen Geräten, ohne dass die Steuerung durch einen Host erforderlich ist. Somit ist über FireWire etwa der Aufbau eines Netzwerks möglich.

Software-Architektur

Alle USB-Transaktionen werden durch die USB-Software auf dem Host-Computer realisiert. Dies geschieht durch den jeweiligen USB-Gerätetreiber, der mit seinem Gerät kommunizieren will. Der USB-Bustreiber ist die Schnittstelle zwischen dem USB-Gerätetreiber und dem USB-Host-Controller.

USB-Gerätetreiber

Die Aufgabe des USB-Gerätetreibers (USB device driver) ist die Erzeugung von Anfragen (Requests) an den USB-Bustreiber. Für eine Anfrage werden I/O-Request-Packets (IRP) verwendet. Diese IRPs initiieren einen Transfer von oder zu USB-Geräten (z. B. Interrupt-Transfer der Tastatur durch Erzeugung eines entsprechenden IRP auslösen).

USB-Bustreiber

Der USB-Bustreiber (USB-Driver) kennt die spezifischen Kommunikationseigenschaften der einzelnen USB-Geräte, zum Beispiel die Datenmenge pro Frame oder Abstände zwischen den periodischen Zugriffen. Diese Eigenschaften erkennt der USB-Bustreiber beim Analysieren der Geräte-Deskriptoren während der Konfigurationsphase. Wenn der USB-Bustreiber ein IRP von einem USB-Gerätetreiber erhält, erzeugt er entsprechend diesem Request einzelne Transaktionen, die innerhalb des Übertragungsrahmens (Frame) von einer Millisekunde ausführbar sind.

USB-Host-Controller-Treiber

Der USB-Host-Controller-Treiber (Host controller driver) organisiert die zeitliche Abfolge der einzelnen Transaktionen (Scheduling). Dazu baut der USB-Host-Controller-Treiber eine Folge von Transaktionslisten auf. Jede dieser Listen besteht aus den noch nicht abgearbeiteten Transaktionen in Richtung eines Gerätes, welches am Bus angeschlossen ist. Sie definiert die Reihenfolge der Transaktionen innerhalb des 1-ms-Zeitrahmens. Der USB-Bustreiber kann eine einzelne Anfrage für einen Datentransfer in mehrere Transaktionen zerlegen. Das Scheduling hängt von einer Reihe von Einflussfaktoren wie Transferart, Geräteeigenschaften und Busbelastung ab. Der USB-Host-Controller-Treiber löst die Transaktionen dann über den Root-Hub aus. Dieser setzt der Reihe nach alle Transaktionen um, die in der aktuellen Liste enthalten sind.

USB-Hubs

Allgemeines

4-Port-USB-Hub mit eigener Stromversorgung *(self powered)*

4-Port-USB-Hub mit Stromversorgung aus dem Bus *(bus powered)*

Ein USB-Hub ist eine spezielle Art von USB-Gerät, welches das USB-Signal an zusätzliche Ports zum Anschluss von weiteren Geräten weiterleitet. Handelsüblich sind USB-Hubs mit bis zu sieben Downstream-Ports.

Hubs können ihren Strom aus dem Bus selbst beziehen *(Bus-Powered)*, oder über eine eigene Stromversorgung verfügen *(Self-Powered)*. Die meisten Self-Powered Hubs werden über ein Steckernetzteil mit Strom versorgt. Manche Monitore haben auch einen USB-Hub eingebaut, die über die Stromversorgung des Monitors mitgespeist werden. Self-Powered Hubs haben den Vorteil, dass jedes an sie angeschlossene Gerät bis zu 500 mA Strom beziehen kann. Bei Bus-Powered Hubs dürfen der Hub und alle an ihn angeschlossenen Geräte gemeinsam maximal 500 mA beziehen. Hybride Self- und Bus-Powered Hubs sind möglich – der Hub ist dann Self-Powered, wenn ein Netzteil an ihn angeschlossen ist und ansonsten Bus-Powered. Manchmal werden Bus-Powered Hubs auch als „passiv“ und Self-Powered Hubs als „aktiv“ bezeichnet, dies ist technisch jedoch falsch.

Bei der Verschachtelung von Hubs werden die Grenzen durch die maximal 127 möglichen USB-Geräte und durch die Signallaufzeit festgelegt – jeder Hub erhöht die Laufzeit, die Verschachtelungstiefe ist auf maximal fünf (Hub-)Ebenen unterhalb des Hostcontrollers bzw. des Root-Hubs begrenzt. Die maximale Distanz zwischen zwei mit USB verbundenen Geräten liegt wegen der Beschränkung von 5 m pro USB-Kabel bei 30 m – sechs Kabel mit je fünf Metern Länge und dazwischen fünf Hubs.

USB 2.0 und Hubs

Low-, Full- und High-Speed-Geräte lassen sich an einem USB-2.0-Host fast beliebig mischen, ohne dass Geschwindigkeitsnachteile entstehen. Hubs nach dem USB-1.x-Standard können an USB-2.0-Hosts verwendet werden. Geräte, die direkt oder indirekt an einen solchen Hub angeschlossen werden, können allerdings lediglich die Geschwindigkeit *Full Speed* erreichen, also 12 MBit/s.

Ein USB-2.0-Host und ein USB-2.0-Hub kommunizieren immer mit High Speed, selbst wenn an dem Hub Low- oder Full-Speed-Geräte angeschlossen sind. Es ist Aufgabe des Hubs, die Daten dieser Geräte in das High-Speed-Protokoll zu verpacken, der Hub hat dazu einen oder mehrere sogenannte „Transaction Translators“ eingebaut. Die Anzahl der Transaction Translators bestimmt, wie viele langsame Geräte an einen USB-2.0-Hub angeschlossen werden können, ohne sich gegenseitig auszubremsen. Werden an einen Host mehr langsame Geräte angeschlossen als Transaction Translators verfügbar sind, so bricht die Datenrate aller an diesen Host angeschlossenen Low-Speed- und Full-Speed-Geräte auf Geschwindigkeiten deutlich unter denen eines USB-1.1-Hosts ein; der Durchsatz von High-Speed-Geräten am selben Hub bleibt hierdurch jedoch unbeeinflusst. An der Spezifikation des Stromverbrauchs hat sich bei USB-2.0 im Vergleich zu USB-1.1 jedoch nichts geändert.

Die verschiedenen Host-Controller

Die USB-Controller-Chips in den PCs halten sich an einen von drei etablierten Standards. Diese unterscheiden sich jeweils in ihrer Leistungsfähigkeit und der Implementierung von bestimmten Funktionen – entweder erledigt sie der Chip von selbst, „in Hardware“, oder der Gerätetreiber muss softwareseitig dafür sorgen. Für ein USB-Gerät sind die verwendeten Controller (fast) vollständig transparent, allerdings ist es für den Benutzer des PC mitunter wichtig, feststellen zu können, welche Art Chip der Rechner verwendet, um den korrekten Treiber auswählen zu können.

- **Universal Host Controller Interface** (UHCI) wurde im November 1995 von Intel spezifiziert. Die aktuelle Version des Dokuments trägt die Revisionsnummer 1.1, daher nennen sich auch alle gegenwärtigen USB-Geräte USB-1.1-kompatibel. UHCI-Chips bieten Unterstützung für USB-Geräte mit 1,5 oder 12 MBit/s Bandbreite. Sie werden ausschließlich von den Herstellern Intel und VIA Technologies gebaut.
- **Open Host Controller Interface** (OHCI) ist eine Spezifikation, die gemeinsam von Compaq, Microsoft und National Semiconductor entwickelt wurde. Version 1.0 des Standards wurde im Dezember 1995 veröffentlicht, die aktuelle Fassung trägt die Versionsnummer 1.0a und stammt von September 1999. Ein OHCI-Controller hat prinzipiell die gleichen Fähigkeiten wie seine UHCI-Pendants, erledigt aber mehr Aufgaben in Hardware und ist dadurch marginal schneller als ein UHCI-Controller. Dieser Unterschied bewegt sich meistens in Bereichen, die gerade noch messbar sind, daher kann man dies in der Benutzung vernachlässigen; Geräteentwickler müssen dies jedoch berücksichtigen. Bei den USB-Controllern auf Hauptplatinen, die nicht von Intel oder VIA stammen, handelt es sich mit großer Wahrscheinlichkeit um OHCI.
- Das **Enhanced Host Controller Interface** (EHCI) stellt die USB-2.0-Funktionen bereit. Das EHCI wickelt dabei nur die Übertragungen im Hi-Speed-Modus (480 MBit/s) ab. Wenn man USB-1.1-Geräte an einen Port mit EHCI-Chip steckt, reicht der EHCI-Controller den Datenverkehr an einen hinter ihm liegenden UHCI- oder OHCI-Controller weiter (diese Controller sind typischerweise auf demselben Chip). Wenn kein EHCI-Treiber verfügbar ist, werden die High-Speed-Geräte ebenfalls an den USB-1.1-Controller durchgereicht und arbeiten dann mit langsamerer Geschwindigkeit, sofern dies überhaupt möglich ist.

Einstellungen und Schnittstellen

Intern adressiert der USB-Controller die angeschlossenen Geräte mit einer sieben Bit langen Kennung, wodurch sich die 127 maximal anschließbaren Geräte ergeben. Die Adresse 0 wird automatisch von Geräten belegt, die ein Reset-Signal erhalten. Wenn an einem oder mehreren Ports neue Geräte detektiert werden, so schaltet der Host-Controller einen dieser Ports ein, sendet dem dort angeschlossenen Gerät einen Reset und versucht dann, das Gerät zu identifizieren. Danach teilt er dem Gerät eine eindeutige Adresse mit. Da immer nur ein Port mit noch nicht konfiguriertem Gerät aktiviert wird, kommt es zu keinen Adresskollisionen.

Der Host-Controller fragt meist zuerst nach einem *Device-Deskriptor*, der unter anderem die Hersteller- und Produkt-ID enthält. Mit weiteren Deskriptoren teilt das Gerät mit, welche alternativen Konfigurationen es besitzt, in die es von seinem Gerätetreiber geschaltet werden kann. Bei einer Webcam könnten diese Alternativen etwa darin bestehen, ob die Kamera eingeschaltet ist oder ob nur das Mikrofon läuft. Für den Controller ist dabei relevant, dass die unterschiedlichen Konfigurationen auch einen unterschiedlichen Strombedarf mit sich bringen. Ohne besondere Freigabe durch das Betriebssystem darf ein Gerät nicht mehr als 100 mA Strom verbrauchen.

Innerhalb einer Konfiguration kann das Gerät verschiedene Schnittstellen definieren, welche jeweils über einen oder mehrere Endpunkte verfügen. Unterschiedlicher Bedarf an reservierter Bandbreite wird über so genannte *Alternate Settings* signalisiert. Ein Beispiel dafür ist eine Kamera (etwa eine Webcam), die in zwei verschiedenen Auflösungen Bilder senden kann. Das Alternate Setting 0 wird aktiviert, wenn ein Gerät keine Daten übertragen möchte und somit pausiert.

Geräteklassen

Damit nicht für jedes Gerät ein eigener Treiber nötig ist, definiert der USB-Standard verschiedene Geräteklassen, die sich durch generische Treiber steuern lassen. Auf diese Weise sind USB-Tastaturen, -Mäuse, USB-Massenspeicher und andere Geräte mit ihren grundlegenden Funktionen sofort startklar, ohne dass erst ein Treiber installiert werden müsste. Herstellerspezifische Erweiterungen (die dann einen eigenen Treiber erfordern) sind möglich. Die Information, zu welchen Geräteklassen sich ein Gerät zählt, kann im Device-Deskriptor (wenn das Gerät nur einer Klasse angehört) oder in einem Interface-Deskriptor (bei Geräten, die zu mehreren Klassen gehören) untergebracht werden.

Übertragungsmodi

Der USB bietet den angeschlossenen Geräten verschiedene Übertragungsmodi, die diese für jeden einzelnen Endpunkt festlegen können.

Endpunkte

USB-Geräte verfügen über eine Anzahl von durchnummerierten „Endpunkten“, gewissermaßen Unteradressen des Gerätes. Die Endpunkte sind in den Geräten hardwareseitig vorhanden und werden von der USB SIE (Serial Interface Engine) bedient. Über diese Endpunkte können voneinander unabhängige Datenströme laufen. Geräte mit mehreren getrennten Funktionen (z. B. Webcams, die Video und Audio übertragen) haben mehrere Endpunkte. Die Übertragungen von und zu den Endpunkten erfolgen meist unidirektional, für bidirektionale Übertragungen ist deshalb ein *IN*- und ein *OUT*-Endpunkt erforderlich (IN und OUT beziehen sich jeweils auf die Sicht des Hostcontrollers). Eine Ausnahme davon sind Endpunkte, die den sogenannten *Control Transfer Mode* verwenden.

In jedem USB-Gerät muss ein Endpunkt mit Adresse 0 vorhanden sein, über den die Erkennung und Konfiguration des Gerätes läuft, darüber hinaus kann er auch noch weitere Funktionen übernehmen. Endpunkt 0 verwendet immer den Control Transfer Mode.

Ein USB-Gerät darf maximal 31 Endpunkte haben: Den Control-Endpunkt (der eigentlich zwei Endpunkte zusammenfasst) und je 15 In- und 15 Out-Endpunkte. Low-Speed-Geräte sind auf Endpunkt 0 plus maximal zwei weitere Endpunkte im Interrupt Transfer Mode mit maximal 8 Bytes pro Transfer beschränkt.

Isochroner Transfer

Der isochrone Transfer ist für Daten geeignet, die eine garantierte Bandbreite benötigen. Diese Transferart steht für Full-Speed- und High-Speed-Geräte zur Verfügung. Definiert das Alternate Setting einen Endpunkt mit isochronem Transfer, so reserviert der Host-Controller-Treiber die erforderliche Bandbreite. Steht diese Bandbreite nicht zur Verfügung, so schlägt die Aktivierung des Alternate Settings fehl, und es kann mit diesem Gerät keine isochrone Kommunikation aufgebaut werden.

Die erforderliche Bandbreite ergibt sich aus dem Produkt des Abfrageintervalls und der Größe des Datenpuffers. Full-Speed-Geräte können jede ms bis zu 1023 Bytes je isochronem Endpunkt übertragen (1023 kByte/s), High-Speed-Geräte können bis zu drei Übertragungen je Micro-Frame (125 µs) mit bis zu 1024 Bytes ausführen (24 MByte/s). Stehen in einem Gerät mehrere isochrone Endpunkte zur Verfügung, erhöht sich die Datenrate entsprechend. Die Übertragung ist mit einer Prüfnummer (CRC16) gesichert, wird aber bei einem Übertragungsfehler durch die Hardware nicht wiederholt. Der Empfänger kann erkennen, ob die Daten korrekt übertragen wurden. Isochrone Übertragungen werden z. B. von der USB-Audio-Class benutzt, die bei externen USB-Soundkarten Verwendung findet.

Interrupt-Transfer

USB-Maus für Notebooks

Interrupt-Transfers dienen zur Übertragung von kleinen Datenmengen, die zu nicht genau bestimmbaren Zeitpunkten verfügbar sind. Im Endpoint Descriptor teilt das Gerät mit, in welchen maximalen Zeitabständen es nach neuen Daten gefragt werden möchte. Das kleinstmögliche Abfrageintervall beträgt bei Low-Speed 10 ms, bei Full-Speed 1 ms und bei High-Speed bis zu drei Abfragen in 125 µs. Bei Low-Speed können pro Abfrage bis zu 8 Byte, bei Full-Speed bis zu 64 Byte und bei High-Speed bis zu 1024 Byte übertragen werden. Daraus ergeben sich maximale Datenraten von 800 Byte/s bei Low-Speed, 64 kByte/s bei Full-Speed und bis zu 24 MByte/s bei High-Speed. Die Daten sind mit einer Prüfnummer (CRC16) gesichert und werden bei Übertragungsfehlern bis zu drei mal durch die Hardware wiederholt. Geräte der HID-Klasse (Human Interface Device), zum Beispiel Tastaturen, Mäuse und Joysticks, übertragen die Daten über den Interrupt Transfer.

Bulk-Transfer

Bulk-Transfers sind für große Datenmengen gedacht, die jedoch nicht zeitkritisch sind. Diese Transfers sind niedrig priorisiert und werden vom Controller durchgeführt, wenn alle isochronen und Interrupt-Transfers abgeschlossen sind und noch Bandbreite übrig ist. Bulk-Transfers sind durch eine Prüfnummer (CRC16) gesichert und werden durch die Hardware bis zu dreimal wiederholt. Low-Speed-Geräte können diese Transferart nicht benutzen. Full-Speed-Geräte benutzen Puffer-Größen von 8, 16, 32 oder 64 Bytes. High-Speed-Geräte verwenden immer einen 512 Byte großen Puffer.

Control-Transfer

Control-Transfers sind eine besondere Art von Datentransfers, die einen Endpunkt erfordern, der sowohl In- als auch Out-Operationen durchführen kann. Control-Transfers werden generell in beide Richtungen bestätigt, so dass Sender und Empfänger immer sicher sein können, dass die Daten auch angekommen sind. Daher wird der Endpunkt 0 im Control-Transfer-Modus verwendet. Control-Transfers sind zum Beispiel nach dem Detektieren des USB-Geräts und zum Austausch der ersten Kommunikation elementar wichtig.

Unterstützung in den Betriebssystemen

- Mac OS unterstützt USB 1.1 ab Mac OS 8.1. In der Zeit wurde der Umfang der Geräte, die mit Klassentreibern unterstützt werden, deutlich erweitert, seit Mac OS 8.5 werden die meisten üblichen Geräteklassen unterstützt.
- Mac OS X unterstützt in allen Versionen USB 1.1 und ab Version 10.2.8 auch USB 2.0.
- Windows 95 hat ab OEM-ServiceRelease 2.1 eine rudimentäre Unterstützung von USB 1.0, die jedoch als fehleranfällig gilt.
- Windows 98 unterstützt USB 1.0, ab der Version Windows 98 SE auch USB 1.1.
- Windows Me unterstützt USB 1.1 und 2.0 – im Gegensatz zu Windows 98 ist nach der Installation gerätespezifischer USB-Treiber kein Neustart erforderlich.
- Windows NT hat keinerlei USB-Unterstützung, von Drittherstellern sind jedoch Systemerweiterungen dafür erhältlich. Gerätehersteller testen ihre Produkte selten mit

derartigen Erweiterungen, deshalb gelten diese Systemerweiterungen nur für Spezialfälle als tauglich.

- Windows 2000 (SP3), XP (mit Patch oder SP1) und neuere Ausgaben (Vista) unterstützen USB 1.1 und USB 2.0. Der USB-Hostcontroller wird allerdings manchmal fehlerhaft erkannt, die meisten Hersteller raten dazu, die Treiber des Chipsatzherstellers zu installieren.
- Der Linux-Kernel unterstützt seit Version 2.2 USB-Controller. Seit der Kernelversion 2.4 sind Treiber für UHCI-, OHCI- und EHCI-Controller sowie Unterstützung für gängige USB-Endgeräte integriert.
- Amiga OS3.x unterstützt von Haus aus kein USB. Lediglich mit Hard- und Software von Drittanbietern ist eine Anbindung von USB-1.1-Geräten möglich. Ab Amiga OS4 wird, je nach Hardware, USB 1.1 und 2.0 unterstützt.
- AROS unterstützt seit neuestem USB in Form von Eingabegeräten. Weitere Klassen als hidd befinden sich gerade in Entwicklung.
- MorphOS wird mit einer Lizenz für *Poseidon*-USB-Stack ausgeliefert.
- NetBSD, FreeBSD und OpenBSD unterstützen UHCI, OHCI und EHCI sowie gängige Endgeräte. NetBSD war 1998 das erste freie Betriebssystem mit USB-Unterstützung.
- OS/2 Warp4 unterstützt erst über den Aufrüstpack Warp 4.51 Convenience Pak 1 (vom Dezember 2000) USB 1.1. Dieser ist kostenpflichtig. Treiber-Updates auf USB 2.0 sind ebenfalls verfügbar.
- eComStation als Nachfolger von OS/2 bringt ebenfalls Unterstützung für USB 2.0 mit.
- Neuere Betriebssystemversionen mit Unix-Basis verwenden immer öfter *libusb* als Basisbibliothek.
- Wo das Betriebssystem die nötige Unterstützung für USB-Geräte nicht hat, kann das Bios nach Aktivieren von „USB Legacy Support“ (engl. etwa „USB-Unterstützung für Erblasten“) in seinen Einstellungen Abhilfe schaffen, da hierdurch USB-Eingabegeräte wie Mäuse und Tastaturen dem Betriebssystem gegenüber als PS/2-Geräte erscheinen. Datenträger (wie USB-Sticks, USB-Floppies oder USB-CD/DVD-Laufwerke) aber werden nur dann für ältere Betriebssysteme emuliert, wenn von ihnen gebootet wird.

USB On-the-go

Logo für USB-OTG-Geräte

Logo für USB-HighSpeed-OTG-Geräte

Durch USB On-the-go (OTG) können entsprechend ausgerüstete Geräte direkt miteinander kommunizieren. Dadurch kann auf einen Computer, der die Host-Funktion übernimmt, verzichtet werden. Bei Geräten mit USB OTG übernimmt eines der beiden Endgeräte eine eingeschränkte Host-Funktionalität, die Geräte können deshalb miteinander kommunizieren. Mögliche Einsatzgebiete sind beispielsweise die Verbindung von Digitalkamera und Drucker oder der Austausch von Musikdateien zwischen zwei MP3-Playern.

Gekennzeichnet werden USB-OTG-Produkte durch das USB-Logo mit zusätzlichem grünem Pfeil auf der Unterseite und weißem „On-The-Go“-Schriftzug. Die USB-OTG-Spezifikation wurde am 18. Dezember 2001 verabschiedet.

Wireless USB

Logo für Wireless-USB-zertifizierte Geräte

Momentan besetzen zwei Initiativen den Begriff „Wireless USB“. Die ältere der beiden wurde von der Firma Cypress initiiert, mittlerweile ist Atmel als zweiter Chiphersteller auf den Zug aufgesprungen. Das „Cypress-WirelessUSB“-System ist eigentlich kein drahtloses USB, sondern eine Technik, um drahtlose Endgeräte zu bauen, die dann über einen am USB angeschlossenen Empfänger/Sender (Transceiver) mit dem Computer verbunden sind. Dazu wird eine Übertragungstechnik im lizenzfreien 2,4-GHz-Band benutzt, die Datenrate beträgt bis zu 62,5 kbit/s (neuere Chips von Cypress erreichen 1 MBit/s) und ist damit für Eingabegeräte völlig ausreichend, für andere Anwendungen aber oft zu knapp bemessen.

Das zweite Wireless-USB-Projekt ist wesentlich anspruchsvoller, das dazugehörige Konsortium wird von Intel angeführt. Ziel ist es, eine Technik zu schaffen, mit der die vollen 480 MBit/s des High-Speed-Übertragungsmodus drahtlos übertragen werden können. Dabei ist eine kurze Reichweite unter 10 m vorgesehen; die Übertragung soll auf einer Ultra-Wideband-Technik basieren.

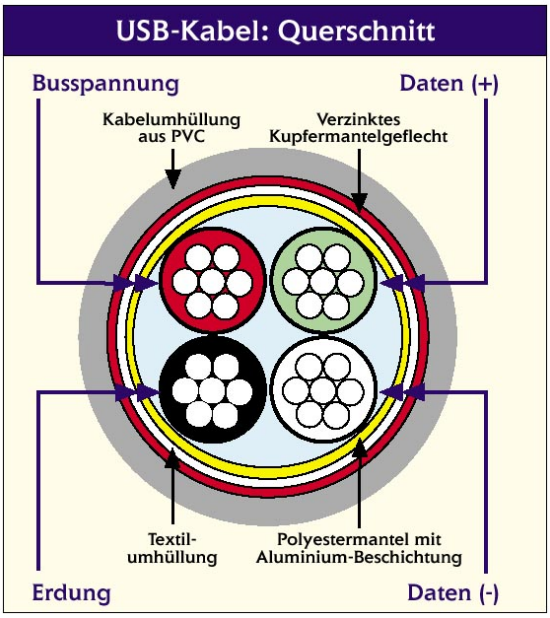

PERFORMANCE	APPLICATIONS	ATTRIBUTES
LOW-SPEED • Interactive Devices • 10 – 100 kb/s	Keyboard, Mouse Stylus Game Peripherals Virtual Reality Peripherals	Lowest Cost Ease-of-Use Dynamic Attach-Detach Multiple Peripherals
FULL-SPEED • Phone, Audio, Compressed Video • 500 kb/s – 10 Mb/s	POTS Broadband Audio Microphone	Lower Cost Ease-of-Use Dynamic Attach-Detach Multiple Peripherals Guaranteed Bandwidth Guaranteed Latency
HIGH-SPEED • Video, Storage • 25 – 400 Mb/s	Video Storage Imaging Broadband	Low Cost Ease-of-Use Dynamic Attach-Detach Multiple Peripherals Guaranteed Bandwidth Guaranteed Latency High Bandwidth

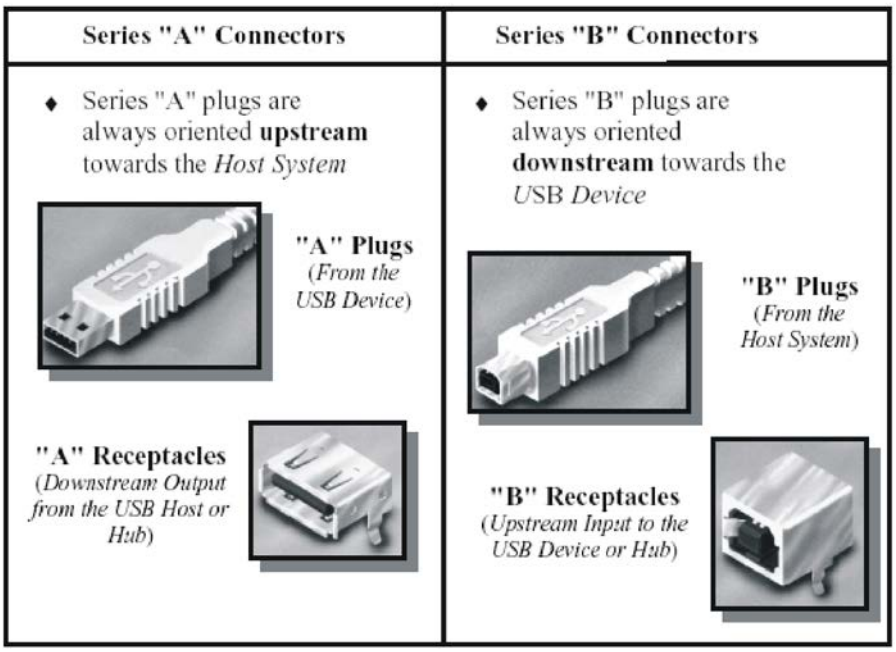

Daten¨ubertragung mittels des USB

• elektrische ¨Ubertragung der Daten als Differenzsignale
• keine ¨Ubertragung des Taktes -¿ R¨uckgewinnung des Taktes aus der Kodierung der Daten
• Verwendung der NRZI (no return to zero inverted (inverted on zero))
• LSB zuerst ¨ubertragen
• 'Little endian coding' verwendet
• jede Daten¨ubertragung startet mit einem 'Sync-pattern'
39
• Daten¨ubertragung erfolgt in Paketen, die mit mit einem Identifier (PID) versehen sind
• zeitlich betrachtet werden die Pakete in Frames gruppiert
• Full/Low-Speed Frame -> Dauer ca. 1ms
• High-Speed Frame -> Dauer ca. 125 µs

Datenkodierung

• Taktrückgewinnung erforderlich

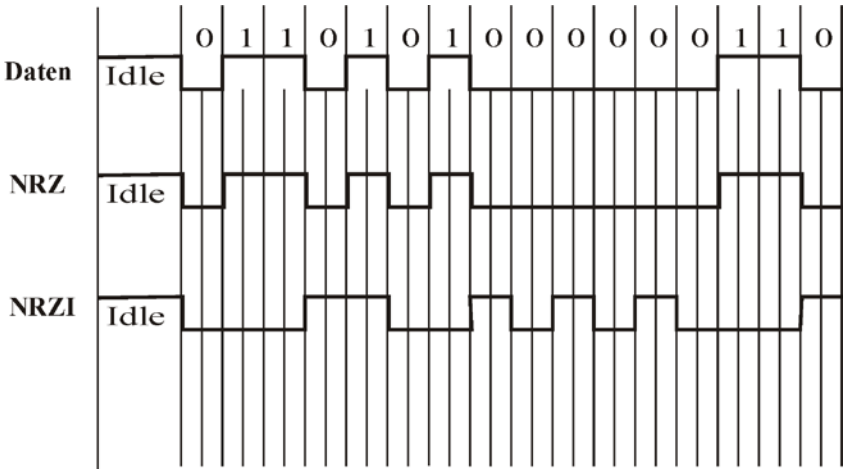

Idle keine Dan liegen auf der Datenleitung

Takt immer bei dem Wechsel zu 0

• bei einer Folge von mehr als 6 'one' -> Integration eines 'zero' notwendig (bitstuffing)

4.3 Parallele Datenübertragung

Bei der **parallelen Datenübertragung** werden mehrere Bits gleichzeitig (*parallel*) übertragen, also auf mehreren physischen Leitungen nebeneinander oder über mehrere logische Kanäle zur gleichen Zeit.

Die Anzahl der Datenleitungen ist nicht festgelegt, wird aber meistens als ein vielfaches von 8 gewählt, so dass volle Bytes übertragen werden können (zum Beispiel 16 Leitungen ergeben 16 Bits = 2 Byte). Häufig werden zusätzliche Leitungen zur Übertragung von Metainformationen wie z.B. einer Prüfsumme (Paritätsbit) oder eines Taktsignals eingesetzt.

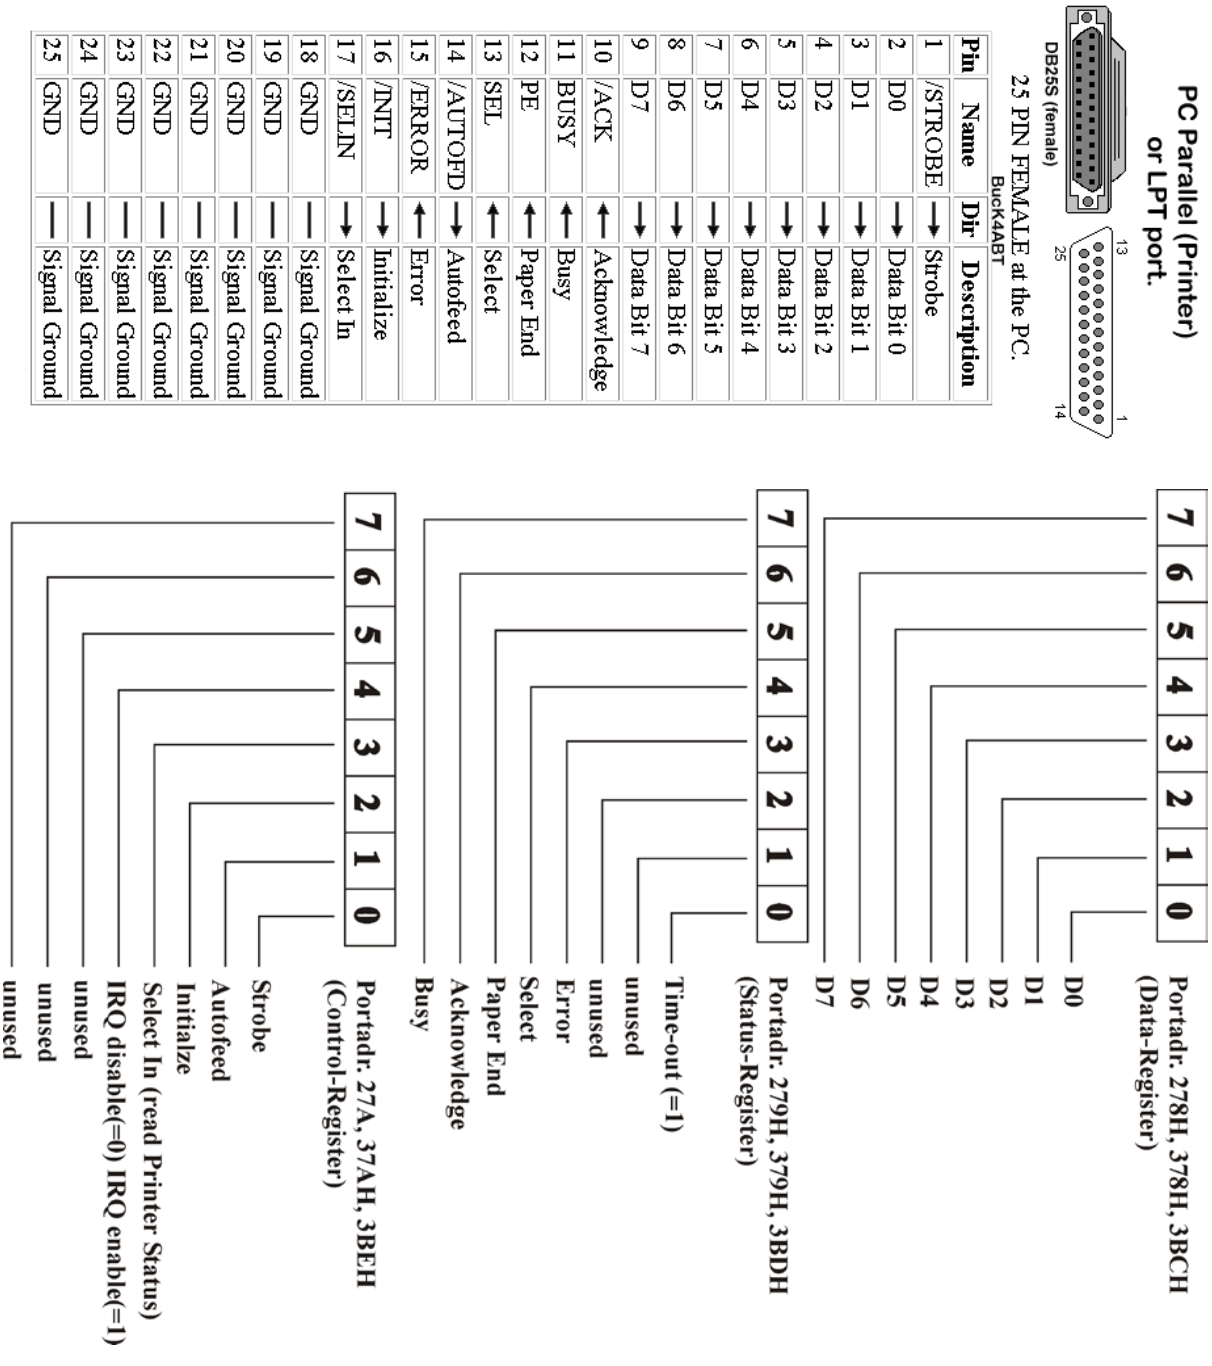

4.4 Schnittstellen Motherboard

- Verarbeitung und Transfer der CPU-Signale durch 'ChipSet'
- Zusammenfassung von Signalen zur Ansteuerung von Speicher und Schnittstellen

- Northbridge

Die **Northbridge**, auch bekannt als **Memory Controller Hub** (**MCH**), ist ein Begriff aus der Computertechnik und bezeichnet einen bestimmten Chip auf der Hauptplatine moderner IBM-PC kompatibler PCs.

Die Northbridge befindet sich im Gegensatz zur Southbridge dicht an der CPU, um Daten schnell transferieren zu können, und ist ein wichtiger Bestandteil der Hauptplatine (auch als Mother- oder Mainboard bezeichnet). Die beiden Chips (North- und Southbridge) werden auch als Chipsatz bezeichnet. Die entstehende Wärme wird meistens durch einen Kühlkörper abgeführt.

Der Chip der Northbridge synchronisiert den Datentransfer und die Datensteuerung zwischen CPU (Prozessor), Arbeitsspeicher, Cache und AGP- oder PCI-Express-Grafikkarte. Durch diesen Mechanismus wird die Reaktionszeit (Latency) negativ beeinflusst, dem beispielsweise mit der „Hyper Path2"-Technik entgegengewirkt wird.

Dabei war der Chip bis Mitte 2005 normalerweise über einen 32-Bit-Bus mit den Komponenten verbunden. Mittlerweile (Mitte 2006) sind Chipsätze mit 64-Bit-Architektur üblich. Die direkte Verbindung zwischen Northbridge und CPU wird als Front Side Bus (FSB) bezeichnet und ist ein Bestandteil des Systembusses.

- Southbridge

Southbridge ist eine Hardwarekomponente einer modernen PC-Hauptplatine (auch Motherboard oder Mainboard genannt). Sie befindet sich nahe an den PCI-Steckplätzen, da sie zu diesen eine direkte Verbindung hat.

Die Southbridge ist neben der Northbridge ein wichtiger Bestandteil des Mainboards. Die beiden Chips werden auch als Chipsatz bezeichnet. Über den Chip der Southbridge erfolgt der Datentransfer und die Datensteuerung zwischen peripheren Geräten (PCI-Bus, ISA-Bus, ATA, etc.) und weiteren Schnittstellen. Außerdem ist bei modernen Mainboards oft ein Teil der Peripherie schon auf der Southbridge integriert, z.B. der USB-Controller. South- und Northbridge kommunizieren entweder ebenfalls über PCI bzw. PCI-X oder eine Proprietäre Schnittstelle (wie VIAs V-Link oder AMDs Hypertransport). In der Regel ist die Leistungsfähigkeit des Chips der Southbridge deutlich geringer als die der Northbridge.

In der Intel-Terminologie trägt die Southbridge heute den Namen **I/O Controller Hub** (**ICH**). I m engeren Sinn ist damit der Chip Intel 82801 gemeint.

Bei dem nForce 4 Chipsatz von nVidia ist die Southbridge bei vielen Versionen direkt in der Northbridge integriert.

Kapitel 5. Einführung in die 8086 Architekturen

Intel 8086
aus Wikipedia, der freien Enzyklopädie

Intel 8086

Der **Intel 8086** ist ein 16-Bit-Mikroprozessor von Intel. Entwickelt 1978, wurde er zum Urvater der 80x86-Familie. Das Design basierte auf Intels 8-Bit-CPUs 8080 und 8085, der Befehlssatz war so konzipiert, dass Assembler-Quellcode für den 8080/8085 leicht automatisch in gültigen 8086-Quellcode umgewandelt werden konnte. Eine direkte Kompatibilität, also die Möglichkeit, die 8080-Programme auch ohne Neuassemblierung ablaufen zu lassen, bestand aber nicht. Wie dem 8080 fehlten dem 8086 einige wesentliche Bausteine wie Interrupt- und DMA-Controller, die als externe Chips dazukamen.

Der 8086 war eine der langsamsten 16-Bit-CPUs, die zu der Zeit auf den Markt kamen.

Inhaltsverzeichnis

- 1 Speichersegmentierung
- 2 Register
- 3 Architektur
- 4 Technische Daten
- 5 Siehe auch
- 6 Weblinks

Speichersegmentierung

Eine Besonderheit ist die Speichersegmentierung. Da es mit einem Arbeitsregister nur möglich ist, maximal 64 kiB Speicher zu adressieren, musste ein anderer Weg gefunden werden, um trotzdem den gesamten Speicher mit den 20 Adressleitungen adressieren zu können. Dazu wird der Speicher in Adressbereiche (Segmente) zu je 64 kiB Größe aufgeteilt, die in 16-Byte-Schritten im Speicher beginnen. Auf diese Weise ist es dem Chip möglich, bis zu ein MiB zu adressieren, wobei innerhalb jedes Segments mit 16-Bit-Adressen gearbeitet werden kann. Als Formel für den Zugriff auf eine physikalische Speicherstelle wurde folgender Zusammenhang festgelegt: Physikalische Adresse = Segmentregister * 16 + Offset. Mit den insgesamt vier Segmentregistern können vier Anfangsadressen gespeichert werden und somit gleichzeitig vier verschiedene Speicherbereiche von maximal 256 KiB adressiert werden.

Vorteil der Speichersegmentierung ist u. a. eine einfachere Portierbarkeit von 8-Bit-Programmen, Nachteil die umständliche Programmierung und die Beschränkung auf ein Megabyte; andere 16-Bit-Architekturen, wie etwa Motorolas 68000, erlaubten meist einen Adressraum von mindestens 16 MiB. Allerdings war 1 MiB damals für einen Mikrocomputer ohnehin viel mehr, als benötigt bzw. tatsächlich an Speicher verbaut wurde (der IBM-PC hatte zum Beispiel 64 kiB Speicher).

Register

Die Register haben meist fest zugewiesene Funktionen. Zum Beispiel muss für eine Multiplikation der Multiplikant im Register AX abgelegt werden und danach der Multiplikationsbefehl mit dem Multiplikator als Argument aufgerufen werden. Das Ergebnis erhält man dann in den Registern DX und AX. Dadurch ist man häufig gezwungen, Werte auf den Stack oder in den Arbeitsspeicher zu sichern und von dort zu laden, da die Prozessorbefehle häufig vorgeben, welche Register gerade für

Zwischenwerte genutzt werden können. Andere 16-Bit Prozessoren wie der Motorola 68000 erlauben dagegen, dass man für jede Operation die zu verwendenen Allzweck-Register auswählt und damit seltener Zwischenergebnise auf Stack und im Arbeitsspeicher sichern muss. Dies ist insofern ein Problem, als dass Zugriffe auf den Arbeitsspeicher im Gegensatz zu Registerzugriffen sehr langsam sind und Caches noch nicht unterstützt waren.

Dieses Register-Konzept vererbte der 8086 auf seinen Nachfolger 80286 und auf alle späteren, zur sog. *x86-Familie* zählenden Prozessoren (also auch Pentium 4 und die Intel-kompatiblen Prozessoren von AMD).

Wie sein 'kleiner Bruder' 8088, der wenig später auf den Markt kam, wurde der 8086 vor allem im IBM-PC und dessen Clones eingesetzt, aber auch z. B. im Space Shuttle.

Architektur

- Max. adressierbarer Speicher: 1 MiB
- Verarbeitungsbreite: 16 Bit
- Datenbus: 16 Bit
- Adressbus: 20 Bit
- Befehle: ca. 100 im Format "[Präfix] Mnemonik [Operand 1][, Operand 2]" ([...] nicht immer nötig)
- 14 Register:
  - 4 allgemeine 16-Bit-Register (ansprechbar auch als Low- oder High-Teil zu je 8-Bit):
    - AX - Akkumulator
    - BX - Basis-Register
    - CX - Count-Register
    - DX - Daten-Register
  - 2 16-Bit Pointer Register:
    - SP - Stackpointer
    - BP - Basepointer
  - 2 16-Bit Index-Register:
    - SI - Source Index
    - DI - Destination Index
  - 4 16-Bit Segment-Register:
    - CS - Codesegment
    - DS - Datensegment
    - SS - Stacksegment
    - ES - Extrasegment

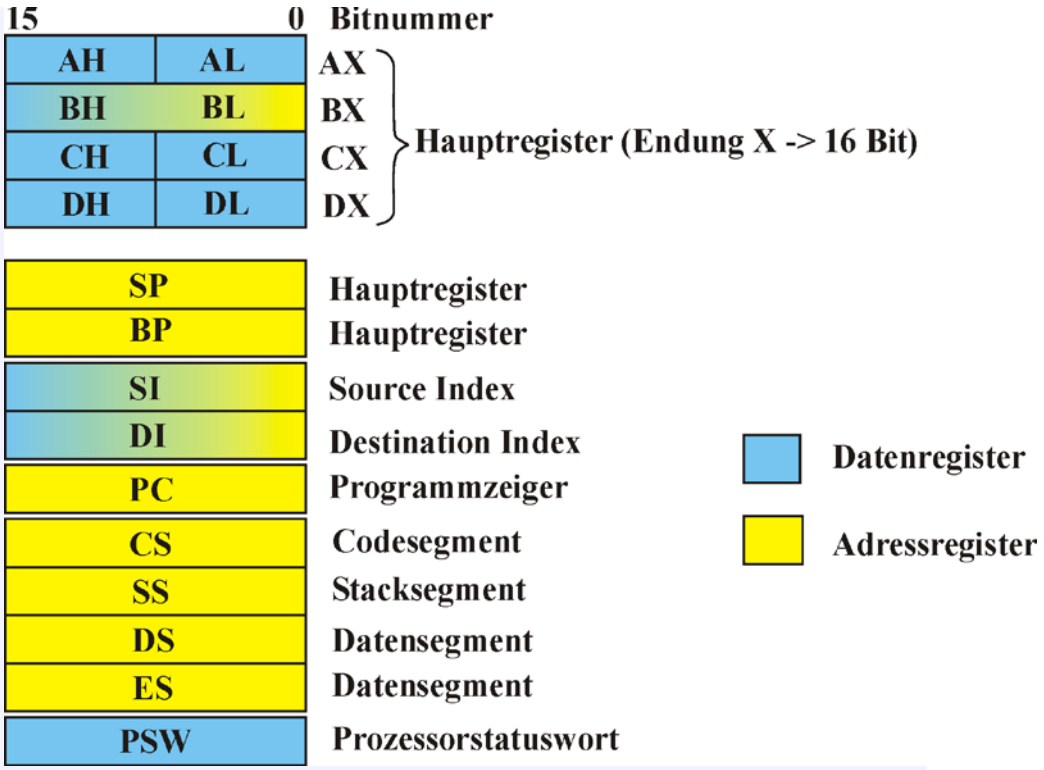

- Befehlszeiger IP - Instruction Pointer

- Status-Register mit 9 Flags:
  - CF - Übertragflag (engl. *carry flag*)
  - PF - Paritätsflag (engl. *parity flag*)
  - AF - Hilfsübertragflag (engl. *auxiliary carry flag*)
  - ZF - Nullflag (engl. *zero flag*)
  - SF - Vorzeichenflag (engl. *sign flag*)
  - TF - Einzelschrittflag (engl. *trap flag*)
  - IF - Interrupt-Aktivierungs-Flag (engl. *interrupt enable flag*)
  - DF - Richtungsflag (engl. *direction flag*)
  - OF - Überlaufflag (engl. *overflow flag*)

Statusregister

Das **Statusregister** (auch Zustandsregister oder Flags, engl. *Condition Code Register*, CCR) ist ein spezielles Register im Steuerwerk eines Mikroprozessors. Es enthält eine Reihe von Flags (Bits) die von der arithmetisch-logischen Einheit (ALU) in Abhängigkeit von der zuletzt durchgeführten Rechenoperation (z. B. Überlauf, negatives Ergebnis) gesetzt werden. Einige Flags können auch durch direkte Anweisungen geändert werden. Manche Prozessoren − z. B. der 6502 − setzen die meisten Statusflags auch schon bei reinen Ladeoperationen.

Inhaltsverzeichnis

- 1 Verwendung
- 2 Allgemeine Flags eines Statusregisters
  - 2.1 Carry-Flag
  - 2.2 Zero-Flag
  - 2.3 Sign-Flag
  - 2.4 Overflow-Flag
  - 2.5 Adjust-Flag
  - 2.6 Parity-Flag
  - 2.7 Interrupt-Enable-Flag
  - 2.8 BCD-Flag
- 3 Siehe auch

Verwendung

Bedingte (Sprung-)Anweisungen hängen ausschließlich von diesen Flags ab und einige Rechenoperationen der ALU werden vom Zustand der Flags beeinflusst.

Der Inhalt des Statusregisters lässt sich auf dem Stack ablegen, um ihn zu sichern. Dieses geschieht automatisch, wenn ein Interrupt aufgerufen wird, damit das Programm nach Beendigung des Interrupts ungestört weiter arbeiten kann.

Art und Umfang des Statusregisters ist herstellerabhängig. Eine Reihe von Flags treten jedoch in den meisten heutigen Mikroprozessoren auf. Zu diesen Flags zählen:

- das Carry-Flag (oder auch Borrow-Flag)
- das Zero-Flag
- das Sign-Flag (auch Negative-Flag)
- das Overflow-Flag
- das Adjust-Flag (auch Auxiliary-Carry-Flag oder Half-Carry-Flag)
- das Parity-Flag
- das Interrupt-Flag
- das BCD-Flag

Allgemeine Flags eines Statusregisters

Carry-Flag

. Das **Übertragsbit** (manchmal auch **Übertragbit** geschrieben, englisch **Carry-Bit**) ist ein Begriff aus der Informatik. Er bezeichnet ein Bit, welches den Übertrag einer Addition oder Subtraktion von Bits auf das nächst höherwertige Bit enthält.

Die für eine elementare Berechnung in einem Prozessor vorgesehenen Werte besitzen zumeist eine feste Speichergröße, zum Beispiel *n* Bit mit den Stellen a_0 bis a_{n-1}. Diese Werte werden meist bitweise bearbeitet (durch 1-Bit ALUs). Entsteht bei der Bearbeitung einer Stelle a_i ein Ergebnis mit zwei Stellen, so wird die im Stellenwertsystem höherwertige Stelle des Ergebnisses als Übertragsbit an die nächste (auch die höherwertige) Stelle a_{i+1} der zu berechnenden Werte weitergegeben, damit diese Stelle korrekt berechnet werden kann.

Das letzte Übertragsbit der Berechnung an der höchstwertigsten Stelle a_{n-1} wird von Prozessoren oft in einem Statusregister als Übertragsflagge (engl. Carry-Flag) gespeichert, um zum Beispiel in mehreren Rechenschritten Zahlen zu bearbeiten, die größer sind als die Bit-Breite der ALU.

Die Übertragsflagge stellt prinzipiell den Übertrag der Stelle a_{n-1} dar, während das Überlaufbit von der Zahleninterpretation abhängt und die Überschreitung des jeweils gültigen Zahlenbereiches signalisiert.

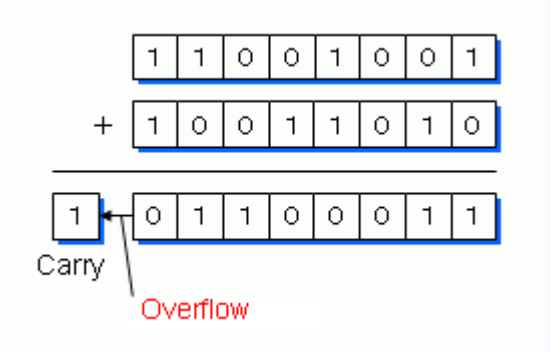

Zero-Flag

Das **Nullbit** bzw. **Zero Flag** ist ein spezielles Bit innerhalb des Statusregisters von Rechenwerken. Es zeigt an, ob das Ergebnis einer Operation gleich 0 war. Dieser Sonderfall als Ergebnis einer Berechnung ist insbesondere für die Prüfung von Schleifenbedingungen von Bedeutung. Diese müssen aufgrund ihres häufigen Auftretens besonders effizient erfolgen können. Mittels des Nullbits kann diese Prüfung mit minimalem Aufwand durchgeführt werden.

Ist dieses Flag gesetzt, dann war das letzte Rechenergebnis gleich null.

Bei einem Vergleichsbefehl werden zwei Operanden, ohne sie zu verändern, intern subtrahiert. Dann zeigt das Zero-Flag an, dass diese beiden Operanden gleich sind.

AL	0 0 0 0	0 0 0 1	+1
+ 1	1 1 1 1	1 1 1 1	-1 (FFH)
	0 0 0 0	0 0 0 0	Zero Flag=1

Sign-Flag

Einfachhalberweise nutzen Microprozessoren das Zweierkomplement. So erkennt man negative Zahlen daran, dass das höchstwertige Bit gesetzt ist. Das Sign-Flag wird entsprechend diesem Bit gesetzt.

AL	0 1 0 1	0 0 0 0	50H
+	0 1 0 0	0 0 0 0	40H
	1 0 0 1	0 0 0 0	Sign Flag=1

Overflow-Flag

Ist dieses Flag gesetzt, dann trat bei der letzten Rechenoperation ein Überlauf auf, wenn man von vorzeichenbehafteten Operanden ausgeht. Beim Vergleich (interne Subtraktion) von vorzeichenbehafteten Werten benötigt man bedingte Sprungbefehle, die neben dem Overflow-Flag auch vom Sign-Flag abhängen.

Adjust-Flag

Hat ein Microprozessor keine speziellen Rechenbefehle für dualkodierten Dezimalziffern (BCD), so ist häufig dieses Flag vorhanden. Es wird bei "normalen" binären Rechenoperationen gesetzt, wenn ein Übertrag zwischen den Halbbytes auftritt; z.B. bei der Addition von 9 und 7 = 16: $1001_2 + 0111_2 = 1\ 0000_2$. Dieses Flag zeigt dann an, ob das Ergebnis korrigiert werden muss. $1001_2 + 0111_2 = 0001_2*(10^1) + 0110_2*(10^0)$.

Einige Microprozessoren besitzen das BCD-(Status-)Flag, mit dem man vorab einstellen kann, ob der Prozessor wie mit "normalen" binären Zahlen oder wie mit dualkodierten Dezimalziffern zu rechnen hat.

Parity-Flag

Ist die Anzahl der Einsen (Quersumme) eines Ergebnisses in Binärdarstellung gerade, so wird das Parity-Flag gesetzt. Ist die Anzahl ungerade, so wird es gelöscht. (Siehe: Paritätsbit)

Interrupt-Enable-Flag

Dieses Flag ist kein Status-Flag, sondern ein Kontroll-Flag. Wird es gelöscht, so werden Interrupts vom Prozessor ausgesetzt. Man löscht dieses Flag zu Beginn von Interrupt-Routinen (manche Prozessoren erledigen dies automatisch), damit diese ungestört bis zum Ende durchlaufen können. Der Prozessor führt nach dem Setzen des Interrupt-Enable-Flags erst noch eine Anweisung aus, bevor er wieder Interrupts zulässt. So kann man in einer Interrupt-Routine nach dem Setzten dieses Flags noch den RETURN-Befehl ausführen lassen.

Es gibt Interrupts, die vom Interrupt-Enable-Flag unberührt bleiben. Diese nennt man nicht-maskierbare Interrupts (NMI).

BCD-Flag

Dieses Flag ist kein Status-Flag, sondern ein Kontroll-Flag. Wird es gesetzt, arbeitet die Prozessor-Arithmetik – die ALU – im BCD-Modus statt in rein binärer Arithmetik. Damit sollen vor allem Finanzrechnungen direkt im Dezimalsystem durchgeführt und Ungenauigkeiten bei Umrechnung von binären Fest- oder Gleitkommazahlen vermieden werden.

Hilfsübertragsbit
aus Wikipedia, der freien Enzyklopädie

Das **Auxiliary-Carry-Flag** (Hilfübertragsflag, kurz: AF) ist ein Begriff aus der Informatik. Dieses Flag des Statusregisters wird gesetzt (AF:=1), wenn bei einer Rechenoperation im unteren Halbbyte ein Überlauf stattgefunden hat. Andernfalls wird es gelöscht (AF:=0).

Gebrauch

Das **Auxiliary-Carry-Flag** wird bei Rechenoperationen im BCD-Format genutzt, um einen möglichen Stellenüberlauf anzuzeigen.

Bei einer binären Addition oder Subtraktion von dualkodierten Dezimalziffern (BCD-Format), zeichnet sich ein Überlauf durch zwei Möglichkeiten aus:

1. Die unteren 4 Bit des Ergebnisses repräsentieren keine gültige Ziffer im BCD-Format. *(1010_2,1011_2,1100_2,1101_2,1110_2,1111_2)*.
2. Ein Überlauf von den unteren 4 Bit zu den oberen 4 Bit hat während der Rechenoperation stattgefunden. (Das Auxiliary-Carry-Flag wurde gesetzt, AF=1.)

Die Maschinenbefehle **AAA** (ASCII Adjust After Addition) und **AAS** (ASCII Adjust AL After Subtraction) reagieren auf das Auxiliary-Carry-Flag.

In beiden Fällen korrigieren die Befehle AAA und AAS die unteren 4 Bit des (AL-)Registers und setzen das Carry-Flag (CF:=1) für weiterführende Berechnungen.

AAA und AAS betrachen nur die unteren 4 Bit des (AL-)Registers und löschen die oberen 4 Bit. So können in das (AL-)Register anstelle der korrekten BCD-kodierten Ziffern auch die entsprechenden ASCII-Zeichen '0'-'9' geladen werden, welche in den oberen Bits die Sigantur 011_2 haben.

Beispiele

Addition 5 + 8 (Das Auxiliary-Carry-Flag wird bei dieser Addition **nicht** gesetzt.)

MOV AL, 05h ; (Lade die Zahl 5 ins AL-Register)

ADD AL, 08h ; (Addiere die Zahl 8 hinzu, AL=13. => AF:=0, da kein Überlauf im Halbbyte auftrat.)

AAA ; (Die Zahl 13 im AL-Register ist größer als 9, also gab es einen BCD-Überlauf. Das Ergebnis wird korrigiert (AL:=3) und das Carry-Flag gesetzt (CF=1).

Addition 8 + 9 (Das Auxiliary-Carry-Flag wird bei dieser Addition gesetzt.)

MOV AL, 08h ; (Lade die Zahl 8 ins AL-Register)

ADD AL, 09h ; (Addiere die Zahl 9 hinzu, AL=17 => Überlauf im Halbbyte: AF:=1)

AAA ; (Da das Auxiliary-Carry-Flag (AF=1) gesetzt ist, wird das Ergebnis korrigiert (AL:=7). Der Überlauf wird jetzt durch das Carry-Flag markiert (CF=1).

Technische Daten

- L1-Cache: nicht vorhanden
- L2-Cache: nicht vorhanden
- Bauform: DIL mit 40 Pins
- Betriebsspannung (VCore): 5 Volt
- Erscheinungsdatum: 1978
- Fertigungstechnik: 3 µm
- Die-Größe: 33 mm² bei 29.000 Transistoren
- Taktraten:
  - 4,77 MHz (0,33 MIPS)
  - 8 MHz (0,66 MIPS)
  - 10 MHz (0,75 MIPS)

5.2 Maschinenbefehlssatz des Pentium

• Maschinenbefehlssatz (ISA instruction set architecture) setzt auf Registermodell auf
• Verwendung von Daten- und Adressregister
• Besonderheit bei 8086 -> Segmentierung
• impliziete Verwendung der Segmentregister (8086) oder Selectoren (Pentium)
• Zuordnung der Segmente
• Programmsegment CS:
• Datensegment DS:
• Stacksegment SS:
• falls die Zuordnung nicht ver¨andert werden soll erfolgt keine Angabe des zugehörigenSegmentes
46
• Veränderungen sind mit dem Segmentvorsatz m¨oglich (insbesondere sinnvoll beim Datensegment)

Adressierungsarten
• Verfahren des Zugriffs auf bestimmte Speicherstellen
• für den Zugriff auf Daten und den Zugriff auf Programmstellen bedeutsam (beim Begriff ?Zugriff? wird nicht zwischen einem Lesezugriff oder einem Schreibzugriff unterschieden)
• Adressierungsarten lassen sich gruppieren in:
  • Registeradressierung
  • Wertadressierung (immediate addressing)
  • direkte Addressierung
  • indirekte Adressierung
  • relative Adressierung
• insbesondere bei den direkten, indirekten und relativen Adressierungen gibt es viele Untervarianten
• In der Hochsprache C sind die einzelnen Adressierungsvarianten versteckt (aber natürlich eingesetz)

indirekte Adressierung

- Die Adresse wird nicht direkt angegeben, sondern indirekt über ein Register
- Das Register enthält somit einen Pointer auf eine Speicherzelle
- Vorteil ist, daß auf Speicher referenziert werden kann, aber keine volle Speicheradresse notwendig wird

Absolute oder direkte Adressierung

Bei dieser Adressierungsart wird die Speicheradresse bei jedem Befehl direkt und vollständig angegeben. Die Gesamtheit der möglichen Adressen bildet den Adressbereich dieser Adressierungsart.

```
# Addiere den Inhalt der Adressen 22 (= 10110₂) und 6 (= 00110₂) und
speichere das Ergebnis in Adresse 1 (= 00001₂)
add 10110, 00110, 00001
```

Häufig können nur zwei Adressen angegeben werden, dabei wird dann das Resultat dort gespeichert, wo vor Ausführung der Addition einer der Operanden stand (Akkumulator-Prinzip). Diese Adressierungsart wird heute nur noch in Integrierten Schaltkreisen und eingebetteten Systemen mit wenig Speicherplatz angewandt. So benötigt in einem Rechner mit einem 32 Bit breitem Adressbus solch einfacher Additionsbefehl allein für die Adressangaben 96 Bit. Zur Verringerung des Speicheraufwands werden zwei weitere Möglichkeiten der Adressierung verwendet

Adresse

Als **Adresse** werden die Daten verschiedener Zielangaben bezeichnet. Beispiele für Adressen im eigentlichen Sinne sind: Postanschrift als Ziel für z. B. einen Brief, die Adresse einer E-Mail, eine Speicheradresse als Ziel eines Speicherzugriffs oder eines Arrays in der EDV oder eine IP-Adresse für den Zugriff auf einen Server in einem IP-Netzwerk.

Es gibt weiterhin Definitionen, nach denen eine Adresse ortsfest sein muss − im Gegensatz zu Namen, die mit dem Objekt wandern. Demnach wären weder E-Mail-Adressen noch IP-Adressen oder Postanschriften Adressen im Sinne dieser Definition, obwohl sie den Adressaten eindeutig bezeichnen.

Von der Bedeutung der Adresse als Zielangabe abgeleitet werden auch schriftliche Meinungsäußerung, welche an Regierung, Präsident oder Parlament gerichtet (adressiert) sind als Adresse bezeichnet wie auch eine Ansprache oder Rede, welche naturgemäß ebenfalls an eine Hörerschaft gerichtet ist.

Adressierung

Als **Adressierung** wird die Angabe einer Adresse bezeichnet. Eine Adressierung kann absolut, relativ oder symbolisch erfolgen. In der Datenverarbeitung wird die Angabe eines Destinationsbezeichners als Adressierung bezeichnet. Dieser kann entweder direkt durch eine Lokationsreferenz oder indirekt durch einen Namen erfolgen. Die Lokationsreferenz kann absolut oder relativ erfolgen. Namen sind symbolisch zu betrachten und müssen durch zusätzliche Hilfsmittel aufgelöst werden.

Absolute Adressierung

Von *absoluter Adressierung* spricht man, wenn die Angabe einer Adresse vollständig ist, d. h. der Adressat kann mit der Adresse von jedem anderen Punkt des Adressraums aus gefunden werden.

Beispiele für absolute Adressen

- eine offizielle IP-Adresse, z. B. 145.97.39.155
- ein absoluter Management Information Base Object Identifier (MIB-OID) [1] z. B. .1.3.6.1.2.1.1.1
- eine komplette Postanschrift (ausgehend davon, dass der Adressraum auf die Erde beschränkt ist und die Sendung von der Post transportiert wird)
- Eine Speicheradresse, vgl. direkte Adressierung
- Ein Fully Qualified Domain Name, z. B. de.wikipedia.org.
- Ein Uniform Resource Locator (URL), z.B. http://de.wikipedia.org/wiki/Adresse#Absolute_Adressierung

Relative Adressierung

Von einer *relativen Adressierung* spricht man, wenn sich die Adresse auf einen bekannten Ausgangspunkt innerhalb des Adressraums bezieht.

Beispiele für relative Adressierungen sind:

- „zweiter Briefkasten von links“
- relative MIB-OID: 2.1.1.1
- relative Speicheradressierung
- Hostname ohne Domain, z. B. www

Symbolische Adressierung

Da numerische Adressen (speziell in der EDV) für Menschen schlecht handhabbar sind, wird häufig ein sprechender Name oder ein Kürzel (Mnemonik) verwendet, der automatisch in eine Adresse umgewandelt werden kann.

Beispiele sind:

- MIB-OID, z. B. SNMPv2-MIB::sysDescr für die OID .1.3.6.1.2.1.1.1
- DNS-Namen, z. B. de.wikipeda.org für die Adresse 66.37.3.245
- Symbolische Speicheradressierung

Indizierte und relative Adressierung

Beide Adressierungsarten verwenden ein Register zur Speicherplatzersparnis. Bei der indizierten Adressierung wird das so genannte Indexregister zu jeder Adressangabe hinzuaddiert.

```
# Addiere den Inhalt der Adressen 22 (Index+00₂) und 23 (Index+01₂) und
speichere das Ergebnis in Adresse 24 (Index+10₂)
load index, 10110
add 00, 01, 10
```

Der Trick besteht darin, dass die relativen Adressen weniger Stellen haben. So kann der Befehl mit relativen Adressen von beispielsweise 8 Bit (8 Binärstellen) einen Bereich von nur 2^8=256 Speicherplätzen, relativ zur im Indexregister gegebenen Speicheradresse, ansprechen. Dafür verringert sich der Speicherbedarf für die Adressen von 96 Bit auf 24 Bit. (Wobei jedoch ggf. das Indexregister zunächst mit dem passenden Wert geladen werden muss.)

Für das Durchlaufen von Speicherbereichen ist dies hervorragend geeignet. Bei der relativen Adressierung speichert das Register die so genannte Basisadresse und die Adressen für die Befehle werden nur noch als Offset angegeben. Dabei sind negative und positive Offsets möglich.

```
# Basis ist 65536 (1000000000000000₂). Addiere den Inhalt der Adressen
65540 (Basis+0100₂)
# und 65549 (Basis+1101₂) und speichere das Ergebnis in 65537 (Basis+0001₂)
load index, 10000000000000000
add 0100, 1101, 0001
```

Da ein Rechner mehr als ein Register hat, muss ein jeder Befehl dieser Art eine Registeradresse enthalten (meist eine 4-bit- oder 8-bit-Angabe), die das Register angibt, das als Index-Register zu benutzen ist. Diese Registeradresse ist in den Beispielen oben nicht dargestellt.

Die relative Adressierung verläuft ähnlich, allerdings wird statt des Indexregisters der Befehlszähler *(program counter,* PC) benutzt. Die Adressierung erfolgt als nicht relativ zu einer im Indexregister angegebenen Adresse, sondern relativ zum Befehlszähler, d. h. der Speicherstelle, die den Befehl selbst enthält.

Normalerweise muss sich der Programmierer nicht um die Relativ-Adressen kümmern, da meist der Assembler oder Compiler die Berechnung der Offsets übernimmt.

Aber auch diese Adressierungsarten sind für heutige Rechner nicht mehr ausreichend.

Registeradressierung

- einfachste Adressierungsvariante
- in jedem Prozessor anzutreffen
- der oder die Operanden stehen in einem oder zwei Register

- z. B. MOV AX,BX ; Inhalt von BX nach AX transferieren

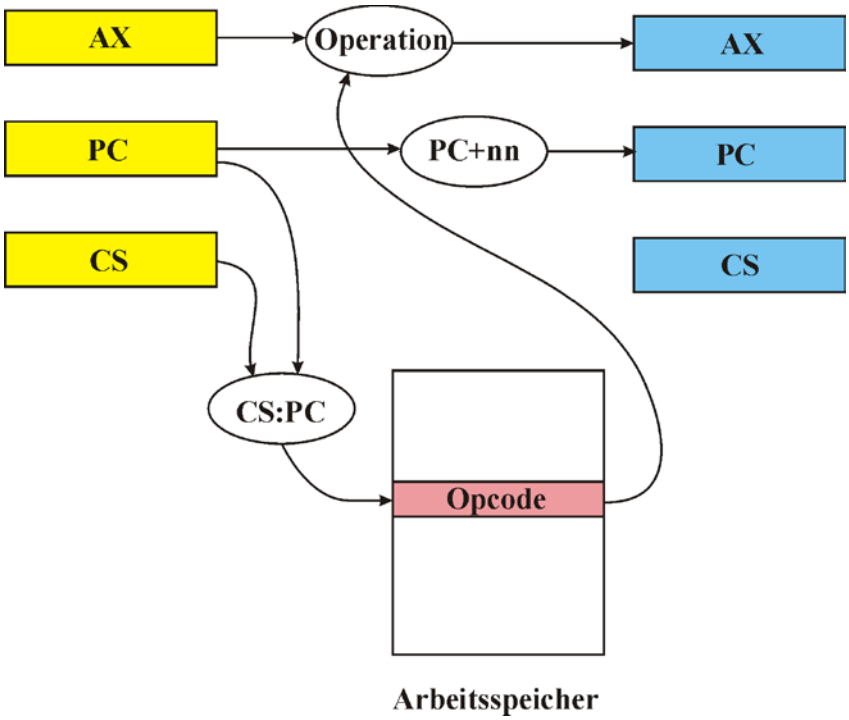

Wertadressierung

- Wert (Konstante) steht im Befehl
- z. B. ADD AX,1234H ;Summe AX plus 1234H

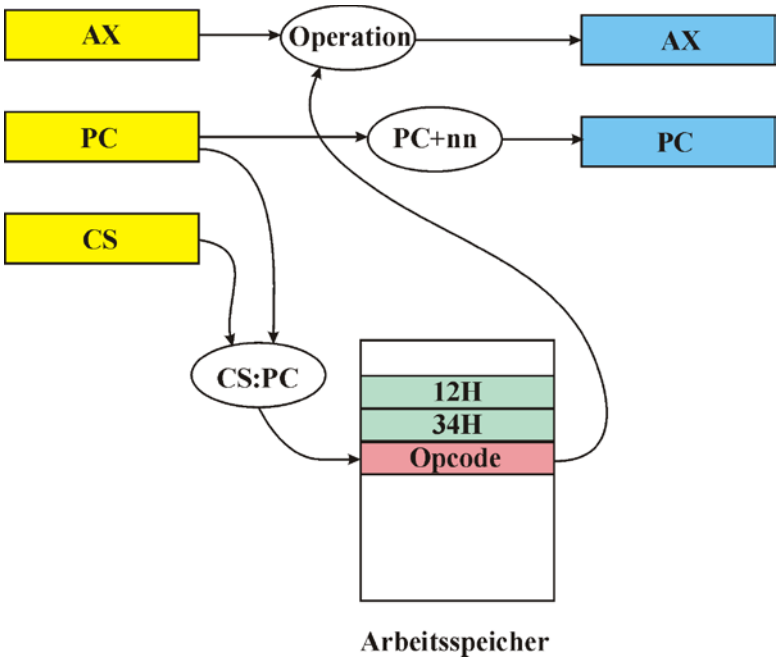

Kapitel 6
8086-Architektur im Pentium

6.1 Begrenzungen der 8086-Architektur

Wie schon zuvor erw¨ahnt (Kap. 5) stellt die 8086-Architektur einen Teil des Pentiums dar. Diese Architektur ist als Kompatibilit¨atsgr¨unden im Pentium zu finden. In diesem Kapitel wollen wir uns zun¨achst noch einmal die Begrenzungen der 8086-Architektur verdeutlichen, die besonders auffallend im klassischen Prozessor 8086 sichtbar werden.Nach diesen Ausf¨uhrungen werden wir dann die Funktionen des Pentiums beleuchten, die ihn als modernen Prozessor kennzeichnen und in jedem Rechnersystem als notwendig angesehen werden.

• die Kenntnis des Programmiermodells und die Verwendung des Statusregister reicht meist f¨ur die Programmierung
• Schwierigkeit sind jedoch dann zu erwarten, wenn Adressbreite und Breite des Addressbusse differieren
• in 8086-Architektur durch Segmentierung behoben
• Segmentierung unterscheidet drei Segmenten
• **Programmsegment**
    • Adresse durch CS:IP
• **Stacksegment**
    • Adresse durch SS:SP
    Adresse durch SS:BP
• **Datensegment**
    • Adresse durch DS:Adressierung innerhalb des Segmentes
    • Adresse durch ES:Adressierung innerhalb des Segmentes
    • beim 8086 k¨onnen auch 'fremde' Segmentregister verwandt werden (Segmentvorsatz) (nicht beim 80386 - Pentium)

Adressraum und Segmentierung

    • Adressbus 8086 -> 20 Bit -> Adressraum 1MByte
    • Adressregister 8086 -> 16Bit -> Adressierung von 64 Kbyte
    • Folgerung -> Speicherbereich innerhalb des Segmentes mehrfach im Adressraum des 8086 vorhanden

• Problml¨osung:
    • Programm, der Stack und die Daten innerhalb von 64KByte
    • Adressierung nur innerhalb des Segmentes (NEAR-Adressierung Programm, Stack und Daten)
    • Segment kann durch Segmentvorsatz beliebig im Speicherbereich des 8086 verschoben werden
    • Modell TINY
• Programm in 64 KByte, Stack und Daten in weiteren 64KByte

• Adressierung nur innerhalb des Segmentes (NEAR-Adressierung Programm, Stack und Daten)
• CS-Segment unterscheidet sich von SS- und DS- oder ES-Segment
• Modell SMALL

• Programm in mehr als 64 Kbyte, Stack in 64 Kbyte, Daten in mehr als 64 Kbyte
• Adressierung außerhalb des Segmentes f¨ur Programm und Daten (FAR-Adressierung,das jeweils zugeh¨orige Segmentregister wird auch ver¨andert)
• CS-Segment und DS- oder ES-Segment werden w¨ahrend der Laufzeit des Programms ver¨andert
• Modell LARGE

• Auswahl der Modelle durch Compiler-, oder Assemblereinstellung

• Adressraum des 8086 kann nicht mit Attributen versehen werden
• keine Einteilung in einen Supervisor- und Usermode m¨oglich
• trotz Segmentierung erfolgt keine Vergabe von Zugriffrechten
• 8086 l¨auft praktisch immer im h¨ochstpriorsierten ?Kernelmode?
• durch Programm-Irrl¨aufer leicht Absturz des Gesamtsystems

• der Adressraum des 8086 ist eingeteilt in:
• Speicherbereich (1 Mbyte)

Beispiel 6.1 MOV AH, [1000H] ;Lade den Inhalt Speicherstelle 1000 in AH
• I/O-Bereich (64 Kbyte)
Beispiel 6.2 IN AL,[DX] ;Lade Inhalt der I/O-Adresse auf die DX zeigt in AL

Adressierungsvarianten
• Einschr¨ankungen bei den Adressierungsvarianten
• keine relativen Adressierungen f¨ur Daten (das Register PC kann nur f¨ur Programmadressen verwandt werden)
• positionsunabh¨angige Programme k¨onnen nicht direkt entwickelt werden (dieser Nachteil wird durch die Segmentierung aufgehoben)
• ein Speicher- zu Speichertransfer ist nicht m¨oglich (Ausnahme: spezielle Stringbefehle)
• Transfer muß ¨uber mindestens ein Register gehen
• generell stehen sehr wenig Register zur Verf¨ugung
• h¨aufiger Zugriff auf den Speicher (auch beim Pentium)

6.2 Erweiterungen der 8086-Architektur

• Implementation der IA32-Architektur (Intel Architecture 32)
• Breite des Hauptregistersatzes 32 Bit
• jedes Hauptregister f¨ur Adressierung des Arbeitspeichers verwendbar
• Adressbreite 32 Bit -> 4 Gbyte Adressraum
• Bereitstellung mehrerer prozessorinterner Rechenwerke
• Floating Point Unit
• Verarbeitung von Datenpaketen (MMX- und SSE-Erweiterung)
• Implementation von zwei Integerrecheneinheiten (U- und V-Pipe)

Die Vergr¨oßerung der Wortbreite des Prozessors von 16 auf 32 Bit stellt zun¨achst eine klassische Erweiterung der 8086-Architektur dar. Mit der Implementation des Pentiums wurden aber auch ein Teil der Beschr¨ankungen in der Verwendung der Register aufgehoben. So sind alle Hauptregister (EAX, EBX, ECX, EDX, ESI, EDI) als Addressregister f¨ur die Adressierung von Daten im Datensegnent geeignet; beim 8086 waren dies nur die Register BX, DI und EI. Die Register EBP und ESP k¨onnen ¨ahnlich wie beim 8086 f¨ur die Adressierung von Daten im Stacksegmet verwendet werden. Eine weitere Verbesserung der Rechenleistung im Pentium ist durch den Einsatz von Rechenwerken für die Verarbeitung von Datenpaketen (MMX- und SSE-Erweiterung) zu verzeichnen.

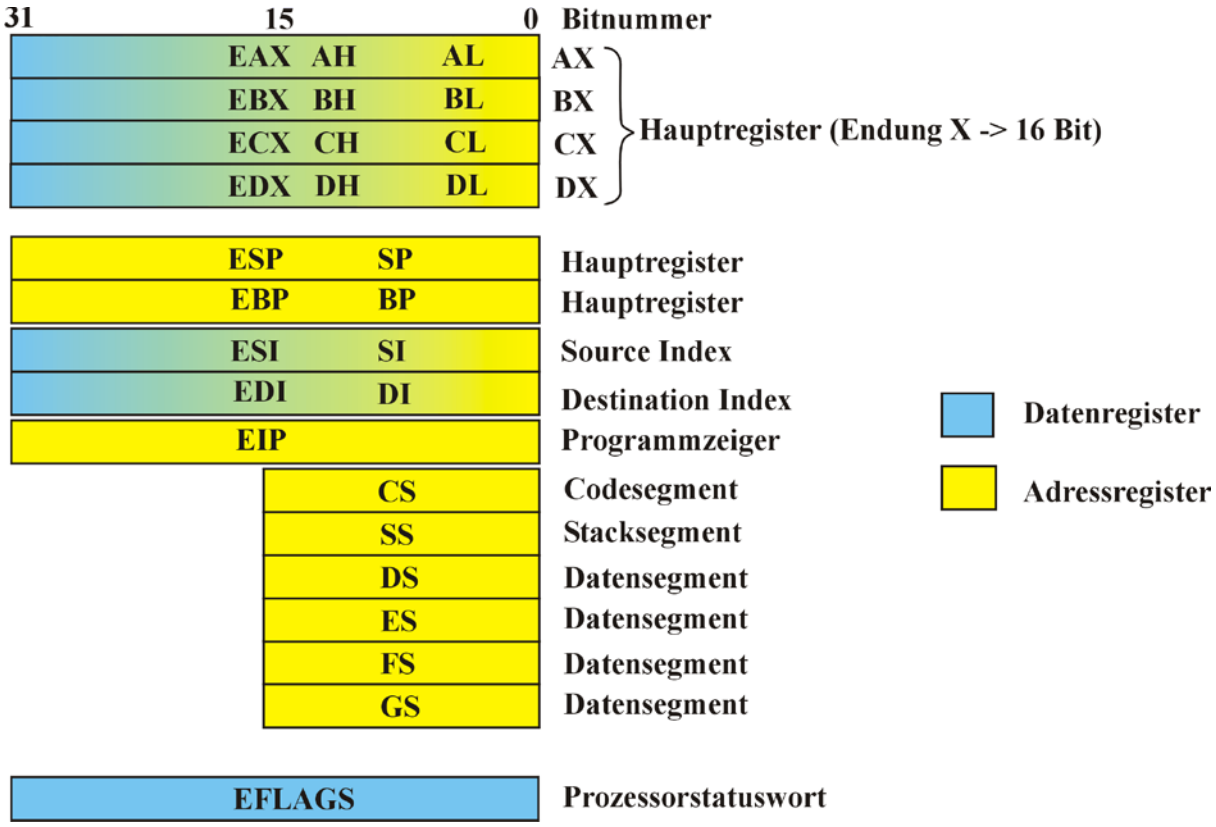

Implementation einer FPU (Floating Point Unit)

• Verwendung eines separaten Registersatzes
• Registersatz mit interner Wortbreite von 80 Bit (Register R0 - R7)
• Registersatz kann als Stack betrieben werden (ST(0) - ST(7))
    • Zugriff erfolgt dann grunds¨atzlich auf den TOP <-> ST(0), (TOP = top of stack)
    • die anderen Register werden entsprechend verschoben
• FPU rechnet mit h¨oherer interner Genauigkeit als externe Floating Point-Zahlentypen erfordern (float -> 32Bit mit 23 Bit Mantisse, double -> 64Bit mit 52 Bit Mantisse)
• Umwandlung der externen Floating Point-Zahlen in interne und umgekehrt erfolgt beim Laden
    • umfaßt eine automatische Rundung beim Speichern einer Flaoting Point-Zahl
• Laden von Zahlen in die FPU-Register (ST(0) - ST(7) erfolgt grunds¨atzlich aus dem Arbeitsspeicher
    • Verwendung der Adressierungsm¨oglichkeiten der CPU f¨ur das Laden und Speichern der Zahlen der FPU
    • direkter Transfer von Daten zwischen Hauptregister und FPU-Register nicht m¨oglich
• Befehle f¨ur die FPU k¨onnen in die Befehlsfolge der CPU eingestreut sein
    • automatische Trennung der Befehle f¨ur CPU und FPU
    • Befehlssatz der FPU umfaßt Lade-, Speicher- und Datenwandlungsbefehle

• Sprungbefehle sind prinzipiell nicht m¨oglich (werden nach Auswertung des Statusregister
der FPU von der CPU ¨ubernommen)

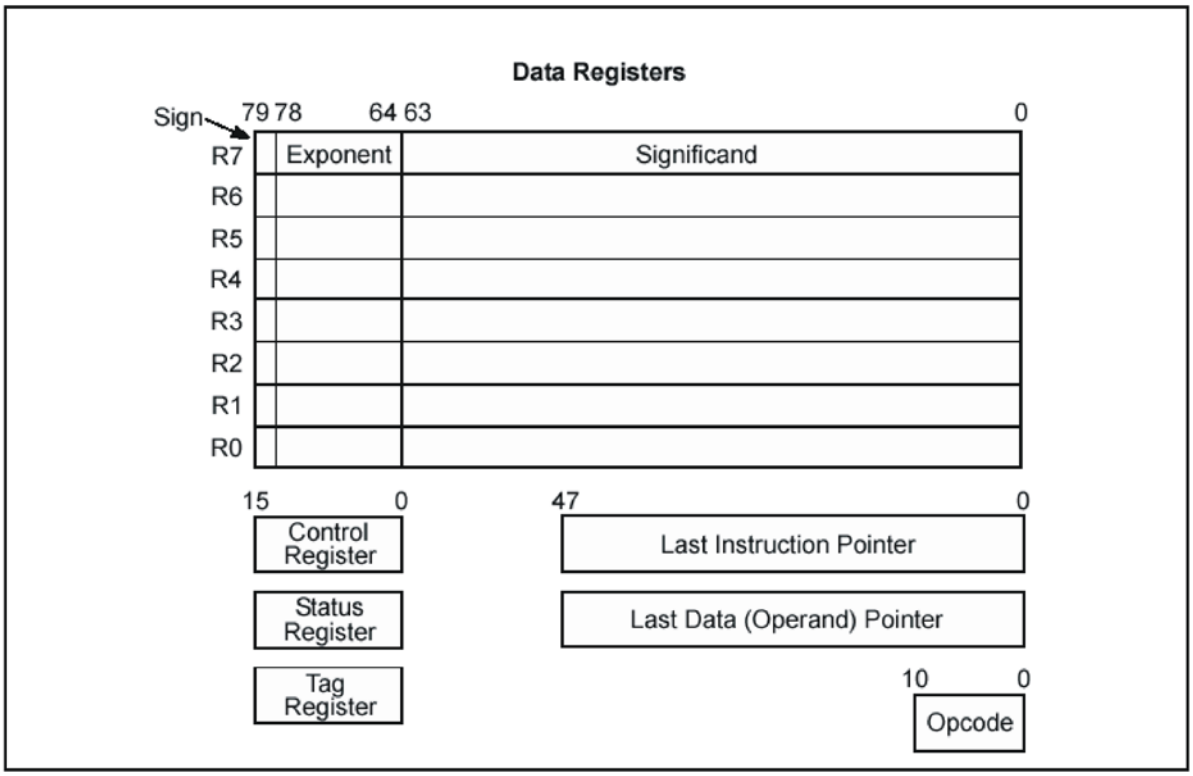

Implementation von Funktionen zur Verarbeitung von Datenpaketen

• Verarbeitung von Datenpaketen immer dann sinnvoll wenn in einem Register mehrere kleinere Datentypen abgelegt werden k¨onnen

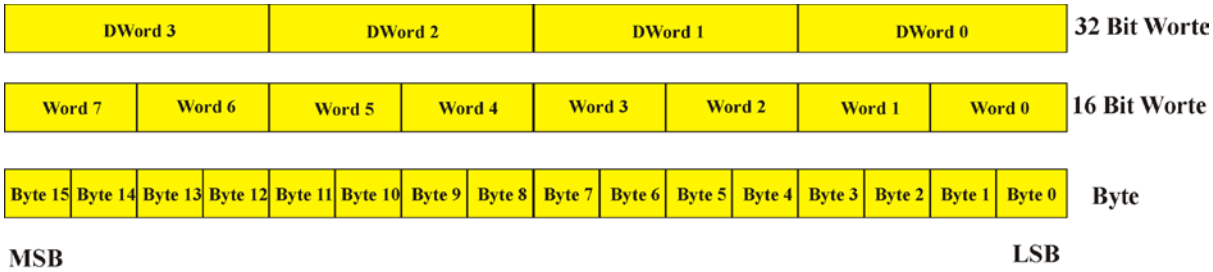

• Verarbeitung von Datenpaketen in zwei Varianten unterst¨utzt
  • MMX-Erweiterung
  • SSE-Erweiterung

MMX-Erweiterung

• MMX-Erweiterung (MMX multimedia extension) -> erstmalige Unterst¨utzung der Verarbeitung von Datenpaketen beim Pentium 57
• Verwendung des Mantissenteils des FPU-Registersatz mit interner Wortbreite von 64 Bit (Register R0 - R7)
• MMX-Erweiterung und FPU k¨onnen nicht parallel verwandt werden
• damit erhebliche Einschr¨ankung in der Nutzung der MMX-Erweiterung
• Bezeichnung der Register als MM0 - MM7
• als Datenpakete k¨onnen vorzeichenbehaftete und vorzeichenlose ganzahlige Datentypen mit 8 oder 16 Bit Wortbreite eingesetzt werden
• Implementation eines separaten Befehlssatzes f¨ur die Verarbeitung von Datenpaketen
• Laden und Speichern der Datenpakete immer aus dem Arbeitsspeicher
• Adressierung der Datenpakete ¨ahnlich dem Verfahren der FPU

SSE-Erweiterung

• SSE-Erweiterung (SIMD streaming extension) -> Implementation eines Rechenwerkes zur Unterst¨utzung der Verarbeitung von Datenpaketen ohne Restriktionen wie bei der MMX-Erweiterung

- Verwendung eines sepaten Registersatzes mit 8 Register a 128 Bit
- SSE-Erweiterung und FPU k¨onnen parallel arbeiten
- Bezeichnung der Register als XMM0 - XMM7
- als Datenpakete k¨onnen vorzeichenbehaftete und vorzeichenlose ganzahlige Datentypen mit 8,16 oder 32 Bit Wortbreite eingesetzt werden
- Verarbeitung von Floating Point-Zahlen (im 32 Bit float-Format) m¨oglich (die meistgenutzte SSE-Anwendung!)
- Implementation eines separaten Befehlssatzes f¨ur die Verarbeitung von Datenpaketen
- Laden und Speichern der Datenpakete immer aus dem Arbeitsspeicher
- Adressierung der Datenpakete ¨ahnlich dem Verfahren der FPU

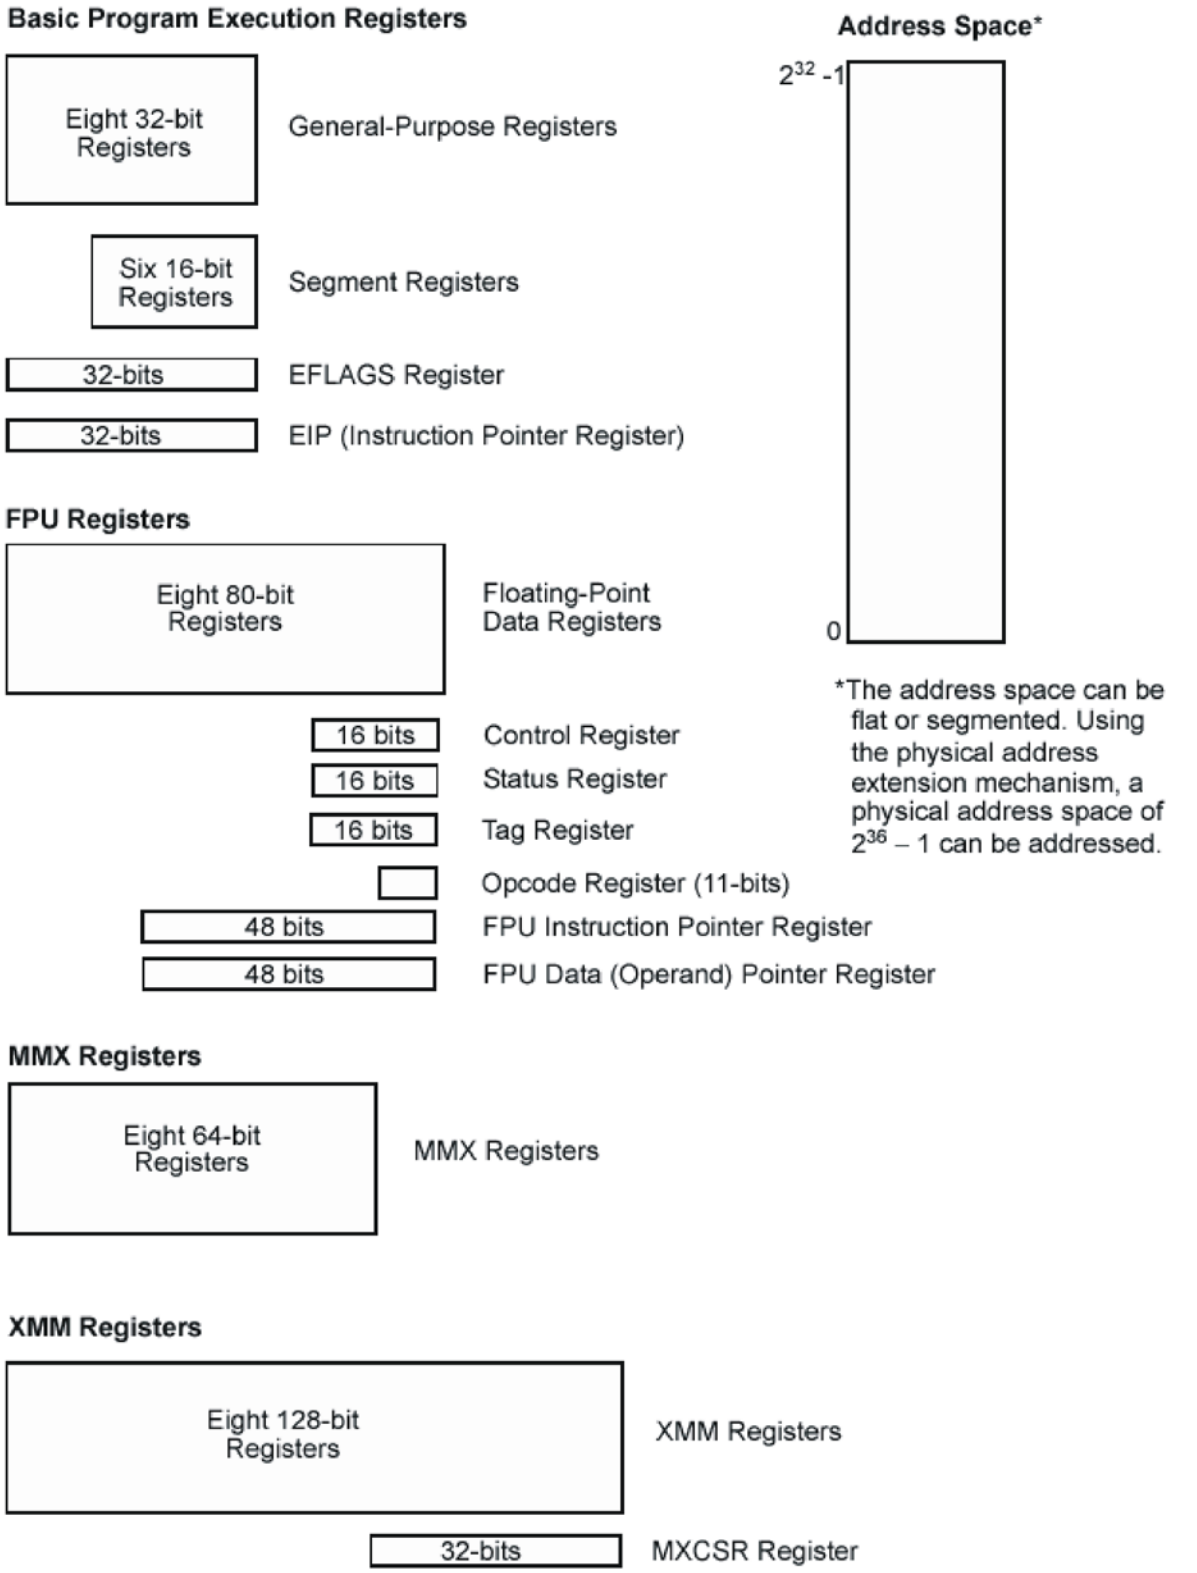

Verwaltung des Arbeitsspeichers

• Implementation einer tabellengest¨utzten Segmentation
• Segmentation arbeitet als Block¨ubersetzung von Adressen
• durch Eintrag in entsprechende Tabellen kann das Betriebssystem ein Programm an eine beliebige Stelle im Arbeitsspeicher schieben
• die Segmentierung ist im ’protected mode’ (Standardmode f¨ur Windows und Linux) immer aktiv
• Implementation einer virtuellen Adressierung

• beim Pentium in der ’paging unit’ realisiert
• die ’paging unit’ arbeitet gleichfalls tabellengest¨utzt
• prinzipiell ist die ’paging unit’ abschaltbar (jedoch nicht sinnvoll, da sowohl Windows als auch Linux die ’paging unit’ voraussetzen)
• ’paging unit’ realisiert eine weitere Adressumsetzung
• Adressumsetzung ist in ’pages’ (a 4 Kbyte) organisiert

Kapitel 7
Assembler und Hochsprache

Was ist Assembler?

Ein Assembler ist ein Übersetzer für Programmcode, der sich aus Maschinenbefehlen zusammensetzt. Diese Befehle können sich je nach verwendeten Prozessor stark unterscheiden. Im normalen PC werden Prozessoren verwendet, die zu dem 8086 von Intel kompatibel sind. Der Befehlssatz wurde über die Jahre erweitert, wobei die Kompatibilität zum "Urmodell" stets gewahrt wurde[01].

In der Art der verwendeten Befehle besteht der wesentliche Unterschied zu allen anderen Programmiersprachen. Während sich Befehle bei den Hochsprachen[02] in der Übersetzung aus mehreren Anweisungen im endgültigen Code zusammensetzen, wird der Assemblerbefehl durch den Assembler lediglich in die entsprechende Binärform[03] übersetzt. Weiterhin ersetzt der Assembler Variablen durch die entsprechenden Speicheradressen.

Die Hochsprachen stellen eine Vielzahl von Funktion wie z. B. clrscr, writeln( ) usw. zur Verfügung. Deren Realisierung würde in Assembler mehrere Zeilen in Anspruch nehmen. Bei solchen Standardfunktionen sollte man immer auf die Funktionen der Hochsprache zurückgreifen.

Assembler-Programmierung wird auch oftmals als Systemprogrammierung bezeichnet. Dieses Wort weist auf den ganz speziellen Charakter hin. Assemblerprogramme sind meist nur auf einer Prozessorplattform lauffähig und können nur unter großem Aufwand auf ein anderes System portiert werden[04]. So kann man bei einem Assembler nicht einstellen einmal 8086 Befehle und für das nächste System RISC-Befehle zu nutzen, da die verwendeten Befehle und deren Einsatz sich stark unterscheiden

Grundkenntnisse über die CPU

Bevor man sich in die Systemprogrammierung stürzt, sollte man zunächst einige grundlegende Sachverhalte über den Aufbau des Computers in das Gedächtnis zurückrufen. Der Computer besteht aus einer Vielzahl einzelner Bauteile wie Speicher, Festplatte, Grafik- und Soundkarte und der Peripherie wie Tastatur, Monitor und Drucker. Im Mittelpunkt steht der Prozessor - die CPU. Sie muss die ganzen Geräte miteinander koordinieren. Zur Kommunikation mit den einzelnen Teilen steht ihr das Bussystem zur Verfügung.

Die CPU unterteilt man nochmals in das Rechenwerk, das Steuerwerk und den internen Speicher in Form von Registern[05]. Für den Programmierer sind dabei die Register von besonderem Interesse. In diesen werden dem Prozessor die Befehle und deren

Parameter übergeben. Rückgabewerte nach der Ausführung eines Befehls werden ebenfalls in den Registern abgelegt. Bestimmte immer wiederkehrende Informationen werden in den Flags dargestellt, die aber dem Prinzip nach auch Register sind.

!Die folgenden Ausführungen beziehen sich nur auf zum 8086 kompatible Prozessoren!

Der 8086 besaß Register mit der Größe von 16bit[06]. Dies war zum einem durch die technischen Möglichkeiten und auf der anderen Seite durch die gemäßigten Ansprüche an die Hardware begründet. Diese Register bekamen nach ihrer Aufgabe bestimmte Namen, aus denen sich die Kürzel ableiten lassen, zugewiesen.

Klasse	Kürzel	Bedeutung	weitere Hinweise
Allgemeine Register	AX	Akkumulator	Teilung in hohes Byte (AH) und niedriges Byte (AL)
	BX	Basis-Register	Teilung in hohes Byte (BH) und niedriges Byte (BL)
	CX	Count-Register	Teilung in hohes Byte (CH) und niedriges Byte (CL)
	DX	Daten-Register	Teilung in hohes Byte (DH) und niedriges Byte (DL)
Pointer-Register	SP	Stack-Pointer	zur Adressierung des Stacks verwendet
	BP	Base-Pointer	zur Adressierung des Stacks verwendet
	IP	Instruction-Pointer	Offset des nächsten Befehls
Index-Register	SI	Source-Index	Unterstützung von Adressierungen
	DI	Destination-Index	Unterstützung von Adressierungen
Segment-Register	CS	Code-Segment	zeigt auf aktuelles Codesegment
	DS	Daten-Segment	zeigt auf aktuelles Datensegment
	SS	Stack-Segment	zeigt auf aktuelles Stapelsegment
	ES	Extra-Segment	zeigt auf weiteres Datensegment

Man sollte am Anfang die Finger von den Pointer-, Index- und Segment-Registern lassen. Diese zeigen auf die Speicherbereiche mit dem Programmcode und den Stack.

In der Übersicht kann man erkennen, dass die Allgemeinen Register jeweils in einen hohen und einen niedrigen Abschnitt unterteilt sind. Bei manchen Operationen reicht ein "halbes" Register aus. Deshalb kann man diese Abschnitte einzeln ansprechen.

Wie bereits erwähnt wurde gibt es neben den Registern noch die Flags. Das sind einzelne Speicherzellen, die jeweils den Wert 0 oder 1 haben. Diese Flags (Flagge, Schalter) haben ebenfalls bestimmte Bezeichnung, aus denen sich ihre Bedeutung und Aufgabe ableiten läßt. Dabei muss man zwischen vom Prozessor zu setzende (Statusflags) und vom Programm setzbare (Kontrollflags) Flags unterscheiden.

Klasse	Kürzel	Name	Bedeutung	Gesetzt durch
Statusflags	CF	Carry-Flag	Übertragflag	Prozessor
	AF	Auxiliary Carry-Flag	Hilfsübertragflag	Prozessor
	ZF	Zero-Flag	Nullflag	Prozessor
	SF	Sign-Flag	Vorzeichenflag	Prozessor
	PF	Parity-Flag	Paritätsflag	Prozessor

	OF	Overflow-Flag	Überlaufflag	Prozessor
Kontrollflags	TF	Trap-Flag	Einzelschrittflag	Programm
	IF	Interrupt Enable-Flag	Interruptflag	Programm
	DF	Direction-Flag	Richtungsflag	Programm

Wenn das Ergebnis einer Operation 0 ist, wird das Zero-Flag gesetzt. Das bedeutet es hat den Wert 1. Dies kann man in seinem Programm überprüfen und nutzen.

Mit jeder neuen Prozessorgeneration kommen neue Flags hinzu. Diese sind aber oftmals nicht dokumentiert und für die einfache Assembler-Programmierung nicht von Bedeutung.

Weiterhin steht der CPU und dem Programmierer der Stack (Stapel) zur Verfügung. Dies ist ein gesonderter Bereich im RAM[07], der zur kurzzeitigen Zwischenspeicherung genutzt werden kann. So übergibt Turbo Pascal intern Werte an Funktionen mit Hilfe des Stack. Bei 8086-Systemen werden die als letztes auf den Stapel "gelegten" Daten zuerst wieder herausgegeben. Dies nennt man das LIFO-Prinzip[08]. Man kann sich dabei den Stack wie einen Stapel Teller vorstellen, bei dem ein neuer Teller immer oben draufgelegt wird. Wird nun ein Teller benötigt nimmt man zuerst den obersten Teller wieder weg.

Der 80386 besitzt folgende Register:

Allgemeine Register	
Name	**Bemerkung**
eax	allgemein verwendbar, spezielle Bedeutung bei Arithmetikbefehlen
ebx	allgemein verwendbar
ecx	allgemein verwendbar, spezielle Bedeutung bei Schleifen
edx	allgemein verwendbar
ebp	Basepointer
esi	Quelle (eng: source) für Stringoperationen
edi	Ziel (eng: destination) für Stringoperationen
esp	Stackpointer

Segmentregister	
Name	**Bemerkung**
cs	Codesegment
ds	Datasegment
ss	Stacksegment
es	beliebiges Segment
fs	beliebiges Segment
gs	beliebiges Segment

Sonstige Register	
Name	**Bemerkung**
eip	Instruction Pointer
ef	Flags

Was ist Speicher?

Meistens reichen die Register nicht aus, um ein Problem zu lösen. In diesem Fall muß auf den Hauptspeicher des Computers zugegriffen werden, der erheblich mehr Information speichern kann. Für den Assemblerpogrammierer sieht der Hauptspeicher wie ein riesiges Array von Registern aus, die je nach Wunsch 8, 16 oder 32 Bits "breit" sind. Die kleinste adressierbare Einheit ist also ein Byte (= 8 Bits). Daher wird auch die Größe des Speichers in Bytes gemessen. Um auf einen bestimmten Eintrag des Arrays "Hauptspeicher" zugreifen zu können, muß der Programmierer den Index, d. h. die *Adresse* des Eintrages kennen. Das erste Byte des Hauptspeichers bekommt dabei die Adresse 0, das zweite die Adresse 1 usw.

In einem Assemblerprogramm können Variablen angelegt werden, indem einer Speicheradresse ein Label zugeordnet und dabei Speicherplatz in der gewünschten Größe reserviert wird.

```
------------------------
[SECTION .data]
gruss:       db 'hello, world'
unglueck:    dw 13
million:     dd 1000000

[SECTION .text]
             mov ax,[million]
             ...
------------------------
```

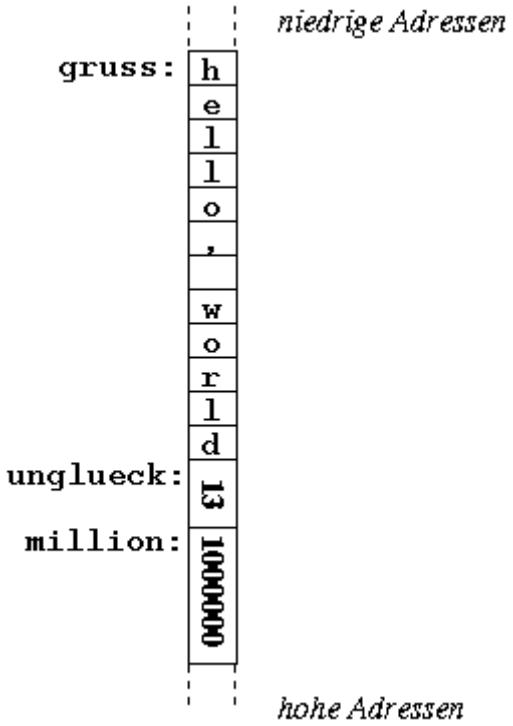

Was ist ein Stack?

Nicht immer will man sich ein neues Label ausdenken, nur um kurzfristig mal den Wert eines Registers zu speichern, beispielsweise, weil man das Register für eine bestimmte Anweisung benötigt, den alten Wert aber nicht verlieren möchte. In diesem Fall wünscht man sich sowas wie einen Schmierzettel. Den bekommt man mit dem Stack. Der Stack ist eigentlich nichts weiter als ein Stück des Hauptspeichers, nur daß dort nicht mit festen Adressen gearbeitet wird, sondern die zu sichernden Daten einfach immer oben drauf geschrieben (`push`) bzw. von oben heruntergeholt werden (`pop`). Der Zugriff ist also ganz einfach, vorausgesetzt man erinnert sich daran, in welcher Reihenfolge die Daten auf den Stapel gelegt wurden. Ein spezielles Register, der *Stackpointer esp* zeigt stets auf das oberste Element des Stacks. Da `push` und `pop` immer nur 32 Bits auf einmal transferieren können, ist der Stack in der folgenden Abbildung vier Bytes breit dargestellt.

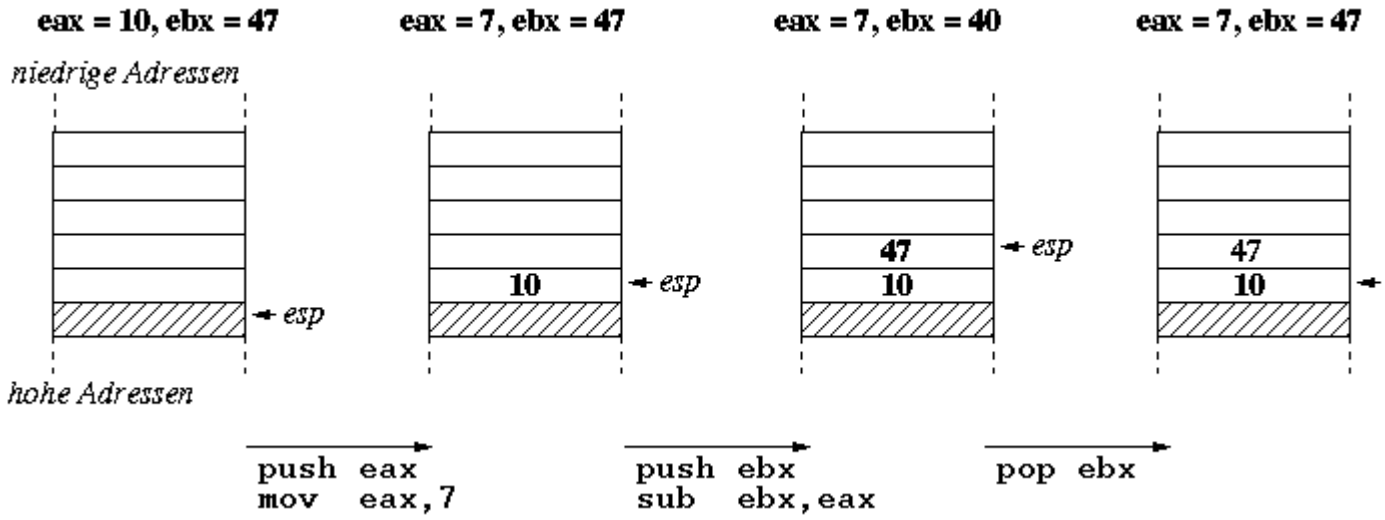

Adressierungsarten

Die meisten Befehle des 80x86 können ihre Operanden wahlweise aus Registern, aus dem Speicher oder unmittelbar einer Konstante entnehmen. Beim `mov` Befehl sind (u. a.) folgende Formen möglich, wobei der erste Operand stets das Ziel und der zweite stets die Quelle der Kopieraktion angeben:

- Registeradressierung: Der Wert eines Registers wird in ein anderes übertragen.
  `mov ebx,edi`
- Unmittelbare Adressierung: Die Konstante wird in das Register übertragen.
  `mov ebx,1000`
- Direkte Adressierung: Der Wert der an der angegebenen Speicherstelle steht, wird in das Register übertragen.
  `mov ebx,[1000]`
- Register-Indirekte Adressierung: Der Wert, der an der Speicherstelle steht, die durch das zweite Register bezeichnet wird, wird in das erste Register übertragen.
  `mov ebx,[eax]`
- Basis-Register Adressierung: Der Wert, der an der Speicherstelle steht, die sich durch die Summe des Inhalts des zweiten Registers und der Konstanten ergibt, wird in das erste Register übertragen.
  `mov eax,[10+esi]`

Anmerkung: Wenn der 80x86 Prozessor im Real-Mode betrieben wird (z.B. bei der Arbeit mit dem Betriebssystem MS DOS), werden Speicheradressen durch ein Segmentregister und einen Offset angegeben. Bei der Veranstaltung Betriebssysteme 1 ist das nicht nötig (sondern sogar falsch), weil Stubs im Protected Mode läuft und die Segmentregister von uns bereits für Euch initialisiert wurden.

Prozeduren

Aus den höheren Programmiersprachen ist das Konzept der Funktion oder Prozedur bekannt. Der Vorteil dieses Konzeptes gegenüber einem goto besteht darin, daß die Prozedur von jeder beliebigen Stelle im Programm aufgerufen werden kann und das Programm anschließend an genau der Stelle fortgesetzt wird, die nach dem Prozeduraufruf folgt. Die Prozedur selbst muß nicht wissen, von wo sie aufgerufen wurde und wo es hinterher weiter geht. Das geschieht irgendwie automatisch. Aber wie?

Die Lösung besteht darin, daß nicht nur die Daten des Programms, sondern auch das Programm selbst im Hauptspeicher liegt und somit zu jeder Maschinencodeanweisung eine eigene Adresse gehört. Damit der Prozessor ein Programm ausführt, muß sein *Befehlszeiger* auf den Anfang des Programms zeigen, also die Adresse der ersten Maschinencodeanweisung in das spezielle Register *Befehlszeiger (instruction pointer eip)* geladen werden. Der Prozessor wird dann den auf diese Weise

bezeichneten Befehl ausführen und im Normalfall anschließend den Inhalt des Befehlszeigers um die Länge des Befehls im Speicher erhöhen, so daß er auf die nächste Maschinenanweisung zeigt. Bei einem Sprungbefehl wird der Befehlszeiger nicht um die Länge des Befehls, sondern um die angegebene relative Zieladresse erhöht oder erniedrigt.

Um nun eine Prozedur oder Funktion (in Assembler dasselbe) aufzurufen, wird zunächst einmal wie beim Sprungbefehl verfahren, nur daß der alte Wert des Befehlszeigers (+ Länge des Befehls) zuvor auf den Stack geschrieben wird. Am Ende der Funktion genügt dann ein Sprung an die auf dem Stack gespeicherte Adresse, um zu dem aufrufenden Programm zurückzukehren.

Beim 80x86 erfolgt das Speichern der Rücksprungadresse auf dem Stack implizit mit Hilfe des call Befehls. Genauso führt der ret Befehl auch implizit einen Sprung an die auf dem Stack liegende Adresse durch:

```
; ----- Hauptprogramm -----
;
main:  ...
       call f1
xy:    ...



; ----- Funktion f1
f1:    ...
       ret
```

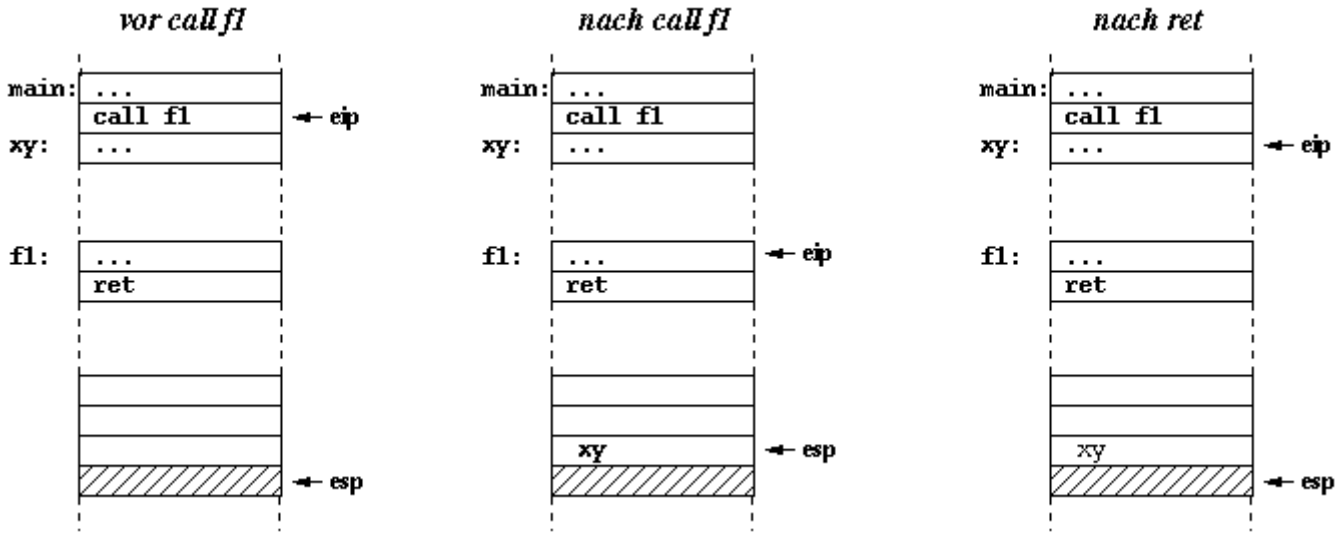

Wenn die Funktion Parameter erhalten soll, werden diese üblicherweise ebenfalls auf den Stack geschrieben, natürlich vor dem call Befehl. Hinterher müssen sie natürlich wieder entfernt werden, entweder mit pop, oder durch direktes Umsetzen des Stackpointers:

```
     push eax     ; zweiter Parameter fuer f1
     push ebx     ; erster Parameter  fuer f1
     call f1
     add esp,8    ; Parameter vom Stack entfernen
```

Um innerhalb der Funktion auf die Parameter zugreifen zu können, wird üblicherweise der *Basepointer ebp* zu Hilfe genommen. Wenn er gleich zu Anfang der Funktion gesichert und dann mit

dem Wert des Stackpointers belegt wird, kann der erste Parameter immer über `[ebp+8]` und der zweite Parameter über `[ebp+12]` erreicht werden, unabhängig davon, wieviele `push` und `pop` Operationen seit Beginn der Funktion verwendet wurden.

```
f1:   push ebp
      mov  ebp,esp
      ...
      mov ebx,[ebp+8]    ; 1. Parameter in ebx laden
      mov eax,[ebp+12]   ; 2. Parameter in eax laden
      ...
      pop ebp
      ret
```

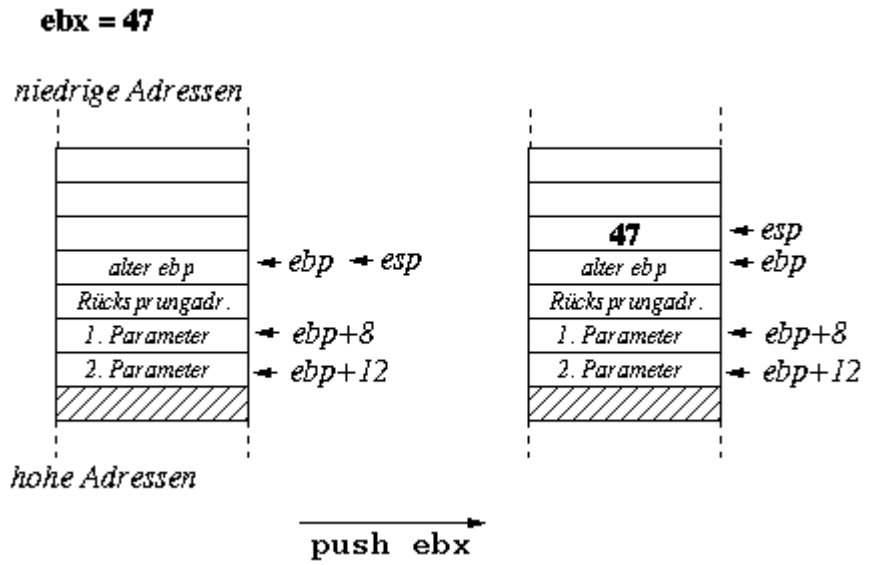

Flüchtige und nicht-flüchtige Register / Anbindung an C

Damit Funktionen von verschiedenen Stellen des Assemblerprogramms heraus aufgerufen werden können, ist es wichtig festzulegen, welche Registerinhalte von der Funktion verändert werden dürfen und welche bei Verlassen der Funktion noch (oder wieder) den alten Wert besitzen müssen. Am sichersten ist es natürlich, grundsätzlich alle Register, die die Funktion zur Erfüllung ihrer Aufgabe benötigt, zu Beginn der Funktion auf dem Stack zu speichern und unmittelbar vor Verlassen der Funktion wieder zu laden.

Die Assemblerprogramme, die der GNU C Compiler erzeugt, verfolgen jedoch eine etwas andere Strategie: Sie gehen davon aus, daß viele Register sowieso nur kurzfristig verwendet werden, zum Beispiel als Zählvariable von kleinen Schleifen oder um die Parameter für eine Funktion auf den Stack zu schreiben. Hier wäre es reine Verschwendung, die ohnehin längst veralteten Werte zu Beginn einer Funktion mühsam zu sichern und am Ende wiederherzustellen. Da man einem Register nicht ansieht, ob sein Inhalt wertvoll ist oder nicht, haben die Entwickler des GNU C Compilers einfach festgelegt, daß die Register **eax**, **ecx** und **edx** grundsätzlich als *flüchtige* Register zu betrachten sind, deren Inhalt einfach überschrieben werden darf. Das Register **eax** hat dabei noch eine besondere Rolle: Es liefert den Rückgabewert der Funktion (soweit erforderlich). Die Werte der übrigen Register müssen dagegen gerettet werden, bevor sie von einer Funktion überschrieben werden dürfen. Sie werden deshalb *nicht-flüchtige* Register genannt.
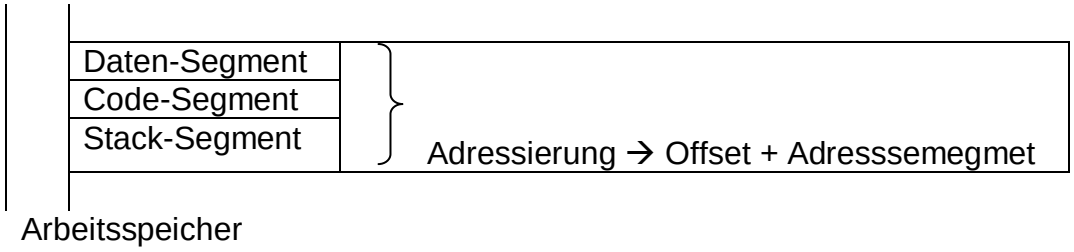
Laden eines auszuführenden Programmes